

Présentation du projet

i-Démo BR-Predict

ELEMENTS CLES DU PROJET

Nom du projet	La première plateforme d'évaluation Prédictive du bénéfice-risque
Durée du projet (en mois)	36 mois
Date de début	01/05/2026
Date de fin	30/04/2029
Coût total du projet (€)	5 360 000 €
Raison sociale du porteur / chef de file	ArcaScience

DESCRIPTION SYNTHETIQUE DU PROJET (5 lignes maximum)

ArcaScience possède une plateforme innovante capable d'agrégier une énorme quantité de données cliniques et ontologiques afin de produire des rapports d'analyse bénéfice/risque réglementaires. Le projet BR-Predict vise à développer un module prédictif capable d'anticiper le profil bénéfice/risque des candidats médicaments dès les phases précoces à partir de données moléculaires, précliniques, génétiques et cliniques. Ce nouveau module se positionnera comme un outil d'aide à la décision pour les entreprises pharmaceutiques.

1. Présentation du porteur du projet.....	4
1.1. Présentation de ArcaScience & actionnariat.....	4
1.2. L'équipe fondatrice et dirigeante.....	5
1.3. Ressources humaines et technologiques.....	6
1.3.1. Effectif actuel et évolution envisagée à court terme.....	6
1.3.2. Comité stratégique et scientifique de ArcaScience.....	8
1.3.3. Principaux sites et moyens de production et de R&D.....	8
1.3.4. Savoir-faire et interne.....	9
1.3.5. Protections industrielles mises en œuvre.....	9
1.3.6. Partenaires et sous-traitants clés.....	10
1.4. Activité de la société.....	12
1.4.1. l'IA au service de l'accompagnement des industriels du médicaments.....	12
1.4.2. Modèle économique.....	13
1.4.3. Clients actuels.....	14
1.5. Ambition et evolution stratégique de la société.....	16
1.5.1. L'ambition d'ArcaScience.....	16
1.5.2. la place de l'analyse bénéfice-risque DANS LE MARCHÉ DU "drug dEVELOPMENT".....	17
1.5.3. Environnement concurrentiel d'arcascience.....	19
1.5.4. Déploiement de barrières à l'entrée du marché.....	22
2. Objectifs et contexte technico-economique.....	23
2.1. Résumé du projet.....	23
2.2. Ambition stratégique du projet.....	24
2.2.1. Problématique dans le succès des essais cliniques.....	24
2.2.2. L'analyse bénéfice risque comme une solution viable.....	25
2.2.3. Limites actuelles du processus d'utilisation de l'analyse bénéfice-risque pour l'aide au développement de médicaments.....	26
2.2.4. Les besoins de l'analyse bénéfice-risque	26
2.2.5. le fonctionnement de la plateforme ArcaScience.....	27
2.2.6. Proposition de valeur.....	28
2.3. Ambition technologique.....	29
2.3.1. Workflow de la plateforme ArcaScience.....	29
2.3.2. Données antérieures.....	31
2.3.3. Verrou lié à l'intégration du nouveau module BR-Predict.....	34
3. Plan de travail.....	38
3.1. Structuration du plan de travail.....	38
3.2. GANTT.....	40

3.3.	Synthèse des principaux jalons décisionnels du projet.....	40
3.4.	Risques identifiés et plan de suivi.....	41
3.5.	Budget et principaux postes de sous-traitance du projet.....	42
4.	<i>Lots détaillés</i>	43
4.1.	Lot 1.....	43
4.2.	Lot 2.....	45
4.3.	Lot 3.....	47
4.4.	Lot 4.....	49
4.5.	Lot 5.....	50
4.6.	Lot 6.....	52
4.7.	Lot 7.....	54
5.	<i>Exploitation industrielle et commerciale des résultats du projet</i>	56
5.1.	Stratégie d'industrialisation des résultats du projet.....	56
5.1.1.	Stratégie de développement technologique.....	56
5.1.2.	Stratégie et conditions réglementaires d'accès.....	56
5.1.3.	Stratégie de protection intellectuelle.....	57
5.2.	Stratégie de commercialisation et projection de revenus.....	58
5.2.1.	Stratégie d'accès marché.....	58
5.2.2.	Modèle économique et pricing.....	59
5.2.3.	Projection de revenus et construction du chiffre d'affaires.....	60
5.3.	Impacts sociétaux et environnementaux.....	62
5.3.1.	Retombées sociales, sociétales pour le territoire national.....	62
5.3.2.	Impact environnemental.....	62
6.	<i>Eléments financiers</i>	64
6.1.	Impact sur le compte de résultats prévisionnel.....	64
6.2.	Plan de financement.....	64
6.2.1.	Planification de dépenses estimées.....	64
6.2.2.	Stratégie de financement sur la durée du programme.....	64
7.	<i>Justification de l'aide</i>	66
7.1.	Activités qui seraient déployées en l'absence de l'aide.....	66
7.2.	Bénéfices nouveaux permis par l'aide.....	66
7.3.	Avantages supplémentaires pour le client final.....	67
7.4.	Retombées pour la filière industrielle et les standards.....	67

PARTIE 1 : PRESENTATION DU PROJET

1. PRÉSENTATION DU PORTEUR DU PROJET

1.1. PRÉSENTATION DE ARCASCIENCE & ACTIONNARIAT

La société ArcaScience a été créée à Paris en 2018 par Romain Clément, Patrick Pierre Et Laurent Romary. Il s'agit d'une **SAS au capital social de 510 257,89 €**. Sa gouvernance repose sur l'implication directe de ses fondateurs, tandis que son actionnariat combine la participation de personnes physiques et celle d'investisseurs spécialisés dans le secteur.

La trajectoire de financement d'ArcaScience, depuis sa création en 2018, comprend trois opérations confirmées :

- Une première levée d'amorçage a été réalisée en 2020 pour un montant de **550 k€**, financée par la société française Quotium Technologies et FrenchTech Seed BPI.
- Une seconde levée est intervenue en 2024 pour un montant de **450 k€**. Elle a permis à plusieurs acteurs reconnus du monde des sciences médicales, notamment Sanofi, Cedars-Sinai et l'ICM d'accéder à la gouvernance de la société, conférant à ArcaScience une légitimité clinique et industrielle de premier plan dès ce stade de développement. Elle a également permis d'accélérer le développement de la plateforme et de structurer les premiers partenariats industriels stratégiques.
- Une troisième levée de fonds a été finalisée fin 2025 pour un montant de **4,65 M€**. Elle vise à **soutenir le développement et l'extension de la société**, notamment via l'industrialisation de sa plateforme technologique. L'investisseur principal de cette opération est le fonds français IT Pleiade Venture. Cette levée a également permis l'entrée au capital de plusieurs fonds d'investissement et holdings, dont The Moon Ventures, Kima Ventures II, Plug & Play Ventures - California, AFRI Mobility, ainsi que 1 SPV spécialisé pharma.

ArcaScience a bénéficié du dispositif d'aide publique mise en place par la région Île-de-France Innov'Up à hauteur de 1,8 M€, fléché sur l'accélération de la R&D et les premiers déploiements de la solution Saas.

ArcaScience a **reçu plusieurs prix d'innovation** et a notamment été primée "Meilleure solution pharmaNLP 2023" par Startus Insights, en reconnaissance de la **robustesse de ses modèles propriétaires d'extraction et structuration de l'évidence biomédicale et de la qualité opérationnelle de sa plateforme d'analyse bénéfice-risque**, et a été sélectionnée par le ministère de la Santé en 2020 comme acteur de confiance pour l'agrégation de données de santé en vue de découvrir un traitement COVID, au milieu de la pandémie.

ArcaScience a su conjuguer des augmentations de capital successives maîtrisées, avec l'obtention de subventions publiques stratégiques et une reconnaissance scientifique solide. Ces atouts lui ont permis de se développer de manière pérenne, de s'intégrer durablement au sein de l'écosystème de la santé et de renforcer sa visibilité ainsi que sa crédibilité auprès des principaux acteurs du secteur, tout en préservant l'autonomie opérationnelle et décisionnelle de ses fondateurs.

Tableau 1 : Table de capitalisation - format NFD (non-fully diluted)

Personnes physiques			
Prénom	Nom	%	Rôle

Romain	CLEMENT	31,16%	Fondateurs
Patrick	PIERRE	6,86%	
Laurent	ROMARY	0,12%	
Alexis	PICOT	0,44%	Business Angels
Stéphane	WATHIER	0,85%	
Geoffroy	CHANDON	0,88%	
Jordan	LAZARO-GUSTAVE	3,68%	
Alexis	BRICE	0,15%	
Philippe	PEYRE	0,71%	
Alexandre	ICHAÏ	0,71%	
Rand	SHERIF	0,65%	
Claire	MASUREL SHERIF	0,65%	
Anne	DONEUX	0,50%	
Barthélémy	DE BEAUPUY	0,97%	
Lilian	THIBAULT	0,21%	
Rea	Trust	0,32%	
Marc	SOUNIGO	0,32%	
Frédéric	GARROY	0,24%	
Thomas	PRUD’HOMME	0,41%	
Personnes Morales			
Raison sociale	N° d'identification	%	Rôle
Quotium Technologies	322 548 355	12,93%	Fonds et Holdings
GO!TECH	830 485 579	2,15%	
Plug & Play INVESTMENT GROUP LLC	202119710330	2,47%	
Financière de la Rosetta	433 355 666	0,74%	
Quantum Leap Venture SPV LTD	000010000	1,18%	
H2 (Cayman) Investments Ltd.	KY1-1108	1,38%	
AFRI MOBILITY	461097	2,12%	
SARL JEC	410 051 163	0,71%	
ARCASCIENCE BY THE MOON VENTURE	943 996 371	10,99%	
Pleiade Venture	500 108 121	8,10%	
AKKA 254 SPV	941 929 135	3,80%	
SHERIF INVEST SA	CHE-246.430.659	0,32%	
Kima Ventures II	831 126 156	0,97%	
STICHTING ADMINISTRATIEKANTOOR CAPITAL CELL	866167791	0,82%	
HTH - HEXAGON TECHNOLOGIES HOLDING	430 097 451	0,50%	
RP&PARTNERS	952 019 073	0,97%	

1.2. L'ÉQUIPE FONDATRICE ET DIRIGEANTE

ArcaScience s'appuie sur une gouvernance reposant sur des expertises complémentaires autant sur les volets technologiques, commerciaux que clinique. Cette complémentarité permet d'assurer à la fois là le pilotage et la coordination des partenaires impliqués dans le projet BR-Predict.

- **Romain Clément**, CEO et co-fondateur, détient quatre masters respectivement de l'ESSEC, de l'Université Sorbonne, Panthéon-Sorbonne et de CentraleSupélec dans les domaines du management, du data management et de la gestion du savoir. Il a construit son expertise en gestion de données scientifiques et cliniques chez GSK où il occupait le poste de SDMS Global

Lead, avant de diriger depuis 2018 la stratégie et le développement d'ArcaScience. Dans le cadre du projet BR-Predict, il sécurise l'accès et la gouvernance des données nécessaires à l'entraînement des modèles, notamment via la mise en place d'accords de mise à disposition de données et de cadres de conformité. Son ancrage académique et ses interactions avec l'écosystème pharmaceutique structurent le réseau permettant l'accès aux données, la validation scientifique et les premiers cas d'usage cliniques. Il a également co-écrit trois publications scientifiques portant sur l'utilisation de modèles d'IA pour l'évaluation du bénéfice et du risque en essais cliniques.

- **Patrick Pierre**, co-fondateur et superviseur technique infrastructure, est diplômé de CentraleSupélec. Il a fondé deux sociétés spécialisées dans le numérique : Prismallia, dédiée au développement de logiciels applicatifs et de solutions d'ingénierie logicielle pour la gestion et le traitement de données, et Lap2, spécialisée dans les services d'ingénierie informatique et le développement de systèmes d'information. Il apporte à ArcaScience une expertise en architecture d'infrastructures et en industrialisation des flux de données. Dans le cadre du projet, il supervise l'industrialisation des pipelines d'ingestion et de traitement des données, l'automatisation des flux et la supervision des systèmes afin de garantir la disponibilité et la reproductibilité de la chaîne de traitement des données.
- **Laurent Romary**, co-fondateur, est directeur de recherche à l'INRIA et président de DARIAH, infrastructure européenne de recherche numérique pour les sciences humaines. Il apporte au projet un réseau académique de haut niveau et une expertise en structuration des données scientifiques. En siégeant au conseil scientifique d'ArcaScience, il garantit l'alignement méthodologique du projet avec l'état de l'art académique et contribue à la crédibilité scientifique de la plateforme.

L'équipe dirigeante couvre les fonctions critiques du projet : architecture logicielle, direction médicale et IA, et développement commercial.

- **Jean-François Arbona**, Chief Technical Officer, est responsable de l'architecture logicielle de la plateforme. Son expérience en direction technique et en conception d'architectures cloud, web et mobile permet de structurer une infrastructure modulaire et scalable. Dans le projet BR-Predict, il conçoit l'architecture logicielle de la plateforme, définit les exigences de performance, de sécurité et de traçabilité des traitements de données, et prépare le packaging technique permettant le déploiement de la solution chez les clients.
- **Vassili Soumelis**, Chief Medical Officer, est ancien directeur médical et responsable du comité scientifique d'Owkin. Spécialiste reconnu en immuno-oncologie et en IA appliquée aux données de santé, il apporte une double expertise médicale et algorithmique. Dans le cadre de BR-Predict, il définit les cas d'usage médicaux, les comparateurs thérapeutiques de référence et les critères de performance clinique, et supervise la validation scientifique des résultats produits par les modèles.
- **Julien Dufour**, Chief Business Officer, pilote la stratégie commerciale et les partenariats industriels. Ancien directeur commercial chez Happytal, où il a structuré l'organisation commerciale jusqu'au rachat de la société par le groupe La Poste, il apporte une expertise en développement d'affaires dans le secteur de la santé. Dans le cadre du projet, il structure les contrats avec les laboratoires pharmaceutiques et les CRO, et organise le déploiement commercial de la plateforme afin de transformer les démonstrateurs technologiques en contrats industriels.

L'ensemble de cette gouvernance permet de couvrir les fonctions critiques du projet : accès et gouvernance des données, architecture logicielle, développement des modèles d'IA, validation clinique et déploiement commercial. Elle garantit la capacité d'ArcaScience à transformer les résultats

scientifiques du projet en solutions opérationnelles utilisables par les acteurs du développement pharmaceutique.

1.3. RESSOURCES HUMAINES ET TECHNOLOGIQUES

EFFECTIF ACTUEL ET ÉVOLUTION ENVISAGÉE À COURT TERME

A date, ArcaScience compte 14,5 ETP salariés et 1 prestataire, complétés par 3 stagiaires. La répartition est la suivante :

- **L'équipe Technique, R&D/Produit** (9,5 ETP) couvre **l'ensemble de la chaîne de valeur data-to-decision**: ingestion multi-sources, annotation sémantique, harmonisation terminologique et industrialisation des pipelines. Les travaux sont menés selon une méthodologie agile avec CI/CD, monitoring de performance. Elles s'appuient sur des profils spécialisés en biomédical data engineering, NLP et MLOps, assurant la continuité de responsabilité de la conception à l'exploitation. Le background de l'équipe comprend à la fois des docteurs, des post-docs, et pour le reste ArcaScience a uniquement recruté des ingénieurs informatiques. L'équipe technique est également constituée de stagiaires notamment sur les sujets data et back-end.
- **L'équipe Commerciale** (3 ETP) opère un parcours d'acquisition adapté aux laboratoires pharmaceutiques et CRO de qualification scientifique et contractualisation récurrente (contrats-cadres, abonnement). Cette approche structure l'industrialisation « **molécule par molécule** » de la plateforme. Elle soutient l'évolution des partenariats de manière **récurrente** afin de **valoriser de plus en plus de molécules** auprès de chaque client et d'augmenter les ventes de manière **exponentielle** au sein de chaque société.
- **Administration** : (2 ETP) la fonction sécurise le support aux opérations et au recrutement, en lien avec l'agence prestataire, pour maintenir la qualité d'exécution dans un contexte de montée en charge.

Cette organisation constitue la base opérationnelle mobilisée au démarrage du projet i-Démo.

Ce total de 14,5 ETP-équivalents au démarrage, combiné au plan de recrutement de 10 personnes en 2026, porte la capacité opérationnelle à ~24,5 ETP en fin d'année 2026, un ratio cohérent avec les travaux planifiés dans les Lots 1-4 et 7. ArcaScience estime que plus de 40% de l'équipe native basculera sur i-Démo dès la première année, avant de passer à 2/3, correspondant à la balance de chiffre d'affaires réalisé entre ses affaires natives et celles générées par BR-Predict à partir de 2029.

Côté R&D, 27 recrutements sont planifiés pour délivrer les lots techniques (6 en 2026, 4 en 2027, 13 en 2028, 4 en 2029), avec un pic en 2028 lors de la démonstration et de l'extension d'usage de BR-Predict. Côté commercial, 14 recrutements visent la structuration des contrats cadres et l'adoption "molécule par molécule" (2 en 2026, 1 en 2027, 7 en 2028, 4 en 2029). Côté industriel, 6 recrutements ciblent l'intégration et l'exploitation onprem chez les clients (2 en 2026, 4 en 2029).

Le plan prévoit 20 recrutements en 2028, correspondant au doublement de l'effectif en 12 mois. Ce pic est géré par les mesures suivantes :

- **Échelonnement par vagues** : 4 recrutements en Q1, 6 en Q2, 6 en Q3, 4 en Q4 ;
- **Pipeline de candidats anticipé** : les 4 doctorants CIFRE (démarrés en 2026) et les 8 stagiaires/an constituent un vivier de recrutement qualifié ;
- **Réseau partenaire** : INRIA, ICM et Future4Care fournissent un accès à des candidats spécialisés en IA biomédicale ;

- Programme d'intégration structuré : onboarding de 4 semaines incluant formation à la plateforme, aux méthodologies et à la culture d'entreprise.

Sur 47 recrutements planifiés sur la période, 33 sont directement orientés vers l'exécution des lots i-Démo (27 en R&D, 6 en industrialisation), soit 70% de l'activité RH totale. La dynamique annuelle montre un poids i-Démo de 80% en 2026 (8/10), 80% en 2027 (4/5), 65% en 2028 (13/20) et 67% en 2029 (8/12), avec un pic de 20 recrutements en 2028 principalement liés à la phase de démonstration et à la montée en charge du module BR-Predict, puis un renfort industrialisation en 2029 pour les mises en production.

	2026	2027	2028	2029	Total
R&D	6	4	13	4	27
Industries	2	0	0	4	6
Commercial	2	1	7	4	14
Total	10	5	20	12	47

En R&D, les profils prioritaires sont l'ingénierie IA et data biomédicale, la bioinformatique et le pilotage de projets de R&D afin de consolider la chaîne datatodecision et d'industrialiser BR-Predict. Les phases de recrutement seront par vagues : d'abord en 2026-2027 pour renforcer les composants cœur, puis 2028 pour étendre les usages, et enfin 2029 pour stabiliser et fiabiliser. En industrialisation, les priorités portent sur l'intégration et l'exploitation onprem, la sécurité et la traçabilité des déploiements ; les premières embauches auront lieu en 2026, avec renforcement en 2029 pour les mises en production. En commercial, les recrutements visent le key account management pharma/CRO et l'avant-vente, avec une montée en charge en 2028 puis 2029.

COMITÉ STRATÉGIQUE ET SCIENTIFIQUE DE ARCA SCIENCE

ArcaScience s'appuie sur un conseil scientifique, technique et stratégique de premier plan afin de sécuriser la qualité méthodologique, d'éclairer les choix technologiques et de renforcer l'ancrage industriel de la société. Ce dispositif est structuré en comité d'experts techniques, stratégiques et déploiement, réunis trimestriellement, de sorte qu'ArcaScience a 1 comité chaque mois en fonction des priorités à date. Ils contribuent à la validation scientifique, à l'orientation stratégique et au développement commercial, en facilitant l'accès à un réseau étendu de décideurs et d'experts issus de l'industrie pharmaceutique, des établissements de santé et de la deeptech.

Le comité réunit des profils complémentaires couvrant recherche publique, clinique, industrie pharmaceutique, data/IA et stratégie :

Pôle scientifique et clinique :

- Laurent Romary, PhD (directeur de recherche émérite à l'Inria, président de DARIAH);
- Pr Alexis Brice, MD, PU-PH (président fondateur de l'ICM, membre de l'Académie des sciences);
- Pr Clemens M. Schirmer, MD, PhD (neurochirurgien, Geisinger School of Medicine);
- Jean Lopategui, MD, PhD (Directeur du département Pathology, Cedars-Sinai).

Pôle industriel et réglementaire :

- Philippe Peyre, PhD (Senior VP et secrétaire général chez Sanofi, représentant Sanofi au comité scientifique d'ArcaScience);
- Serge Bauin, PhD (ancien DGA à la science au CNRS, expert Data Science ministériel).

Pôle data/IA et innovation :

- Hal Lavender (AI, Data and Business Transformation Leader VP chez IBM);
- Stéphane Rouault, PhD, biostatisticien (Clinical Innovation Lead chez Argenx et Roche).
- Eric Genevois Marlin, PhD, Biostatisticien (Global Head of Data & AI, Sanofi)

Pôle marché, financement et déploiement :

- Kerry Coffee (fondatrice Schiller Discovery Healthtech Venture);
- Emmanuel Capitaine, MD (Coordinateur médical international, Vivalto Santé; ancien responsable innovation AstraZeneca);
- Geneviève Laurans (administratrice et CFO, Quotium Technologies);
- Fabien Lantieri (stratégie santé et innovation, EIT Health; expert au Génopole);
- Béatrice du Sordet (fondatrice d'Aplusa);
- Jordan Lazaro-Gustave (fondateur d'AAVE).

PRINCIPAUX SITES ET MOYENS DE PRODUCTION ET DE R&D

ArcaScience est implantée au sein de **Future4Care, hub d'innovation en santé** situé au Biopark (75013 Paris), offrant un accès direct à un écosystème de startups, de groupes pharmaceutiques, d'institutions et d'investisseurs spécialisés. Cette implantation facilite l'accès à des ressources mutualisées pour ses besoins de R&D et industriels. Des environnements multi-cloud sont mobilisés pour le développement et les tests, compétence clé qu'ArcaScience a développé afin de ne pas s'attacher à un seul cloud provider, tout en préservant l'essentiel de ses infrastructures en France (OVH / Scaleway).

Les déploiements en production sont réalisés directement chez les clients. Ainsi, la **localisation de la société au cœur de Paris**, combinée à la **présence d'une agence états-unienne à Boston**, permet d'assurer les **capacités d'industrialisation de la solution**.

Les modèles sont entraînés en interne par ArcaScience avant d'être installé chez le client. Les déploiements s'appuient sur des **outils DevOps open source standard** : Docker pour l'isolation applicative, Kubernetes pour l'orchestration des microservices et Ansible pour l'automatisation des installations. Une fois installée, la solution fonctionne de manière autonome, avec un accès **ArcaScience** compatible avec les règles de compliance client, et planifié au strict suivi de performance ; chaque résultat est traçable jusqu'à sa source.

SAVOIR-FAIRE ET INTERNE

L'entreprise dispose d'une **expertise avancée dans la gestion et l'analyse de données biomédicales** issues de sources multiples telles que la littérature scientifique, les essais cliniques, ainsi que des données chimiques, physiologiques et biomédicales. La plateforme s'appuie sur la maîtrise des ontologies biomédicales, des méthodes de structuration sémantique et des techniques de traitement automatique du langage scientifique afin d'extraire et structurer l'évidence issue de documents non structurés. Elle repose notamment sur le développement de modèles de langage spécialisés de petite taille (Contextualizing SLMs) entraînés sur des corpus biomédicaux et réglementaires, permettant de transformer des corpus scientifiques hétérogènes en bases de connaissances exploitables pour l'analyse et la modélisation. Cette expertise est structurée au sein du pôle data dirigé par Romain Clément, avec l'appui scientifique de Serge Bauin (INIST-CNRS) sur les problématiques de structuration de l'information scientifique.

ArcaScience dispose également d'un savoir-faire solide en **ingénierie logicielle**. L'équipe maîtrise la conception de logiciels capables de traiter de grands volumes de données et d'intégrer différents outils d'analyse. Elle possède des compétences dans la conception de modèles d'intelligence artificielle, leur entraînement et leur mise en production. Plus important encore, l'équipe possède la capacité de structurer ces expertises en données et en intelligence artificielle au sein d'architectures logicielles complexes, cohérentes et optimisées. Ces compétences sont notamment portées par le pôle architecture technique de Patrick Pierre et par Jean-François Arbona, CTO de l'entreprise, qui possède plus de vingt ans d'expérience en développement logiciel et en architecture technique. Par ailleurs, la NLP et modèles de langage biomédicaux sont au centre du socle d'expertise d'ArcaScience. La société dispose d'une expertise distinctive dans le développement de modèles de langage de petite taille (Contextualizing SLMs) entraînés sur des corpus biomédicaux et réglementaires. Ces modèles constituent le moteur d'extraction et de structuration de l'évidence scientifique au cœur de la plateforme.

Ces expertises sont complétées par une verticale clé d'ArcaScience dans le domaine de **l'application clinique et drug development**. Docteur Vassili Soumelis, figurant chez ArcaScience au poste de CMO, ancien CMO de Owkin, PUPH immuno-hématologue et pionnier de l'immunologie systémique, notamment grâce à sa découverte de la TSLP humaine, établit la capacité d'ArcaScience à ancrer ses développements dans la réalité du développement pharmaceutique et de la pratique clinique. Ce pôle garantit l'adéquation entre les sorties de la plateforme et les besoins opérationnels des industriels du médicament ainsi que son passage à l'échelle sur le plan médical. Il apporte une expertise essentielle pour replacer l'utilisation des logiciels et des données dans le contexte réel du développement des médicaments et de la pratique clinique.

PROTECTIONS INDUSTRIELLES MISES EN ŒUVRE

La stratégie de propriété intellectuelle d'ArcaScience repose sur une combinaison structurée de **plusieurs leviers juridiques : droit des brevets, droit d'auteur et secret d'affaires**. La base de données propriétaire d'ArcaScience est protégée au titre du droit d'auteur, en raison de l'originalité de son architecture, de sa structuration et de ses méthodes d'annotation. Le secret d'affaires couvre les éléments non divulgués du savoir-faire interne, notamment les paramètres d'entraînement, les choix d'optimisation des modèles et les procédés d'industrialisation.

ArcaScience met en œuvre une protection « **by design** » fondée sur le déploiement **on-premise** chez les clients et un contrôle strict des accès. Ce mode d'industrialisation réduit structurellement le risque de fuite d'IP et renforce la souveraineté des données côté client. Il est complété par des mesures organisationnelles, dont le dépôt annuel du code et des modèles auprès d'un **escrow agent** et la confidentialité des éléments clés (architecture de pipeline clinique holistique, mécanismes d'intégration, de normalisation et de cohérence des données, structure et workflows d'inférence des **vingt-quatre** modèles propriétaires).

Les différents modules de la société seront protégés par des brevets pour chaque groupe d'algorithmes. Ces brevets couvriront aussi bien les méthodes de curation des données que leur harmonisation et la production des rapports de chaque module. Cette méthode permettra à **ArcaScience** d'étendre progressivement son portefeuille de brevets tout en conservant son architecture de base sous le régime du secret d'affaires. Le cadre du dépôt de brevets se comportera comme suit : dans le cadre du programme i-Démo, ArcaScience prévoit le dépôt de brevets couvrant (i) les méthodes de curation et d'harmonisation des données multimodales, (ii) les architectures de modèles prédictifs B-R spécifiques à la transposition préclinique-clinique, et (iii) les procédés d'intégration multi-échelle du World Model, un dépôt par groupe fonctionnel d'algorithmes, planifié à chaque jalon EC.

ArcaScience procèdera par ailleurs à des **publications scientifiques sélectives**, permettant d'établir une antériorité publique sur les contributions méthodologiques non brevetables tout en renforçant la crédibilité académique de la plateforme.

PARTENAIRES ET SOUS-TRAITANTS CLÉS

DESCRIPTION PARTENAIRE/ SOUS-TRAITANT	
Partenaires de recherche et académiques	
	Partenaire Direct, non-sous-traitant : l'ICM est un partenaire académique structurant, mobilisé sur des projets de recherche appliquée et des validations cliniques. La collaboration couvre notamment l'identification de candidats pour le repositionnement de médicaments dans le glioblastome, ainsi qu'un projet européen IHI sur le cancer du cerveau pédiatrique auquel ArcaScience participe aux côtés d'ICM et d'industriels (Sanofi, AstraZeneca, Siemens). L'ICM apporte une expertise médicale de haut niveau, l'accès à des corpus cliniques et un cadre méthodologique pour l'évaluation bénéfice/risque, renforçant la crédibilité scientifique des livrables et leur alignement avec les usages cliniques et réglementaires.
	Partenaire Direct, non-sous-traitant : Inria est au cœur des briques IA d'ArcaScience, avec une collaboration historique qui a contribué à concevoir l'architecture SLM propriétaire. Des chercheurs Inria ont rejoint l'entreprise, sécurisant la maîtrise interne des composants critiques. Inria apporte un appui méthodologique sur l'ingénierie des modèles, l'annotation sémantique et les pipelines d'apprentissage, ainsi que des références de recherche pour consolider la traçabilité et l'explicabilité de la chaîne data-to-decision. Cet ancrage accélère la montée en robustesse des modèles et l'industrialisation de l'usine logicielle.
Ecosystème et structure de soutien	
	Partenaire Direct, non-sous-traitant : Hub d'innovation santé où ArcaScience est implantée, Future4Care offre un accès à un écosystème opérationnel (startups, industriels, institutions, investisseurs). Ce cadre facilite l'accès à des ressources mutualisées pour la R&D et l'industrialisation (mentorat, plateformes, réseau), et consolide l'ancrage marché grâce aux fondateurs Sanofi et Generali, partenaires de longue date d'ArcaScience. Future4Care soutient la mise à l'échelle des déploiements on-prem et les interactions avec les décideurs pharma et hospitaliers, en complément d'un accompagnement Business France et de connexions internationales (Plug and Play, Cedars-Sinai).
	Partenaire Direct, non-sous-traitant : ArcaScience est intégrée dans la communauté internationale liée à Cedars-Sinai, ce qui renforce son accès aux écosystèmes cliniques et aux décideurs en santé aux États-Unis. Cette connexion est complétée par la présence d'experts de Cedars-Sinai au conseil d'ArcaScience, facilitant les retours sur les exigences cliniques, la qualité des données et les modalités d'industrialisation conformes aux pratiques hospitalières. Le réseau apporte une crédibilité clinique et un relais pour les déploiements et validations.

Partenaires commerciaux	
	Partenaire Direct, non-sous-traitant : ICON est l'une des plus grandes CRO mondiales et un partenaire opérationnel d'ArcaScience pour des projets d'analyse bénéfice-risque, avec des capacités de conduite d'essais et de structuration de données cliniques à grande échelle. Sa filiale MAPI (MRT) apporte une expertise sur les PRO/mesures de résultats rapportés par les patients, utile à la consolidation des profils B/R. L'apport d'ICON/MAPI se matérialise par des cas d'usage chez des clients communs, l'industrialisation des workflows et l'articulation avec les standards CRO, renforçant la valeur des analyses comparatives et leur intégration dans les processus décisionnels.
	Partenaire sous-traitant : Gradient Health intervient comme fournisseur de données pour renforcer les jeux d'entraînement et de validation (RWE et hospitalier), avec un objectif d'équilibrage des datasets et de performance cible (précision >95 %) dans les usages visés. L'accès à ces données soutient la montée en échelle des corpus, la couverture des endpoints et l'amélioration des métriques de qualité, tout en assurant la conformité avec les pratiques d'intégration de données du secteur et la traçabilité des sources exploitées par la plateforme.
	Sanofi intervient à double titre : partenaire écosystème via Future4Care (fondateur) et partenaire scientifique au comité d'ArcaScience (représenté par Philippe Peyre), avec une implication dans les projets de validation des modèles IA sur plusieurs années. Sanofi est également partenaire du projet IHI pédiatrique, renforçant l'intégration d'ArcaScience dans des consortiums européens. Les contributions portent sur la validation scientifique, l'accès à des référentiels métiers, et l'adéquation des livrables aux processus internes d'affaires réglementaires et de développement clinique.
	AstraZeneca est cité comme partenaire dans le cadre du projet IHI pédiatrique aux côtés d'ICM et Sanofi. Son rôle s'inscrit dans la structuration de projets collaboratifs R&D et l'alignement des besoins industriels avec les livrables d'ArcaScience. La collaboration contribue à ancrer la solution dans les cas d'usage cliniques des grands laboratoires, facilitant l'intégration des analyses B/R dans les processus d'évaluation et d'aide à la décision.

Parmi ces différents partenariats, la complétion du projet BR-Predict s'appuiera majoritairement sur Sanofi dans le cadre de la réalisation du démonstrateur du nouveau module.

1.4. ACTIVITÉ DE LA SOCIÉTÉ

L'IA AU SERVICE DE L'ACCOMPAGNEMENT DES INDUSTRIELS DU MÉDICAMENTS

Activité actuelle

ArcaScience conçoit une **plateforme IA dédiée à l'évaluation bénéfice-risque (B/R) des médicaments**, pour **soutenir les décisions réglementaires et cliniques tout au long du développement**. L'analyse bénéfice-risque est un processus structuré et systématique visant à identifier, caractériser et mettre en

balance les bénéfices thérapeutiques attendus d'un médicament avec les risques associés à son utilisation. Cette évaluation repose sur l'intégration de différentes sources de données, incluant notamment les données précliniques, cliniques, pharmacologiques et les connaissances relatives au mécanisme d'action. Elle prend également en compte le contexte thérapeutique en comparant le profil bénéfice-risque du candidat médicament à celui des traitements ou actifs déjà disponibles, afin d'évaluer sa valeur ajoutée potentielle pour une indication et une population donnée. À ce jour, la société a développé un premier module, **Trial Balancer**. Concrètement, il agrège principalement des données concernant les **actifs déjà testés sur le marché**. Ces données sont enrichies par des informations détaillées sur les pathologies et leurs différentes variantes (historique de traitement, biomarqueurs, etc.). L'ensemble est ensuite transformé en une **base de données structurée** qui s'intègre aux données du client afin de générer un **corpus de preuves exhaustif, traçable et exploitable**. Cette base alimente les analyses à toutes les étapes du processus BRAT (Benefit-Risk Action Team) pour les médicaments à partir de la phase 2 clinique. Ce module permet de répondre à deux cas d'usage principaux :

- L'analyse des données cliniques obtenues à la suite des phases 2 et 3 d'un essai clinique pour un candidat médicament, ainsi que leur comparaison avec les données des traitements déjà disponibles sur le marché. Cela permet au partenaire de recherche d'orienter son développement, d'adapter le design des essais cliniques suivants et de réaliser des avenants auprès des autorités de santé en fonction de l'analyse réalisée par la plateforme. Une fois la plateforme déployée, elle peut être utilisée de manière autonome par le client pour réaliser autant d'analyses que nécessaire. Par ailleurs, sa capacité de mise à jour automatique permet au partenaire de générer une nouvelle analyse dès que de nouvelles données deviennent disponibles, sans avoir à repasser par une intervention de la société.
- La construction d'un rapport d'**analyse bénéfice-risque** structuré dans un document conforme aux attentes des autorités de santé. La structuration des analyses suit le framework **BRAT**, qui s'aligne avec les attentes des régulateurs (dossiers acceptés par la FDA et l'EMA) et avec les considérations de la FDA concernant l'usage IA en support des décisions réglementaires. Les cas documentés démontrent l'applicabilité opérationnelle de ces cadres, avec une explicabilité intégrée des résultats et une justification par mécanismes d'action. La capacité de mise à jour automatique de la plateforme permet également de répondre aux exigences des autorités de santé, qui requièrent la production régulière de rapports afin d'assurer le suivi du profil bénéfice-risque et le maintien d'un médicament sur le marché.

Le module Trial Balancer est déjà déployé chez plusieurs laboratoires pharmaceutiques et CRO.

Historique de développement

La société a progressivement développé plusieurs briques technologiques constituant aujourd'hui la base de sa plateforme. Les premiers travaux ont porté sur des outils d'exploitation et de structuration de la littérature scientifique et des données biomédicales. Ces développements ont ensuite été étendus à l'analyse de données cliniques et à leur comparaison avec les standards thérapeutiques existants.

Ils ont permis de construire :

- Une brique de collecte et de structuration de la littérature scientifique et des bases de connaissances biomédicales
- Une brique d'intégration de données cliniques issues des essais et des traitements de référence
- Une brique ontologique permettant d'harmoniser et de relier les différentes typologies de données biomédicales
- Une brique d'analyse permettant de produire des évaluations comparatives bénéfice-risque

- Une brique de mise à jour automatique permettant d'intégrer de nouvelles données et de régénérer les analyses lorsque de nouvelles informations deviennent disponibles.

L'ensemble de ces briques constitue aujourd'hui le module **Trial Balancer** et le socle technologique de la plateforme ArcaScience, qui servira de base au développement du futur module prédictif **BR-Predict**.

MODÈLE ÉCONOMIQUE

Le modèle économique d'ArcaScience repose sur l'établissement de **contrats-cadres** conclus avec des laboratoires pharmaceutiques et des CRO, permettant une **analyse bénéfice-risque** des molécules de **manière industrialisée**. L'approche consiste à déployer un module en **modèle SaaS chez le client**, paramétré selon ses besoins en termes de type d'actif et de pathologie cible, et à **facturer chaque nouvelle molécule analysée** sans coût initial d'installation. Un pipeline étant programmé pour produire des évaluations prospectives de bénéfice-risque uniquement pour la drogue en cours de développement (modèles choisis, ontologies appliquées et sourcées, datasources stratifiées), ainsi ArcaScience n'a pas besoin de tracker son utilisation. Les prix de chacun des modules de la solution ArcaScience sont définis en fonction d'une quantification du service rendu par rapport au temps gagné, tout en restant en adéquation avec les besoins client.

ArcaScience est consciente de la réticence des entreprises pharmaceutiques à déployer de nouvelles solutions SaaS en interne, notamment en raison des besoins de formation et des contraintes opérationnelles associées. La solution a donc été conçue pour être intégrée et largement automatisée, nécessitant peu de formation et peu d'actions de la part des utilisateurs pour être exploitée. Son déploiement auprès des différentes équipes R&D et dans plusieurs domaines thérapeutiques est ainsi facilité.

En amont du contrat-cadre, ArcaScience réalise un démonstrateur co-développé avec le client sur une molécule d'intérêt, à partir de ses données pharma, pour délivrer l'outcome attendu (profil B/R comparé au standard of care, éléments de décision, traçabilité complète) selon des KPI conjointement définis (délai d'analyse, complétude des sources, performance des signaux, conformité). Une fois ces résultats atteints et documentés, le contrat-cadre est signé pour industrialiser l'approche "molécule par molécule", avec une tarification à l'usage et un dispositif d'accompagnement (paramétrage, QA des analyses, support métier) permettant l'utilisation autonome de la plateforme sur les molécules suivantes.

Le modèle SaaS est par essence plus scalable que le modèle CRO. La plateforme ArcaScience renforce cet aspect sur plusieurs axes :

- **L'extension intra-client**, correspondant à l'analyse de plusieurs molécules appartenant à une même classe d'actifs thérapeutiques (par exemple petites molécules chimiques ou anticorps monoclonaux). Dans ce cadre, les bases de données mobilisées restent en grande partie communes, notamment pour les propriétés structurales et les profils ADMET. La plateforme peut ainsi être utilisée pour analyser différentes cibles thérapeutiques au sein d'un même pipeline de développement. Cette extension peut ensuite être élargie à des pathologies reposant sur des mécanismes biologiques proches, permettant de réutiliser les mêmes référentiels de données et modèles d'analyse.
- **L'extension des modules à différents types de molécules et à différentes familles de pathologies reposant sur des mécanismes d'action proches**. Cela concerne notamment des pathologies partageant des bases physiopathologiques similaires ou des régulations biologiques communes, par exemple des processus d'immunomodulation, d'inflammation ou certains déterminants génétiques.

- **L'extension du nombre de modules ciblant différents cas d'usage**, avec le développement progressif de nouveaux modules venant compléter Trial Balancer et BR-Predict.

Ainsi, la feuille de route prévoit, après le programme i-Démo, un développement selon deux axes : l'extension de la plateforme à de nouvelles aires thérapeutiques et l'introduction de nouveaux modules permettant de couvrir de nouveaux cas d'usage.

CLIENTS ACTUELS

Grâce à leur activité focalisée sur **l'analyse bénéfice-risque** et à un modèle économique progressif, ArcaScience a signé **neuf contrats avec sept clients à fin juin 2025**, couvrant des **laboratoires pharmaceutiques** comme Sanofi, AstraZeneca et Dilon Technologies, ainsi **qu'une CRO de premier plan**, ICON, et sa filiale Mapi Research Trust. Cette traction valide l'adéquation de la solution aux usages réglementaires et cliniques ciblés.

Clients		Montant (k€/an) et spécificités des contrats	Description des travaux
	Juillet 2025 : 600 k€	Risk Management Group (200 clients) : structuration de données cliniques CRO à grande échelle, industrialisation des workflows d'analyse risque, intégration des standards de risk management dans les processus décisionnels sur leurs 200 clients.	
	Août 2025 : 235 k€	Découverte traitements Cancers du cerveau pédiatrique : participation au projet IHI pédiatrique, structuration de projets collaboratifs R&D, alignement des données industrielles pour découverte de molécules à repositionner sur les cas de cancers du cerveau chez l'enfant.	
	Juin 2025 : 100 k€	Prédiction bénéfice-risque maladie de Verneuil : Analyse comparative bénéfice-risque en dermatologie, calibration des modèles sur données internes Sanofi et mise en place du premier pipeline européen dynamique d'actualisation du bénéfice-risque du candidat médicament. Premier pipeline de positionnement clinique de médicament à l'échelle mondiale avec intégration de comparateurs environnementaux, à partir du mécanisme d'action du candidat.	
	Septembre 2024 : 90 k€	Prédiction du bénéfice-risque Sclérose en plaques : POC initial, structuration de la base de données et profiling moléculaire sur molécules du portefeuille	
	Septembre 2025 : 180 k€	Plateforme Nationale Interactions médicamenteuses : Intégration des données de référence médicamenteuses Vidal dans la Profiling Base, enrichissement du corpus réglementaire pour renseigner les 230.000 médecins adhérents. La solution d'ArcaScience remplace une approche obsolète et dangereuse basée sur l'interprétation de données de l'ANSM non-sourcées.	
			

	Décembre 2024 : 156 k€	Leader Efficience Clinique : Structuration des PRO (Patient-Reported Outcomes) et mesures de résultats patients, consolidation des profils B/R pour le N°1 mondiale des Clinical Outcome Assessments ; ArcaScience améliore par 30% la complétude de leurs livrables.
	POC mars 2025 : 20 k€ Juin 2025 : 126 k€	Evaluation dynamique Bénéfice-Risque : POC en développement préclinique sur molécules candidates, puis licence plateforme Trial Balancer
	POC février 2025 : 20 k€ Mai 2025 : 42 k€	Plateforme Evaluation Bénéfice-Risque pour soumission régulateurs : POC en développement clinique sur molécules phase 3, livrables ArcaScience approuvés par la FDA en décembre 2025.
	Septembre 2025 : 60 k€	Evaluation mondiale Bénéfice-Risque de la Résistance Antimicrobienne : Validation des modèles IA sur cas d'usage AMR (Antimicrobial-Resistance) pour conception de stratégie de développement clinique niveau COMEX, et analyse géopolitique du sujet au niveau mondial afin de statuer des composés disponibles pour mitiger le risque étatique de la résistance.

Les deux proof of concept réalisés à ce jour se sont convertis en contrats. Ce taux de conversion de 100 %, significativement supérieur au benchmark SaaS B2B de 20-40 %, démontre l'adéquation immédiate de la solution avec les besoins opérationnels des clients. La valeur perçue lors du démonstrateur est systématiquement suffisante pour déclencher un engagement contractuel pérenne. Ces premiers résultats confirment ainsi la pertinence du modèle économique choisi par la société.

1.5. AMBITION ET EVOLUTION STRATÉGIQUE DE LA SOCIÉTÉ

L'AMBITION D'ARCASCIENCE

Aujourd'hui, les analyses bénéfice-risque sont principalement réalisées à partir de données issues des phases cliniques avancées, notamment les **phases 2 et 3**. À ce stade du développement, les marges d'ajustement sont limitées alors que les entreprises pharmaceutiques ont déjà investi près de **10 ans** de développement et environ **2 milliards d'euros** pour amener un candidat médicament à ce niveau de maturité.

Les marges d'ajustement sont alors quasi nulles : modifier le protocole, recentrer la population cible ou réorienter le positionnement thérapeutique devient extrêmement coûteux et chronophage. L'analyse intervient donc dans une logique de consolidation et de justification réglementaire, non dans une logique d'aide à la décision.

Or, l'analyse des causes d'échec en développement clinique révèle que 40 à 54 % des abandons sont attribuables à un manque d'efficacité démontrée, et 17 à 30 % à des problèmes de toxicité qui auraient pu être anticipés plus tôt. Ces échecs tardifs, survenus après l'engagement de centaines de millions d'euros en phase III, constituent la principale source de destruction de valeur dans l'industrie pharmaceutique.

L'enjeu stratégique est donc **d'ancrer l'analyse bénéfice-risque en amont du développement clinique**, en s'appuyant non sur les données propres à la molécule candidate, mais sur des données externes de nature préclinique, génomique et de vie réelle. Cette approche prédictive permettrait d'identifier dès les phases précoces les candidats dont le profil bénéfice-risque est insuffisant pour justifier un engagement clinique coûteux, et de concentrer les ressources sur les actifs à plus forte probabilité de succès.

La société aspire à devenir un partenaire de référence, non seulement réglementaire, mais également pour les décisions de R&D et le positionnement clinique des portefeuilles. Cette trajectoire repose sur une extension progressive des cas d'usage.

Pour cela, ArcaScience développera progressivement de nouveaux modules intégrant des **SLM** capables d'exploiter les données agrégées par la plateforme afin de produire de nouveaux types de recommandations pour les entreprises pharmaceutiques à différentes étapes du développement d'un médicament.

Par ailleurs, près de **90 %** de l'architecture de la solution repose sur des modèles non spécifiques à une pathologie. L'adaptation à différentes aires ou sous-aires thérapeutiques ne nécessite donc que des ajustements limités, permettant une extension rapide de la plateforme aux spécificités des actifs et des indications étudiées. Ce socle commun favorise un élargissement progressif aux aires thérapeutiques dynamiques, avant une généralisation multi-pathologies.

À ce jour, ArcaScience dispose d'une plateforme opérationnelle dédiée à l'analyse bénéfice-risque des candidats médicaments, principalement utilisée dans des contextes réglementaires et d'évaluation clinique avancée via la technologie Trial Balancer.

L'ambition stratégique de la société, en adéquation avec le programme i-Démo, consiste désormais à **étendre ces capacités vers des analyses prédictives capables d'intervenir plus en amont du développement clinique**. Cette évolution repose sur l'architecture technologique déjà en place et sur les savoir-faire développés par l'équipe en matière d'intégration de données biomédicales et de modélisation par IA. Elle implique le développement de nouveaux modules permettant d'exploiter des données précliniques, cliniques externes et biomédicales afin d'anticiper le profil bénéfice-risque des candidats médicaments.

Le premier développement de ce type sera réalisé dans le cadre du projet **BR-Predict** sur l'indication du **NSCLC**, qui servira de preuve de concept. Les méthodes développées pourront ensuite être étendues à d'autres indications en oncologie, puis à d'autres aires thérapeutiques, notamment dans les pathologies d'immunologie et d'inflammation.

Cette évolution positionne ArcaScience comme un acteur complémentaire aux approches actuellement utilisées par les entreprises pharmaceutiques pour la sélection et l'évaluation des candidats médicaments. L'ambition est d'intégrer pour la première fois une capacité de prédiction du profil bénéfice-risque directement dans le pipeline de sélection des actifs, afin d'éclairer plus tôt les décisions de développement et de priorisation des candidats.

LA PLACE DE L'ANALYSE BÉNÉFICE-RISQUE DANS LE MARCHÉ DU "DRUG DEVELOPMENT"

Le processus de découverte et de développement des médicaments représente un pilier essentiel de l'innovation pharmaceutique, mais il reste marqué par des défis structurels et financiers. Ce processus se divise en deux grandes étapes : **Drug Discovery** et **Drug Development**.

La phase de **Drug Discovery** inclut l'identification de cibles thérapeutiques, le criblage de molécules (« hits ») et le développement des molécules sectionnées (« lead »),

La phase du **Drug Development** contient les **développement préclinique** et **développement clinique** jusqu'à l'obtention d'une autorisation réglementaire de mise sur le marché.

Le cycle de développement complet de la découverte d'une molécule à son approbation peut durer entre **10 et 15 ans**, est marqué par un taux d'échec élevé (**90 %**) et des coûts moyens par molécule estimés entre **2 et 3 milliards de dollars**. Une fois le médicament sur le marché, les entreprises concernées ont un devoir de pharmacovigilance afin de sécuriser l'utilisation du médicament et de pouvoir conserver sa place sur le marché. Le marché de l'analyse bénéfice-risque représente aujourd'hui

un segment stratégique de l'évaluation des médicaments. Ce marché est estimé à environ **13,2 milliards de dollars par an**.

Ces moyennes par molécule reflètent le coût unitaire d'une analyse bénéfice-risque à chaque phase, et non le poids relatif de chaque segment dans le marché total. En volume, plus des deux tiers du marché (8,4 milliards de dollars) sont aujourd'hui concentrés sur le post-marketing. À l'inverse, les phases précoces (préclinique et phase 1) représentent le plus grand nombre de molécules mais un coût unitaire nettement plus faible, car les analyses y sont aujourd'hui moins exhaustives et moins structurées. C'est précisément ce déséquilibre qu'ArcaScience adresse : industrialiser une analyse bénéfice-risque de qualité dès les phases précoces, à un coût compatible avec la volumétrie des portefeuilles de candidats.

L'analyse bénéfice-risque est désormais intégrée à l'ensemble du processus de **drug development**, depuis les phases précoces de développement jusqu'aux phases cliniques avancées et aux interactions réglementaires. Toutefois, son niveau d'utilisation et sa profondeur analytique varient selon les **phases de développement du médicament**.

Ainsi, le marché peut être segmenté en fonction des différentes étapes du développement clinique de la molécule cible faisant l'objet d'une analyse bénéfice-risque, chaque phase mobilisant ces analyses à des degrés différents.

Phase de développement du médicament	Taille du marché	Nombre de molécules par phase	Moyenne par molécule
Préclinique	\$1.15Mds	11 351	\$100K
Phase 1	\$1.47Mds	2 947	\$250K
Phase 2	\$1.39Mds	1 385	\$1M
Phase 3	\$0.39Md	388	\$1,2M
Approbation	\$0.32Md	213	\$500k
Post-Marketing	\$8.4Mds	196	\$4,3M

Aujourd'hui, plus de deux tiers du marché de l'analyse bénéfice-risque se concentre sur les activités post-marketing. À l'inverse, les entreprises investissent encore relativement peu dans ce type d'analyse pour les actifs situés en début de développement.

Toutefois, la demande de l'industrie pharmaceutique évolue progressivement vers une utilisation plus précoce de ces analyses, notamment dans les phases de développement clinique. L'intégration d'une analyse bénéfice-risque permet en effet d'orienter la stratégie de développement d'un candidat médicament avant l'engagement d'essais pivots particulièrement coûteux.

Le principal goulot d'étranglement reste aujourd'hui l'entrée en clinique. Les industriels cherchent donc à faire évoluer ces approches afin de pouvoir réaliser des analyses bénéfice-risque dès les stades précliniques.

Ces besoins et contraintes ont permis l'évolution du domaine avec le développement d'approches quantitatives, notamment les méthodes **MCDA (Multi-Criteria Decision Analysis)**, permettant de structurer plus finement l'évaluation des bénéfices et des risques des candidats médicaments.

Finalement, aux stades précoces du drug development, notamment durant les phases précliniques et les premières phases cliniques, l'analyse bénéfice-risque peut être assimilée à un ensemble de recommandations structurantes permettant aux entreprises d'orienter leurs choix stratégiques de développement.

Dans ce contexte, le marché ne se limite plus aux seules solutions visant à formaliser ou structurer l'analyse bénéfice-risque. Il englobe désormais l'ensemble des outils et approches permettant d'éclairer la prise de décision des entreprises disposant d'un pipeline de candidats médicaments, notamment dans les phases de priorisation et de sélection des actifs.

Ce marché élargi, centré sur la sélection des leads à amener en clinique ainsi que sur l'optimisation du développement préclinique, est estimé à 6,38 milliards de dollars¹. Il comprend notamment les activités liées à la caractérisation des propriétés ADME, à la définition des profils pharmacodynamiques et pharmacocinétiques, ainsi qu'à l'analyse de données issues d'études in vitro et in vivo.

Aujourd'hui, ce marché est fortement porté par la montée en puissance des approches numériques et de l'intelligence artificielle dans les phases précoces du développement pharmaceutique, qui transforment progressivement le secteur en permettant un criblage des candidats médicaments plus rapide, plus ciblé et plus prédictif.

L'efficacité de ces approches est déjà faite ces preuves dans les phases amont du développement en drug discovery. L'intégration de l'intelligence artificielle (IA) dans cette phase permettrait de **réduire significativement les coûts** (–20 % à –40 %) et les délais (–30 % à –50 %), tout en **augmentant les taux de succès des projets**. En effet, certaines études montrent que les molécules identifiées par IA augmentent leurs chances de réussite en phase 1 clinique de près de 80 %².

Dans ce contexte, le développement de médicaments assisté par IA constitue aujourd'hui une dynamique structurante pour l'industrie pharmaceutique. Face à la **pression croissante sur les coûts** de R&D et aux **taux d'échec persistants**, les laboratoires cherchent à **internaliser ces capacités en déployant leurs propres infrastructures data** et en constituant des équipes dédiées en IA, notamment pour l'identification de cibles, la priorisation de candidats ou l'optimisation de protocoles.

Cependant, dans le cadre du développement préclinique, aucune solution n'a encore réussi à démontrer de manière incontestable sa valeur ajoutée ni à s'imposer comme une solution de référence auprès des partenaires pharmaceutiques.

ENVIRONNEMENT CONCURENTIEL D'ARCASCIENCE

Environnement Concurrentiel de Trial Balancer

Le module Trial Balancer d'ArcaScience positionne la société sur le segment de l'analyse bénéfice-risque allant de la phase 2 clinique jusqu'aux activités de pharmacovigilance. Aujourd'hui, ce marché est principalement détenu par des CRO spécialisées qui réalisent pour le compte des laboratoires pharmaceutiques les analyses nécessaires aux dossiers réglementaires et au suivi post-autorisation. Ces acteurs produisent notamment des analyses bénéfice-risque, des synthèses de littérature scientifique ainsi que différents livrables réglementaires tels que les PSUR/PBRER ou les plans de gestion des risques, dans le cadre des obligations de pharmacovigilance et du maintien de l'autorisation de mise sur le marché. Sur ce segment, les principaux concurrents d'ArcaScience regroupent donc ces grandes CRO internationales ainsi que certains cabinets spécialisés en affaires réglementaires et pharmacovigilance.

Entreprise	Pays	Activité principale
 YolaRX	Etats-Unis	Cabinet de conseil spécialisé en pharmacovigilance, safety science et gestion du bénéfice/risque pour l'industrie pharmaceutique.
 BioBOSTON CONSULTING	Etats-Unis	Cabinet de conseil en stratégie et développement clinique pour biotech et pharma, incluant accompagnement réglementaire et accès au marché.

¹ <https://www.sphericalinsights.com/fr/reports/drug-discovery-services-market>

² <https://www.platformexecutive.com/insight/health-care-research/ai-in-drug-discovery/> ; <https://nano-gpt.com/blog/ai-in-drug-discovery-cost-breakdown>

	Etats-Unis	Société spécialisée dans l'analyse de données cliniques, pharmacovigilance et gestion des données réglementaires.
	Royaume-Uni	Société internationale spécialisée en affaires réglementaires, pharmacovigilance, compliance et services réglementaires globaux.
	Etats-Unis	Cabinet de conseil en pharmacovigilance et gestion du risque, spécialisé dans les systèmes PV et la conformité réglementaire.
	Etats-Unis	Société de conseil spécialisée en pharmacovigilance, gestion du risque et stratégie réglementaire.

La proposition de ces entités repose sur **l'expertise réglementaire**, l'accès à des équipes dédiées et l'accompagnement à la soumission. Toutefois, ces approches restent intensives en main-d'œuvre (screening, extraction, harmonisation), peu reproductibles d'un cycle à l'autre et coûteuses lorsqu'il s'agit de couvrir un portefeuille multi-pathologies.

Au-delà de ces solutions d'analyse manuelle, **ArisGlobal**, se distingue en proposant une solution de **l'analyse bénéfice-risque** en mode **SaaS**, basée sur une plateforme permettant d'optimiser le workflow interne des laboratoires pharmaceutiques, et revendique une accélération de près de **40 %** du temps consacré à la réalisation de **l'analyse bénéfice-risque** (soit environ **huit mois**).

Par rapport aux approches CRO et à la solution SaaS d'ArisGlobal, la solution d'ArcaScience présente deux avantages principaux.

- **Temps et coûts** : Trial Balancer permet de réaliser une analyse bénéfice-risque en quelques semaines pour un coût d'environ **125 k€**, contre **plus d'un million d'euros et plus d'un an de travail** via des CRO. ArisGlobal améliore le workflow interne mais reste centré sur l'organisation des processus existants.
- **Volume de données analysées** : la solution d'ArcaScience permet d'intégrer **10 à 100 fois plus de datapoints** issus de sources scientifiques et réglementaires. Les analyses produites sont donc **plus exhaustives** que celles reposant sur des bases propriétaires limitées ou des revues manuelles.

Ainsi, Trial Balancer permet de produire des analyses bénéfice-risque plus rapidement, à moindre coût et sur un périmètre de données plus large que les solutions existantes. Cette combinaison positionne ArcaScience comme la solution la plus performante du marché pour industrialiser l'analyse bénéfice-risque au sein des laboratoires pharmaceutiques.

Environnement Concurrentiel de BR-Predict

Le module **BR-Predict** se positionne en amont de ces phases avec l'objectif de devenir **un outil d'aide à la décision pour les entreprises disposant de pipelines précliniques et cliniques**.

Bien que les CRO mentionnées et ArisGlobal soient solidement implantées sur le marché des **analyses bénéfice-risque**, leur repositionnement vers ce segment amont reste limité par plusieurs contraintes opérationnelles et techniques :

- **Le coût des analyses bénéfice-risque**, estimé aujourd'hui à près de **1,2 million de dollars par molécule**, est trop élevé pour des actifs aussi précoces. Les entreprises pharmaceutiques ne peuvent pas appliquer ce type d'analyse à l'ensemble de leurs pipelines précliniques.
- **Les méthodes actuelles restent majoritairement manuelles et lentes**, et reposent principalement sur des données d'efficacité et de sécurité cliniques. Avant la phase 2, ces données sont fragmentées et proviennent souvent de modèles animaux dont la transposabilité à l'humain est

limitée. Les données disponibles sont donc insuffisantes pour produire une analyse bénéfice-risque robuste avec les approches traditionnelles.

Dans ce contexte, ces solutions ne constituent pas une concurrence directe pour **BR-Predict**.

ArcaScience se trouve davantage confrontée aux **solutions IA d'aide à la décision en phase préclinique**, qui visent à interpréter des données telles que la pharmacocinétique, la pharmacodynamique ou les propriétés ADME. Deux catégories d'acteurs se distinguent :

Les laboratoires pharmaceutiques eux-mêmes. Chaque grand laboratoire développe progressivement ses propres workflows internes afin d'améliorer la prédiction de l'efficacité et de la sécurité des candidats médicaments. Toutefois, ces capacités restent souvent fragmentées.

Les sociétés développant des **plateformes spécialisées**. Ces acteurs proposent des solutions clés en main couvrant principalement les phases amont du développement, telles que **l'identification de cibles thérapeutiques**, la **détection de hits** ou **l'optimisation de leads**. Certains élargissent désormais leur positionnement vers des services à plus forte valeur stratégique, en accompagnant les laboratoires dans l'optimisation du design clinique ou dans l'évaluation prédictive de certaines caractéristiques des candidats médicaments.

Ces offres visent à fluidifier l'accès aux données et à renforcer la conformité opérationnelle, mais **elles ne proposent pas nativement une analyse bénéfice risque comparative complète, explicable et reproductible par rapport au standard of care**.

Entreprise	Pays	Activité principale
 nterence [®]	Etats-Unis	Parmi les capacités revendiquées par la plateforme, nterence met en avant l'analyse de trajectoires patients à partir de données hospitalières structurées et non structurées (EHR, biologie, comptes rendus cliniques). Les cas d'usage incluent l'enrichissement de protocoles cliniques, l'identification de sous-groupes de patients et l'analyse rétrospective de populations pour documenter des signaux cliniques. L'entreprise a levée près de 300 M\$
 Tempus	Etats-Unis	Parmi les capacités revendiquées par la plateforme, Tempus met en avant des études translationnelles et des analyses clinico-génomiques destinées à orienter la sélection des patients dans les essais cliniques, principalement en oncologie. L'entreprise a levée près de 1,1 Md\$
 OWKIN	Etats-Unis	Parmi les capacités revendiquées par la plateforme, Owkin développe des modèles d'apprentissage automatique appliqués à des données multimodales (imagerie, données cliniques, données moléculaires), souvent dans un cadre d'apprentissage fédéré. Les cas d'usage mis en avant incluent l'identification de biomarqueurs associés à des issues cliniques, l'analyse de facteurs corrélés à la réponse observée dans des cohortes existantes et l'optimisation du design d'essais cliniques (enrichissement de population, définition d'endpoints). L'entreprise a levée près de 300 M\$ levés
 Benevolent ^{AI}	Royaume-Uni	Parmi les capacités revendiquées par la plateforme, BenevolentAI se positionne sur la priorisation de candidats médicaments en phase

		préclinique via l'analyse intégrée de données biologiques, chimiques et issues de la littérature scientifique. Société internationale spécialisée en affaires réglementaires, pharmacovigilance, compliance et services réglementaires globaux.
--	--	---

Ces acteurs sont tous américains ou britanniques. Les montants des levées de fonds réalisées confirment la dynamique d'investissement massive dans ce segment ainsi que l'absence d'acteurs d'Europe continentale, renforçant ainsi la pertinence stratégique du positionnement d'ArcaScience.

Finalement, les solutions positionnées sur le segment de développement préclinique demeurent complémentaires à l'approche portée par le nouveau module d'ArcaScience. Là où ces outils optimisent l'identification et la conception des candidats, BR-Predict intervient en aval pour **structurer et anticiper leur profil analyse bénéfice-risque** dans une logique décisionnelle globale.

La solution s'inscrit ainsi en continuité des molécules conçues par IA, dont la probabilité de succès est déjà optimisée en phase de découverte. Elle permet de capitaliser sur ces actifs en apportant une couche d'analyse stratégique supplémentaire, orientée vers la priorisation clinique et la sécurisation des choix d'investissement. Par ailleurs, le module est conçu pour **s'intégrer avec d'autres outils d'aide à la décision**, renforçant une approche combinée et cohérente du développement pharmaceutique.

Cependant, si ces plateformes ne sont pas aujourd'hui positionnées explicitement sur le segment de **l'analyse bénéfice-risque prédictive**, elles disposent d'atouts structurels susceptibles d'en faire des concurrents directs à moyen terme.

Elles adressent la même clientèle cible et les mêmes **problématiques de R&D et de translation clinique** des laboratoires pharmaceutiques. De plus, les plateformes développées par ces sociétés suivent la même dynamique en cherchant à devenir des outils de plus en plus exhaustifs pour ces entreprises pharmaceutiques. Également au niveau technique, elles se basent sur des **données d'entrée** et mobilisent des expertises techniques similaires en matière de **modélisation IA**, d'**ingénierie des données** et d'**intégration multimodale**.

Les barrières technologiques à l'entrée sur le segment spécifique de **l'analyse bénéfice-risque prédictive** restent donc modérées pour ces acteurs. Une extension fonctionnelle de leurs plateformes vers ce cas d'usage serait cohérente avec leur positionnement stratégique actuel, notamment dans une logique d'intégration verticale de la chaîne décisionnelle en développement clinique.

À ce stade, ArcaScience demeure toutefois le seul acteur spécialisé et structuré autour d'une **analyse bénéfice-risque automatisée, comparative et industrialisable**. Cette spécialisation constitue un avantage différenciant clair.

DÉPLOIEMENT DE BARRIÈRES À L'ENTRÉE DU MARCHÉ

La stratégie d'ArcaScience vise précisément à transformer cette avance technologique en barrière à l'entrée marché durable :

- **Barrière technologique** : La première barrière à l'entrée repose sur l'avance technologique d'ArcaScience dans le développement d'architectures logicielles dédiées à l'analyse bénéfice-risque des candidats médicaments. Bien que certains acteurs du secteur disposent en théorie des compétences techniques nécessaires pour développer des solutions similaires, leur temps de développement serait particulièrement long en raison des besoins d'accès aux données, de structuration des ontologies, d'entraînement des modèles et de validation scientifique. Cette avance technologique permet à ArcaScience de déployer progressivement des modèles spécialisés sur un nombre croissant de pathologies. En maintenant un rythme d'innovation

continu au-delà du programme i-Démo, l'entreprise pourra consolider cette avance et couvrir un large périmètre d'indications avant que d'éventuels concurrents ne puissent développer des solutions comparables.

- **Barrière de marché :** Une seconde barrière repose sur la dynamique d'adoption progressive de la plateforme par les entreprises pharmaceutiques, les biotechnologies et les CRO. La solution d'ArcaScience se caractérise par une forte polyvalence et peut être utilisée sur un large éventail d'actifs thérapeutiques et de pathologies. À mesure que la société déploie sa plateforme auprès d'un nombre croissant d'acteurs industriels, elle renforce sa présence sur un marché très large. Dans ce contexte, de nouveaux entrants rencontreraient des difficultés à s'imposer sur l'ensemble du segment. Leur stratégie consisterait probablement à cibler des niches thérapeutiques ou des cas d'usage spécifiques afin de proposer des solutions plus spécialisées. Toutefois, ArcaScience conserverait un avantage en tant que solution généraliste capable de couvrir un grand nombre de pathologies et de types d'actifs, ce qui lui permettrait de rester la plateforme de référence pour les analyses bénéfice-risque polyvalentes.
- **Barrière liée au modèle économique et au SaaS :** Le modèle économique d'ArcaScience contribue également à renforcer les barrières à l'entrée. La plateforme est déployée directement chez les clients en mode SaaS et intégrée dans leurs processus internes d'évaluation des candidats médicaments. Une fois la solution installée, les entreprises disposent d'une licence leur permettant d'analyser de nouvelles molécules dans leurs pipelines de développement. Dans ce contexte, le coût organisationnel et financier d'un changement de solution devient significatif. Tant que les exigences réglementaires associées aux analyses bénéfice-risque restent stables, les laboratoires ont peu d'incitation à adopter une solution concurrente nécessitant un nouvel investissement et une réintégration dans leurs workflows internes. Cette dynamique favorise l'installation de relations contractuelles durables entre ArcaScience et ses clients.
- **Barrière liée à la propriété intellectuelle :** Enfin, ArcaScience met en place une stratégie de propriété intellectuelle visant à protéger certaines briques technologiques développées dans le cadre du projet. Les innovations méthodologiques associées aux modules Trial Balancer et BR-Predict font l'objet de dépôts de brevets couvrant notamment certaines approches de structuration et d'analyse des données biomédicales. Si la protection d'un logiciel dans son ensemble reste limitée, ces dépôts permettent de sécuriser plusieurs innovations clés et de limiter la reproduction directe de certaines méthodes par des concurrents. Cette stratégie de protection vient ainsi compléter les autres barrières technologiques et commerciales développées par l'entreprise.

ArcaScience sera en mesure d'ancrer un positionnement différenciant et défendable, limitant significativement la capacité d'acteurs généralistes à pénétrer ce segment sans investissements lourds et réorientation stratégique majeure.

Enfin, ArcaScience est la solution la plus avancée pour développer ce module répondant parfaitement aux besoins des entreprises pharmaceutiques. Les analyses manuelles sont longues, coûteuses et pas assez exhaustives ni avancées technologiquement. Les solutions d'aides à la prise de décisions de développement ne couvrent que certains aspects encore trop ciblés de tous les éléments nécessaires à prendre en compte pour établir un choix de développement éclairé.

2. OBJECTIFS ET CONTEXTE TECHNICO-ECONOMIQUE

2.1. RÉSUMÉ DU PROJET

Aujourd'hui, ArcaScience développe une plateforme d'IA dédiée à l'analyse bénéfice-risque des médicaments. Cette solution agrège et structure un large volume de données scientifiques, cliniques et

biomédicales afin de produire des analyses comparatives entre un candidat médicament et les traitements de référence.

Ce socle technologique constitue le module actuellement déployé, Trial Balancer, qui permet d'exploiter des données cliniques issues des essais thérapeutiques, des données de référence sur les traitements standards ainsi que des données ontologiques biomédicales. La plateforme structure ces informations afin de produire des évaluations comparatives du profil bénéfice-risque d'un candidat médicament et de générer des analyses exploitables par les équipes cliniques et réglementaires. L'architecture développée permet également de mettre à jour ces analyses lorsque de nouvelles données deviennent disponibles.

Le programme i-Démo BR-Predict vise à exploiter cette architecture existante afin de développer un nouveau module capable de produire des analyses bénéfice-risque prédictives dès les phases précoces du développement des médicaments. Ce module étendra les capacités actuelles de la plateforme en intégrant de nouvelles typologies de données, notamment des données moléculaires, précliniques, génomiques et de vie réelle.

Ces données seront utilisées pour modéliser les relations entre mécanisme d'action, profils biologiques, réponse clinique et événements indésirables. Le projet prévoit ainsi le développement de nouveaux modèles d'intelligence artificielle capables d'exploiter ces données multimodales afin d'identifier des signaux prédictifs du profil bénéfice-risque d'un candidat médicament avant son entrée en clinique.

À l'issue du programme i-Démo, la plateforme ArcaScience disposera ainsi d'un module BR-Predict capable de produire des analyses bénéfice-risque prédictives en amont des premières phases cliniques. Le programme permettra également de développer un démonstrateur appliqué au cancer du poumon non à petites cellules, afin de valider la capacité du module à exploiter ces nouvelles données et à produire des évaluations prédictives dans un contexte thérapeutique réel.

BR-Predict est le seul projet français, et à la connaissance d'Arcasience européen, visant à créer une plateforme souveraine d'intelligence artificielle pour l'évaluation prédictive du rapport bénéfice-risque des médicaments. Ce segment stratégique de 13,2 milliards de dollars est aujourd'hui intégralement dominé par des acteurs américains et britanniques. En s'appuyant sur 24 modèles de langage propriétaires déployés on-premise, sur une base de connaissances de 100 milliards de points de données, et sur des partenariats structurants avec Sanofi, INRIA et l'ICM, ArcaScience est en position de combler une lacune critique de souveraineté sanitaire et technologique en Europe. Le financement de BR-Predict dans le cadre du programme France 2030 / i-Démo permettrait à la France de positionner un champion national sur ce marché en pleine structuration, avant que la fenêtre d'opportunité ne se referme au profit des acteurs anglo-saxons.

Le projet BR-Predict répond directement à deux des dix objectifs du plan d'investissement France 2030 (54 milliards d'euros), ainsi qu'aux critères spécifiques du programme i-Démo de BPI France.

Pour l'Objectif 3 - « Produire en France au moins 20 biomédicaments, notamment contre les cancers et les maladies chroniques », BR-Predict contribue à cet objectif en accélérant la sélection et la priorisation des candidats médicaments :

- Réduit le taux d'attrition en phases cliniques (aujourd'hui 92 % entre la phase préclinique et la mise sur le marché) en fournissant une évaluation prédictive dès la phase de criblage ;
- Accélère les délais de développement de 30 à 50 % sur les phases amont ;
- Renforce la compétitivité des laboratoires pharmaceutiques français (Sanofi, Servier, Ipsen, Pierre Fabre) en leur donnant accès à un outil d'aide à la décision souverain.

Concernant l'Objectif 4 - « Sécuriser la maîtrise des technologies numériques souveraines », BR-Predict incarne la souveraineté numérique appliquée à la santé :

- 24 modèles de langage propriétaires développés en France : aucune dépendance aux LLMs américains (OpenAI, Anthropic, Google) ;
- Déploiement exclusivement on-premise chez les clients, garantissant que les données sensibles de R&D ne quittent jamais le périmètre souverain ;
- Architecture technique maîtrisée de bout en bout, sans brique logicielle critique contrôlée par un acteur extra-européen.

Critère i-Démo		Réponse BR-Predict
Innovation de rupture	de	Première plateforme intégrant 6 couches prédictives multi-sources pour le B-R médicamenteux
Maturité technologique		TRL 4 (Trial Balancer validé en conditions réelles) → TRL 7 visé
Potentiel de marché		13,2 Mds\$ (analyse bénéfice-risque) + 6,38 Mds\$ (drug discovery services)
Capacité d'exécution		Équipe ESSEC/CentraleSupélec/INRIA/ex-Owkin, 9 contrats signés, série A 4,65 M€
Effet structurant		Seul acteur européen, 47 emplois créés, partenariats INRIA/ICM/Sanofi

2.2. AMBITION STRATÉGIQUE DU PROJET

PROBLÉMATIQUE DANS LE SUCCÈS DES ESSAIS CLINIQUES

Le développement clinique d'un médicament représente aujourd'hui l'un des processus industriels les plus longs, les plus capitalistiques et les plus incertains du secteur de la santé. Depuis le début du XXI^e siècle, **l'investissement moyen nécessaire pour conduire un candidat jusqu'à la commercialisation est estimé entre 1 et 2 milliards de dollars. La durée moyenne des essais cliniques atteint désormais près de 7,3 ans par molécule³.**

Malgré ce niveau d'engagement financier et humain considérable, la performance globale demeure faible. En pratique, **moins de 10 % des molécules entrant en développement atteignent effectivement le marché⁴.** Ce décalage entre l'intensité des investissements et le taux de succès constitue un enjeu industriel majeur.

L'analyse des causes d'échec met en évidence un point central. Entre **40 et 54 % des échecs** sont attribués à un **manque d'efficacité démontrée**, tandis que **17 à 30 %** sont liés à des **problèmes de toxicité⁵**. Autrement dit, dans près de deux tiers des cas, l'échec ne résulte pas d'un défaut d'exécution opérationnelle de l'essai, mais d'une inadéquation scientifique entre le mécanisme d'action du candidat, la population ciblée et l'effet clinique réellement observé.

³ Jörg J. Möhrle, 2024

⁴ Thomas et al., 2016 ; Pfizer France ; Sun et al., 2022

⁵ Patsnap, 2023 ; Fogel, 2018 ; Sun et al., 2022

En outre, l'industrie pharmaceutique s'oriente de plus en plus vers l'exploration de nouveaux mécanismes d'action, délaissant les cibles biologiques bien documentées au profit de territoires thérapeutiques moins balisés⁶. Cette évolution n'est pas anodine sur le plan du risque : **les médicaments first-in-class affichent un taux de succès clinique d'environ 5%, contre 8% pour les molécules s'appuyant sur des cibles déjà validées**⁷. À mesure que les programmes s'aventurent dans des indications nouvelles, la difficulté de valider des cibles inédites s'accroît mécaniquement⁸.

À ces abandons s'ajoute une instabilité significative des protocoles. En moyenne, deux à trois amendements sont réalisés par protocole en phase avancée dont **45 % sont évitables**. Ces modifications interviennent souvent en réaction à l'apparition de nouvelles informations de sécurité, à des demandes de modification stratégique, à une mauvaise conception initiale du protocole ou à des difficultés de recrutement. Cette instabilité se traduit par des retards importants : **près de 85 % des dossiers accusent des délais supplémentaires**, associés à des **surcoûts évitables** estimés en moyenne à **535 000 dollars** par dossier⁹.

Les améliorations méthodologiques récentes, designs adaptatifs, enrichissement de population, meilleure sélection des patients n'ont pas permis d'améliorer de manière significative les taux de réussites des essais cliniques

L'ANALYSE BÉNÉFICE RISQUE COMME UNE SOLUTION VIABLE

Dans ce contexte, l'enjeu n'est pas seulement d'optimiser l'exécution des essais cliniques, mais d'améliorer la capacité à anticiper le profil bénéfice/risque des candidats médicaments en amont des essais. Cette anticipation inclut également le choix des populations cibles, qui conditionne la capacité à démontrer un bénéfice thérapeutique et à construire un profil bénéfice/risque robuste.

Une analyse bénéfice/risque structurée et réalisée précocement permettrait d'orienter les décisions de développement : identifier les candidats insuffisamment différenciés, détecter plus tôt certains risques mécanistiques, ajuster le design clinique et cibler les populations les plus susceptibles de répondre au traitement. Elle constitue ainsi un levier pour réduire les abandons tardifs, l'optimiser l'allocation des ressources en R&D et pour réduire les risques pris par les volontaires sains participants. Concrètement, une analyse bénéfice-risque réalisée en amont du développement clinique agit sur trois leviers décisionnels. Premièrement, elle permet de qualifier le positionnement thérapeutique du candidat par rapport aux traitements existants dès la phase préclinique, en s'appuyant sur des données de structure moléculaire, de mécanisme d'action et de profils ADMET prédits, avant tout investissement clinique. Deuxièmement, elle oriente la sélection de la population cible en identifiant les sous-groupes de patients pour lesquels le rapport bénéfice-risque est le plus favorable, ce qui réduit le risque d'échec lié à un positionnement thérapeutique inadapté. Troisièmement, elle permet d'anticiper les signaux de toxicité potentiels grâce à l'exploitation des données de pharmacovigilance existantes sur des molécules analogues, à MoA similaires ou partiellement assimilables, limitant l'exposition de patients à des profils de risque évitables. Ces trois mécanismes réduisent directement la probabilité d'échec en phase II et III sans nécessiter de données propres à la molécule candidate, ce qui constitue la rupture technologique centrale du module BR-Predict.

Aujourd'hui, l'analyse bénéfice/risque occupe une place centrale dans l'évaluation réglementaire des médicaments et dans les dossiers d'autorisation de mise sur le marché. Toutefois, dans la pratique industrielle, elle est encore principalement utilisée a posteriori, pour consolider les données générées au cours du développement et justifier le profil bénéfice/risque d'un actif. Son potentiel comme outil d'aide à la décision en amont du développement reste donc largement sous-exploité.

⁶ Zhou et al., 2025

⁷ Pharma's Almanac, 2024

⁸ Norstella, 2024

⁹ Intuition Labs ; Getz et al., 2016

L'analyse bénéfice/risque actuelle ne constitue pas un outil prédictif intégré permettant de modéliser différents scénarios de développement, d'anticiper la probabilité de succès clinique ou d'évaluer quantitativement la robustesse d'un positionnement thérapeutique face aux traitements sur le marché.

LIMITES ACTUELLES DU PROCESSUS D'UTILISATION DE L'ANALYSE BÉNÉFICE-RISQUE POUR L'AIDE AU DÉVELOPPEMENT DE MÉDICAMENTS

Si l'analyse bénéfice/risque apparaît comme un levier stratégique évident pour améliorer le succès des essais cliniques, sa mise en œuvre en amont du développement se heurte aujourd'hui à des contraintes technologiques majeures.

En pratique, une évaluation complète du profil bénéfice/risque nécessite près d'un an de travail pour une seule molécule. Ce délai est incompatible avec les rythmes décisionnels des phases précoces, où les arbitrages doivent être réalisés rapidement pour sélectionner, prioriser ou arrêter des candidats. Dans sa pratique actuelle l'analyse est effectuée en aval, dans une logique réglementaire, mais pas dans une logique dynamique d'aide à la décision. Cette lourdeur opérationnelle s'explique par :

- Les analyses bénéfice-risque reposent fortement sur le travail d'experts cliniques, réglementaires et en pharmacovigilance. Une analyse complète mobilise plusieurs profils spécialisés pendant une longue période et représente en moyenne près de 18 mois de travail pour une seule molécule.
- Une grande partie des données exploitées provient de sources non structurées (publications scientifiques, rapports d'essais cliniques, documents réglementaires). Leur exploitation repose encore largement sur des processus manuels de lecture, d'extraction et de consolidation.
- Le volume de données biomédicales continue d'augmenter rapidement et se répartit entre données précliniques, essais cliniques, littérature scientifique, bases de pharmacovigilance, données génomiques et données de vie réelle. Avec un volume aussi important et en croissance constante, il devient impossible d'exploiter l'ensemble des données disponibles de manière exhaustive.
- Le développement pharmaceutique s'oriente par ailleurs vers de nouveaux mécanismes d'action pour lesquels les données historiques sont limitées, ce qui réduit la capacité des approches actuelles à anticiper de manière fiable les profils d'efficacité et de sécurité.
- Cette combinaison de complexité technique et d'intensité humaine se traduit par un coût élevé. Le coût estimé d'une analyse complète avoisine 1,2 million d'euros par molécule, ce qui rend impossible son utilisation systématique sur des portefeuilles larges de candidats en phase précoce.

LES BESOINS DE L'ANALYSE BÉNÉFICE-RISQUE

Au regard des contraintes techniques et opérationnelles de l'utilisation des analyses bénéfice-risque dans un contexte de développement de candidats médicament, plusieurs besoins sont mis en évidence :

- Le premier besoin concerne la **précision des analyses**. Les industriels doivent pouvoir mieux orienter leurs décisions sur les actifs à développer, prioriser ou repositionner dans le schéma de prise en charge. Il s'agit d'évaluer plus finement la cohérence entre le mécanisme d'action, l'efficacité attendue et les risques, tout en comparant les résultats de l'actif analysé aux thérapies déjà sur le marché.
- Le second besoin concerne la capacité à **étendre ces analyses à des mécanismes d'action de plus en plus variés et complexes**. Les nouveaux candidats médicaments reposent sur des approches biologiques et thérapeutiques diversifiées, ce qui nécessite d'intégrer et d'exploiter des volumes

importants de données hétérogènes. Les données pertinentes sont nombreuses, distribuées et de nature très différente. Les industriels ont donc besoin d'outils capables de structurer, annoter et croiser ces jeux de données afin de produire des analyses cohérentes et adaptées à ces nouveaux mécanismes thérapeutiques.

- Un troisième besoin concerne la **réduction des délais et des coûts d'analyse**. Les processus actuels sont longs et coûteux. Pour être réellement décisionnelle, l'analyse bénéfice/risque doit devenir plus rapide, standardisée et industrialisable.

Ces besoins convergent vers une même exigence : rendre l'analyse bénéfices-risques plus précise et capable d'intégrer un périmètre de données plus large. À terme, ces améliorations permettront de faire évoluer ces analyses vers une approche prédictive.

LE FONCTIONNEMENT DE LA PLATEFORME ARCASCIENCE

La plateforme ArcaScience se met en route lorsque qu'une requête est émise par l'utilisateur. Une requête déclenche une recherche parmi les documents indexés dans Elasticsearch, qui repose sur un système hybride combinant recherche par mots-clés (BM25), recherche vectorielle et expansion de requêtes via des ontologies reconnues (MedDRA, ATC, SNOMED-CT). Un LLM d'appraisal évalue ensuite la pertinence de chaque document retrouvé par rapport à la question posée. Lorsque l'évaluation du corpus révèle des lacunes (comparateurs manquants, critères non couverts), le système relance automatiquement une recherche ciblée.

Les documents retenus, accompagnés de métadonnées pour chacun, sont déjà traités par 24 modèles d'intelligence artificielle propriétaires de type SLM (Small Language Models), incluant des modèles NER, de classification et d'extraction de relations, couplés à une normalisation par ontologies pour l'harmonisation et le codage des entités (Pre-indexation). Chacun de ces modèles est entraîné pour une problématique spécifique de l'analyse bénéfice/risque, telle que la caractérisation des patients, des modalités de traitement, des caractéristiques de risque, des critères d'évaluation, des caractéristiques des effets bénéfiques, ou encore la caractérisation des pathologies.

Le résultat de cette requête est une base de données structurée et harmonisée couvrant l'indication d'intérêt, le candidat médicament, ainsi qu'un nombre exhaustif de traitements testés ou utilisés dans cette indication. L'ajout de nouvelles données clients (hors pipeline habituel) implique une indexation à la demande de ces données par nos modèles propriétaires, mais sur le serveur du client lui-même, ce qui limite la fuite de données sensibles. Ces résultats sont ensuite ajoutés à la base de données déjà décrite.

Ces informations sont ensuite mises à disposition de l'utilisateur via une plateforme qui structure, pour la première fois, le processus complet d'analyse bénéfice/risque en respectant l'un des frameworks les plus couramment utilisés dans le domaine (Benefit-Risk Action Team) ainsi que les exigences réglementaires en vigueur.

Les fonctionnalités de la plateforme incluent la disposition des informations en relation avec la pathologie et les options thérapeutiques disponibles, la sélection intelligente des critères d'évaluation et des risques à atténuer, l'évaluation et la comparaison des points de critères et des risques pour le benchmark thérapeutique, ainsi que l'évaluation des points d'incertitude. Elle permet également la génération de visualisations de données spécifiques à l'analyse bénéfice-risque, comme le Benefit-Risk Tree, les forest plots et les tableaux comparatifs, l'introduction d'un système de pondération intégrant la voix des patients et d'autres considérations, la réalisation de calculs biostatistiques, ainsi que la génération de documents à usage interne ou réglementaire.

La plateforme délivre ainsi à l'utilisateur un outil d'aide à la décision couvrant plusieurs dimensions clés : la compréhension de la population cible et de son unmet need, le choix du comparateur, la sélection de

l'ensemble des critères du protocole clinique, un outil de caractérisation des bénéfices et des risques sans limitation du nombre de comparateurs ni de critères d'évaluation, ainsi qu'un outil de génération de documents directement utilisables auprès des autorités réglementaires (BRAD, PBRER, eCTD) en utilisant des modèles LLM.

Au niveau des performances et de la maintenance de ces modèles, ceux-ci subissent une réévaluation tous les 3 à 6 mois (selon le niveau de criticité du modèle). Ce rythme de réévaluation tient compte du fait que l'intégration continue de nouvelles données peut induire un data drift progressif, susceptible de dégrader silencieusement les performances. Un réentraînement est déclenché lorsque les résultats des évaluations révèlent une dégradation significative (hausse du micro-F1 de +5 à 10 %). En général, les modèles SLM utilisés obtiennent un F1 compris entre 80 % et 95 %, selon le modèle. Le modèle d'appraisal montre une précision entre 80 % et 95 %, qui dépend de la complexité de la question d'intérêt ainsi que de la complexité du sujet.

Ce qui différencie la plateforme au niveau technique, c'est que les traitements d'extraction et de structuration reposent sur des SLM propriétaires, entraînés pour des tâches spécifiques, dont ArcaScience maîtrise la performance, garantissant reproductibilité, traçabilité et fiabilité. Les LLM interviennent uniquement pour le raisonnement métier (appraisal de pertinence) et la génération de résumés, où le risque d'hallucination est encadré par le système de RAG : chaque sortie s'appuie sur des extraits sourcés et des documents vérifiables.

L'actualisation continue des données dans la plateforme constitue également un point différenciant, notamment par rapport au travail manuel et aux approches impliquant des CRO. Dès le lancement du projet, nos technologies ajoutent de nouvelles informations dans la base de données associée au projet et notifient l'utilisateur de manière continue si ces informations nécessitent son attention.

De plus, ce qui distingue la plateforme, c'est qu'elle a été conçue avec des experts en développement clinique, en pharmacovigilance et en affaires réglementaires, ce qui la rend capable de répondre aux « pain points » de chacun tout en restant alignée avec les normes du métier.

Aujourd'hui, la plateforme est principalement utilisée dans une logique réglementaire et comparative. Toutefois, elle répond déjà aux principaux besoins techniques et opérationnels nécessaires à une analyse prédictive : exploitation harmonisée de données massives et hétérogènes, vision systémique du profil bénéfice/risque et capacité d'industrialisation à grande échelle.

Elle constitue ainsi la base technologique naturelle pour évoluer vers une analyse bénéfice/risque prédictive en amont du développement clinique, objectif central du projet BR-Predict.

1.1.1. PROPOSITION DE VALEUR

La plateforme ArcaScience a été conçue précisément pour répondre aux points de friction évoqués.


Pain point industriel identifié	Bénéfice apporté par la solution ArcaScience
Temps d'analyse long (jusqu'à 18 mois)	Quelques semaines, permettant une intégration dans les cycles décisionnels précoces
Coût élevé d'une analyse complète (~1,2 M€ via CRO)	Réduction drastique des coûts (environ 125 k€), rendant l'analyse scalable sur un portefeuille large de candidats
Données massives non exploitées, hétérogènes et majoritairement non structurées	- Intégration de jeux de données 10 à 100 fois plus volumineux que les approches traditionnelles. - Architecture data unifiée permettant ingestion multi-source, structuration automatisée et harmonisation clinique.¹⁰

	Comparaisons illimitées avec les traitements testés ou commercialisés pour identifier la différenciation et le positionnement optimal du candidat.
Processus non structuré, dépendant de plusieurs acteurs et plusieurs livrables	Une plateforme unique où tous les acteurs sont connectés, travaillent sur des livrables communes dans un framework structuré, garantissant qu'aucune information n'est oubliée ou perdue.
Pas de mise à jour continue du projet et système de notifications	Une plateforme qui intègre de manière continue les données pertinentes et les ajoute à la base de données du projet, sans ajout manuel, sans temps de latence et sans traitement tardif des informations.

La solution ArcaScience ne constitue pas une simple optimisation incrémentale des pratiques existantes. Elle modifie la nature même de l'analyse bénéfice/risque en la rendant plus rapide, plus exhaustive, plus structurée et économiquement scalable.

2.3. AMBITION TECHNOLOGIQUE

WORKFLOW DE LA PLATEFORME ARCASCIENCE



La plateforme ArcaScience repose sur un workflow structuré en cinq étapes successives, permettant de transformer des données hétérogènes et massives en une analyse bénéfice/risque exploitable.

10rois modalités de données sont intégrées par ArcaScience que les approches manuelles ou CRO traditionnelles n'exploitent pas systématiquement. Les données de pharmacovigilance en vie réelle (FAERS, base EudraVigilance) permettent de détecter des signaux de risque post-commercialisation sur des molécules analogues, inaccessibles lors d'une analyse fondée uniquement sur les essais cliniques. Les données génomiques et de biomarqueurs (variants, profils d'expression) permettent d'anticiper la réponse thérapeutique dans des sous-populations spécifiques, une dimension absente des analyses réglementaires classiques. Enfin, les données précliniques structurées issues des bases publiques (BindingDB, ToxCast, DrugCentral) permettent d'inférer des profils ADMET et des propriétés de sécurité avant toute donnée clinique sur la molécule candidate.

1. Récupération des données

La première étape repose sur l'alimentation de la base de données. Cette dernière agrège et structure plusieurs sources, incluant des publications scientifiques (PubMed, Medline), des registres d'essais cliniques (ClinicalTrials.gov), des bases biomédicales publiques, des données partenaires hospitaliers et privés, ainsi que des bases de données d'ontologies médicales.

ArcaScience stocke cette masse importante de données dans un **data lake** afin de permettre un stockage efficace, la sécurité des données et une récupération rapide des sources brutes.

L'objectif de cette étape est de créer une base de données exhaustive sur laquelle nos traitements IA seront appliqués.

2. Harmonisation et structuration des données

La seconde étape repose sur un **Framework IA** constitué de 12 **SLMs** de structuration qui constituent la fondation du système.

Ces modèles traitent les documents bruts (PDF, XML, rapports d'essais, publications) afin de transformer des données majoritairement non structurées en un format standardisé, normalisé et exploitable.

Cette phase comprend :

- La conversion des documents,
- L'annotation sémantique,
- L'identification des concepts et ontologies,
- L'agrégation inter-sources,
- La suppression des doublons.

La deuxième couche de traitement sémantique correspond à des SLM Contextualisant, au nombre de 12. Elle exploite notamment des modèles (liste non-exhaustive) comme :

- **Arca Efficacy**, dédié à l'extraction automatisée des caractères d'efficacité (temps jusqu'à l'effet, importance de l'effet, odds ratios, etc.) ;
- **Arca PV**, focalisé sur l'identification et la caractérisation des risques ainsi que des informations de toxicité (gravité, grade, délai avant survenue, etc.) ;
- **Arca Patient Profile**, structurant les caractéristiques démographiques et cliniques des cohortes afin de permettre une analyse stratifiée et contextualisée.

Les autres modèles incluent des modèles d'extraction, de clustering et de classification des points d'évaluation, des modèles de classification des publications, ainsi que des modèles de caractérisation des modalités de traitement.

Cette étape permet de transformer un corpus documentaire fragmenté en une base de données harmonisée et interopérable, regroupant **100 milliards** de points de données issus de sources hétérogènes.

3. Stockage, indexation et recherche sémantique

Les données structurées sont ensuite stockées dans une architecture centralisée (ElasticSearch). Les documents sont également convertis en **embeddings vectoriels**, permettant une recherche sémantique rapide et précise. Cette capacité d'indexation constitue un levier clé pour explorer des volumes

documentaires massifs et effectuer des requêtes complexes grâce à un système hybride combinant recherche par mots-clés (BM25), recherche vectorielle et expansion de requêtes via des ontologies reconnues (MedDRA, ATC, SNOMED-CT...).

L'infrastructure technique repose sur une **stack DevOps** industrialisée : Docker pour la containerisation, Kubernetes pour l'orchestration, Ansible pour l'automatisation des déploiements. La sécurité est assurée par des protocoles de chiffrement avancés (AES 256-bit), le respect de standards industriels comme HIPAA, et un monitoring continu via Prometheus et Grafana. La gestion de version et la qualité logicielle sont pilotées par GitLab et SonarQube.

4. Mise à jour continue des connaissances

La plateforme intègre un mécanisme de veille automatisée. Les nouveaux contenus scientifiques sont détectés automatiquement, analysés et intégrés dans la base. Les modèles mettent à jour les signaux d'efficacité et de risque en continu, assurant une actualisation dynamique du référentiel.

Cette fonctionnalité est particulièrement structurante pour une plateforme SaaS. Une fois installée chez le client et correctement mise en place, celle-ci peut générer un rapport bénéfice-risque d'une année à l'autre sans devoir retravailler la solution.

5. Analyse étendue et construction du profil bénéfice/risque

La dernière étape mobilise l'ensemble du framework "Ensemble Model".

Les données harmonisées sont exploitées pour :

- Analyser le contexte thérapeutique,
- Examiner les critères d'évaluation (endpoints),
- Contextualiser les résultats au regard des autres traitements.
- Évaluer les risques potentiels ou identifiés,
- Caractériser les effets bénéfiques d'intérêt

La plateforme qui reçoit ces informations propose des fonctionnalités de visualisation des données, de synthèse et de filtrage, ce qui permet la production d'une analyse bénéfice/risque complète, comparative et traçable.

Le workflow technologique d'ArcaScience permet aujourd'hui de transformer un volume massif de données biomédicales hétérogènes en une analyse bénéfice/risque structurée, comparative et traçable, dans des délais et à des coûts compatibles avec un usage industriel.

DONNÉES ANTÉRIEURES

État de l'art des performances des solutions existantes

À notre connaissance, aucun travail n'a à ce jour visé une prédiction multimodale et intégrée du rapport bénéfice/risque des médicaments. Les travaux existants, menés principalement par des entités académiques dans une visée exploratoire, se limitent chacun à une seule modalité de données et ont été conçus pour une pathologie ou aire thérapeutique spécifique.

Concernant la prédiction par structure chimique, les modèles de pointe (DNN, Random Forest, GNN) offrent de bonnes performances pour les molécules proches du jeu d'entraînement, mais leur précision diminue sur des structures chimiquement dissemblables ¹¹. Les performances rapportées dans la

11 Soares TA, Nunes-Alves A, Mazzolari A, Ruggiu F, Wei GW, Merz K. The (Re)-Evolution of Quantitative Structure–Activity Relationship (QSAR) Studies Propelled by the Surge of Machine Learning Methods. *J Chem Inf Model*. 2022;62(22):5317–5320. doi:10.1021/acs.jcim.2c01422

littérature restent ainsi contextuelles : QSAR pour l'activité FGFR-1 avec $R^2 = 0,74$ en test¹², et modèle QSAR hybride classique-quantique avec une précision de 88 % et un F1-score de 82 %¹³.

À partir des données précliniques, les modèles hybrides ML et mécanistiques pour la prédiction pharmacocinétique in vivo atteignent 64 % de prédictions dans une marge d'erreur $\times 2$ pour la clairance et 62 % pour le volume de distribution¹⁴, reflétant la difficulté de la transposition animal-humain.

L'intégration de données génétiques et multi-omiques humaines constitue l'avancée la plus récente. UGenome (2025) revendique jusqu'à 99 % de précision pour la prédiction des réponses thérapeutiques via données multi-omiques, validés par comparaison aux essais cliniques et recommandations réglementaires¹⁵. Park et al. (2023) confirment la robustesse de modèles ML/DL pour prédire la réponse (InIC50) dans divers cancers, mais avec des résultats spécifiques à chaque traitement et contexte cellulaire¹⁶. Miranda et al. (2021) intègrent polymorphismes et variables cliniques pour prédire réponse et effets indésirables au tamoxifène, avec des performances encourageantes mais dans un contexte très ciblé¹⁷.

Enfin, les modèles entraînés sur données de vie réelle (RWE) atteignent généralement des AUC $> 0,8$ et des précisions d'environ 80 %¹⁸, comme les modèles Random Forest en cardiologie (AUC $\approx 0,85$) ou les SVM en oncologie (accuracy ≈ 83 %)¹⁹.

L'ensemble de ces approches partagent une limite commune : un périmètre applicatif étroit, limité à une aire thérapeutique précise, sans vision transversale du rapport bénéfice/risque à l'échelle du développement médicamenteux.

Résultats d'ArcaScience

Entre 2018 et 2021, les premiers modèles d'IA ont été développés pour classer les sujets liés aux bénéfices et aux risques, puis pour détecter les modalités de traitement et les caractéristiques patients via des briques NLP spécialisées. Cette phase a permis de poser les bases méthodologiques de structuration de données biomédicales non structurées.

À partir de 2023, les développements se sont accélérés avec :

12 Nagare SD, Desai SA, Patel VP, Sapkal S, More M, Kate A, Shahiwala AF, Varma T, Garg P. Developing a predictive QSAR model for FGFR-1 inhibitors: integrating computational and experimental validation. *J Comput Aided Mol Des*. 2025;39(1):89. doi:10.1007/s10822-025-00671-8

13 Hangun B, Altun O, Eyecioglu O. A Hybrid Classical-Quantum Model for QSAR-Based Biodegradability Prediction. In: *2025 IEEE High Performance Extreme Computing Conference (HPEC)*; 2025. p. 1–6. IEEE.

14 Jia X, Teutonico D, Dhakal S, Psarellis YM, Abos A, Zhu H, Mavroudis PD, Pillai N. Application of Machine Learning and Mechanistic Modeling to Predict Intravenous Pharmacokinetic Profiles in Humans. *J Med Chem*. 2025;68(7):7737–7750. doi:10.1021/acs.jmedchem.5c00340

15 UGenome. Predictive pharmacogenomics platform: AI-driven multiomics models for therapeutic response prediction [Internet]. 2025 [cité le 16 mars 2026]. Disponible sur : <https://ugenome.io/et-predictive-pharmacogenomics/>

16 Park A, Lee Y, Nam S. A performance evaluation of drug response prediction models for individual drugs. *Sci Rep*. 2023;13(1):11911. doi:10.1038/s41598-023-39179-2

17 Miranda C, Galleguillos M, Torres R, et al. Preliminary pharmacogenomic-based predictive models of tamoxifen response in hormone-dependent Chilean breast cancer patients. *Front Pharmacol*. 2021;12:661443. doi:10.3389/fphar.2021.661443

18 Fitzke H, et al. Real-world evidence: state-of-the-art and future perspectives. *J Comp Eff Res*. 2025;14(3):e240130. doi:10.57264/cer-2024-0130

19 Alhumaidi NH, Dermawan D, Kamaruzaman HF, Alotaiq N. The use of machine learning for analyzing real-world data in disease prediction and management: systematic review. *JMIR Med Inform*. 2025;13:e68898. doi:10.2196/68898

- La création de modèles dédiés à l'extraction des endpoints,
- Le clustering des publications,
- L'identification des risques (grading, sévérité, temporalité),
- Le développement d'algorithmes de génération automatique de rapports.

En 2024, les modèles d'extraction de relations ont permis d'identifier les liens entre biomarqueurs, mécanismes d'action et pathologies spécifiques, et ont démontré leur capacité à améliorer les performances des modèles existants, notamment ceux d'extraction de bénéfices et de risques, lorsqu'ils y étaient couplés. C'est lors de cette année que le partenariat avec Sanofi a débuté.

En 2025 la plateforme a atteint le niveau d'architecture présenté précédemment. Un cas d'usage structurant a été conduit avec Sanofi avec les données de phase 2 clinique d'un médicament biologique comparé à un actif déjà commercialisé avec des données cliniques et RWD disponibles, dans une pathologie dermatologique inflammatoire.

Les modèles spécialisés ont alors réalisé une analyse bénéfices/risques à partir des résultats cliniques et des données agrégées. Les résultats ont été évalués selon des métriques standardisées (F1-score et taux de couverture des données) et comparé avec la méthode actuelle de Sanofi :

Extraction de biomarqueurs	
Validation avec un Golden standard : F1	90.05%
Validation externe (Disgenet) : taux de couverture des données	92% pour top 30 biomarqueurs
Extraction des Risques	
Validation avec un Golden standard : F1	88.1%
Validation externe (Sanofi) : taux de couverture des données	96%
Extraction des bénéfices	
Validation avec un Golden standard : F1	92%
Validation externe (Sanofi) : taux de couverture des données	97%

Ces résultats confirment la robustesse des briques d'extraction et la capacité de la plateforme à structurer des données biomédicales complexes provenant de plus de 25 000 publications avec un haut niveau de précision. De plus, les étapes respectent les exigences des frameworks BRAT et FDA pour la conception de l'analyse bénéfice-risque.

Cette analyse a permis de réaliser en deux mois l'équivalent de près de 18 mois de travail. De plus, l'analyse produite par la solution ArcaScience a mis en lumière certains risques, ce qui a conduit à un ajustement du protocole de phase 3 du médicament analysé.

Les résultats ont ensuite été comparés aux travaux internes réalisés par Sanofi lors de la conception de la phase 1, afin de vérifier si les outputs de la pipeline d'ArcaScience étaient comparables à ceux produits par l'équipe en amont :

Extraction des Risques potentiels	
Nombre de risques à considérer identifiés jamais documentés	5
Validation externe (Sanofi) : taux de couverture des données	72.1%
Extraction des bénéfices potentiels	
Validation externe (Sanofi) : taux de couverture des données	40%

Finalement, la solution a montré une capacité prédictive limitée dans ce contexte spécifique. Toutefois, celle-ci n'ayant pas été initialement conçue pour réaliser ce type d'analyse prospective, les résultats obtenus, bien que partiels, mettent en évidence un potentiel particulièrement élevé.

C'est finalement grâce à cette démonstration que les membres de l'équipe d'ArcaScience ont pu mettre en place un programme de développement visant à renforcer cette capacité innovante de la plateforme. Cette innovation sera portée par le programme i-Démo.

Ainsi la plateforme maîtrise aujourd'hui :

- L'agrégation multi-sources (publications scientifiques, essais cliniques, bases réglementaires),
- L'harmonisation des données cliniques,
- L'extraction structurée des signaux d'efficacité et de sécurité,
- La comparaison au standard of care,
- La production d'analyses bénéfice-risque traçables et explicables.

Le module **BR-Predict** s'inscrit donc dans une logique **d'extension d'une architecture déjà éprouvée**. Il réutilise les briques validées et vise à intégrer de manière systémique de nouvelles catégories de données :

- Données de structures moléculaires et d'interaction cible,
- Données toxicologiques et pharmacodynamiques précliniques,
- Informations sur les polymorphismes génétiques et biomarqueurs,
- Données de vie réelle.

Ce nouveau module intégrera l'entièreté de ces nouvelles données dans un **World Model** simplifiant l'utilisation de la solution et assurant la qualité des livrables produits. L'objectif est de **transformer une analyse enrichie descriptive en une capacité véritablement prédictive du profil bénéfice/risque**.

VERROU LIÉ À L'INTÉGRATION DU NOUVEAU MODULE BR-PREDICT

- **Verrou technologique n°1 : accès et disponibilité des données**

Le premier verrou concerne l'accès structuré et exploitable aux différentes catégories de données nécessaires au modèle prédictif. Certaines données moléculaires et précliniques sont fragmentées. Les données génétiques et de vie réelle peuvent être soumises à des contraintes d'accès, de format ou de conformité réglementaire.

La stratégie d'ArcaScience repose sur l'exploitation prioritaire de données publiques et privées structurées et non structurées, la mobilisation de partenariats data existants et une architecture permettant l'intégration directe des données clients sur leur infrastructure, garantissant conformité et souveraineté. Plus en détail, ArcaScience intègre dans sa roadmap la qualification de plusieurs bases de données publiques couvrant l'ensemble des types de données mobilisés : chimie et bioactivité (ChEMBL, ToxCast, NCGC qHTS), génomique et réponse thérapeutique (PharmGKB, ClinVar, COSMIC, OncoKB, cBioPortal), ainsi que variants génétiques des enzymes de métabolisation et des cibles thérapeutiques (UniProt, gnomAD, dbSNP, ClinGen, CPIC). Ces sources publiques sont complétées par des partenariats existants et à venir avec des fournisseurs de données propriétaires, notamment pour les volets précliniques et cliniques.

- **Verrou technologique n°2 : traitement et normalisation de données hétérogènes**

Les nouvelles données à intégrer diffèrent en nature, granularité et format. Leur traitement nécessite des pipelines spécialisés et une harmonisation sémantique robuste afin d'éviter les biais et incohérences.

ArcaScience dispose d'un framework de 24 SLM propriétaires déjà opérationnels sur les données cliniques et de pharmacovigilance et validé sur des volumes massifs de données non structurées. Le

programme i-Démo étend ce framework à quatre nouvelles modalités de données, chacune nécessitant une approche algorithmique dédiée.

- **Données de structure moléculaire** : la plateforme déploiera des architectures Graph Neural Network (GNN) entraînées sur les bases ChEMBL et ToxCast pour prédire les propriétés ADMET et les profils de toxicité à partir de la représentation moléculaire SMILES. Ces modèles s'appuient sur des descripteurs RDKit enrichis et des fingerprints Morgan, avec une validation par leave-one-scaffold-out pour garantir la généralisation à de nouvelles structures chimiques.
- **Données précliniques in vivo** : ArcaScience développera des modèles de transfert de transposabilité espèce-vers-humain, entraînés sur des jeux de données croisés BindingDB et DrugCentral. Ces modèles intégreront un score de fiabilité calibré (conformal prediction) permettant de quantifier explicitement l'incertitude de chaque prédiction, un prérequis indispensable pour l'usage décisionnel en contexte réglementaire.
- **Données génomiques et biomarqueurs** : des modèles de type attention-based transformer seront appliqués sur des matrices d'expression génique normalisées (TPM) afin d'identifier les associations variants-réponse thérapeutique. L'harmonisation sémantique entre ontologies (Gene Ontology, HPO, OMIM) sera assurée par des pipelines de normalisation d'entités biomédicales déjà maîtrisés par l'équipe.
- **Données de vie réelle FAERS et EDS** : ArcaScience déploiera des modèles de détection de signal de disproportionnalité (EBGM, PRR) couplés à des modèles de NLP pour l'extraction d'événements indésirables en texte libre, avec une chaîne de dédoublonnage et de normalisation vers MedDRA assurant la cohérence inter-sources.

L'ensemble de ces pipelines alimentera un knowledge graph unifié (WP5) construit sous Neo4j, structurant les relations causales et directionnelles entre structures moléculaires, mécanismes d'action, biomarqueurs et profils de sécurité. Ce graphe constitue la couche sémantique sur laquelle le World Model (WP6) viendra inférer des représentations latentes multimodales intégrant l'ensemble des dimensions du profil bénéfice-risque d'un candidat médicament.

- **Verrou technologique n°3 : orchestration multimodale et cohérence prédictive**

Le défi central réside dans l'analyse conjointe de ces dimensions multiples. L'agrégation directe de modèles indépendants peut générer incohérences, conflits d'interprétation et perte de traçabilité.

Le développement d'un "World Model" permettra d'orchestrer les sorties des modèles spécialisés dans une architecture unifiée. Cette approche vise à construire une représentation causale intégrant mécanisme d'action, profil biologique, données comparatives et signaux cliniques, avec quantification explicite des incertitudes. Appliqué au profil bénéfice-risque d'une molécule candidate, il s'agit de construire un espace latent unifié dans lequel chaque dimension du profil B-R, structurale, préclinique, génomique, clinique et de vie réelle, est représentée de manière cohérente et mutuellement contrainte.

L'architecture proposée apprend la structure interne d'un problème pour simuler des états non observés, inférer des trajectoires causales et raisonner sur des configurations jamais directement rencontrées. Cette capacité de raisonnement contrefactuel est précisément ce qui manque aux approches prédictives classiques en développement pharmaceutique : prédire le profil bénéfice-risque d'un candidat médicament en phase préclinique non pas à partir de ses propres données cliniques, mais à partir d'une représentation interne apprise des relations mécanistiques entre structures moléculaires, profils biologiques et signaux de sécurité observés sur des milliers de composés analogues.

Architecture JEPA et fusion multimodale

ArcaScience structure son World Model autour du paradigme JEPA (Joint Embedding Predictive Architecture), dont le principe est d'apprendre à prédire des représentations abstraites dans un espace

latent partagé plutôt que des observations brutes. Cette propriété est fondamentale pour BR-Predict : un espace latent commun aux cinq modalités du projet permet d'inférer des relations croisées que chaque modalité prise isolément ne peut révéler. L'architecture repose sur un encodeur spécialisé par modalité dont les représentations latentes sont fusionnées par un mécanisme d'attention croisée, analogue à ce que le modèle EVA a récemment démontré pour l'immunologie en combinant transcriptomique multi-espèces et histologie dans un encodeur unique, atteignant l'état de l'art sur plusieurs benchmarks biomédicaux avec des lois d'échelle claires montrant que l'augmentation de la taille du modèle améliore directement les performances sur des tâches aval de développement de médicaments.

La variante causale de cette architecture introduit des interventions au niveau des représentations latentes pour distinguer les relations causales des simples corrélations, une propriété indispensable pour tout usage décisionnel en contexte réglementaire.

Trois verrous technologiques et leur résolution

- Le premier verrou est la cohérence sémantique entre espaces latents hétérogènes. Des données de structure moléculaire (graphes), de génomique (matrices d'expression), de pharmacovigilance (texte) et de données précliniques (séries temporelles) ne partagent naturellement aucune représentation commune. ArcaScience résout ce problème en imposant un espace latent partagé entre encodeurs, une approche dont la validité a été démontrée sur des modalités aussi disparates que le texte, l'image, l'audio et la vidéo dans un espace d'embedding commun sans perte de performance spécifique à chaque modalité. Cette architecture garantit que les inférences du World Model reposent sur une compréhension cohérente de l'ensemble des signaux disponibles, et non sur une simple agrégation de scores indépendants.
- Le deuxième verrou est la cohérence prédictive causale. L'agrégation directe de modèles indépendants produit des incohérences mécanistiques, par exemple des prédictions d'efficacité élevée couplées à une toxicité nulle sur des mécanismes biologiquement liés. ArcaScience résout ce verrou par un cadre de modélisation causale structurelle qui contraint les inférences du World Model à respecter les relations directionnelles encodées dans le Knowledge Graph (WP5). Une prédiction non causalement cohérente serait immédiatement disqualifiée par un évaluateur réglementaire : cette couche causale est donc un prérequis non négociable, et non une amélioration optionnelle.
- Le troisième verrou est l'efficacité computationnelle sur de longs contextes documentaires. Les données d'entrée impliquent des séquences longues : des milliers de publications pour le contexte clinique, des matrices génomiques denses, des historiques précliniques étendus. ArcaScience évalue des architectures alternatives aux transformers classiques, notamment des approches sans mécanisme d'attention qui démontrent de meilleures performances sur les benchmarks de classification de tokens et de retrieval en contexte long, tout en réduisant significativement le coût computationnel à l'inférence. Cette efficacité est un prérequis direct pour un déploiement industriel on-premise chez les clients pharmaceutiques.

Enfin, chaque sortie du World Model est accompagnée d'un intervalle de confiance calibré par conformal prediction, permettant de distinguer les prédictions à haute fiabilité des zones d'incertitude nécessitant une investigation complémentaire. Ce niveau de transparence est un prérequis explicite des guidelines EMA et FDA sur l'usage des algorithmes d'IA en aide à la décision pharmaceutique, et constitue un facteur de différenciation majeur par rapport aux approches de type boîte noire développées par les acteurs américains du secteur.

Ambition technologique et KPI du programme i-Démo

L'ambition du programme est d'atteindre une performance prédictive d'au moins 80 % pour une plateforme générique indépendante de la pathologie, et jusqu'à 90 % dans des contextes pathologie-spécifiques, avec une première preuve de concept réalisée sur le cancer du poumon. La solution devra également garantir une traçabilité complète des prédictions ainsi qu'une conformité aux exigences réglementaires relatives à l'IA explicable.

Le cancer du poumon comme preuve de concept structurante

Le cancer du poumon constitue un cas d'usage structurant en raison de la richesse des données disponibles, de la forte stratification biomarqueur, de l'équilibre complexe entre bénéfice de survie et toxicités significatives, et de l'intensité concurrentielle du segment.

Il offre un environnement scientifique exigeant, un intérêt industriel immédiat et une transférabilité méthodologique vers d'autres indications oncologiques à l'issue du programme.

Extension aux nouvelles aires pathologiques

Le world model est conçu selon le principe 90/10 : 90 % de l'architecture est pathologie-agnostique (encodeurs moléculaires, module d'attention multimodale, SCM, module d'incertitude, Mental Map, pipeline de validation), et ~10 % nécessitent une calibration spécifique (sous-graphe KG pathologie, pondération des endpoints cliniques, seuils de décision). L'ajout d'une nouvelle pathologie se traduit par :

1. Peuplement du sous-graphe KG correspondant ;
2. Fine-tuning de la couche de calibration sur un jeu de données annoté limité (objectif : < 500 cas annotés suffisants grâce au transfert) ;
3. Validation rétrospective sur les molécules connues de cette pathologie. Ce processus est documenté et reproductible.

La Profiling Base (100 milliards de relations) et les 24 Contextualizing SLMs fournissent la couche de pré-entraînement qui rend ce transfert réaliste : les représentations moléculaires et cliniques apprises sont fondamentalement transversales.



GOVERNEMENT

Liberté
Égalité
Fraternité



DU PLAN DE TRAVAIL

bpi**france**

Le projet se décline en **7 lots** (6 lots techniques et 1 lot de management) sur une période de 36 mois.

- Le lot 1 a pour objectif de prédire les bénéfices et les risques potentiels associés à une molécule en se basant uniquement sur sa structure chimique. La validité de cette approche sera évaluée par le taux de précision obtenu sur des molécules déjà commercialisées.
- Le lot 2 vise à prédire les bénéfices et les risques potentiels d'une intervention à partir des données in vivo disponibles et des études toxicologiques de la littérature, tout en intégrant un score de fiabilité par pathologie pour chaque modèle préclinique.
- Le lot 3 vise à prédire les bénéfices et risques d'une molécule à partir de ses effets sur les biomarqueurs de la pathologie, de sa cible moléculaire et des polymorphismes génétiques associés. La prédiction est évaluée par sa précision sur des molécules commercialisées.
- Le lot 4 vise à développer des modèles prédictifs de bénéfices et de risques basés sur les données de vie réelle, intégrant :
 - Les conditions d'utilisation en pratique,
 - Les populations non sélectionnées,
 - Les comorbidités, la polymédication,
 - Les facteurs socio-démographiques
- Le lot 5 vise à créer un cadre de connaissances structuré et interopérable qui intègre de multiples sources de données hétérogènes (structures moléculaires, résultats précliniques, données génomiques, données de vie réelle) dans une couche sémantique unifiée. Ce « paysage de connaissances » sert d'ontologie fondamentale et d'architecture de données permettant de contextualiser, comparer et combiner les prédictions des tâches du lot 4.
- Le lot 6 intègre tous les modèles prédictifs (lots 1-4) avec le paysage de connaissances (lot 5) pour créer un « **World model** » capable de simuler des profils bénéfice-risque pour n'importe quelle molécule. Ce modèle prédit les résultats au niveau individuel, les interactions médicamenteuses et les risques spécifiques au contexte en apprenant les relations causales entre les propriétés moléculaires, les mécanismes biologiques et les caractéristiques des patients.

Lot	Date prévisionnelle	Livrables attendus
		(Référence / mois de disponibilité / intitulé)
Lot 1 : Rapport de validation du modèle chimique (prédiction B/R depuis la structure)	T0 + 15 mois (Juillet 2027)	L1.1 (M6) : Base de données traitée structure-activité-toxicité. L1.2 (M9) : Modèles QSAR validés sur les cibles d'intérêt en oncologie pulmonaire. L1.3 (M9) : Modèles QSTR validés sur les endpoints toxicologiques prioritaires.



GOVERNEMENT

Liberté
Égalité
Fraternité

FRANCE

bpifrance

validation du pipeline <i>in vivo</i> (prédiction B/R depuis les résultats des modèles précliniques)	<i>T0 + 18 mois</i> (Novembre 2027)	L1.4 (M12) : Score B-R composite intégré et rapport de L2.1 (M3) : Infrastructure commune opérationnelle (WP3/WP4). L2.2 (M9) : Modèle NLP fonctionnel pour l'extraction de données <i>in vivo</i>. L2.3 (M12) : Score de fiabilité par modèle préclinique et par pathologie, calibré sur l'oncologie pulmonaire. L2.4 (M18) : Modèles ML prédictifs Bénéfits d'un côté et Risks de l'autre, basés sur les données <i>in vivo</i>, validés.
Lot 3 : Rapport de validation du modèle génomique (prédiction B/R à partir du polymorphisme génétique de la cible et de son impact sur des biomarqueurs contextuels)	<i>T0 + 18 mois</i> (Novembre 2027)	L3.1 (M9) : Pipeline opérationnel combinant (i) des modèles NLP pour l'extraction et la structuration sémantique d'informations génétiques et pharmacogénomiques à partir de la littérature biomédicale et des bases spécialisées, et (ii) des modèles statistiques dédiés au traitement des données omiques structurées (matrices d'expression, profils de variants, données CNV), reposant sur des approches de réduction dimensionnelle supervisée et de sélection de features à haute dimensionnalité (LASSO, elastic net, méthodes d'importance par permutation) adaptées aux spécificités des données génomiques. L3.2 (M12) : Base de données intégrée cibles <-> biomarqueurs <-> pathologie <-> variants génétiques. L3.3a (M18) : Modèle ML prédictif de bénéfice basé sur les biomarqueurs génomiques et les associations cibles-pathologie, validé. L3.3b (M18) : Modèle ML prédictif de risque basé sur les polymorphismes pharmacogénomiques, validé. L3.4 (M18) : Démonstration quantifiée de la capacité de prédiction B-R pour une drogue donnée via son profil génomique et les caractéristiques de sa cible, avec objectifs de performance explicites : AUC > 0,80 pour les associations de niveau de preuve 1A/1B, AUC > 0,75 pour les associations émergentes (niveau 2), mesurés sur les cohortes partenaires.
Lot 4 : Rapport de validation du pipeline RWE (prédictions cliniques en vie réelle)	<i>T0 + 18 mois</i> (Novembre 2027)	L4.1 (M12) : Pipeline d'extraction/structuration opérationnel ; grille de qualification appliquée à FAERS et à 2 EDS partenaires, avec résultats documentés sur la couverture, la complétude et les biais de chaque source, constituant le socle de sélection des données pour les modèles prédictifs T4.3/T4.4. L4.2 (M18) : Modèles prédictifs RWE B-R pour le cancer du poumon, rapport de calibration externe. L4.3 (M28) : Modèle généralisable intégrant données RWE + moléculaires + précliniques (WP1-3 + WP4), applicable à 2+ pathologies. L4.4 (M28) : Documentation complète du pipeline, code reproductible, rapport de validation multi-pathologies.
Lot 5 : Modèle	<i>T0 + 30 mois</i>	L5.1 (M18) : Schéma ontologique finalisé, validé par le comité



GOVERNEMENT

Liberté
Égalité
Fraternité

du knowledge graph	octobre 2028)	scientifique ; tables de correspondance WP1-3 livrées ; 80 % des entités WP L5.2 (M30) : KG peuplé avec intégration complète des données RWE (WP4) ; > 100 000 entités, > 1 million de relations. L5.3 (M30) : API opérationnelle testée selon les exigences WP6, documentation technique et guide d'utilisation, rapport qualité données (couverture, scores de confiance, taux de contradictions résolues).
Lot 6 : Rapport de validation du modèle unifié + démonstrateur interactif	T0+36 mois (Avril 2029)	L6.1 (M18) : Architecture du world model validée, encodeurs pré-entraînés opérationnels, prototype d'intégration d'ensemble sur cancer du poumon. L6.2 (M30) : Module d'interactions (DDI, gène-drug), module d'incertitude, prototype Mental Map fonctionnel. L6.3 (M36) : World model opérationnel intégrant WP1-5, rapport de validation rétrospective (≥ 200 molécules), rapport de validation prospective (monitoring partenaires), tests d'acceptation utilisateur avec ≥ 5 partenaires pharmaceutiques. L6.4 (M36) : Documentation utilisateur, matériaux de formation, système déployable avec quantification d'incertitude.



bpi**france**

2.5. GANTT




GOVERNEMENT

Liberté
Egalité
Fraternité

FRANCE

bpifrance



2.6. SYNTHÈSE DES PRINCIPAUX JALONS DÉCISIONNELS DU PROJET

Le programme se structure en 3 étapes clés lesquelles aboutissant à l'atteinte d'un jalon créateur de valeur :

Date prévisionnelle	Description du jalon	Indicateurs de succès du jalon
EC1 : 0 + 18 mois (09/2027)	MS1 : Prédiction du profil B-R à partir de la structure chimique seule (WP1). MS2 : Intégration des premières données précliniques in vivo (WP2). Pipeline RWE opérationnel (WP4). Modèles ML prédictifs Bénéfices d'un côté et Risks de l'autre, basés sur les données <i>in vivo</i> , validés	AUC > 0,75 sur jeu de validation externe pour les modèles QSAR/QSTR (WP1). AUC > 0,70 sur le score de fiabilité préclinique (WP2). Pipeline FAERS + 2 EDS opérationnel avec couverture > 80 % des EIG connus (WP4).
EC2 : 0 + 28 mois (07/2028)	MS2 : Prédiction intégrant les données précliniques et le MOA : AUC > 0,75 (générique). Modèle généralisable intégrant données RWE + moléculaires + précliniques (WP1-3 + WP4), applicable à 2+ pathologies. Documentation complète du pipeline, code reproductible, rapport de validation multi-	Précision des prédictions pour des molécules déjà commercialisées, supérieure à celle obtenue dans le L1 Cette prédiction est évaluée par sa précision sur des molécules déjà commercialisées. Précision des modèles RWE supérieure à celle obtenue via L1/2/3



GOVERNEMENT

*Liberté
Égalité
Fraternité*

gies.



bpifrance

**EC3 : 0 + 36 mois
(04/2029)**

Architecture complète intégrant le knowledge graphe et les données en vie réelles

Intégration réussie de $\geq 90\%$ des entités de données des L1-4 dans un graphe de connaissances standardisé avec des relations sémantiques validées. Temps de réponse aux requêtes < 2 secondes pour les requêtes complexes multi-sources

**EC3 : 0 + 36 mois
(04/2029)**

MS4 : Modèles finalisés : AUC $> 0,8$ (générique) et AUC $> 0,9$ (spécifique poumon).

Sensibilité et spécificité élevées pour la prédiction d'événements indésirables graves sur des molécules de test

Capacité à générer des profils bénéfice-risque cohérents incluant ≥ 3 sources de données indépendantes

Validation utilisateur : $\geq 70\%$ des experts évaluateurs jugent les prédictions comme « cliniquement plausibles »

2.7. RISQUES IDENTIFIES ET PLAN DE SUIVI

Les risques du projet ont été détaillés par étape clé comme indiqués dans le tableau ci-dessous :

Risques	Probabilité Gravité	Plan de contingence
Les modèles QSAR ne couvrent pas tout l'espace chimique	[P] Modérée [G] Elevée	Développer des modèles hybrides combinant ML et approches mécanistiques pour améliorer la généralisation.
Les modèles avancés comme DNN ou GNN montrent des performances variables selon les données d'entraînement.	[P] Modérée [G] Modérée	Enrichir les jeux de données avec des molécules diversifiées et effectuer une validation croisée rigoureuse
Certaines données critiques sont sous paywall ou inaccessibles.	[P] Elevée [G] Elevée	Collaborer avec des partenaires industriels pour obtenir des licences ou utiliser des données publiques alternatives.
Les biais dans les études publiées peuvent affecter la qualité des modèles	[P] Modérée [G] Modérée	Mettre en place des algorithmes pour détecter et corriger les biais dans les données
Les nouvelles cibles ou maladies rares peuvent ne pas être bien représentées.	[P] Modérée [G] Modérée	Collaborer avec des experts pour enrichir les ontologies utilisées.
Maintenir la cohérence avec l'arrivée de nouvelles données peut être complexe.	[P] Modérée [G] Modérée	Mettre en place une curation continue des données et des relations

**GOVERNEMENT**Liberté
Egalité
Fraternité

ne pas être détectés par les modèles.

Fuite de données entre jeux d'entraînement et de validation (data leakage), invalidation des résultats de performance

Pic de recrutement 2028 : 20 embauches en 12 mois, risque organisationnel

aux rent	[P] Elevée [G] Elevée	Utiliser des approches bayésiennes pour gérer et intégrer des données simulées.
rent	[P] Modérée [G] Elevée	Mettre en place des mécanismes d'apprentissage actif pour intégrer de nouvelles informations
	[P] Faible [G] Élevée	Protocole anti-leakage strict : split temporel (hold-out 2022-2025), validation croisée par exclusion de molécules (leave-drug-out), nested cross-validation pour l'optimisation d'hyperparamètres. Audit de conformité à chaque jalon.
	[P] Modérée [G] Modérée	Recrutement par vagues de 4-6 maximum ; pipeline de candidats alimenté par le réseau INRIA/ICM/Future4Care.

**FRANCE**

Utiliser des approches bayésiennes pour gérer et intégrer des données simulées.

bpifrance**2.8. BUDGET ET PRINCIPAUX POSTES DE SOUS-TRAITANCE DU PROJET**

Tableau 2 : Budget par Lot et par poste de dépense

Poste de dépense (k€)	Lot 1	Lot 2	Lot 3	Lot 4	Lot 5	Lot 6	Lot 7	Total
Personnel (salaires + charges)	540	615	695	880	470	1 100	130	4 430
Sous-traitance	70	85	100	150	45	110	20	580
Achats (licences, données)	25	30	35	40	20	50	5	205
Amortissements	15	20	20	30	15	40	5	145
Total	650	750	850	1 100	550	1 300	160	5 360

Partenaire	Lots	Montant (k€)	Nature de la prestation
Gradient Health	L1, L2, L4	170	Fourniture de jeux de données RWE annotés et structurés
Cedars-Sinai / Mayo Clinic	L2, L4	105	Accès EDS, cohortes rétrospectives, validation externe
INRIA	L1, L5	75	Support méthodologique, ontologique, traçabilité
ICM	L3	60	Cohortes génomiques, validation clinique



GOUVERNEMENT

*Liberté
Égalité
Fraternité*

réglementaire

Total

L6

60

L7

20

580



Validation méthodologique internationale
world model

Préparation et dépôt de deux brevets

bpifrance

DESCRIPTION DES LOTS

3. LOTS DÉTAILLÉS

3.1. LOT 1

Lot n°:	1	Durée :	T0 + 12 mois
Intitule du lot :	Modèles prédictifs QSAR/QSTR pour l'estimation du rapport bénéfice-risque à partir de la structure moléculaire seule.		
Nature du lot :	RDI		
Coût total du lot :	650 k€		
Objectifs			
L'objectif de ce lot est de démontrer qu'il est possible, dès la phase de criblage chimique, de produire une estimation quantitative du profil bénéfice-risque (B-R) d'un candidat-médicament à partir de sa seule représentation structurale. Ce lot constitue la couche prédictive la plus précoce de BR-PREDICT : il intervient en amont de toute donnée biologique ou clinique et vise à réduire le taux d'attrition (aujourd'hui de 92 % entre la phase préclinique et la mise sur le marché) en identifiant, dès la conception moléculaire, les signaux d'efficacité potentielle et les alertes de toxicité structurelle.			
Travaux réalisés			
Tâche 1.1 (M1 – M6) : Qualification des sources de données : Trois corpus de référence sont exploités Le corpus d'entraînement s'appuie sur ChEMBL 34 (~2,4M composés avec données de bioactivité sur des milliers de cibles), ToxCast (~10K composés sur ~600 endpoints de toxicité haut débit) et NCGC qHTS (~300K composés en criblage de cytotoxicité). Chaque molécule est représentée par un vecteur de ~2 250 features (fingerprints Morgan/ECFP en 2 048 dimensions + ~200 descripteurs physicochimiques RDKit), complété par des graphes moléculaires pour les architectures GNN. Les modèles QSAR de bénéfice sont entraînés sur l'ensemble des cibles disposant de données suffisantes dans ChEMBL ; les modèles QSTR de risque couvrent l'ensemble des endpoints de ToxCast et NCGC. Pour la validation sur le cancer du poumon, un panel prioritaire de cibles (EGFR, ALK, KRAS, PD-L1) et d'endpoints de toxicité (hERG, AMES, DILI) est utilisé. Chaque source fait l'objet d'un audit de couverture, de cohérence et de biais de publication avant intégration dans la Profiling Base.			
Tâche 1.2 (M1 – M6) : Construction et traitement (« curation ») de la base de données : Cette tâche a pour but de constituer un dataset consolidé de molécules commercialisées, adjuvants et protéines avec profils bénéfice–risque documentés. Une base dédiée est constituée, regroupant les molécules pharmacologiques commercialisées, disposant d'un profil B-R documenté, soit une estimation de 4500 molécules (d’après la version ChEMBL35). Afin d’étendre la base de données, ArcaScience inclura également certaines molécules en phase clinique suffisamment avancée (phase 2 ou 3) ayant un profil B-R documenté (à sélectionner parmi les 15000 molécules de ChEMBL ayant atteint une phase clinique). La curation inclut la normalisation des identifiants chimiques (InChI, SMILES canoniques), des composés chimiques (tautomère, forme saline, stéréochimie, état de pronation) en via MolVS/ChemBL standardizer RDKit Standardize, la déduplication, et l'annotation croisée avec les données réglementaires (RCP, rapports PSUR) disponibles dans la Profiling Base 100B d'ArcaScience, complétée par les informations réglementaires publiques (labels FDA, rapports d'évaluation de l'EMA, DailyMed).			
Tâche 1.3 (M1 – M8) : Représentation moléculaire &calcul des descripteurs : Chaque molécule est convertie en			



GOVERNEMENT

Liberté
Égalité
Fraternité



bpi**france**

exploitables par les modèles ML : Fingerprints moléculaires (Morgan/ECFP, MACCS), descripteurs physicochimiques (RDKit), et représentations par graphes moléculaires pour les GNN. Ces représentations complémentaires permettant d'alimenter plusieurs familles

Tâche 1.4 (M5 – M9) : Développement de modèles QSAR (bénéfice) : Plusieurs approches ML sont entraînées et comparées : Random Forest, Gradient Boosting, et réseaux de neurones sur graphes (GNN). Un domaine d'applicabilité est défini pour chaque modèle afin de quantifier la confiance de la prédiction en fonction de la distance au jeu d'entraînement. La base ChEMBL (v35) compile plus de 21 millions de points de bioactivité (IC50, EC50, Ki, Kd) pour plus de 2,4 millions de composés sur plus de 17 000 cibles protéiques, EGFR étant parmi les mieux documentées (>8 200 mesures d'IC50). ToxCast/Tox21 couvre environ 10 000 substances, testées sur plus de 700 essais ciblant plus de 300 voies de signalisation. En entrée : chaque molécule est représentée par un vecteur de descripteurs (estimé entre 500 et 2000 variables) combinant fingerprints moléculaires (Morgan/ECFP, MACCS), descripteurs physicochimiques (RDKit) et représentation par graphe (pour les GNN). En sortie : Le modèle QSAR génère un score d'activité prédite (type pIC50/pEC50/pKi) et un score de confiance pour chaque cible du panel oncologie pulmonaire (EGFR, ALK, KRAS, PD-L1, etc.). Ces 8 à 10 prédictions sont ensuite agrégées en un score de bénéfice composite. Les modèles sont entraînés sur l'ensemble des données d'activité, incluant pour incluant les cibles pertinentes en oncologie pulmonaire (EGFR, ALK, KRAS, PD-L1, etc.).

Tâche 1.5 (M5 – M9) : Développement de modèles QSTR (risque) : Selon une architecture parallèle, des modèles ML sont entraînés sur les données de toxicité pour produire un score de risque structural. Les données ToxCast et NCGC alimentent ces modèles, ainsi que les données dérivées du développement clinique et post-AMM. Les modèles QSTR (toxicité) s'appuient sur plusieurs sources de données : ToxCast/Tox21 (~10 000 substances testées sur >700 essais haute débit pour la cytotoxicité, génotoxicité, etc.), NCGC (cytotoxicité pour >8 000 composés) et ChEMBL (cardiotoxicité hERG et hépatotoxicité). Ces données sont complétées par des informations cliniques/post-AMM (RCP, PSUR) pour 2 000 à 3 000 molécules commercialisées. Au total, l'entraînement utilise environ 15 000 à 20 000 couples {structure/profil de risque}, avec une couverture variable selon l'endpoint :

- Cytotoxicité : ~10 000 composés
- Cardiotoxicité hERG : ~10 000-15 000 composés
- Génotoxicité : ~5 000-8 000 composés
- Hépatotoxicité : ~3 000-5 000 composés

Une attention particulière est portée au déséquilibre de classes, traité par pondération des pertes et ajustement du seuil de décision (threshold tuning), afin de maximiser la performance prédictive tout en maintenant une calibration rigoureuse.

Tâche 1.6 (M10 – M12) : Intégration & validation : Les scores QSAR (bénéfice) et QSTR (risque) sont intégrés dans un score B-R composite, calibré sur des molécules commercialisées ou ayant atteint des phases cliniques avancées dont le profil B-R est connu. Les scores sont combinés via un méta-modèle calibré (régression logistique ou stacking) entraîné sur les issues réglementaires (approbation, retrait) pour trouver la pondération optimale bénéfice/risque. La confiance de la prédiction est rapportée séparément, basée sur le domaine d'applicabilité et la variance inter-modèles, afin de distinguer la prédiction de sa fiabilité. La validation repose sur trois piliers : 1) une validation croisée stratifiée, 2) un test sur un sous-ensemble de molécules à B-R connu tenues à l'écart, et 3) une validation externe sur la base de données multi-thérapeutique WITHDRAWN (incluant des retraits pour motifs de sécurité) et des molécules sous avertissement encadré de la FDA (boxed warnings). L'approche structurale du WP1 étant indépendante de la pathologie, cet élargissement permet de pallier la rareté des retraits pour motif de sécurité spécifiquement en oncologie et de garantir une évaluation robuste du volet risque.. Le jeu de test externe pour le risque utilise la base mondiale de 578 médicaments retirés au lieu de se limiter aux retraits en oncologie pulmonaire. Ce choix est cohérent avec le caractère pathologie-agnostique des

Livrables

- L1.1 (M6)** : Base de données traitée structure-activité-toxicité.
- L1.2 (M9)** : Modèles QSAR validés sur les cibles d'intérêt en oncologie pulmonaire.
- L1.3 (M9)** : Modèles QSTR validés sur les endpoints toxicologiques prioritaires.
- L1.4 (M12)** : Score B-R composite intégré et rapport de validation.

Description des dépenses

Dépenses de sous-traitance	Gradient Health : 40 k€ pour fourniture de jeux de données annotés et structurés. INRIA : 30 k€ pour support méthodologique sur l'ingénierie des modèles et la traçabilité des pipelines. Total : 70 k€
Dépenses des achats	Licences logicielles (RDKit Pro, bases de données ChEMBL/ToxCast), accès aux données réglementaires (labels FDA, rapports EMA). Total : 25 k€
Contribution aux amortissements	Serveurs GPU dédiés à l'entraînement des modèles QSAR/QSTR. Total : 15 k€

3.2. LOT 2

Lot n°:	2	Durée :	T0 + 18 mois
Intitule du lot :	Modèles prédictifs de transposition préclinique-clinique pour l'estimation du rapport bénéfice-risque à partir des données in vivo.		
Nature du lot :	RDI		
Coût total du lot :	750 k€		
Objectifs			
L'objectif de ce lot est de construire une couche prédictive qui exploite les données d'études précliniques (efficacité pharmacologique in vivo, toxicologie réglementaire, pharmacocinétique animale) pour prédire le profil B-R chez l'humain. Le WP2 introduit une innovation majeure : un score de fiabilité par modèle préclinique et par pathologie.Ce lot se situe en aval du WP1 (structure chimique) et constitue le deuxième niveau de résolution prédictive de BR-PREDICT, mobilisable dès la fin des études précliniques réglementaires et pendant les phases I/II.			
Travaux réalisés			
Tâche 2.1 (M1 – M4) : Préparation de l'infrastructure (tâche mutualisée WP2/WP3/WP4) : Déployée en Q2 2026, cette tâche met en place l'infrastructure commune de stockage, d'indexation et de requêtage de la Profiling Base dédiée à BR-PREDICT. Elle comprend l'extension du graphe de connaissances existant (100 milliards de points de données/relations), le déploiement des pipelines ETL pour les nouvelles sources partenaires et multimodales, et la configuration des environnements d'entraînement ML (GPU, versioning des modèles, traçabilité des expériences via MLflow).			
Tâche 2.2 (M4 – M6) : Qualification des sources de données pré-cliniques in vivo : Trois catégories de sources sont qualifiées : (i) données d'efficacité préclinique (modèles xénogreffe, PDX, modèles transgéniques, données			



GOVERNEMENT

Liberté
Égalité
Fraternité



bpi**france**

données toxicologiques réglementaires (études de dose-réponse, études de génotoxicité, études de carcinogénicité), (iii) littérature générale clinique connue. Chaque source est évaluée selon sa couverture, sa standardisation, et sa publication, sous-déclaration des résultats négatifs).

Tâche 2.3 (M4 – M9) : Extraction NLP et structuration : Les Contextualizing SLMs d'ArcaScience (24 modèles spécialisés -classifieurs de phrases, modèles NER, modèles d'embedding, modules hybrides règles+modèles - entraînés sur données annotées selon des guides définis avec des cliniciens sont adaptés pour extraire, à partir de la littérature et des rapports d'études, les données structurées nécessaires : espèce, souche, modèle pathologique, doses, schéma posologique, endpoints d'efficacité (TGI, survie, réponse tumorale), endpointsextraction est validée par confrontation avec des données manuellement annotées (précision démontrée > 90 %). Elle reposera sur trois indicateurs de toxicité (NOAEL, LOAEL, organes cibles, sévérité), et paramètres PK (Cmax, AUC, t½, clairance). L's de performance : (1) le F1-score par entité sur un jeu de test indépendant (cible > 0,85 par champ), (2) le taux de complétude par enregistrement pour évaluer l'absence d'erreurs cumulées (cible > 0,70), et (3) l'impact en aval sur le modèle de machine learning. Ce dernier sera mesuré par l'écart d'AUC entre le modèle WP2 entraîné sur données manuelles et celui entraîné sur données NLP, la qualité d'extraction étant jugée suffisante si cet écart est inférieur à 0,02.

Tâche 2.4 (M4 – M9) : Création de la base traitée et structurée : Les données extraites sont intégrées dans une base relationnelle liant chaque molécule à ses résultats précliniques (efficacité + toxicité), au modèle animal utilisé, et à l'issue clinique connue (pour les molécules commercialisées ou ayant échoué en développement clinique). Cette base constitue le corpus d'entraînement et de validation des modèles ML. Une première estimation réalisée à partir de nos outils suggère entre 5 000 et 8 000 composés pharmacologiques avec des données précliniques d'efficacité et/ou de toxicologie accessibles publiquement de façon utile, en fonction du paramétrage de la recherche. Ceci garantit la faisabilité des étapes suivantes de modélisation même sur la limite basse de cette estimation.

Tâche 2.5 (M9 – M12) : Modèle ML de prédiction d'efficacité avec score de fiabilité : Un modèle ML est entraîné pour prédire l'efficacité clinique à partir des données précliniques. L'innovation clé réside dans l'intégration d'un score de fiabilité par modèle préclinique et par pathologie, calculé à partir de la concordance historique entre résultats précliniques et issues cliniques pour chaque combinaison {modèle animal x pathologie}. Les données de la littérature indiquent une concordance globale de l'ordre de 57 % (IC 95 % : 51–63 %) pour les modèles murins standard, et de 67 % (IC 95 % : 58–75 %) pour les modèles PDX, justifiant la différenciation du score de fiabilité par type de modèle (Gao et al., 2015 ; Hutchinson & Kirk, 2011 ; Ghosh A. et al., 2024)Ce score pondère la prédiction et permet de quantifier la confiance accordée à chaque donnée d'entrée. En oncologie pulmonaire, par exemple, les modèles PDX EGFR-mutés auront un score de fiabilité distinct de celui des xénogreffes sous-cutanées sur lignées cellulaires (Gandara et al., 2016)

Tâche 2.6 (M9 – M18) : Modèle ML de prédiction de risque : Un modèle parallèle, basé sur une architecture XGBoost adaptée à la tâche, exploitant des descripteurs tabulaires, est entraîné pour prédire les risques toxiques humains. Les entrées sont organisées en trois catégories : les paramètres dose-réponse (NOAEL/LOAEL, marges de sécurité HED/MRHD), les données toxicologiques qualitatives (organes cibles, signaux de toxicité fonctionnelle) et les variables de contexte. Le modèle apprend ainsi les facteurs de transposition inter-espèces et les patterns de toxicité clinique historiquement non détectés en préclinique. Contrairement aux prédictions d'efficacité ou de propriétés moléculaires pour lesquelles des corpus pré-entraînés de grande taille sont disponibles, les données de transposition préclinique-clinique en toxicologie sont structurellement peu nombreuses, hétérogènes et fortement tabulaires. Dans ce régime de faible volumétrie, les modèles gradient boosting surpassent systématiquement les architectures neuronales profondes, qui requièrent un volume de données d'entraînement bien supérieur pour converger et s'adapte mieux aux contextes réglementaires d'interprétabilité des décisions.

Tâche 2.7 (M14 – M18) : Validation et intégration : Les modèles sont validés selon le même principe que le WP1:



GOVERNEMENT

Liberté
Égalité
Fraternité



validation sur un dataset indépendant, environ 30% du dataset global,
3) validation sur des molécules commercialisées en oncologie pulmonaire
développement (attrition pour efficacité insuffisante ou toxicité inacceptable).

bpifrance

Le protocole de validation est conçu pour garantir une évaluation rigoureuse et sans biais : il s'appuie exclusivement sur des molécules dont l'issue clinique est définitivement connue (approbation réglementaire ou arrêt documenté pour échec), ce qui constitue le standard le plus exigeant en matière de validation rétrospective. Les performances de WP1 et WP2 seront comparées à leur combinaison (WP1+WP2) sur un socle de tests commun, ce qui permettra de quantifier le gain de précision issu des données *in vivo* par un test de DeLong (AUC appariée) comparant le modèle global au WP1 seul.

La crédibilité du protocole de validation est renforcée par la définition anticipée d'un panel de référence en oncologie pulmonaire, constitué de molécules dont le profil B-R clinique est documenté de façon irréfutable. Ce panel inclut notamment : des succès thérapeutiques majeurs (osimertinib, alectinib, lorlatinib) dont le bénéfice clinique est solidement établi, ainsi que des molécules ayant échoué pour toxicité inacceptable (buparlisib, idelalisib) ou efficacité insuffisante (selumetinib en monothérapie, vandetanib en 2e ligne).

Livrables

L2.1 (M3) : Infrastructure commune opérationnelle (partagée avec WP3/WP4).

L2.2 (M9) : Modèle NLP fonctionnel pour l'extraction de données *in vivo*.

L2.3 (M12) : Score de fiabilité par modèle préclinique et par pathologie, calibré sur l'oncologie pulmonaire.

L2.4 (M18) : Modèles ML prédictifs Bénéfits d'un côté et Risks de l'autre, basés sur les données *in vivo*, validés ;

Description des dépenses

Dépenses de sous-traitance	Gradient Health : 50 k€ pour données RWE annotées et structurées. Cedars-Sinai : 35 k€ pour validation clinique sur cohortes rétrospectives. Total : 85 k€
Dépenses des achats	Bases de données précliniques (PubChem BioAssay, EPA ToxCast), licences logicielles. Total : 30 k€
Contribution aux amortissements	Infrastructure GPU/cloud pour entraînement des modèles. Total : 20 k€

3.3. LOT 3

Lot n°:	3	Durée :	T0 + 18 mois
Intitule du lot :	Modèles prédictifs pharmaco-génomiques pour l'estimation du rapport bénéfice-risque par intégration des biomarqueurs, cibles thérapeutiques et variants génétiques.		
Nature du lot :	RDI		
Coût total du lot :	850 k€		
Objectifs			
L'objectif de ce lot est de construire la couche prédictive la plus granulaire de BR-PREDICT, exploitant les relations entre une drogue, ses cibles moléculaires, les biomarqueurs génomiques associés à une pathologie, et les polymorphismes génétiques influençant la réponse thérapeutique et la survenue d'effets indésirables. Le			



GOVERNEMENT

Liberté
Égalité
Fraternité



bpifrance

novation avancé du projet : si les couches de pharmacogénomique des périmètres restreints (UGenon 2025 : jusqu'à 99 % de précision) sont déployées à l'échelle d'une plateforme systématique de prédiction B-R intégrant l'écoulement, profil génomique et contexte pathologique. Ce lot s'applique à toutes les modalités thérapeutiques (petites molécules, biologiques, thérapies ciblées) et pose les fondations de la médecine personnalisée prédictive dans BR-PREDICT.

Travaux réalisés

Tâche 3.1 (M4 – M6) : Qualification des sources : Deux axes de sources sont qualifiés, correspondant aux deux composantes du rapport B-R : (i) les bases de données biomarqueurs génomiques-pathologie (PharmGKB, ClinVar, COSMIC, OncoKB, cBioPortal), qui alimentent le volet efficacité en reliant profils génomiques et réponse thérapeutique ; (ii) les bases de données de variants génétiques des enzymes de métabolisation et des cibles thérapeutiques (UniProt variants, gnomAD, dbSNP, ClinGen, CPIC), exploités prioritairement pour les variants à perte de fonction dont l'impact sur la pharmacocinétique et la toxicité est documenté de façon cliniquement actionnable, et qui alimentent le volet risque en caractérisant les polymorphismes modulant la toxicité.

Tâche 3.2 (M7 – M9) : Extraction NLP des polymorphismes génétiques et structuration fonctionnelle. Les *Contextualizing SLMs* sont entraînés pour extraire de la littérature biomédicale les variants génétiques organisés en trois catégories distinctes : (i) polymorphismes constitutionnels (variants germinaux modulant la pharmacocinétique et la toxicité, notation HGVS) ; (ii) variants et mutations somatiques tumoraux (mutations driver, amplifications, fusions géniques, spécifiques à l'oncologie) ; (iii) variants génétiques des cibles thérapeutiques (modifications d'affinité, résistance acquise). Pour chaque catégorie, le niveau de preuve est explicitement tracé et conditionne l'intégration dans le modèle. On y retrouve l'effet fonctionnel rapporté (perte/gain de fonction, modification d'affinité, altération métabolique), l'association à une réponse thérapeutique ou à un effet indésirable, et le niveau de preuve (étude de cas, cohorte, essai contrôlé). Seuls les variants de niveau de preuve 1 et 2 (PharmGKB) sont intégrés dans les modèles prédictifs, garantissant la robustesse clinique des associations exploitées. Comme pour les WP précédents, ArcaScience estime les variables utiles pour la modélisation à plusieurs milliers. A titre d'exemple, les variants géniques ayant un impact sur l'efficacité ou la toxicité d'une drogue peuvent être estimés à 100-300 pour une preuve de niveau 1 (cliniquement actionnables) et à 10000 pour les variants avec preuve de niveau 2 (PharmGKB). ArcaScience exclura de son projet les preuves de niveau 3 (variants identifiés par des études GWAS sur la base d'associations significatives) en raison d'une trop grande incertitude sur l'implication de ces variants.

Tâche 3.3 (M9 – M12) : Base de données intégrée multi-dimensionnelle. La base de données du WP3 structure deux graphes relationnels complémentaires : (i) Drogue $\Rightarrow$ Biomarqueurs génomiques $\Rightarrow$ Pathologie, reliant chaque drogue à ses biomarqueurs prédictifs de réponse (mutations driver, amplifications, fusions géniques) et aux pathologies concernées, avec le niveau de preuve clinique associé à chaque relation, reliant chaque drogue à ses biomarqueurs de réponse et aux pathologies concernées ; (ii) Drogue $\Rightarrow$ Cible $\Rightarrow$ Variants $\Rightarrow$ Impacts fonctionnels, reliant chaque drogue à ses cibles thérapeutiques, aux variants connus de ces cibles, et aux conséquences toxicologiques et fonctionnelles documentées, notamment les variants modulant la pharmacocinétique (métabolisation, élimination) et ceux associés à des effets indésirables graves (cardiotoxicité, hépatotoxicité, neurotoxicité). Ces deux graphes sont intégrés dans la Profiling Base existante et indexés pour le requête par les modèles ML.

Tâche 3.4 (M13 – M18) : Modèle ML de prédiction du bénéfice. Le modèle de bénéfice prend en entrée le profil génomique du patient (variants germinaux, mutations somatiques driver, statut d'amplification et fusions géniques) ainsi que les caractéristiques de la cible thérapeutique, et produit en sortie une prédiction de bénéfice (probabilité de réponse, durée de réponse estimée). L'architecture repose sur un réseau à attention sur graphe (GAT ou Relational Graph Transformer) opérant directement sur le sous-graphe {molécule-cibles-biomarqueurs-pathologie}. Les nœuds, initialisés par des embeddings pré-entraînés (RotatE/ComplEx), sont affinés par des couches d'attention lors de l'entraînement supervisé. Ce processus génère des représentations contextualisées



GOVERNEMENT

*Liberté
Égalité
Fraternité*



bpifrance

Le biomarqueur est dynamiquement ajusté en fonction de la structure co... (l'oncologie pulmonaire), le modèle est entraîné sur les associations de réponse aux TKI, réarrangements ALK/ROS1 et réponse au crizotinib/lorlatinib, et la réponse aux anti-PD-1/PD-L1, charge mutationnelle tumorale et réponse à l'immunothérapie. Ce panel repose sur une centaine d'associations de niveau de preuve 1 (statut FDA reconnu, PharmGKB 1A/1B), volume suffisant pour entraîner et valider les architectures de graphes retenues, comme démontré dans la littérature sur des périmètres comparables (Park et al., 2023 ; UGenome, 2025). Ceci inclut une centaine de biomarqueurs avec impact clinique démontré (preuve de niveau 1, statut FDA reconnu).

Tâche 3.5 (M14 – M18) : Modèle ML de prédiction du risque. Le modèle de risque prend en entrée les polymorphismes pharmacogénomiques constitutionnels (enzymes de métabolisation, transporteurs) et le mécanisme d'action de la molécule, et produit en sortie une prédiction de risque (probabilité et sévérité des effets indésirables). Le génotype de la cible thérapeutique contribue au volet efficacité (T3.4) ; le volet risque s'appuie prioritairement sur les variants modulant la pharmacocinétique et l'exposition systémique. Ce modèle exploite les relations connues entre polymorphismes pharmacogénomiques et toxicité, par exemple variants CYP2D6 et toxicité des métaboliseurs lents, variants DPYD et toxicité au 5-fluorouracile, variants UGT1A1 et toxicité à l'irinotécan (10000 variants estimés, cf T3.2). L'objectif est de généraliser ces relations à l'ensemble des couples {cible x molécule} par apprentissage sur les données historiques.

Tâche 3.6 (M15 – M18) : Validation et intégration. La validation suit un protocole en deux temps : (i) validation rétrospective sur des cohortes de patients avec profil génomique et issue clinique connus (données Cedars-Sinai, Mayo Clinic, ICM), dont la taille et la couverture en variables génomiques seront caractérisées dès T3.1 pour garantir la puissance statistique suffisante à chaque niveau de preuve ciblé ; (ii) confrontation croisée avec les prédictions WP1 et WP2 pour évaluer la complémentarité et le gain incrémental de la couche génomique. Les résultats sont intégrés dans le moteur BR-PREDICT via le WP5.

Livrables

L3.1 (M9) : Pipeline opérationnel combinant (i) des modèles NLP pour l'extraction et la structuration sémantique d'informations génétiques et pharmacogénomiques à partir de la littérature biomédicale et des bases spécialisées, et (ii) des modèles statistiques dédiés au traitement des données omiques structurées (matrices d'expression, profils de variants, données CNV), reposant sur des approches de réduction dimensionnelle supervisée et de sélection de features à haute dimensionnalité (LASSO, elastic net, méthodes d'importance par permutation) adaptées aux spécificités des données génomiques.

L3.2 (M12) : Base de données intégrée cibles <-> biomarqueurs <-> pathologie <-> variants génétiques.

L3.3a (M18) : Modèle ML prédictif de bénéfice basé sur les biomarqueurs génomiques et les associations cibles-pathologie, validé.

L3.3b (M18) : Modèle ML prédictif de risque basé sur les polymorphismes pharmacogénomiques, validé.

L3.4 (M18) : Démonstration quantifiée de la capacité de prédiction B-R pour une drogue donnée via son profil génomique et les caractéristiques de sa cible, avec objectifs de performance explicites : AUC > 0,80 pour les associations de niveau de preuve 1A/1B, AUC > 0,75 pour les associations émergentes (niveau 2), mesurés sur les cohortes partenaires.

Description des dépenses

Dépenses de sous-traitance	Gradient Health : 80 k€ pour données RWE structurées et annotées. Cedars-Sinai / Mayo Clinic : 70 k€ pour accès EDS et validation externe. Total : 150 k€
Dépenses des achats	Accès bases FAERS, licences MedDRA 27.x, outils de normalisation terminologique. Total : 40 k€
Contribution aux	Infrastructure cloud/GPU pour traitement des volumes de données RWE. Total :

**GOVERNEMENT**Liberté
Égalité
Fraternité

30 k€

**bpi**france

Lot n°:	4	Durée :	T0 + 28 mois
Intitule du lot :	Extraction, structuration et modélisation prédictive des données de vie réelle (RWE) pour la validation et le renforcement des relations structure-cible-bénéfice-risque.		
Nature du lot :	RDI		
Coût total du lot :	1 100 k€		
Objectifs			
L'objectif est double. Premièrement, construire un pipeline reproductible d'extraction et de normalisation des données de pharmacovigilance et des données de réponse thérapeutique en conditions réelles, incluant les trajectoires de traitement, les mesures d'efficacité (survie, réponse RECIST) et les événements indésirables, documentés dans les systèmes de soins réelles issues de FAERS (FDA Adverse Event Reporting System), d'entrepôts de données de santé hospitaliers (EDS), dont au minimum un exemple opérationnel avec données d'oncologie pulmonaire annotées a été vérifié en amont avec chaque partenaire (Cedars-Sinai, Mayo Clinic, ICM) pour confirmer la disponibilité et la richesse des variables d'intérêt (indication, posologie, réponse tumorale, événements indésirables codés MedDRA). Deuxièmement, développer des modèles prédictifs qui exploitent ces données pour valider, compléter et, le cas échéant, corriger les profils bénéfice-risque (B-R) générés par les WP1-3 à partir de données moléculaires, précliniques et génomiques. La valeur ajoutée de WP4 réside dans l'intégration de facteurs parfois absents des essais cliniques contrôlés (comorbidités, polymédication) mais surtout d'étudier des cohortes de patients ayant une variabilité socio-démographique et ethnique importante et des conditions d'utilisation en pratique beaucoup plus variables et hétérogènes que dans les essais contrôlés.			
Travaux réalisés			
Tâche 4.1 (M1 – M12) : Qualification des sources RWE : Chaque source RWE est évaluée selon une grille multicritère (couverture, granularité, complétude MedDRA/CIM-10/ATC, biais) et intégrée via un protocole d'harmonisation rigoureux. Ce processus assure l'alignement des historiques CIM-9 vers la CIM-10, le mapping des codes médicaments locaux vers la nomenclature ATC, ainsi que la standardisation des unités de dosage. Une caractérisation fine de la population est également réalisée pour permettre les ajustements statistiques et corriger les biais de sélection identifiés. Un score de qualité composite est attribué ; seules les sources dépassant le seuil prédéfini alimentent les modèles. Pour cette tâche, une estimation du nombre de données disponibles n'est pas faisable à ce stade. Il dépendra de l'accès aux données propriétaires de centres cliniques ou de systèmes de santé ainsi que de la qualité et richesse d'annotation des bases. Il s'agit donc d'un WP plus risqué mais dont la faisabilité ne remet pas en cause l'ensemble du projet (pas de dépendance stricte, les WP1-3 et 5 sont suffisants à délivrer un modèle original et ambitieux) L'accès aux sources RWE est conditionné par des accords de partage de données formalisés avec chaque partenaire institutionnel (Cedars-Sinai, Mayo Clinic, ICM), d'ores et déjà accordés par Cedars-Sinai et l'ICM. Pour FAERS, les données sont publiques et immédiatement accessibles. Pour les EDS hospitaliers, les protocoles de pseudonymisation et de gouvernance des données sont définis en conformité avec le RGPD et le HIPAA, et constituent un livrable explicite de T4.1. Ce cadre rigoureux d'accès aux données est un gage de reproductibilité et de conformité réglementaire de l'ensemble du WP4.			
Tâche 4.2 (M4 – M12) : Les Contextualizing SLMs d'ArcaScience - modèles de langage de petite taille entraînés			



GOVERNEMENT

Liberté
Égalité
Fraternité



bpi**france**

it les entités pertinentes des notifications FAERS (champs libre-texte) ; rendus d'hospitalisation des EDS partenaires (Cedars Sinai, Mayo Clinic) ; normalisation terminologique vers MedDRA 27.x, Ontologie ArcaScience optimisée ; index temporel (date index = date de première prescription). Le pipeline intègre un module de dédoublement probabiliste (record linkage) pour les cas FAERS multiples et un module de pseudonymisation conforme RGPD/HIPAA.

Tâche 4.3 (M13 – M18) : Modèles prédictifs RWE (Bénéfices) : Pour chaque molécule, les variables RWE structurées sont fusionnées avec les descripteurs moléculaires et précliniques issus de WP1-3. L'architecture retenue est un modèle gradient-boosted (XGBoost/LightGBM) pour la prédiction tabulaire, complété par une architecture inspirée des réseaux à attention temporelle (type Temporal Fusion Transformer), spécifiquement adaptée au caractère asynchrone des trajectoires patients. Cette approche permet de pondérer les événements cliniques passés via des mécanismes d'attention, tout en intégrant des embeddings d'intervalles de temps pour traiter l'irrégularité des suivis longitudinaux. Les finalités à prédire sont : (i) survenue d'EIG codés MedDRA PT dans les 6/12/24 mois ; (ii) réponse thérapeutique (survie sans progression, réponse RECIST pour l'oncologie). Les modèles sont entraînés avec validation croisée stratifiée par source pour garantir la robustesse inter-bases.

Tâche 4.4 (M13 – M18) : Modèles prédictifs RWE (Risques) : Processus identique à la tâche 4.3

Tâche 4.5 (M19 – M28) : Validation & calibration : La validation est conduite en deux temps : (i) validation spécifique cancer du poumon sur cohortes rétrospectives indépendantes (Mayo Clinic, ICM), avec évaluation sur le panel de molécules de référence défini transversalement aux WPs (osimertinib, alectinib, buparlisib, etc.) ; (ii) calibration externe multi-sources avec mesure du gain incrémental par rapport aux prédictions WP1-3 seules. Analyse de sous-groupes (âge, comorbidités, ethnie déclarée) pour identifier les populations où le gain RWE est maximal.

Livrables

L4.1 (M12) : Pipeline d'extraction/structuration opérationnel ; grille de qualification appliquée à FAERS et à 2 EDS partenaires, avec résultats documentés sur la couverture, la complétude et les biais de chaque source, constituant le socle de sélection des données pour les modèles prédictifs T4.3/T4.4.

L4.2 (M18) : Modèles prédictifs RWE B-R pour le cancer du poumon, rapport de calibration externe.

L4.3 (M28) : Modèle généralisable intégrant données RWE + moléculaires + précliniques (WP1-3 + WP4), applicable à 2+ pathologies.

L4.4 (M28) : Documentation complète du pipeline, code reproductible, rapport de validation multi-pathologies.

Description des dépenses

Dépenses de sous-traitance	INRIA : 45 k€ pour support ontologique, méthodologique et alignement sur les standards internationaux. Total : 45 k€
Dépenses des achats	Licences Neo4j Enterprise, infrastructure de stockage, outils de visualisation de graphes. Total : 20 k€
Contribution aux amortissements	Serveurs dédiés au KG et à l'indexation. Total : 15 k€

3.5. LOT 5



GOVERNEMENT

Liberté
Égalité
Fraternité



bpi**france**

GOUVERNEMENT		5	Durée :	bpma
Liberté Égalité Fraternité			Conception et déploiement d'un graphe de connaissances interopérable intégrant les données moléculaires, précliniques, génomiques et de vie réelle dans une couche sémantique unifiée au service du world model BR-PREDICT.	
Intitulé du lot :		RDI		
Nature du lot :		550 k€		
Coût total du lot :				
Objectifs				
L'objectif de ce lot est de créer un cadre de connaissances structuré et interopérable qui intègre de multiples sources de données hétérogènes (structures moléculaires, résultats précliniques, données génomiques, données de vie réelle) dans une couche sémantique unifiée. Ce « paysage de connaissances » sert d'ontologie fondamentale et d'architecture de données permettant de contextualiser, comparer et combiner les prédictions des L1-4.				
Travaux réalisés				
Tâche 5.1 (M13 – M18) : Conception ontologique. Le schéma est construit par composition modulaire : un noyau partagé (upper ontology) définit les classes de premier niveau (Molecule, Target, Pathway, Phenotype, AdverseEvent, Patient, ClinicalOutcome) et les types de relations (binds_to, inhibits, causes, associated_with, treats, metabolized_by). Ce noyau est aligné sur les ontologies de référence : MedDRA 27.x pour les événements indésirables, Ontologie ArcaScience optimisée pour les concepts cliniques, ChEBI pour les entités chimiques, Gene Ontology et Reactome pour les voies biologiques, Disease Ontology pour les pathologies. Les extensions pathologie-spécifiques (ex. staging TNM, mutations driver EGFR/ALK/ROS1 pour le cancer du poumon) sont modélisées en sous-ontologies enfichables, validées par les experts du comité scientifique (Pr. Alexis Brice, Dr. Philippe Peyre). Tâche 5.2 (M17 – M18) : Harmonisation et mapping d'entités. Chaque sortie de WP1-4 est projetée sur le schéma ontologique via un pipeline de résolution d'entités (<i>entity linking</i>) combinant : (i) correspondance exacte sur identifiants normalisés (CAS, DrugBank ID, UniProt ID, MedDRA PT code) ; (ii) correspondance approximative par un pipeline en deux étapes : recherche par plus proches voisins approchés (ANN) avec seuil de similarité cosinus > 0,70 pour maximiser le rappel, suivie d'un réordonnement par <i>cross-encoder</i> pour optimiser la précision ; approche cohérente avec l'état de l'art en <i>entity linking</i> biomédical (SapBERT, Liu et al., NAACL 2021); (iii) arbitrage humain pour les entités ambiguës (< 5 % attendu). Les tables de correspondance sont versionnées et auditées. Tâche 5.3 (M13 – M30) : Construction du Graphe de Connaissances : Le graphe est implémenté sur une base de données graphe (Neo4j ou équivalent) avec un stockage RDF parallèle pour l'interopérabilité SPARQL. Les nœuds portent des attributs typés (identifiants, scores de confiance, provenance WP, <i>timestamps</i>). Les arêtes sont pondérées par un score de confiance composite intégrant : la fréquence d'observation dans la Profiling Base, le niveau de preuve (essai clinique > cohorte RWE > cas rapporté > prédiction <i>in silico</i>), et la concordance inter-WP. L'objectif cible est un KG de > 100 000 entités et > 1 million de relations au stade EC3, dont > 95 % des arêtes annotées avec un score de confiance, une provenance traçable (WP d'origine, source de données) et un niveau de preuve (essai clinique randomisé, cohorte, cas rapporté, <i>in silico</i>). Cette exigence de qualité différencie fondamentalement le KG BR-PREDICT des graphes publics de référence (DRKG : 5,9M arêtes non pondérées ; PrimeKG : 4M relations sans statut causal) et répond directement aux exigences d'auditabilité réglementaire (ICH E2C(R2), CIOMS XII). Tâche 5.4 (M18 – M30) : Extraction et Validation des Relations : Les 24 Contextualizing SLMs d'ArcaScience				



GOVERNEMENT

Liberté
Égalité
Fraternité



bpifrance

ctions à partir de la littérature, de supports réglementaires et des
Chaque relation extraite est score de précision estimée, rappel par
de validation croisée : concordance entre SLMs indépendants, cohérence avec les
détection de contradictions), validation par échantillonnage expert (*gold standard* sur
5 % des nouvelles relations par trimestre).

Tâche 5.5 (M25 – M30) : Développement de l'Interface de Requête et de l'API : Une API RESTful et GraphQL expose le KG avec un langage de requête multi-niveaux : requêtes simples (entité -> voisins directs), requêtes de chemin (plus court chemin entre deux entités, chemins causaux), requêtes agrégées (profil B-R complet d'une molécule = sous-graphe de toutes les relations bénéfice et risque avec scores). Un système de cache hiérarchique (in-memory pour les requêtes fréquentes, disque pour les requêtes complexes) garantit le respect du KPI de latence < 2 s. L'API est conçue pour être consommée par le world model de WP6 et par l'interface de visualisation (Mental Map, T6.5).

Livrables

L5.1 (M18) : Schéma ontologique finalisé, validé par le comité scientifique ; tables de correspondance WP1-3 livrées ; couverture >= 80 % des entités WP1-3.

L5.2 (M30) : KG peuplé avec intégration complète des données RWE (WP4) ; > 100 000 entités, > 1 million de relations.

L5.3 (M30) : API opérationnelle testée selon les exigences WP6, documentation technique et guide d'utilisation, rapport qualité données (couverture, scores de confiance, taux de contradictions résolues).

Description des dépenses

Dépenses de sous-traitance	- 37,5K INRIA conception ontologique et validation infra KG
Dépenses des achats	- 50k infra Neo4j Cloud
Contribution aux amortissements	/

3.6. LOT 6

Lot n°:	6	Durée :	T12 + 24 mois
Intitule du lot :	Conception, intégration et validation d'un world model capable de simuler des profils bénéfice-risque complets pour toute molécule en développement, de la phase préclinique à la phase II, par fusion multimodale des modèles prédictifs WP1-4 et du graphe de connaissances WP5.		
Nature du lot :	RDI		
Coût total du lot :	1 300 k€		
Objectifs			
Le world model BR-PREDICT constitue la finalité scientifique et industrielle du projet. Il ne s'agit pas d'une			



GOVERNEMENT

Liberté
Égalité
Fraternité



bpi**france**

mais d'un système intégré qui prend à pondérer, réconcilier des données hétérogènes (structure moléculaire, profils précliniques réels) en exploitant les relations causales et directionnelles encodées dans le KG. Les arêtes de types (i) causales validées et (ii) directionnelles inférées, dont la fraction et la distribution par domaine thérapeutique seront caractérisées et rapportées dans le livrable L5.1.1. L'objectif est de fournir, pour une molécule entrant en phase I ou II, un profil B-R simulé comprenant : prédiction d'efficacité, profil de sécurité avec hiérarchisation des risques, comparaison aux thérapies existantes, estimation de l'incertitude, et visualisation interactive sous forme de Mental Map.

Travaux réalisés

Tâche 6.1 (M4 – M18) : Architecture du world model : Le world model repose sur une représentation en espace latent multimodal où chaque WP constitue une vue partielle et complémentaire du profil B-R d'une drogue. Ces vues sont de nature fondamentalement différente (structure moléculaire, transposabilité préclinique, variants génomiques, signaux RWE) et ne sont pas supposées partager un espace latent commun a priori. L'architecture est donc conçue pour traiter l'absence de modalités comme le cas par défaut : chaque module fonctionne de façon dégradée mais robuste lorsque certaines sources de données sont indisponibles, ce qui est la situation la plus fréquente pour les molécules en développement précoce. Chaque drogue est encodée comme un vecteur latent z_{drug} (représentation de la drogue dans l'espace latent moléculaire) issu d'un encodeur pré-entraîné sur la Profiling Base. Le nombre de molécules disposant simultanément de données dans les quatre WPs est estimé à 200-800 (molécules approuvées avec données structurales, précliniques, pharmacogénomiques et post-AMM documentées), volume suffisant pour calibrer le module d'intégration de second niveau, mais insuffisant pour entraîner un espace latent partagé profond. L'architecture retenue traite donc explicitement les modalités manquantes via des embeddings de remplacement et des masques d'attention, garantissant des prédictions robustes y compris pour les molécules en développement précoce disposant uniquement de données structurales (fingerprints moléculaires, descripteurs ADMET, profils d'activité cible). Chaque patient est représenté par un vecteur z_{pat} intégrant données démographiques, comorbidités, co-médications et variants pharmacogénomiques. Le contexte pathologique est encodé via un vecteur z_{path} extrait du sous-graphe WP5 correspondant (topologie locale du KG autour de la pathologie d'intérêt). La fusion de ces représentations s'opère par un module d'attention multimodale (cross-modal attention) : chaque source de prédiction (WP1-4) est traitée comme un token d'évidence portant un embedding, un score de confiance et une provenance. Le mécanisme d'attention apprend à pondérer ces tokens en fonction du contexte (pathologie, type de molécule, données disponibles). Le module temporel ne sera développé que si les données longitudinales du WP4 fournissent un suivi ≥ 12 mois par molécule. À défaut, la dynamique temporelle sera traitée via des features agrégées (durée d'exposition, dose cumulée). Le WP6 revendique un pré-entraînement sur 100 milliards de relations. Le WP5 cible ~ 1 million de relations en fin de projet. Ces chiffres sont incohérents d'un facteur $\sim 100\,000$. Le document doit clarifier ce qui est réellement utilisé pour le pré-entraînement. Les Contextualizing SLMs, entraînés par des cliniciens sur des corpus réglementaires et de pharmacovigilance, fournissent les embeddings textuels des événements indésirables, des mécanismes d'action et des endpoints cliniques, garantissant que l'espace latent du world model est ancré dans un vocabulaire clinique validé. Cette fondation en données propriétaires massives est ce qui rend crédible un world model opérationnel dans le calendrier du projet : le pré-entraînement est largement réalisé, le projet i-Démo finance la couche d'intégration et de raisonnement causal.

Tâche 6.2 (M13 – M18) : Intégration en Ensemble des WP1-4 : Les prédictions de WP1 (structure-activité), WP2 (préclinique), WP3 (génomique) et WP4 (RWE) ne sont pas moyennées. Le module d'intégration implémente une méta-apprenante (stacking) où les prédictions individuelles et leurs intervalles de confiance sont les features d'un modèle de second niveau. Ce modèle apprend les schémas de concordance et de contradiction entre WPs. Lorsque deux WPs divergent significativement (ex. WP1 prédit faible risque hépatotoxique, WP4 détecte un signal FAERS), un module de résolution de conflit est activé : il interroge le KG (WP5) pour identifier si une variable confondante (ex. co-médication hépatotoxique fréquente en RWE) explique la divergence, et propage l'incertitude résiduelle vers la sortie finale. Cette approche est fondamentalement supérieure à un vote



GOVERNEMENT

Liberté
Égalité
Fraternité



bpifrance

e pondérée fixe.

Modélisation Causale et Prédiction des Interactions : Le world model intègre un Structural Causal Model (SCM) dont la topologie est initialisée à partir des arêtes de types (i) causales inférées du KG (WP5, T5.3) et (ii) directionnelles inférées du KG (WP5, T5.3). Ce sous-graphe causal, explicitement délimité lors de la construction du KG, constitue le squelette du SCM ; ses paramètres sont ensuite estimés par les données WP1-4. Cette approche garantit que le raisonnement causal du world model repose sur des relations à évidence interventionnelle ou mécanistique, et non sur de simples co-occurrences. Les paramètres sont estimés par les données WP1-4. Ce SCM permet : (i) la simulation d'interactions médicamenteuses (drug-drug interactions, DDI) en combinant données moléculaires (inhibition enzymatique CYP, compétition au site de liaison) et signaux RWE (co-prescription observée + événements associés) ; (ii) la prédiction d'interactions gène-médicament (pharmacogénomique) en intégrant les variants identifiés en WP3 avec les voies métaboliques du KG ; (iii) la simulation dose-réponse et temps-vers-événement (time-to-event) via des modèles de survie paramétriques conditionnés par les variables latentes du world model. Le raisonnement contrefactuel est opéré par intervention sur les noeuds du SCM (ex. do(CYP2D6 = poor metabolizer)) et propagation des effets dans le graphe, permettant de répondre à des questions du type "quel profil de sécurité pour cette molécule si le patient était un métaboliseur lent ?".

Tâche 6.4 (M19 – M30) : Quantification de l'Incertitude : L'incertitude est modélisée à deux niveaux. Le coût computationnel de cette approche est maîtrisé par une stratégie d'inférence optimisée : les ensembles de modèles (10 répliques) sont évalués en parallèle sur GPU, et l'approximation variationnelle bayésienne est limitée aux couches critiques du modèle, réduisant le surcoût de calcul à moins de 30 % par rapport à une inférence déterministe standard. Au niveau épistémique (incertitude liée aux données insuffisantes) : ensembles de modèles (deep ensembles, 10 répliques avec initialisation différente) et approximation variationnelle bayésienne sur les couches critiques. Au niveau aléatoire (variabilité intrinsèque) : modélisation hétéroscédastique des résidus. La sortie du world model est donc un profil B-R probabiliste : pour chaque événement prédit, un intervalle de confiance et une décomposition des sources d'incertitude (données moléculaires limitées vs. signal RWE contradictoire vs. faible couverture KG). Cette décomposition est essentielle pour l'interprétabilité et pour guider le pharmacien/clinicien vers les zones nécessitant une investigation complémentaire.

Tâche 6.5 (M19 – M30) : Interface de Visualisation – Mental Map : La Mental Map est une interface frontend interactive, développée comme composant applicatif autonome consommant l'API WP5 (T5.5) et les profils B-R probabilistes produits par T6.2-6.4. Elle projette le profil B-R d'une molécule sous forme de réseau navigable, avec une architecture frontend découplée du moteur de prédiction pour garantir l'indépendance des cycles de développement et la maintenabilité à long terme. Elle sera représentée avec la molécule au centre connectée à ses cibles thérapeutiques, elles-mêmes liées aux voies métaboliques perturbées, débouchant sur les résultats cliniques (efficacité et effets indésirables). Chaque nœud et chaque arête portent leur score de confiance, leur provenance (WP d'origine, source de données), et leur niveau de preuve. L'utilisateur peut filtrer par type de données, par seuil de confiance, par sous-population patient, ou simuler un scénario contrefactuel (ajout d'une co-médication, changement de variant génomique). La Mental Map est conçue pour être utilisable par un évaluateur réglementaire, un pharmacovigilant ou un clinicien investigateur sans formation spécifique en data science.

Tâche 6.6 (M31 – M36) : Validation et Calibration : La validation est conduite en deux phases. Phase rétrospective : le world model est évalué sur un jeu de ≥ 200 molécules commercialisées ou retirées du marché, dont les profils B-R réels sont connus. Ce seuil de 200 molécules est cohérent avec les standards de validation des plateformes de prédiction B-R publiées dans la littérature, et sera appliqué de façon homogène à chaque WP pour permettre une comparaison directe des performances entre niveaux de résolution prédictive. Les métriques sont : AUC-ROC pour la prédiction d'EIG sévères (objectif cible $> 0,8$ en validation externe), taux de faux négatifs $< 10\%$ pour les DDI connues, et évaluation qualitative par un panel d'experts (objectif cible : $> 70\%$ des prédictions jugées "cliniquement plausibles"). Phase prospective :



GOVERNEMENT

Liberté
Égalité
Fraternité



elles sur des molécules en développement chez les partenaires (Sa
on longitudinale entre prédiction et observations de pharmacovig
lra sur la validation des méthodologies d'évaluation.

bpi**france**

Livrables

L6.1 (M18) : Architecture du world model validée, encodeurs pré-entraînés opérationnels, prototype d'intégration d'ensemble sur cancer du poumon.

L6.2 (M30) : Module d'interactions (DDI, gène-drug), module d'incertitude, prototype Mental Map fonctionnel.

L6.3 (M36) : World model opérationnel intégrant WP1-5, rapport de validation rétrospective (≥ 200 molécules), rapport de validation prospective (monitoring partenaires), tests d'acceptation utilisateur avec ≥ 5 partenaires pharmaceutiques.

L6.4 (M36) : Documentation utilisateur, matériaux de formation, système déployable avec quantification d'incertitude.

Description des dépenses

Dépenses de sous-traitance	AMI Labs : 60 k€ pour validation méthodologique et évaluation indépendante. Sanofi : 50 k€ pour validation clinique prospective sur cas d'usage réels. Total : 110 k€
Dépenses des achats	Infrastructure GPU haute performance (A100/H100), licences logicielles de visualisation, outils de monitoring ML. Total : 50 k€
Contribution aux amortissements	Serveurs GPU dédiés à l'entraînement du world model et aux deep ensembles. Total : 40 k€

3.7. LOT 7

Lot n°:	7	Durée :	T0 + 36 mois
Intitulé du lot :	Management du projet		
Nature du lot :	ADM		
Coût total du lot :	160 k€		

Objectifs

Ce work package vise à assurer la coordination globale du projet, le suivi administratif et scientifique, la diffusion des résultats, le développement des partenariats industriels nécessaires aux phases de test, ainsi que la gestion de la propriété intellectuelle issue des travaux de R&D.

Travaux réalisés

Tâche 7.1 (M1 – M36) : Reporting et suivi du projet : ArcaScience assurera la coordination globale du projet et le suivi de son avancement scientifique, technique et financier. Cette tâche comprend la préparation des rapports périodiques à destination de l'organisme financeur, le suivi des jalons et des livrables, ainsi que la consolidation des contributions des différents work packages. Des réunions de pilotage régulières seront organisées afin de suivre l'avancement des travaux, identifier les éventuels écarts par rapport au planning initial et mettre en place



GOVERNEMENT

Liberté
Égalité
Fraternité



bpi**france**

aires.

Dissémination et valorisation scientifique : ArcaScience assurera la diffusion des technologies issus du projet. Cette dissémination passera notamment par la participation à des congrès internationaux et à des conférences scientifiques dans les domaines de l'intelligence artificielle et de la recherche biomédicale. L'objectif est de présenter les avancées méthodologiques développées dans le cadre du projet et de renforcer la visibilité de la solution auprès de l'écosystème académique et industriel.

Tâche 7.3 (M1 – M24) : Discussions partenariales avec l'industrie pharmaceutique : ArcaScience mènera des discussions avec des entreprises pharmaceutiques et des sociétés de biotechnologie afin d'identifier des partenaires industriels pour les phases de test prévues dans le WP6. Ces échanges permettront de sélectionner des actifs pertinents pour l'évaluation de la plateforme et de définir les modalités de collaboration, notamment en ce qui concerne l'accès aux données et les conditions d'évaluation des analyses produites.

Tâche 7.4 (M1 – M36) : Gestion de la propriété intellectuelle : ArcaScience mettra en œuvre les actions nécessaires à la protection des innovations développées dans le cadre du projet. En cohérence avec la stratégie de propriété intellectuelle de l'entreprise, cette tâche comprendra la veille permanente afin de garantir la liberté d'exploitation tout au long du projet, la préparation des éléments techniques et scientifiques nécessaires, ainsi que la rédaction des dossiers de dépôt. Ces travaux viseront à permettre le dépôt des deux brevets correspondant aux principales innovations développées dans le cadre du projet.

Livrables

L7.1 (T0 + 6 mois, soit 11/2026, puis semestriel) : Rapports de suivi du projet

L7.2 (T0 + 12 mois, soit 05/2027, puis annuel) : Synthèse des actions de diffusion et de valorisation

L7.3 (T0 + 36 mois, soit 04/2029) : Deux brevets déposés correspondant aux principales innovations du projet

Description des dépenses

Dépenses de sous-traitance	Cabinets de propriété intellectuelle et conseil réglementaire pour la préparation et le dépôt des brevets. Total : 20 k€
Dépenses des achats	Inscriptions congrès, frais de publication, outils de veille PI. Total : 5 k€
Contribution aux amortissements	Outils de gestion de projet et de reporting. Total : 5 k€

RETOMBÉES ÉCONOMIQUES

4. EXPLOITATION INDUSTRIELLE ET COMMERCIALE DES RÉSULTATS DU PROJET

4.1. STRATÉGIE D'INDUSTRIALISATION DES RÉSULTATS DU PROJET

STRATÉGIE DE DÉVELOPPEMENT TECHNOLOGIQUE

Le programme i-Démo se terminera le **30 avril 2029**. À cette date, ArcaScience aura démontré les capacités de sa plateforme au moyen d'un cas d'usage portant sur le cancer du poumon.

Les performances associées à la validation obtenue dans le cas d'usage du cancer du poumon serviront de base pour la plateforme et constitueront également une base de discussion avec les entreprises pharmaceutiques.

Une fois l'ancrage comme outils d'aide aux développements des médicaments sécurisés auprès des entreprises pharmaceutiques, **ArcaScience** continuera ses travaux de R&D sur deux axes complémentaires :

- **L'intégration de nouveaux modules**, afin d'étendre les cas d'usage couverts par la plateforme pour se rapprocher d'un accompagnement de plus en plus complet
- **L'intégration de nouvelles sources de données**, permettant de développer de nouveaux modèles ou d'élargir les aires thérapeutiques prises en charge par la solution.

A long terme, la plateforme doit converger vers deux livrables majeurs : une stratégie "tout oncologie" opérationnelle et un module immuno-inflammation prêt à l'exploitation. La roadmap positionne l'extension de **BR-Predict** à **l'ensemble des segments oncologiques entre 2029 et 2031**, puis l'extension en **immuno-inflammation entre 2030 et 2032**, jalonnant la montée en maturité depuis le démonstrateur jusqu'à la couverture de portefeuilles larges, avec une ouverture à **d'autres aires thérapeutiques** à partir de **2029** par enrichissements incrémentaux de sources et activation de briques spécialisées lorsque la valeur clinique le justifie.

En parallèle, la stratégie consiste à étendre les cas d'usage en développant des modules additionnels le long du schéma de développement des médicaments notamment les essais cliniques in silico en amont pour éclairer les choix de protocole et la priorisation d'actifs. Cette extension modulaire, permet d'industrialiser l'usage "molécule par molécule" via contrats-cadres, d'abord en oncologie et en immuno-inflammation, puis par diffusion graduée aux aires thérapeutiques à forte dynamique, sans refonte d'architecture grâce au socle générique stabilisé en 2026–2028.

STRATÉGIE ET CONDITIONS RÉGLEMENTAIRES D'ACCÈS

La **récupération des données** par la plateforme **ArcaScience** s'effectue dans un **cadre conforme au RGPD** et aux exigences applicables aux données de santé. Les sources sont identifiées et documentées, les finalités définies en amont et limitées aux cas d'usage validés. Les données sont pseudonymisées dès l'ingestion et intégrées selon une logique de minimisation. Lorsque la plateforme est déployée on premises chez le client, la souveraineté et la maîtrise des flux restent intégralement sous son contrôle.



GOVERNEMENT

*Liberté
Égalité
Fraternité*



bpifrance

onnées, cœur technologique de la plateforme, repose sur des données garantissant intégrité, traçabilité et auditabilité. Les données sont conformes de 21 CFR Part 11 et respectent les principes ALCOA+. Les analyses sont conformes aux standards ICH E6 et ICH E9, et les modules IA intègrent des mécanismes d'explicabilité et de documentation des performances, en cohérence avec les attentes des autorités concernant l'usage de l'IA en support décisionnel.

Le stockage et la sécurisation des données sont assurés par un chiffrement en transit et au repos, ainsi que par une gestion stricte des habilitations et des journaux d'accès. L'hébergement peut être réalisé sur des infrastructures conformes aux exigences HDS ou directement sur les serveurs du client. Les durées de conservation sont définies en fonction des finalités analytiques, avec des mécanismes de purge maîtrisés.

Le déploiement de la plateforme chez les clients intègre un niveau de sécurité conforme aux standards industriels internationaux applicables aux données de santé. Les données sont chiffrées en transit (TLS 1.2 ou supérieur) et au repos via un chiffrement de type AES-256. Les environnements sont cloisonnés par conteneurisation et orchestrés via Kubernetes, avec gestion fine des habilitations, journalisation des accès et revues périodiques des droits.

L'architecture est conçue pour s'aligner avec les exigences réglementaires applicables aux marchés adressés. En Europe, la conformité RGPD et, le cas échéant, l'hébergement HDS sont assurés. Dans une perspective de déploiement aux États-Unis, l'infrastructure est compatible avec les exigences HIPAA relatives à la protection des données de santé (PHI), notamment en matière de contrôle d'accès, d'auditabilité, de chiffrement et de gestion des incidents.

La solution peut être déployée on premises sur l'infrastructure du client ou dans un environnement cloud sécurisé conforme aux standards du secteur, garantissant souveraineté, traçabilité et maîtrise complète des flux de données par le client.

Les livrables générés par Trial Balancer et BR-Predict sont structurés pour être directement exploitables dans le cadre réglementaire du développement du médicament. L'analyse bénéfice/risque suit une approche formalisée compatible avec le cadre BRAT et avec la structuration attendue dans le CTD. En pharmacovigilance, l'identification des signaux est alignée avec les Bonnes Pratiques de Pharmacovigilance. La plateforme intervient ainsi comme outil d'aide à la décision, en renforçant la conformité, la traçabilité et la qualité documentaire sans modifier les protocoles imposés par les autorités.

En ce qui concerne le positionnement réglementaire initial et la trajectoire SaMD, la plateforme BR-Predict est positionnée initialement comme un outil de recherche et d'aide à la décision (Research Use Only / Decision Support Tool), et non comme un dispositif médical de diagnostic. Ce positionnement permet une mise sur le marché rapide sans certification SaMD/MDR, tout en préparant la trajectoire réglementaire future.

La conformité progressive est planifiée en trois phases :

Phase	Période	Statut réglementaire	Actions
1	2026-2028 (i-Démo)	Research Use Only	Développement conforme aux principes de qualité logicielle (IEC 62304), traçabilité, reproductibilité

 GOVERNEMENT <i>Liberté</i> <i>Egalité</i> <i>Fraternité</i>	Pré-qualification SaMD	 FRANCE Contact Innovation Tool A Regulatory Sandbox ou pré-soumission FDA Drug 
3	2031+	Qualification SaMD classe I/IIa Soumission MDR, qualification FDA DDT selon les performances EC3

L'architecture on-premise, la traçabilité complète des données et la quantification de l'incertitude (WP6) sont conçues dès le départ pour être compatibles avec les futures exigences réglementaires de l'AI Act européen et du cadre SaMD.

STRATÉGIE DE PROTECTION INTELLECTUELLE

À la clôture du programme i-Démo (période projet 2026-2028), ArcaScience aura constitué un portefeuille PI articulé autour de **deux dépôts de brevets**, couvrant d'une part le pipeline clinique holistique et ses 24 modèles d'IA, et d'autre part le Large World Model (LWM) et ses déclinaisons Latent World Models, conformément à la trajectoire technique prévue et aux jalons de performance atteints pendant le projet.

Le **premier brevet** concerne le **pipeline clinique holistique et architecture multi-modèles** (cible **2026-2027**). Ce premier dépôt sécurise l'antériorité et le périmètre des revendications sur l'intégration/normalisation des données, le protocole d'annotation, les logiques de prédiction et les outils d'aide à l'évaluation bénéfice/risque couvrant l'architecture des **24 modèles d'IA**. Le dépôt interviendra dès que les preuves de fonctionnement et validations génériques seront franchies (MS1 AUC > 0,6 ; MS2 AUC > 0,75), puis une extension géographique sera engagée en **phase d'industrialisation (2027-2028)** pour couvrir les marchés cibles prioritaires.

Le **second dépôt** protégera l'originalité algorithmique du **LWM** et des **Latent World Models**, distincte des modèles IA « classiques ». Il sera engagé lorsque l'architecture complète intégrant le knowledge graph et les données de vie réelle sera stabilisée (MS3) et que les modèles unifiés atteindront les niveaux de performance visés (MS4).

La base de données propriétaire (architecture/structure) est protégée par le droit d'auteur, et les éléments non brevetables à haute valeur, architecture interne du pipeline, mécanismes de cohérence des données, paramètres et workflows d'inférence des 24 modèles, relèvent d'un secret d'affaires documenté (politiques d'accès, procédures internes, journalisation). Un **escrow privé annuel** est maintenu pour le code et les modèles (2026, 2027, 2028), garantissant l'opposabilité et la continuité d'exploitation. Les déploiements **on-premises** limitent le risque de fuite d'actifs PI et renforcent la souveraineté des données chez les clients.

4.2. STRATÉGIE DE COMMERCIALISATION ET PROJECTION DE REVENUS

STRATÉGIE D'ACCES MARCHÉ

Stratégie de commercialisation

ArcaScience s'inscrit pleinement dans l'évolution actuelle du marché pharmaceutique en proposant une évaluation du bénéfice/risque à la fois rapide, structurée et stratégique. La plateforme accompagne la prise de décision tout au long du cycle de développement en permettant une priorisation plus rapide



GOVERNEMENT

Liberté
Égalité
Fraternité



bpi france

tion de stratégies de positionnement pour des actifs
bilité de succès des programmes cliniques.

rché est conçue pour s'intégrer étroitement aux modes de fonctionnement
des organisations pharmaceutiques. **ArcaScience** ne vise pas à remplacer les outils existants au sein des
directions R&D. La solution apporte des **analyses complémentaires** qui **s'insèrent naturellement dans
les workflows actuels** et dans les processus décisionnels déjà en place. Cette approche limite les
frictions organisationnelles et facilite l'adoption.

Initialement positionnée auprès des CRO et des grandes entreprises pharmaceutiques, la société
capitalisera sur les capacités de son nouveau module, agissant sur des phases plus en amont dans le
développement du médicament, pour développer son positionnement auprès de **l'ensemble des
entreprises** disposant d'un **portefeuille d'actifs étendu dans les aires thérapeutiques couvertes par la
solution** :

- Renforcement de son positionnement auprès des grandes entreprises pharmaceutiques ;
- Accès au marché des entreprises pharmaceutiques de taille intermédiaire et des grandes
entreprises de biotechnologie.

La stratégie de commercialisation de la société consiste à capitaliser sur le module Trial Balancer, déjà
positionné auprès de grandes entreprises pharmaceutiques comme Sanofi et AstraZeneca. ArcaScience
renforcera ces partenariats en parallèle du programme i-Démo afin de faire levier pour promouvoir son
nouveau module BR-Predict.

En parallèle du **renforcement des partenariats existants**, ArcaScience mènera des actions de
dissémination ciblées auprès d'un périmètre élargi d'industriels, notamment lors de congrès spécialisés
et au sein de l'écosystème Future4Care. Cette approche vise à **accroître la visibilité** de la plateforme au-
delà des clients existants, et notamment auprès d'une cible de clients biotech encore non adressée par
le module actuel d'ArcaScience.

La société proposera initialement à ses clients actuels et futurs de réaliser un **POC sous forme de
prestation de services à prix réduit, avant de proposer l'installation de sa solution SaaS**. Cette
approche par étapes facilite l'alignement interne des équipes cliniques, réglementaires et stratégiques,
et ouvre la voie à la mise en place d'accords-cadres, notamment pour l'intégration du module **BR-
Predict**. La mise en place de ces accords-cadres favorisera la diffusion de l'approche ArcaScience et
permettra de capter de nouveaux clients.

En parallèle, l'exploitation du modèle pathogénérique de la plateforme permettra de se développer sur
de nouvelles aires thérapeutiques à très forte dynamique, notamment en oncologie et en immuno-
inflammatoire.

La progression sur les plans technologique et commercial permettra à la société d'étendre son champ
d'action, avec une expansion internationale. ArcaScience visera en priorité les **États-Unis** afin d'y établir
plusieurs contrats-cadres.

1.1.2. MODÈLE ÉCONOMIQUE ET PRICING

La stratégie économique d'**ArcaScience** repose sur la signature de contrats cadres avec les sociétés
pharmaceutiques et biotechnologiques clientes. L'objectif est d'installer directement chez ces acteurs
une plateforme logicielle opérée en mode **SaaS**, déployée sur leur propre infrastructure afin de garantir

En amont de l'installation de la plateforme, **ArcaScience** propose une offre de service permettant au client de tester concrètement la valeur scientifique et opérationnelle de la solution. Cette phase correspond à un proof of concept visant à **démontrer la capacité de la plateforme à analyser un type d'actif donné** (par exemple petites molécules, biologiques ou thérapies cellulaires) dans un contexte pathologique proche. L'objectif n'est donc pas d'évaluer une molécule isolée, mais de démontrer la pertinence de la plateforme pour une classe d'actifs et une famille de pathologies. Par exemple, dans le domaine de l'immunologie, un proof of concept peut être réalisé sur des pathologies proches comme la maladie de Crohn et la rectocolite hémorragique pour des petites molécules. Si les résultats sont jugés probants, le client peut décider d'installer la plateforme en mode SaaS et de l'intégrer dans ses processus décisionnels.

Le module Trial Balancer constitue la base de la solution ArcaScience. Il permet de réaliser les analyses bénéfice-risque comparatives nécessaires à l'évaluation d'un candidat médicament. Une première phase de proof of concept est proposée pour un montant de **75 k€**, permettant de démontrer la pertinence de ces analyses dans un contexte donné. Une fois la valeur démontrée et la plateforme déployée, la tarification s'établit à environ **125 k€** par licence annuelle.

Le module **BR-Predict** vient s'ajouter à cette base logicielle. Il introduit une couche supplémentaire de données et d'analyses permettant d'anticiper plus précocement le profil bénéfice-risque des candidats médicaments. Ce module ne peut fonctionner qu'en **complément du module Trial Balancer**, dont il utilise l'ensemble des briques logicielles et analytiques. Il est donc proposé comme un add-on à la solution existante pour un montant supplémentaire de **125 k€**. Le coût total d'utilisation du module BR-Predict s'élève ainsi à environ **250 k€** par molécule analysée.

Ce modèle économique présente un caractère fortement structurant pour la croissance d'ArcaScience. Les proof of concept permettent de démontrer la pertinence de la plateforme pour une classe d'actifs et un ensemble de pathologies proches. Une fois cette étape franchie, les industriels peuvent déployer la solution et l'utiliser directement sur plusieurs molécules de leur portefeuille. Dans ce modèle, chaque molécule analysée correspond à une licence, ce qui crée une dynamique d'usage récurrent et potentiellement pluriannuelle au sein des mêmes organisations.

Voici plusieurs indicateurs clés du modèle SaaS :

Métrique	Valeur actuelle (2025)	Cible 2028	Benchmark SaaS B2B
Taux de conversion POC → licence	100 % (2/2 : Biocodex, Dilon)	> 60 %	20-40 % (SaaS B2B moyen)
Valeur moyenne par client (ACV)	125 k€ (Trial Balancer seul)	250 k€ (TB + BR-Predict)	80-150 k€ (SaaS healthtech)
Coût d'acquisition client (CAC)	~30 k€ (POC + démo)	~40 k€	50-100 k€ (entreprise SaaS)

	> 10x (licence récurrente)	> 8x	> 3x (\$
	0 % (aucun client perdu à date)	< 10 %/an	5-15 % (SaaS B2B)
NRR (Net Revenue Retention)	> 150 % (Biocodex : 20k → 126k, Sanofi : multi-contrats)	> 130 %	> 110 % (bon SaaS)

Le taux de conversion POC de 100 % (2/2) est un indicateur exceptionnel qui mérite d'être mis en avant. Il démontre que la valeur perçue par les clients lors du POC est suffisante pour déclencher systématiquement un engagement contractuel. Ce ratio est significativement supérieur aux benchmarks du secteur SaaS B2B (20-40 %).

Williness to pay

Les laboratoires pharmaceutiques doivent en permanence arbitrer entre plusieurs actifs à faire entrer en clinique et décider où concentrer leurs ressources financières et humaines afin de maximiser leurs probabilités de succès. Ces choix structurants reposent aujourd'hui sur des analyses longues, coûteuses et parfois fragmentées, alors même que chaque décision d'engagement en phase II ou III représente plusieurs dizaines à centaines de millions d'euros d'exposition au risque.

Dans ce contexte, la disposition à payer des industriels repose sur un raisonnement économique direct : **tout outil capable d'améliorer la priorisation des molécules, de sécuriser le positionnement clinique et d'augmenter la probabilité de succès d'un programme génère une valeur immédiatement mesurable**. Une meilleure sélection des actifs en amont permet d'éviter des essais non pertinents, d'optimiser les protocoles et de réduire les amendements tardifs, avec un impact significatif sur les coûts et les délais.

La solution ArcaScience répond précisément à cette attente en fournissant une évaluation bénéfice/risque rapide, structurée et stratégique, complémentaire des outils déjà en place au sein des directions R&D. Elle ne se substitue pas aux systèmes existants mais apporte une couche décisionnelle supplémentaire, directement exploitable dans les comités de priorisation et les revues de pipeline.

Le modèle commercial, progressif et modulaire, renforce cette disposition à payer. La possibilité de démarrer par un proof of concept limite le risque d'adoption et permet aux industriels d'évaluer concrètement la valeur générée avant un déploiement élargi. La tarification par molécule analysée est cohérente avec les budgets déjà alloués aux analyses stratégiques et reste marginale au regard des montants engagés dans un programme clinique.

En permettant un développement plus ciblé, plus rapide et moins risqué, la plateforme génère une valeur économique directe pour les industriels. Cette création de valeur tangible constitue le principal moteur de la traction commerciale observée auprès des grands acteurs pharmaceutiques.

1.1.3. PROJECTION DE REVENUS ET CONSTRUCTION DU CHIFFRE D'AFFAIRES


Construction du Chiffre d'affaires

Années	2026	2027	2028	2029	2030
Module Trial Balancer					
Nombre de PoC	4	9	18	26	34



GOVERNEMENT

*Liberté
Égalité
Fraternité*



bpifrance

	7	14	22	32	62
	300	675	1 350	1 950	2 550
CA Trial Balancer (en K€)	625	1 312	2 250	3 375	5 875
CA Total (en K€)	925	1 987	3 600	5 325	8 425
Module BR-Predict					
Nombre de PoC			2	10	46
Nombre de molécule		1	2	9	22
CA molecule (en K€)			125	750	3 500
CA projet (en K€)		75	225	825	2 325
CA BR-Predict (en K€)		75	350	1 575	5 825
CA Total (en K€)	925	2 062	3 950	6 900	14 250

L'évolution du chiffre d'affaires prévisionnel d'ArcaScience reflète une stratégie de déploiement progressive de la plateforme et de ses modules analytiques. Les revenus passent ainsi de **0,5 M€ en 2025 à 4,3 M€ en 2028**, période durant laquelle la croissance est principalement portée par l'adoption du module Trial Balancer et par l'élargissement progressif de la base clients. À partir de **2029**, le lancement commercial du module **BR-Predict** entraîne une accélération de la croissance, avec un chiffre d'affaires atteignant **8,3 M€ en 2029 puis 19,1 M€ en 2030**. La trajectoire se poursuit ensuite avec une montée en puissance des licences logicielles, conduisant à un chiffre d'affaires de **32,1 M€ en 2031 puis 51,5 M€ en 2032**. Un TCAC agressif de 84% sur 3 ans est soutenu par une croissance exceptionnelle du secteur (Accroissement de l'usage de l'IA en pharma, IDC, 2025), associé au positionnement unique de sa solution dans un environnement concurrentiel uniquement dominé par des sociétés de service américaines et anglaises subissant de plein fouet la bascule vers des technologies IA (Olwad D.B, et al., 2025).

La première phase de croissance repose principalement sur le module Trial Balancer, qui cible des molécules plus matures dans les portefeuilles R&D. Ces actifs étant moins nombreux, la stratégie consiste d'abord à élargir progressivement la base clients en adressant les grandes biotechs, les mid-pharmas et les grands groupes pharmaceutiques. Cette dynamique commerciale permet d'**augmenter progressivement le nombre de molécules analysées**, qui passe **de 3 en 2025 à 20 en 2028**.

La seconde phase de croissance débute en 2029 avec le lancement commercial du module **BR-Predict** à l'issue du programme i-Démo. Avant cette date, les travaux correspondent principalement à des proof of concept et à des phases de validation technologique. À partir de **2029**, le module peut être intégré dans les **processus décisionnels** des laboratoires pour **l'évaluation précoce des candidats médicaments**, ce qui explique la montée progressive du nombre de licences sur la période 2029-2030.

La croissance s'accélère ensuite à partir de **2031** avec l'extension des aires thérapeutiques couvertes par la plateforme. À cette échéance, **ArcaScience** prévoit de disposer de modules analytiques opérationnels pour plusieurs indications majeures en **oncologie** ainsi que de premiers modèles en **immunologie** et dans les pathologies inflammatoires. Cet élargissement augmente fortement le nombre de molécules



GOVERNEMENT

Liberté
Égalité
Fraternité



bpi**france**

aduit par une hausse significative du nombre de licences associées. Le proof of concept reflète la maturation progressive du marché. Dans les premières années, les POC jouent un rôle central pour démontrer la valeur scientifique et opérationnelle de la plateforme. À mesure que la crédibilité technologique d'ArcaScience s'installe, les laboratoires devraient installer directement la plateforme pour leurs nouvelles molécules d'intérêt, chaque actif analysé donnant lieu à une licence d'utilisation. Les POC resteront toutefois nécessaires pour certaines extensions fonctionnelles, notamment lors de l'ouverture de nouvelles aires thérapeutiques.

IMPACTS SOCIÉTAUX ET ENVIRONNEMENTAUX

RETOMBÉES SOCIALES, SOCIÉTALES POUR LE TERRITOIRE NATIONAL

Le projet porté par ArcaScience présente un impact socio-économique structurant, à la fois sur l'accélération de l'innovation thérapeutique, sur l'organisation du développement clinique et sur la dynamique industrielle du territoire.

En permettant d'identifier plus précocement les candidats médicaments les plus prometteurs, la solution contribue à accélérer l'arrivée de thérapies innovantes sur le marché, en particulier pour des **populations médicalement délaissées**. En améliorant la priorisation des actifs et la robustesse des décisions en amont, le module BR-Predict participe à **réduire les délais de développement et à renforcer la probabilité de succès des programmes**. Cet effet d'accélération a un impact direct sur l'accès aux soins et sur l'amélioration de la qualité de vie des patients.

Le projet a également un impact sociétal fort en matière d'éthique des essais cliniques. Un essai de phase 1 mobilise généralement entre 10 et 50 volontaires sains, tandis qu'un essai de phase II peut inclure entre 50 et 300 patients, parfois davantage selon l'indication. En améliorant la sélection des candidats en amont, chaque essai évité grâce à une meilleure anticipation du profil bénéfice/risque peut permettre **d'épargner entre 10 et 300 personnes**, volontaires et patients confondus. La solution contribue ainsi à un développement pharmaceutique plus responsable, en limitant l'exposition inutile à des traitements à faible probabilité de succès.

Sur le plan économique et territorial, le projet prévoit la création directe de **47 emplois qualifiés**, incluant des ingénieurs en intelligence artificielle, des bioinformaticiens, des chefs de projet R&D et des profils spécialisés en affaires réglementaires. Il inclut également l'intégration de **4 doctorants** et la formation de **8 stagiaires par an** (alternants, jeunes diplômés). Au-delà de ces emplois directs, des retombées indirectes sont attendues auprès des sous-traitants technologiques et scientifiques, contribuant au renforcement de l'écosystème local en santé numérique et en intelligence artificielle appliquée au médicament.

Enfin, l'impact filière est significatif. En repositionnant l'analyse bénéfice-risque au cœur de la décision stratégique, ArcaScience transforme une contrainte historiquement perçue comme réglementaire en un levier industriel structurant. La solution offre aux entreprises pharmaceutiques une capacité renforcée de priorisation de leurs portefeuilles, contribuant à une allocation plus efficace des ressources R&D. Ce changement de paradigme favorise un développement pharmaceutique plus efficient, plus durable et plus compétitif à l'échelle internationale.

Ainsi, le projet s'inscrit dans une logique de transformation du modèle de développement du



GOVERNEMENT

Liberté
Égalité
Fraternité

des patients, des professionnels de santé, des industriels et



bpi**france**

INEMENTAL

Le projet BR-Predict génère des impacts environnementaux structurants. Il contribue d'une part à une rationalisation du développement pharmaceutique, qui permet de réduire les ressources mobilisées pour des projets à faible probabilité de succès, et d'autre part il facilite l'adaptation au changement climatique du système de santé en permettant de raccourcir les temps de développement des traitements.

Rationalisation du développement pharmaceutique et réduction des expérimentations inutiles

Le développement des médicaments est un processus long et fortement consommateur de ressources, mobilisant infrastructures de laboratoire, équipements analytiques, réactifs chimiques et consommables biologiques. Une part importante des candidats échoue à un stade avancé après des investissements expérimentaux significatifs. En permettant d'identifier plus précocement les candidats présentant un profil bénéfice/risque défavorable ou une probabilité de succès limitée, la plateforme BR-Predict contribue à **limiter la poursuite de projets peu viables**. Par ailleurs, l'exploitation et l'analyse de données scientifiques existantes permettent de **réduire la duplication d'études expérimentales déjà réalisées**. Cette capacité de priorisation et de valorisation des données contribue à concentrer les efforts sur les candidats réellement prometteurs et à éviter la mobilisation de ressources pour des programmes à faible probabilité de succès.

- **Réduction de la consommation de ressources et des déchets expérimentaux**

La rationalisation du développement thérapeutique se traduit ainsi par **une réduction des ressources nécessaires aux activités de R&D pharmaceutique**. Les phases précliniques et cliniques mobilisent en effet des volumes importants de **matières premières, de réactifs chimiques, de consommables plastiques et biomédicaux** ainsi que des infrastructures expérimentales énergivores. En limitant les expérimentations peu pertinentes, la solution contribue à réduire la consommation de ces ressources. Chaque étude préclinique ou essai clinique génère également des **déchets spécialisés importants (plastiques, réactifs, matériaux biologiques ou dispositifs médicaux à usage unique)**. En identifiant plus tôt les candidats non viables, la plateforme contribue indirectement à **limiter ces flux de déchets** dans les laboratoires et les centres d'investigation clinique.

- **Réduction de l'empreinte carbone de la R&D pharmaceutique**

Les programmes de développement mobilisent des essais multicentriques, des transports d'échantillons biologiques et des échanges logistiques entre partenaires scientifiques et industriels, **générant des émissions significatives**. Les analyses du cycle de vie estiment qu'un essai clinique multicentrique peut représenter de l'ordre de **1 000 à 10 000 tCO₂e** selon son ampleur et le nombre de sites impliqués (NHS Sustainable Development Unit ; Lancet Planetary Health). En améliorant la sélection des candidats médicaments et en limitant les projets poursuivis jusqu'à des phases avancées, la plateforme peut contribuer à éviter certaines de ces activités et les émissions associées. À l'inverse, l'empreinte carbone liée au fonctionnement des modèles d'intelligence artificielle reste généralement de l'ordre de **quelques tonnes de CO₂e par an** pour des modèles d'apprentissage automatique utilisés en bioinformatique (Patterson et al., 2021 ; Lacoste et al., 2019). Ainsi, si la plateforme permet d'éviter ou d'interrompre plus précocement ne serait-ce qu'un seul programme de développement à faible probabilité de succès,

L'analyse prédictive des profils de sécurité et d'efficacité des candidats médicaments peut également contribuer à orienter plus efficacement les programmes de recherche et à concentrer les études expérimentales sur les molécules les plus prometteuses. Cette approche peut conduire à limiter certains essais exploratoires, notamment les études animales en phase préclinique. Elle s'inscrit dans la logique des principes internationaux des « 3R » (Reduce, Replace, Refine) visant à réduire le recours aux modèles animaux lorsque cela est scientifiquement possible.

- **Réduction des résidus pharmaceutiques liés aux médicaments inefficaces ou abandonnés tardivement**

En améliorant la sélection des candidats médicaments et leur profil bénéfice/risque, la plateforme peut contribuer à éviter le développement ou la mise sur le marché de molécules présentant un profil défavorable, y compris en termes de toxicité. Une meilleure sélection en amont peut donc limiter la diffusion de substances pharmaceutiques dans les milieux aquatiques via les effluents hospitaliers et domestiques.

Contribution indirecte à l'adaptation du système de santé aux évolutions environnementales

Enfin, en améliorant la capacité d'analyse et de décision dans les phases précoces du développement thérapeutique, la plateforme peut contribuer à accélérer l'identification et l'évaluation de nouveaux candidats médicaments. Cette accélération du processus de développement peut renforcer la capacité du système de santé à répondre plus rapidement à l'évolution des pathologies et aux nouveaux besoins de santé, dont certains peuvent être influencés par les transformations environnementales et climatiques. La solution participe ainsi indirectement à la capacité d'adaptation du développement pharmaceutique face aux évolutions sanitaires liées au changement climatique.

En synthèse, le projet BR-Predict génère des impacts positifs liés à l'optimisation du processus de développement pharmaceutique. En réduisant le nombre d'expérimentations inutiles, en limitant la consommation de ressources expérimentales, en diminuant les volumes de déchets associés aux activités de recherche et en contribuant à rationaliser les programmes de développement, la solution participe à l'émergence d'un modèle de recherche pharmaceutique plus efficient et plus responsable sur le plan environnemental.

ELÉMENTS FINANCIERS

IMPACT SUR LE COMPTE DE RÉSULTATS PRÉVISIONNEL

PLAN DE FINANCEMENT



GOVERNEMENT

Liberté
Égalité
Fraternité

DE DÉPENSES ESTIMÉES



bpi**france**

t d'ArcaScience sur les trois prochaines années correspondent principalement
saires au développement technologique de la plateforme, au renforcement
de l'équipe scientifique et technique et à la structuration progressive de l'activité commerciale.

Sur la période du projet, il est estimé à **16 042 k€**, la structure des dépenses se répartit selon les grandes catégories suivantes :

- **Ressources humaines : 13 218 K€ – 83 %** : Cette catégorie constitue la part principale des dépenses. Elle correspond au recrutement progressif de profils scientifiques, techniques et data nécessaires au développement des différents modules de la plateforme, ainsi qu'au renforcement des équipes d'ingénierie logicielle et d'intelligence artificielle.
- **Activité de marketing : 761 K€ – 4 %** : Ce coût évolue graduellement tout au long du projet avec le scale-up de l'activité marketing, en adéquation avec la stratégie de mise sur le marché et d'expansion de la clientèle.
- **Autres dépenses opérationnelles : 2 063 K€ – 13 %** : Cette catégorie regroupe les dépenses de fonctionnement nécessaires à l'activité de l'entreprise, notamment les coûts liés au développement logiciel, aux outils technologiques, aux frais de structure ainsi qu'aux activités de développement commercial et marketing associées à la mise sur le marché progressive de la solution.

L'évolution de ces besoins de financement est principalement liée à la croissance de l'équipe au cours des prochaines années. Les dépenses de ressources humaines augmentent progressivement afin de soutenir les activités de R&D et l'industrialisation de la plateforme. Par ailleurs, les dépenses liées au marketing et au développement commercial augmentent à mesure que la stratégie de go-to-market se déploie et que l'entreprise élargit sa base de clients. Les autres dépenses restent principalement liées aux besoins opérationnels de l'activité et au maintien de l'infrastructure technologique.

STRATÉGIE DE FINANCEMENT SUR LA DURÉE DU PROGRAMME

La stratégie de financement d'ArcaScience repose sur une combinaison de subventions publiques, d'une levée de fonds privée et de la montée progressive des revenus générés par l'activité commerciale de la plateforme. L'objectif est de sécuriser les ressources financières nécessaires au développement technologique et au déploiement commercial de la solution jusqu'à l'atteinte du point d'équilibre financier prévu à l'horizon **2030**.

Subventions publiques

Les financements publics constituent un levier structurant pour soutenir les activités de recherche et développement de la plateforme au cours des premières années.

Dans ce cadre, ArcaScience bénéficie tout d'abord du dispositif **Innov'Up**, qui contribue au financement des premières briques technologiques du projet.

- **Innov'Up – prêt d'amorçage : 283 K€** – Arcascience a reçu en décembre 2025 un prêt d'amorçage innovation.
- **Innov'Up – acompte : 240 K€** – La première tranche de la subvention octroyée par le dispositif Innov'Up a été reçue en février 2026.



GOVERNEMENT

d'innovation : 797 K€ – Le dispositif Innov'Up prévoit la forme d'un prêt d'innovation. Ce prêt a été reçu en fin de première tranche de la subvention.



bpifrance

- **Innov'Up – solde : 160 K€** – Le solde de la subvention (pour un montant total de 400 K€) sera versé lors de la finalisation des travaux prévus pour la fin d'année 2027.

Le projet bénéficie également du financement **i-Démo**, qui soutient le développement des modules avancés de la plateforme et leur industrialisation.

- **i-Démo – acompte (EC1) : 325 K€** – acompte versé lors de la validation du programme i-Démo. Cette première tranche aura pour objectif de financer la première étape clés du programme afin de valider la Prédiction basée sur la structure chimique à AUC > 0,6 (générique).
- **i-Démo – tranche 2 (EC2) : 1 350 K€** – versée début Q3 2027 afin de financer les Workpackage 2, 3 et 4 et d'atteindre Prédiction intégrant les données précliniques et le MOA : AUC > 0,75 (générique).
- **i-Démo – solde (EC3) : 1 005k €** – La dernière tranche du programme i-Démo sera versée début Q2 2028 afin de financer la finalisation du programme et l'atteinte des résultats.

Ces subventions permettent de financer une part significative des travaux de R&D et de réduire le risque technologique associé au développement de la solution.

Levée de fonds

En complément des financements publics, ArcaScience prévoit la réalisation d'une levée de fonds auprès d'investisseurs afin de soutenir l'accélération du développement de l'entreprise.

Cette levée de fonds fera suite celle de **4,65M €** réalisé lors de la fin de l'année **2025**. Elle sera de **20M €** prévu pour **2028**. Elle permettra principalement de financer la croissance des équipes techniques et scientifiques, ainsi que la structuration des activités commerciales nécessaires au déploiement de la plateforme auprès des acteurs pharmaceutiques et biotechnologiques.

Contribution des revenus

À mesure que la solution sera déployée chez les partenaires industriels, les revenus issus des licences d'utilisation de la plateforme contribueront progressivement au financement de l'activité de l'entreprise. La croissance du chiffre d'affaires repose notamment sur l'adoption progressive des modules Trial Balancer et BR-Predict et sur l'augmentation du nombre de molécules analysées par les partenaires industriels.

La combinaison des subventions publiques, de la levée de fonds et des premiers revenus commerciaux doit permettre à ArcaScience de financer son développement technologique et commercial jusqu'à l'atteinte du **break-even prévu en 2030**. À partir de cette échéance, la croissance du chiffre d'affaires devrait permettre de soutenir de manière autonome l'activité de l'entreprise.

5. JUSTIFICATION DE L'AIDE

5.1. ACTIVITÉS QUI SERAIENT DÉPLOYÉES EN L'ABSENCE DE L'AIDE

En l'absence du soutien i-Démo, ArcaScience ne disposerait pas des capacités financières nécessaires pour développer le module BR-Predict dans les délais compatibles avec l'opportunité marché identifiée.



GOVERNEMENT

Liberté
Égalité
Fraternité

ArcaScience pour réaliser ces deux activités en parallèle ne s



bpi**france**

st, en effet, destiné principalement au **recrutement de profils techniques hautement qualifiés**, indispensables au développement du nouveau module prédictif, tout en maintenant la continuité des activités commerciales existantes. Sans cette aide, l'entreprise ne pourrait pas mobiliser simultanément des ressources sur la R&D avancée et sur la structuration commerciale.

La société serait contrainte de concentrer ses ressources humaines et financières sur le déploiement commercial du module Trial Balancer afin d'assurer la consolidation de son chiffre d'affaires et sa présence sur le marché.

Par ailleurs, la société ne peut interrompre ou ralentir le développement du module Trial Balancer au profit exclusif de BR-Predict. **Trial Balancer constitue aujourd'hui la porte d'entrée stratégique sur le marché pharmaceutique et le socle de reconnaissance d'ArcaScience au sein de l'écosystème du développement du médicament.** Abandonner ou fragiliser cette activité compromettrait la crédibilité industrielle et la traction commerciale nécessaires au lancement ultérieur du module prédictif.

En termes de scénario contrefactuel : que se passe-t-il si la France ne finance pas ce projet ?

Scénario 1 - Captation américaine. Sans champion européen, les laboratoires français (Sanofi, Servier, Ipsen) devront s'appuyer sur des solutions américaines. Conséquences : transit de données de R&D stratégiques vers des infrastructures soumises au Cloud Act, perte de maîtrise des algorithmes décisionnels, transfert de valeur estimé entre 200 et 400 M€/an vers les prestataires américains. Cette estimation repose sur deux données publiques convergentes : le marché français de la pharmacovigilance, évalué à 288 millions de dollars en 2024 (Spherical Insights), dont 61 % est externalisé contractuellement vers des prestataires dont la grande majorité est soumise au droit américain, et le taux mondial d'externalisation des analyses bénéfice-risque, supérieur à 68 % selon les données sectorielles disponibles, appliqué à la part française du marché BRA mondial estimé à 13,2 milliards de dollars. Ce transfert structurel de valeur, déjà en cours, s'accélérerait à mesure que les acteurs américains intègrent des capacités IA dans leurs offres, creusant davantage l'écart technologique et rendant un rattrapage européen de plus en plus difficile.

Scénario 2 - Fuite des cerveaux. L'équipe d'ArcaScience (INRIA, ex-Owkin) serait progressivement débauchée par les acteurs américains. Les compétences rares accumulées (4 CIFRE, 8 stagiaires/an) seraient perdues pour l'écosystème français. Précédent documenté : Owkin, dont le siège opérationnel s'est déplacé aux États-Unis.

Scénario 3 - Fragmentation. Le marché européen de l'analyse bénéfice-risque prédictive resterait fragmenté entre des initiatives académiques non industrialisées. Résultat : un segment de 13,2 milliards de dollars dominé à 100 % par des acteurs extra-européens.

Comparaison avec le contexte international : une course à l'investissement

Pays/Région	Investissements récents en IA pharma	Ratio vs France
États-Unis	~3,6 Mds\$ (2023-2024) : NIH ARPA-H, BARDA, fonds privés	x18
Royaume-Uni	~1,2 Md£ : ARIA, NHS AI Lab, UKRI	x6
Chine	~50 Mds¥ (~6,5 Mds€) : Plan national IA 2030	x32
France	~200 M€ : France 2030, BPI France, ANR	Référence

5.2. BÉNÉFICES NOUVEAUX PERMIS PAR L'AIDE

Le soutien i-Démo permettrait à ArcaScience d'accélérer significativement la mise sur le marché du module BR-Predict, dans un contexte où le timing concurrentiel est particulièrement favorable. La société dispose déjà d'une plateforme reconnue pour ses gains de temps, de coût et de qualité dans l'analyse bénéfice/risque réglementaire. **À ce stade, aucun acteur de l'analyse bénéfice risque ne possède la technologie pour aller sur le segment prédictif.**

De plus les sociétés développant des plateformes IA d'aide aux développements de médicaments n'ont pas encore essayé de se positionner sur ce segment.

Le **financement i-Démo** permettra de **lever les incertitudes techniques identifiées**, notamment autour du World Model et de l'intégration multi-niveaux des données, afin de **sécuriser le développement d'un module prédictif** robuste avant l'arrivée de concurrents sur ce marché.

Cette avance stratégique renforcera la probabilité que **BR-Predict** devienne une **référence dans l'aide à la décision en développement pharmaceutique**, d'abord en France et aux États-Unis, puis à l'international. Elle offrira également à **ArcaScience** la capacité d'étendre progressivement sa **gamme de modules pour couvrir davantage de phases de développement et d'aires thérapeutiques**, consolidant ainsi sa position comme outil structurant du développement du médicament.

5.3. AVANTAGES SUPPLÉMENTAIRES POUR LE CLIENT FINAL

Le module BR-Predict apportera aux entreprises pharmaceutiques et aux grandes biotechnologies un **outil inédit capable d'anticiper le profil bénéfice/risque de leurs candidats médicaments en amont des phases cliniques avancées.**

Les clients disposeront ainsi d'un niveau d'information supérieur à celui offert par les approches actuelles, leur permettant de prendre des décisions plus éclairées et plus structurées. L'identification précoce des bénéfices probables et des risques potentiels contribuera à :

- **Prioriser les actifs** à engager en développement clinique ;
- Concevoir des **protocoles cliniques mieux adaptés** au mécanisme d'action et au profil patient ciblé ;
- **Réduire l'exposition inutile de volontaires sains et de patients** à des candidats à faible probabilité de succès.

Cette capacité prédictive constitue un avantage différenciant majeur par rapport aux offres existantes, qui restent principalement descriptives ou segmentées.

5.4. RETOMBÉES POUR LA FILIÈRE INDUSTRIELLE ET LES STANDARDS

Le projet contribuera à faire évoluer l'utilisation des analyses BRA dans les processus de développement pharmaceutique. Aujourd'hui, ces analyses sont principalement utilisées dans une logique réglementaire et de pharmacovigilance. La plateforme développée permettra de les intégrer plus tôt



GOVERNEMENT

*Liberté
Égalité
Fraternité*



bpifrance

afin d'évaluer plus systématiquement le potentiel des candidats ; d'efficacité et de sécurité aux traitements de référence.

on permettra d'améliorer la robustesse des stratégies de développement pharmaceutique. L'identification plus précoce des signaux d'efficacité ou de toxicité permettra d'ajuster les programmes de développement, de mieux cibler les populations de patients et d'optimiser la conception des essais cliniques, contribuant ainsi à réduire le risque d'échec tardif.

Le projet participera également à l'émergence d'outils industriels permettant d'exploiter à grande échelle les données biomédicales pour soutenir les décisions stratégiques en développement pharmaceutique. En automatisant et en systématisant ces analyses, la plateforme contribuera à faire évoluer les pratiques du secteur vers des approches davantage fondées sur les données.

Ces capacités pourront notamment bénéficier aux sociétés de biotechnologie, qui disposent souvent de ressources limitées pour conduire des analyses stratégiques approfondies sur leurs actifs

Également, BR Predict s'aligne avec les politiques publiques françaises et européennes, notamment :

- Le Plan Innovation Santé 2030 :
 - Mesure 1 - « Accélérer la recherche biomédicale » : BR-Predict accélère la sélection des candidats médicaments en fournissant une évaluation B-R prédictive dès les phases précoces.
 - Mesure 7 - « Développer l'utilisation des données de santé » : le projet exploite et structure les données de pharmacovigilance (FAERS), les EDS hospitaliers et les données génomiques.
 - Mesure 10 - « Renforcer l'attractivité de la France pour les essais cliniques » : en optimisant la sélection des candidats et le design des essais.
- La Stratégie Nationale pour l'Intelligence Artificielle (SNIA) :
 - IA de confiance, explicable et traçable, conforme aux principes de l'AI Act européen ;
 - Valorisation des compétences françaises en IA (partenariat organique avec l'INRIA) ;
 - Formation d'une nouvelle génération : 4 CIFRE + 8 stagiaires/an.
- Le European Health Data Space (EHDS) :
 - Interopérabilité native (MedDRA, SNOMED CT, ChEBI) ;
 - Traçabilité complète de la chaîne de données ;
 - Architecture de Knowledge Graph interopérable (WP5) contribuant directement aux objectifs EHDS.

ArcaScience est en position de devenir un acteur de référence français dans l'implémentation de l'EHDS appliqué au développement pharmaceutique, produisant un réel impact sur la balance commerciale :

- Marché européen d'externalisation des analyses B/R : estimé entre 3 et 4 milliards d'euros/an.
- Part captée par des prestataires non européens : 60-70 %, soit 2 à 2,8 milliards d'euros/an.
- Potentiel de relocalisation via BR-Predict : 20 à 60 M€ de revenus d'exportation d'ici 2032.
- Premiers contrats d'export déjà signés : ICON (600 k€), Sanofi (235 k€), AstraZeneca (60 k€).



GOUVERNEMENT

*Liberté
Égalité
Fraternité*

contribue à la création d'une filière de compétences encore
trois domaines :



bpifrance

	Compétence	Formation associée
Intelligence artificielle	NLP biomédical, graph neural networks, modèles causaux	2 thèses CIFRE IA
Sciences biomédicales	Pharmacologie computationnelle, pharmacogénomique, toxicologie prédictive	1 thèse CIFRE pharmacologie
Réglementation pharmaceutique	Qualification SaMD/MDR, soumission réglementaire IA	1 thèse CIFRE réglementaire

Cette filière croisée n'existe dans aucune formation française aujourd'hui. Les 4 doctorats CIFRE et les 8 stages annuels contribueront à former la première génération de spécialistes français en IA réglementaire pharmaceutique et à alimenter un vivier de compétences critique pour l'ensemble de l'écosystème national.