

Présentation du projet

i-Démo BR-Predict

ELEMENTS CLES DU PROJET

Nom du projet	La première plateforme d'évaluation Prédictive du bénéfice-risque
Durée du projet (en mois)	36 mois
Date de début	01/01/2026
Date de fin	31/12/2028
Coût total du projet (€)	5 360 000 €
Raison sociale du porteur / chef de file	ArcaScience

DESCRIPTION SYNTHETIQUE DU PROJET (5 lignes maximum)

ArcaScience possède une plateforme innovante capable d'agréger une énorme quantité de données cliniques et ontologiques afin de produire des rapports d'analyse bénéfice/risque réglementaires. Le projet BR-Predict vise à développer un module prédictif capable d'anticiper le profil bénéfice/risque des candidats médicaments dès les phases précoces à partir de données moléculaires, précliniques, génétiques et cliniques. Ce nouveau module se positionnera comme un outil d'aide à la décision pour les entreprises pharmaceutiques.

TABLE DES MATIERES

1. Présentation du porteur du projet	4
1.1. Présentation de ArcaScience & actionnariat	4
1.2. L'équipe fondatrice et dirigeante	5
1.3. Ressources humaines et technologiques.....	6
1.3.1. Effectif actuel et évolution envisagées à court terme	6
1.3.2. Comité stratégique et scientifique de ArcaScience	7
1.3.3. Principaux sites et moyens de production et de R&D	8
1.3.4. Savoir-faire et interne.....	8
1.3.5. Protections industrielles mises en œuvre	9
1.3.6. Partenaires et sous-traitants clés	9
1.4. Activité de la société.....	11
1.4.1. L'IA au service de l'accompagnement des industriels du médicaments.....	11
1.4.2. Modèle économique	12
1.4.3. Clients actuels	13
1.5. Ambition et evolution stratégique de la société.....	14
1.5.1. L'ambition d'ArcaScience	14
1.5.2. Positionnement marché et concurrentielle de ArcaScience	15
2. Objectifs et contexte technico-economique	20
2.1. Résumé du projet.....	20
2.2. Ambition stratégique du projet	21
2.2.1. Problématique dans le succès des essais cliniques.....	21
2.2.2. L'analyse bénéfice risque comme une solution viable	22
2.2.3. La place du BRA dans le développement de médicament.....	22
2.2.4. Limites actuelles du processus d'utilisation du bra pour l'aide au développement de médicaments	22
2.2.5. Les besoins dans l'analyse bénéfices – risques.....	23
2.2.6. la plateforme ArcaScience	23
2.2.7. Proposition de valeur	24
2.3. Ambition technologique	24
2.3.1. Workflow de la plateforme ArcaScience	24
2.3.2. Données antérieurs.....	26
2.3.2.1. Innovation porté par le programme i-demo : module br-predict	28
3. Plan de travail.....	31
3.1. Structuration du plan de travail	31
3.2. GANTT	34
3.3. Synthèse des principaux jalons décisionnels du projet et de leurs indicateurs de succès associés	34
3.4. Risques identifiés et plan de suivi.....	35
3.5. Budget et principaux postes de sous-traitance du projet	35

4. Lots détaillés	36
4.1. Lot 1	36
4.2. Lot 2	37
4.3. Lot 3	38
4.4. Lot 4	39
4.5. Lot 5	40
4.6. Lot 6	41
4.7. Lot 7	42
5. Exploitation industrielle et commerciale des résultats du projet.....	44
5.1. Stratégie d’industrialisation des résultats du projet	44
5.1.1. Stratégie de développement technologique.....	44
5.1.2. Stratégie et conditions réglementaires d’accès	44
5.1.3. Stratégie de protection intellectuelle.....	45
5.2. Stratégie de commercialisation et projection de revenus.....	46
5.2.1. Stratégie d’accès marché	46
5.2.2. Modèle économique et pricing.....	46
5.2.3. Projection de revenus et construction du chiffre d’affaires	48
5.3. Impacts sociétaux et environnementaux.....	49
5.3.1. Retombées sociales, sociétales pour le territoire national	49
5.3.2. Impact environnemental	49
6. Eléments financiers.....	51
6.1. Impact sur le compte de résultats prévisionnel.....	51
6.2. Plan de financement	51
6.2.1. Planification de dépenses estimées	51
6.2.2. Stratégie de financement sur la durée du programme.....	51
7. Justification de l’aide	52
7.1. Activités qui seraient déployées en l’absence de l’aide.....	52
7.2. Bénéfices nouveaux permis par l’aide.....	53
7.3. Avantages supplémentaires pour le client final	53
7.4. Retombées pour la filière industrielle et les standards.....	53

PARTIE 1 : PRESENTATION DU PROJET

1. PRESENTATION DU PORTEUR DU PROJET

1.1. PRESENTATION DE ARCA SCIENCE & ACTIONNARIAT

La société ArcaScience a été créée à Paris en 2018 par Romain Clement, Patrick Pierre Et Laurent Romary. Il s'agit d'une **SAS au capital social de 510 257,89 €**. Sa gouvernance repose sur l'implication directe de ses fondateurs, tandis que son actionnariat combine la participation de personnes physiques et celle d'investisseurs spécialisés dans le secteur.

La trajectoire de financement d'ArcaScience, depuis sa création en 2018, comprend trois opérations confirmées :

- Une première levée d'amorçage a été réalisée en 2020 pour un montant de **550 k€**, financée par XXX.
- Une seconde levée est intervenue en 2024 pour un montant de **450 k€**. Elle a permis à plusieurs acteurs reconnus du monde des sciences médicales, notamment Sanofi, Cedars-Sinai et l'ICM d'accéder à la gouvernance de la société.
- Une troisième levée de fonds a été finalisée fin 2025 pour un montant de **4,65 M€**. Elle vise à **soutenir le développement et l'extension de la société**, notamment via l'industrialisation de sa plateforme technologique. L'investisseur principal de cette opération est le fonds de santé Pleiade Venture. Cette levée a également permis l'entrée au capital de plusieurs fonds d'investissement et holdings, dont Quotium Technologies, Kima Ventures II, GO!TECH, Plug & Play Investment Group, AFRI Mobility, ainsi que plusieurs SPV dédiés.

ArcaScience a bénéficié du dispositif d'aide publique mise en place par la région Île-de-France Innov'Up à hauteur de 1,8 M€, fléché sur l'accélération de la R&D et les premiers déploiements de la solution Saas.

ArcaScience a **reçu plusieurs prix d'innovation** et a notamment été primée "Meilleure solution pharma-NLP 2023" par Startus Insights, en reconnaissance de la **robustesse de ses modèles propriétaires d'extraction et structuration de l'évidence biomédicale et de la qualité opérationnelle de sa plateforme de BRA** (analyse bénéfice-risque).

ArcaScience a su conjuguer des augmentations de capital successives maîtrisées, avec l'obtention de subventions publiques stratégiques et une reconnaissance scientifique solide. Ces atouts lui ont permis de se développer de manière pérenne, de s'intégrer durablement au sein de l'écosystème de la santé et de renforcer sa visibilité ainsi que sa crédibilité auprès des principaux acteurs du secteur, tout en préservant l'autonomie opérationnelle et décisionnelle de ses fondateurs.

Tableau 1 : Table de capitalisation - format NFD (non-fully diluted)

Personnes physiques			
Prénom	Nom	%	Rôle
Romain	CLEMENT	31,16%	Fondateurs
Patrick	PIERRE	6,86%	
Laurent	ROMARY	0,12%	
Alexis	PICOT	0,44%	Business Angels
Stéphane	WATHIER	0,85%	
Geoffroy	CHANDON	0,88%	
Jordan	LAZARO-GUSTAVE	3,68%	
Alexis	BRICE	0,15%	
Philippe	PEYRE	0,71%	
Alexandre	ICHAÏ	0,71%	
Rand	SHERIF	0,65%	

Claire	MASUREL SHERIF	0,65%	
Anne	DONEUX	0,50%	
Barthélémy	DE BEAUPUY	0,97%	
Lilian	THIBAULT	0,21%	
Rea	Trust	0,32%	
Marc	SOUNIGO	0,32%	
Frédéric	GARROY	0,24%	
Thomas	PRUD’HOMME	0,41%	
Personnes Morales			
Raison sociale	N° d'identification	%	Rôle
Quotium Technologies	322 548 355	12,93%	Fonds et Holdings
GO!TECH	830 485 579	2,15%	
Plug & Play INVESTMENT GROUP LLC	202119710330	2,47%	
Financière de la Rosetta	433 355 666	0,74%	
Quantum Leap Venture SPV LTD	000010000	1,18%	
H2 (Cayman) Investments Ltd.	KY1-1108	1,38%	
AFRI MOBILITY	461097	2,12%	
SARL JEC	410 051 163	0,71%	
ARCASCIENCE BY THE MOON VENTURE	943 996 371	10,99%	
Pleiade Venture	500 108 121	8,10%	
AKKA 254 SPV	941 929 135	3,80%	
SHERIF INVEST SA	CHE-246.430.659	0,32%	
Kima Ventures II	831 126 156	0,97%	
STICHTING ADMINISTRATIEKANTOOR CAPITAL CELL	866167791	0,82%	
HTH - HEXAGON TECHNOLOGIES HOLDING	430 097 451	0,50%	
RP&PARTNERS	952 019 073	0,97%	

1.2. L'EQUIPE FONDATRICE ET DIRIGEANTE

ArcaScience s'appuie sur une gouvernance reposant sur des expertises complémentaires autant sur les volets technologiques, commerciaux que clinique. Cette complémentarité permet d'assurer à la fois la pilotage et la coordination des partenaires impliqués dans le projet BR-Predict.

- **Romain Clément**, CEO et co-fondateur, est diplômé de l'ESSEC, de l'Université Panthéon-Sorbonne et de CentraleSupélec. Il a construit son expertise en gestion de données scientifiques cliniques chez GSK, puis dirige depuis 2018 la stratégie et le développement d'ArcaScience. Son ancrage académique et ses interactions avec l'écosystème pharmaceutique structurent le réseau nécessaire à l'accès aux données, à la validation scientifique et aux premiers cas d'usage cliniques.
- **Patrick Pierre**, co-fondateur et superviseur technique infrastructure, est diplômé de CentraleSupélec. Il a fondé deux sociétés spécialisées dans le numérique : Prismallia, dédiée au développement de logiciels applicatifs et de solutions d'ingénierie logicielle pour la gestion et le traitement de données, et Lap2, spécialisée dans les services d'ingénierie informatique et le développement de systèmes d'information. Il apporte à ArcaScience une expertise en architecture d'infrastructures, en industrialisation des flux de données et en fiabilité opérationnelle. Sa culture produit orientée mise à l'échelle et qualité logicielle contribue à sécuriser les systèmes de traitement de données de la plateforme.

- **Laurent Romary**, co-fondateur, est le directeur de recherche à l'INRIA et le président de DARIAH (infrastructure de recherche numérique pour les arts et les sciences humaines). Il apporte un réseau de haut niveau dans la recherche, facilitant l'accès à des expertises pointues, des standards méthodologiques et des partenariats. En siégeant au conseil scientifique de la société, il confère une crédibilité scientifique au projet et renforce l'intégration d'ArcaScience dans les écosystèmes médicaux et universitaires.

L'équipe dirigeante couvre les fonctions critiques du projet : architecture logicielle, direction médicale et IA, et développement commercial.

- **Julien Dufour**, Chief Business Officer, pilote la stratégie commerciale et les partenariats. Son expérience en conseil et en développement d'affaires lui apporte une vision d'ensemble pour structurer une trajectoire de croissance cohérente. Chez La Poste, en tant que Health and Social Services Offer Manager, il a structuré l'animation commerciale et noué des partenariats stratégiques. Il sécurise ainsi l'accès aux industriels du médicament, tout en pilotant des indicateurs de traction commerciale tels que le pipeline d'essais pilotes, les contrats et les cycles de vente.
- **Jean-François Arbona**, Chief Technical Officer, apporte une compétence d'architecture logicielle et d'industrialisation structurante pour la plateforme. Son expérience en direction technique, cloud, web et mobile, garantit la conception d'une architecture modulaire, scalable et pérenne. Il structure les exigences de performance et de fiabilité (SLA, sécurité, robustesse des pipelines), et l'intégration des briques logicielles d'ingestion de données conformément aux exigences de gestion des données de santé.
- **Vassili Soumelis**, Chief Medical Officer, est l'ancien directeur médical d'Owkin. Il apporte une double compétence médicale en immuno-oncologie et logicielle avec une expertise IA appliquée aux données de santé. Il assure l'adéquation et la cohérence des travaux sur la solution IA d'ArcaScience et la réalité terrain.

L'équipe dirigeante est alignée sur les livrables clés de BR-Predict dans i-démo et les transforme en résultats opérationnels. Romain Clément sécurise l'accès et la gouvernance des données (accords de mise à disposition, conformité, interopérabilité) pour constituer un corpus traçable exploitable pour l'entraînement et l'évaluation des modèles. Jean-François Arbona conçoit l'architecture modulaire et scalable de la plateforme, fixe les exigences de fiabilité, sécurité et traçabilité, et prépare le packaging de déploiement on-prem chez les clients. Patrick Pierre industrialise les flux d'ingestion et les pipelines de traitement, automatise l'orchestration et la supervision, et garantit la disponibilité et la reproductibilité de la chaîne data-to-model. Sur le versant clinique et IA, Vassili Soumelis définit les cas d'usage médicaux, les comparateurs "standard of care" et les critères de performance, pilote les protocoles de validation et l'interprétation clinique des résultats afin d'ancrer BR-Predict dans la pratique. Côté marché, Julien Dufour structure les contrats-cadres avec laboratoires/CRO et le modèle d'adoption "molécule par molécule" pour convertir les démonstrateurs en revenus récurrents. En gouvernance scientifique, Laurent Romary apporte les standards méthodologiques et l'alignement avec l'état de l'art académique. Les livrables attendus sont un corpus normalisé et documenté, des pipelines d'ingestion et de traçabilité opérationnels, des modèles BR-Predict validés face au standard of care, un package de déploiement on-prem prêt chez clients et un portefeuille de pilotes/contrats, en cohérence avec les jalons de maturation, de démonstration et de pré-industrialisation du projet.

1.3. RESSOURCES HUMAINES ET TECHNOLOGIQUES

1.3.1. EFFECTIF ACTUEL ET EVOLUTION ENVISAGEE A COURT TERME

A date, ArcaScience compte 8 ETP et 1 prestataire, complétés par 3 stagiaires. La répartition est la suivante :

- **L'équipe Technique – R&D/Produit** (6 ETP) couvre **l'ensemble de la chaîne de valeur data-to-decision**: ingestion multi-sources, annotation sémantique, harmonisation terminologique et industrialisation des pipelines. Les travaux sont menés selon une méthodologie agile avec CI/CD, monitoring de performance. Elles s'appuient sur des profils spécialisés en biomédical data engineering, NLP et MLOps, assurant la continuité de responsabilité de la conception à l'exploitation. L'équipe technique est également constituée de stagiaires notamment sur les sujets data et back-end.
- **L'équipe Commerciale** (1 ETP) opère un parcours d'acquisition adapté aux laboratoires pharmaceutiques et CRO de qualification scientifique et contractualisation récurrente (contrats-cadres, abonnement). Cette approche structure l'industrialisation « **molécule par molécule** » de la plateforme. Elle soutient l'évolution des partenariats de manière **récurrente** afin de **valoriser de plus en plus de molécules** auprès de chaque client et d'augmenter les ventes de manière **exponentielle** au sein de chaque société.
- **Administration** : (1 ETP) la fonction sécurise le support aux opérations et au recrutement, en lien avec l'agence prestataire, pour maintenir la qualité d'exécution dans un contexte de montée en charge.

Cette organisation constitue la base opérationnelle mobilisée au démarrage du projet i-DÉMO.

Côté R&D, 27 recrutements sont planifiés pour délivrer les lots techniques (6 en 2026, 4 en 2027, 13 en 2028, 4 en 2029), avec un pic en 2028 lors de la démonstration et de l'extension d'usage de BR-Predict. Côté commercial, 14 recrutements visent la structuration des contrats-cadres et l'adoption "molécule par molécule" (2 en 2026, 1 en 2027, 7 en 2028, 4 en 2029). Côté industriel, 6 recrutements ciblent l'intégration et l'exploitation on-prem chez les clients (2 en 2026, 4 en 2029).

	2026	2027	2028	2029	Total
R&D	6	4	13	4	27
Industries	2	0	0	4	6
Commercial	2	1	7	4	14
Total	10	5	20	12	47

En R&D, les profils prioritaires sont l'ingénierie IA et data biomédicale, la bioinformatique et le pilotage de projets de R&D afin de consolider la chaîne datatodecision et d'industrialiser BRPredict. Les phases de recrutement seront par vagues : d'abord en 2026/2027 pour renforcer les composants cœur, puis 2028 pour étendre les usages, et enfin 2029 pour stabiliser et fiabiliser. En industrialisation, les priorités portent sur l'intégration et l'exploitation onprem, la sécurité et la traçabilité des déploiements ; les premières embauches auront lieu en 2026, avec renforcement en 2029 pour les mises en production. En commercial, les recrutements visent le key account management pharma/CRO et l'avantvente, avec une montée en charge en 2028 puis 2029.

Sur 47 recrutements planifiés sur la période, 33 sont directement orientés vers l'exécution des lots iDÉMO (27 en R&D, 6 en industrialisation), soit 70% de l'activité RH totale. La dynamique annuelle montre un poids iDÉMO de 80% en 2026 (8/10), 80% en 2027 (4/5), 65% en 2028 (13/20) et 67% en 2029 (8/12), avec un pic de 20 recrutements en 2028 principalement liés à la phase de démonstration et à la montée en charge du module BRPredict, puis un renfort industrialisation en 2029 pour les mises en production.

1.3.2. COMITE STRATEGIQUE ET SCIENTIFIQUE DE ARCASCIENCE

ArcaScience s'appuie sur un conseil scientifique, technique et stratégique de premier plan afin de sécuriser la qualité méthodologique, d'éclairer les choix technologiques et de renforcer l'ancrage industriel de la société. Ce dispositif, structuré en **Partners Club**, contribue à la validation scientifique, à l'orientation stratégique et au développement commercial, en facilitant l'accès à un réseau étendu de décideurs et d'experts issus de l'industrie pharmaceutique, des établissements de santé et de la deeptech. Le comité réunit des profils complémentaires couvrant recherche publique, clinique, industrie pharmaceutique, data/IA et stratégie :

Pôle scientifique et clinique :

- Laurent Romary, PhD (directeur de recherche émérite à l'Inria, président de DARIAH);
- Pr Alexis Brice, MD, PU-PH (président fondateur de l'ICM, membre de l'Académie des sciences);
- Pr Clemens M. Schirmer, MD, PhD (neurochirurgien, Geisinger School of Medicine);
- Jean Lopategui, MD, PhD (Directeur du département Pathology, Cedars-Sinai).

Pôle industriel et réglementaire :

- Philippe Peyre, PhD (Senior VP et secrétaire général chez Sanofi, représentant Sanofi au comité scientifique d'ArcaScience);
- Serge Bauin, PhD (ancien DGA à la science au CNRS, expert Data Science ministériel).

Pôle data/IA et innovation :

- Hal Lavender (AI, Data and Business Transformation Leader VP chez IBM);
- Stéphane Rouault, PhD (Clinical Innovation Lead chez Argenx et Roche).

Pôle marché, financement et déploiement :

- Kerry Coffee (fondatrice Schiller Discovery Healthtech Venture);
- Emmanuel Capitaine, MD (Coordinateur médical international, Vivalto Santé; ancien responsable innovation AstraZeneca);
- Geneviève Laurans (administratrice et CFO, Quotium Technologies);
- Fabien Lantieri (stratégie santé et innovation, EIT Health; expert au Génomex);
- Béatrice du Sordet (fondatrice d'Aplusa);
- Jordan Lazaro-Gustave (fondateur d'AAVE).

1.3.3. PRINCIPAUX SITES ET MOYENS DE PRODUCTION ET DE R&D

ArcaScience est implantée au sein de **Future4Care, hub d'innovation en santé** situé au Biopark (75013 Paris), offrant un accès direct à un écosystème de startups, de groupes pharmaceutiques, d'institutions et d'investisseurs spécialisés. Cette implantation facilite l'accès à des ressources mutualisées pour ses besoins de R&D et industriels. Des environnements cloud sont mobilisés pour le développement et les tests (GCP)

Les déploiements en production sont réalisés directement chez les clients. Ainsi, la **localisation de la société au cœur de Paris**, combinée à la **présence d'une agence états-unienne**, permet d'assurer les **capacités d'industrialisation de la solution**.

Les déploiements s'appuient sur des **outils DevOps open source standard** : Docker pour l'isolation applicative, Kubernetes pour l'orchestration des microservices et Ansible pour l'automatisation des installations. Une fois installée, la solution fonctionne de manière autonome, avec un accès **ArcaScience** limité et planifié au strict suivi de performance ; chaque résultat est traçable jusqu'à sa source.

1.3.4. SAVOIR-FAIRE ET INTERNE

L'entreprise possède tout d'abord une expertise forte dans la **gestion et l'analyses de données multimodales biologiques et cliniques** : L'équipe maîtrise les spécificités des données chimiques, physiologiques et biomédicales issues de la littérature scientifique et des essais cliniques. Elle dispose également d'une forte maîtrise des ontologies et des méthodes de structuration sémantique de ces

données. Cette expertise est notamment portée par le pôle data dirigé par Romain Clément, qui possède une expérience dans la gestion de données scientifiques et cliniques au sein de l'industrie pharmaceutique.

ArcaScience dispose également d'un savoir-faire solide en **ingénierie logicielle**. L'équipe maîtrise la conception de logiciels capables de traiter de grands volumes de données et d'intégrer différents outils d'analyse. Elle possède des compétences dans la conception de modèles d'intelligence artificielle, leur entraînement et leur mise en production. Plus important encore, l'équipe possède la capacité de structurer ces expertises en données et en intelligence artificielle au sein d'architectures logicielles complexes, cohérentes et optimisées. Ces compétences sont notamment portées par le pôle architecture et par Jean-François Arbona, CTO de l'entreprise, qui possède plus de vingt ans d'expérience en développement logiciel et en architecture technique.

Enfin, l'entreprise dispose de **compétences médicales et scientifiques permettant d'interpréter les données biomédicales** avec rigueur. L'arrivée de profils médicaux au sein de l'équipe, notamment Vassili Soumelis, renforce cette capacité d'analyse scientifique. Il apporte une expertise essentielle pour replacer l'utilisation des logiciels et des données dans le contexte réel du développement des médicaments et de la pratique clinique.

L'ensemble de ces compétences complémentaires constitue le socle du savoir-faire d'**ArcaScience** et permet à l'entreprise d'aborder de manière intégrée les problématiques liées aux données biomédicales, à l'intelligence artificielle et au développement pharmaceutique.

1.3.5. PROTECTIONS INDUSTRIELLES MISES EN ŒUVRE

La stratégie de propriété intellectuelle d'ArcaScience repose sur une combinaison structurée de **plusieurs leviers juridiques : droit des brevets, droit d'auteur et secret d'affaires**. La base de données propriétaire d'ArcaScience est protégée au titre du droit d'auteur, en raison de l'originalité de son architecture, de sa structuration et de ses méthodes d'annotation. Le secret d'affaires couvre les éléments non divulgués du savoir-faire interne, notamment les paramètres d'entraînement, les choix d'optimisation des modèles et les procédés d'industrialisation.

ArcaScience met en œuvre une protection « **by design** » fondée sur le déploiement **on-premise** chez les clients et un contrôle strict des accès. Ce mode d'industrialisation réduit structurellement le risque de fuite d'IP et renforce la souveraineté des données côté client. Il est complété par des mesures organisationnelles, dont le dépôt annuel du code et des modèles auprès d'un **escrow agent** et la confidentialité des éléments clés (architecture de pipeline clinique holistique, mécanismes d'intégration, de normalisation et de cohérence des données, structure et workflows d'inférence des **vingt-quatre** modèles propriétaires).

Les différents modules de la société seront protégés par des brevets pour chaque groupe d'algorithmes. Ces brevets couvriront aussi bien les méthodes de curation des données que leur harmonisation et la production des rapports de chaque module. Cette méthode permettra à **ArcaScience** d'étendre progressivement son portefeuille de brevets tout en conservant son architecture de base sous le régime du secret d'affaires.

1.3.6. PARTENAIRES ET SOUS-TRAITANTS CLES

DESCRIPTION PARTENAIRE/ SOUS-TRAITANT	
Partenaires de recherche et académiques	
	ICM est un partenaire académique structurant, mobilisé sur des projets de recherche appliquée et des validations cliniques. La collaboration couvre notamment l'identification de candidats pour le repositionnement de

	médicaments dans le glioblastome, ainsi qu'un projet européen IHI sur le cancer du cerveau pédiatrique auquel ArcaScience participe aux côtés d'ICM et d'industriels (Sanofi, AstraZeneca, Siemens). L'ICM apporte une expertise médicale de haut niveau, l'accès à des corpus cliniques et un cadre méthodologique pour l'évaluation bénéfice/risque, renforçant la crédibilité scientifique des livrables et leur alignement avec les usages cliniques et réglementaires.
	Inria est au cœur des briques IA d'ArcaScience, avec une collaboration historique qui a contribué à concevoir l'architecture SLM propriétaire. Des chercheurs Inria ont rejoint l'entreprise, sécurisant la maîtrise interne des composants critiques. Inria apporte un appui méthodologique sur l'ingénierie des modèles, l'annotation sémantique et les pipelines d'apprentissage, ainsi que des références de recherche pour consolider la traçabilité et l'explicabilité de la chaîne data-to-decision. Cet ancrage accélère la montée en robustesse des modèles et l'industrialisation de l'usine logicielle.
Ecosystème et structure de soutien	
	Hub d'innovation santé où ArcaScience est implantée, Future4Care offre un accès à un écosystème opérationnel (startups, industriels, institutions, investisseurs). Ce cadre facilite l'accès à des ressources mutualisées pour la R&D et l'industrialisation (mentorat, plateformes, réseau), et consolide l'ancrage marché grâce aux fondateurs Sanofi et Generali, partenaires de longue date d'ArcaScience. Future4Care soutient la mise à l'échelle des déploiements on-prem et les interactions avec les décideurs pharma et hospitaliers, en complément d'un accompagnement Business France et de connexions internationales (Plug and Play, Cedars-Sinai).
	ArcaScience est intégrée dans la communauté internationale liée à Cedars-Sinai, ce qui renforce son accès aux écosystèmes cliniques et aux décideurs en santé aux États-Unis. Cette connexion est complétée par la présence d'experts de Cedars-Sinai au conseil d'ArcaScience, facilitant les retours sur les exigences cliniques, la qualité des données et les modalités d'industrialisation conformes aux pratiques hospitalières. Le réseau apporte une crédibilité clinique et un relais pour les déploiements et validations.
Partenaires commerciaux	
	ICON est l'une des plus grandes CRO mondiales et un partenaire opérationnel d'ArcaScience pour des projets BRA, avec des capacités de conduite d'essais et de structuration de données cliniques à grande échelle. Sa filiale MAPI (MRT) apporte une expertise sur les PRO/mesures de résultats rapportés par les patients, utile à la consolidation des profils B/R. L'apport d'ICON/MAPI se matérialise par des cas d'usage chez des clients communs, l'industrialisation des workflows et l'articulation avec les standards CRO, renforçant la valeur des analyses comparatives et leur intégration dans les processus décisionnels.
	Gradient Health intervient comme fournisseur de données pour renforcer les jeux d'entraînement et de validation (RWE et hospitalier), avec un objectif d'équilibrage des datasets et de performance cible (précision >95 %) dans les usages visés. L'accès à ces données soutient la montée en échelle des corpus, la couverture des endpoints et l'amélioration des métriques de qualité, tout

	en assurant la conformité avec les pratiques d'intégration de données du secteur et la traçabilité des sources exploitées par la plateforme.
	Sanofi intervient à double titre: partenaire écosystème via Future4Care (fondateur) et partenaire scientifique au comité d'ArcaScience (représenté par Philippe Peyre), avec une implication dans les projets de validation des modèles IA sur plusieurs années. Sanofi est également partenaire du projet IHI pédiatrique, renforçant l'intégration d'ArcaScience dans des consortiums européens. Les contributions portent sur la validation scientifique, l'accès à des référentiels métiers, et l'adéquation des livrables aux processus internes d'affaires réglementaires et de développement clinique.
	AstraZeneca est cité comme partenaire dans le cadre du projet IHI pédiatrique aux côtés d'ICM et Sanofi. Son rôle s'inscrit dans la structuration de projets collaboratifs R&D et l'alignement des besoins industriels avec les livrables d'ArcaScience. La collaboration contribue à ancrer la solution dans les cas d'usage cliniques des grands laboratoires, facilitant l'intégration des analyses B/R dans les processus d'évaluation et d'aide à la décision.

Parmi ces différents partenariats, la complétion du projet BR-Predict s'appuiera majoritairement sur Sanofi dans le cadre de la réalisation du démonstrateur du nouveau module.

1.4. ACTIVITE DE LA SOCIETE

1.4.1. L'IA AU SERVICE DE L'ACCOMPAGNEMENT DES INDUSTRIELS DU MEDICAMENTS

Activité actuelle

ArcaScience conçoit une **plateforme d'IA dédiée à l'évaluation bénéfice-risque (B/R) des médicaments**, pour **soutenir les décisions réglementaires et cliniques tout au long du développement**. Une analyse bénéfice-risque consiste à identifier les contraintes de toxicité d'un médicament ainsi que ses résultats d'efficacité clinique. Ces deux éléments sont ensuite mis en corrélation afin d'évaluer l'intérêt d'un actif et de le comparer aux autres pour ne retenir que le meilleur candidat. À ce jour, la société a développé un premier module, **Trial Balancer**. Concrètement, il agrège principalement des données cliniques concernant les **actifs déjà testés sur le marché**. Ces données sont enrichies par des informations détaillées sur les pathologies et leurs différentes variantes (historique de traitement, biomarqueurs, etc.). L'ensemble est ensuite transformé en une **base de données structurée** qui s'intègre aux données du client afin de générer un **corpus de preuves exhaustif, traçable et exploitable**. Cette base alimente les analyses à toutes les étapes du processus BRAT pour les médicaments à partir de la phase 2 clinique. Ce module permet de répondre à deux cas d'usage principaux :

- L'analyse des données cliniques obtenues à la suite des phases 2 et 3 d'un essai clinique pour un candidat médicament, ainsi que leur comparaison avec les données des traitements déjà disponibles sur le marché. Cela permet au partenaire de recherche d'orienter son développement, d'adapter le design des essais cliniques suivants et de réaliser des avenants auprès des autorités de santé en fonction de l'analyse réalisée par la plateforme. Une fois la plateforme déployée, elle peut être utilisée de manière autonome par le client pour réaliser autant d'analyses que nécessaire. Par ailleurs, sa capacité de mise à jour automatique permet au partenaire de générer une nouvelle analyse dès que de nouvelles données deviennent disponibles, sans avoir à repasser par une intervention de la société.

- La construction d'un rapport de **BRA** structuré dans un document conforme aux attentes des autorités de santé. La structuration des analyses suit le framework **BRAT** (Benefit-Risk Action Team), qui s'aligne avec les attentes des régulateurs (dossiers acceptés par la FDA et l'EMA) et avec les considérations de la FDA concernant l'usage de l'IA en support des décisions réglementaires. Les cas documentés démontrent l'applicabilité opérationnelle de ces cadres, avec une explicabilité intégrée des résultats et une justification par mécanismes d'action. La capacité de mise à jour automatique de la plateforme permet également de répondre aux exigences des autorités de santé, qui requièrent la production régulière de rapports afin d'assurer le suivi du profil bénéfice-risque et le maintien d'un médicament sur le marché.

Le module Trial Balancer est déjà déployé chez plusieurs laboratoires pharmaceutiques et CRO.

Historique de développement

La société a progressivement développé plusieurs briques technologiques constituant aujourd'hui la base de sa plateforme. Les premiers travaux ont porté sur des outils d'exploitation et de structuration de la littérature scientifique et des données biomédicales. Ces développements ont ensuite été étendus à l'analyse de données cliniques et à leur comparaison avec les standards thérapeutiques existants.

- Ils ont permis de construire :
- Une brique de collecte et de structuration de la littérature scientifique et des bases de connaissances biomédicales ;
- Une brique d'intégration de données cliniques issues des essais et des traitements de référence ;
- Une brique ontologique permettant d'harmoniser et de relier les différentes typologies de données biomédicales ;
- Une brique d'analyse permettant de produire des évaluations comparatives bénéfice-risque ;
- Une brique de mise à jour automatique permettant d'intégrer de nouvelles données et de régénérer les analyses lorsque de nouvelles informations deviennent disponibles.

L'ensemble de ces briques constitue aujourd'hui le module **Trial Balancer** et le socle technologique de la plateforme ArcaScience, qui servira de base au développement du futur module prédictif **BR-Predict**.

1.4.2. MODELE ECONOMIQUE

Le modèle économique d'ArcaScience repose sur l'établissement de **contrats-cadres** conclus avec des laboratoires pharmaceutiques et des CRO, permettant une **BRA** des molécules de **manière industrialisée**. L'approche consiste à déployer un module en **modèle SaaS chez le client**, paramétré selon ses besoins en termes de type d'actif et de pathologie cible, et à **facturer chaque nouvelle molécule analysée** sans coût initial d'installation. Les prix de chacun des modules de la solution ArcaScience sont définis en fonction d'une quantification du service rendu par rapport au temps gagné, tout en restant en adéquation avec les besoins client.

ArcaScience est consciente de la réticence des entreprises pharmaceutiques à déployer de nouvelles solutions SaaS en interne, notamment en raison des besoins de formation et des contraintes opérationnelles associées. La solution a donc été conçue pour être intégrée et largement automatisée, nécessitant peu de formation et peu d'actions de la part des utilisateurs pour être exploitée. Son déploiement auprès des différentes équipes R&D et dans plusieurs domaines thérapeutiques est ainsi facilité.

En amont du contrat-cadre, ArcaScience réalise un démonstrateur co-développé avec le client sur une molécule d'intérêt, à partir de ses données pharmas, pour délivrer l'outcome attendu (profil B/R comparé au standard of care, éléments de décision, traçabilité complète) selon des KPI conjointement définis (délai d'analyse, complétude des sources, performance des signaux, conformité). Une fois ces résultats atteints

et documentés, le contrat-cadre est signé pour industrialiser l’approche “molécule par molécule”, avec une tarification à l’usage et un dispositif d’accompagnement (paramétrage, QA des analyses, support métier) permettant l’utilisation autonome de la plateforme sur les molécules suivantes.

Le modèle SaaS est par essence plus scalable que le modèle CRO. La plateforme ArcaScience renforce cet aspect sur plusieurs axes :

- **L’extension intra-client**, correspondant à l’analyse de plusieurs molécules appartenant à une même classe d’actifs thérapeutiques (par exemple petites molécules chimiques ou anticorps monoclonaux). Dans ce cadre, les bases de données mobilisées restent en grande partie communes, notamment pour les propriétés structurales et les profils ADMET. La plateforme peut ainsi être utilisée pour analyser différentes cibles thérapeutiques au sein d’un même pipeline de développement. Cette extension peut ensuite être élargie à des pathologies reposant sur des mécanismes biologiques proches, permettant de réutiliser les mêmes référentiels de données et modèles d’analyse.
- **L’extension des modules à différents types de molécules et à différentes familles de pathologies reposant sur des mécanismes d’action proches**. Cela concerne notamment des pathologies partageant des bases physiopathologiques similaires ou des régulations biologiques communes, par exemple des processus d’immunomodulation, d’inflammation ou certains déterminants génétiques.
- **L’extension du nombre de modules ciblant différents cas d’usage**, avec le développement progressif de nouveaux modules venant compléter Trial Balancer et BR-Predict.

Ainsi, la feuille de route prévoit, après le programme i-Démo, un développement selon deux axes : l’extension de la plateforme à de nouvelles aires thérapeutiques et l’introduction de nouveaux modules permettant de couvrir de nouveaux cas d’usage.

1.4.3. CLIENTS ACTUELS

Grâce à leur activité focalisée sur le **BRA** et à un modèle économique progressif, ArcaScience a signé **neuf contrats avec sept clients à fin juin 2025**, couvrant des **laboratoires pharmaceutiques** comme Sanofi, AstraZeneca et Dilon Technologies, ainsi **qu’une CRO de premier plan**, ICON, et sa filiale Mapi Research Trust. Cette traction valide l’adéquation de la solution aux usages réglementaires et cliniques ciblés.

Clients		Montant (k€/an) et spécificités des contrats	Description des travaux
	Juillet 2025 : 600 k€		
	Août 2025 : 235 k€		
	Juin 2025 : 100 k€		
	Septembre 2024 : 90 k€		
	Septembre 2025 : 250 k€		
	Décembre 2024 : 156 k€		
	POC mars 2025 : 20 k€		
	Juin 2025 : 126 k€		
	POC février 2025 : 20 k€		
	Mai 2025 : 42 k€		
	Septembre 2025 : 60 k€		

Ces partenariats sont très structurants pour la société, autant pour la montée en puissance technologique basée sur des résultats en conditions réelles que pour la sécurisation d'un écosystème riche ouvrant de nombreuses voies vers de futures actions commerciales.

1.5. AMBITION ET EVOLUTION STRATEGIQUE DE LA SOCIETE

1.5.1. L'AMBITION D'ARCASCIENCE

Aujourd'hui, les analyses bénéfice-risque sont principalement réalisées à partir de données issues des phases cliniques avancées, notamment les phases 2 et 3. À ce stade du développement, les marges d'ajustement sont limitées alors que les entreprises pharmaceutiques ont déjà investi près de 10 ans de développement et environ 2 milliards d'euros pour amener un candidat médicament à ce niveau de maturité.

Afin de réduire ces risques liés à une évaluation tardive, l'enjeu consiste à anticiper le profil bénéfice-risque d'un candidat médicament et d'orienter plus tôt les décisions de développement.

La société aspire à devenir un partenaire de référence, non seulement réglementaire, mais également pour les décisions de R&D et le positionnement clinique des portefeuilles. Cette trajectoire repose sur une extension progressive des cas d'usage.

Pour cela, ArcaScience développera progressivement de nouveaux modules intégrant des **SLM** capables d'exploiter les données agrégées par la plateforme afin de produire de nouveaux types de

recommandations pour les entreprises pharmaceutiques à différentes étapes du développement d'un médicament.

Par ailleurs, près de 90 % de l'architecture de la solution repose sur des modèles non spécifiques à une pathologie. L'adaptation à différentes aires ou sous-aires thérapeutiques ne nécessite donc que des ajustements limités, permettant une extension rapide de la plateforme aux spécificités des actifs et des indications étudiées. Ce socle commun favorise un élargissement progressif aux aires thérapeutiques dynamiques, avant une généralisation multi-pathologies.

À ce jour, ArcaScience dispose d'une plateforme opérationnelle dédiée à l'analyse bénéfice-risque des candidats médicaments, principalement utilisée dans des contextes réglementaires et d'évaluation clinique avancée via le module Trial Balancer.

L'ambition stratégique de la société, en adéquation avec le programme i-démo, consiste désormais à étendre ces capacités vers des analyses prédictives capables d'intervenir plus en amont du développement clinique. Cette évolution repose sur l'architecture technologique déjà en place et sur les savoir-faire développés par l'équipe en matière d'intégration de données biomédicales et de modélisation par IA. Elle implique le développement de nouveaux modules permettant d'exploiter des données précliniques, cliniques externes et biomédicales afin d'anticiper le profil bénéfice-risque des candidats médicaments.

Le premier développement de ce type sera réalisé dans le cadre du projet BR-Predict sur l'indication du **NSCLC**, qui servira de preuve de concept. Les méthodes développées pourront ensuite être étendues à d'autres indications en oncologie, puis à d'autres aires thérapeutiques, notamment dans les pathologies d'immunologie et d'inflammation.

Cette évolution positionne ArcaScience comme un acteur complémentaire aux approches actuellement utilisées par les entreprises pharmaceutiques pour la sélection et l'évaluation des candidats médicaments. L'ambition est d'intégrer pour la première fois une capacité de prédiction du profil bénéfice-risque directement dans le pipeline de sélection des actifs, afin d'éclairer plus tôt les décisions de développement et de priorisation des candidats.

1.5.2. LA PLACE DU BRA DANS LE MARCHÉ DU DRUG DEVELOPMENT

Le processus de découverte et de développement des médicaments représente un pilier essentiel de l'innovation pharmaceutique, mais il reste marqué par des défis structurels et financiers. Ce processus se divise en deux grandes étapes : **Drug Discovery** et **Drug Development**.

La phase de **Drug Discovery** inclut l'identification de cibles thérapeutiques, le criblage de molécules (« hits ») et le développement des molécules sectionnées (« lead »),

La phase du **Drug Development** contient les **développement préclinique** et **développement clinique** jusqu'à l'obtention d'une autorisation réglementaire de mise sur le marché.

Le cycle de développement complet de la découverte d'une molécule à son approbation peut durer entre **10 et 15 ans**, est marqué par un taux d'échec élevé (**90 %**) et des coûts moyens par molécule estimés entre **2 et 3 milliards de dollars**. Une fois le médicament sur le marché, les entreprises concernées ont un devoir de pharmacovigilance afin de sécuriser l'utilisation du médicament et de pouvoir conserver sa place sur le marché.

Le marché du BRA représente aujourd'hui un segment stratégique de l'évaluation des médicaments. Ce marché est estimé à environ **13,2 milliards de dollars par an**.

L'analyse bénéfice-risque est désormais intégrée à l'ensemble du processus de **drug development**, depuis les phases précoces de développement jusqu'aux phases cliniques avancées et aux interactions réglementaires. Toutefois, son niveau d'utilisation et sa profondeur analytique varient selon les **phases de développement du médicament**.

Ainsi, le marché peut être segmenté en fonction des différentes étapes du développement clinique de la molécule cible faisant l'objet d'une analyse bénéfice-risque, chaque phase mobilisant ces analyses à des degrés différents.

Phase de développement du médicament	Taille du marché	Nombre de molécules par phase	Moyenne par molécule
Préclinique	\$1.15Mds	11 351	\$100K
Phase 1	\$1.47Mds	2 947	\$250K
Phase 2	\$1.39Mds	1 385	\$1M
Phase 3	\$0.39Md	388	\$1,2M
Approbation	\$0.32Md	213	\$500k
Post-Marketing	\$8.4Mds	196	\$4,3M

Aujourd'hui, plus de deux tiers du marché de l'analyse bénéfice-risque se concentre sur les activités post-marketing. À l'inverse, les entreprises investissent encore relativement peu dans ce type d'analyse pour les actifs situés en début de développement.

Toutefois, la demande de l'industrie pharmaceutique évolue progressivement vers une utilisation plus précoce de ces analyses, notamment dans les phases de développement clinique. L'intégration d'une analyse bénéfice-risque permet en effet d'orienter la stratégie de développement d'un candidat médicament avant l'engagement d'essais pivots particulièrement coûteux.

Le principal goulot d'étranglement reste aujourd'hui l'entrée en clinique. Les industriels cherchent donc à faire évoluer ces approches afin de pouvoir réaliser des analyses bénéfice-risque dès les stades précliniques.

Ces besoins et contraintes ont permis l'évolution du domaine avec le développement d'approches quantitatives, notamment les méthodes **MCDA (Multi-Criteria Decision Analysis)**, permettant de structurer plus finement l'évaluation des bénéfices et des risques des candidats médicaments.

Finalement, aux stades précoces du drug development, notamment durant les phases précliniques et les premières phases cliniques, l'analyse bénéfice-risque peut être assimilée à un ensemble de recommandations structurantes permettant aux entreprises d'orienter leurs choix stratégiques de développement.

Dans ce contexte, le marché ne se limite plus aux seules solutions visant à formaliser ou structurer le BRA. Il englobe désormais l'ensemble des outils et approches permettant d'éclairer la prise de décision des entreprises disposant d'un pipeline de candidats médicaments, notamment dans les phases de priorisation et de sélection des actifs.

Ce marché élargi, centré sur la sélection des leads à amener en clinique ainsi que sur l'optimisation du développement préclinique, est estimé à 6,38 milliards de dollars¹. Il comprend notamment les activités liées à la caractérisation des propriétés ADME, à la définition des profils pharmacodynamiques et pharmacocinétiques, ainsi qu'à l'analyse de données issues d'études in vitro et in vivo.

Aujourd'hui, ce marché est fortement porté par la montée en puissance des approches numériques et de l'intelligence artificielle dans les phases précoces du développement pharmaceutique, qui transforment progressivement le secteur en permettant un criblage des candidats médicaments plus rapide, plus ciblé et plus prédictif.

L'efficacité de ces approches est déjà faite ces preuves dans les phases amont du développement en drug discovery. L'intégration de l'intelligence artificielle (IA) dans cette phase permettrait de **réduire significativement les coûts** (–20 % à –40 %) et les délais (–30 % à –50 %), tout en **augmentant les taux de**

¹ <https://www.sphericalinsights.com/fr/reports/drug-discovery-services-market>

succès des projets. En effet, certaines études montrent que les molécules identifiées par l'IA augmentent leurs chances de réussite en phase 1 clinique de près de 80 %.

Dans ce contexte, le développement de médicaments assisté par l'IA constitue aujourd'hui une dynamique structurante pour l'industrie pharmaceutique. Face à la **pression croissante sur les coûts** de R&D et aux **taux d'échec persistants**, les laboratoires cherchent à **internaliser ces capacités en déployant leurs propres infrastructures data** et en constituant des équipes dédiées en IA, notamment pour l'identification de cibles, la priorisation de candidats ou l'optimisation de protocoles.

Cependant, dans le cadre du développement préclinique, aucune solution n'a encore réussi à démontrer de manière incontestable sa valeur ajoutée ni à s'imposer comme une solution de référence auprès des partenaires pharmaceutiques.

1.5.3. ENVIRONNEMENT CONCURENTIEL D'ARCASCIENCE

Environnement Concurrentiel de Trial Balancer

Le module Trial Balancer d'ArcaScience positionne la société sur le segment du BRA allant de la phase 2 clinique jusqu'aux activités de pharmacovigilance. Aujourd'hui, ce marché est principalement détenu par des CRO spécialisées qui réalisent pour le compte des laboratoires pharmaceutiques les analyses nécessaires aux dossiers réglementaires et au suivi post-autorisation. Ces acteurs produisent notamment des analyses BRA, des synthèses de littérature scientifique ainsi que différents livrables réglementaires tels que les PSUR/PBRER ou les plans de gestion des risques, dans le cadre des obligations de pharmacovigilance et du maintien de l'autorisation de mise sur le marché. Sur ce segment, les principaux concurrents d'ArcaScience regroupent donc ces grandes CRO internationales ainsi que certains cabinets spécialisés en affaires réglementaires et pharmacovigilance.

Enterprise	Pays	Activité principale
	Etats-Unis	Cabinet de conseil spécialisé en pharmacovigilance, safety science et gestion du bénéfice/risque pour l'industrie pharmaceutique.
	Etats-Unis	Cabinet de conseil en stratégie et développement clinique pour biotech et pharma, incluant accompagnement réglementaire et accès au marché.
	Etats-Unis	Société spécialisée dans l'analyse de données cliniques, pharmacovigilance et gestion des données réglementaires.
	Royaume - Uni	Société internationale spécialisée en affaires réglementaires, pharmacovigilance, compliance et services réglementaires globaux.
	Etats-Unis	Cabinet de conseil en pharmacovigilance et gestion du risque, spécialisé dans les systèmes PV et la conformité réglementaire.
	Etats-Unis	Société de conseil spécialisée en pharmacovigilance, gestion du risque et stratégie réglementaire.

La proposition de ces entités repose sur l'**expertise réglementaire**, l'accès à des équipes dédiées et l'accompagnement à la soumission. Toutefois, ces approches restent intensives en main-d'œuvre (screening, extraction, harmonisation), peu reproductibles d'un cycle à l'autre et coûteuses lorsqu'il s'agit de couvrir un portefeuille multi-pathologies.

Au delà de ces solutions d'analyse manuelle, **ArisGlobal**, se distingue en proposant une solution de **BRA** en mode **SaaS**, basée sur une plateforme permettant d'optimiser le workflow interne des laboratoires pharmaceutiques, et revendique une accélération de près de **40 %** du temps consacré à la réalisation de **BRA** (soit environ **huit mois**).

Par rapport aux approches CRO et à la solution SaaS d'ArisGlobal, la solution d'ArcaScience présente deux avantages principaux.

- **Temps et coûts** : Trial Balancer permet de réaliser une analyse BRA en quelques semaines pour un coût d'environ **125 k€**, contre **plus d'un million d'euros et plus d'un an de travail** via des CRO. ArisGlobal améliore le workflow interne mais reste centré sur l'organisation des processus existants.
- **Volume de données analysées** : la solution d'ArcaScience permet d'intégrer **10 à 100 fois plus de datapoints** issus de sources scientifiques et réglementaires. Les analyses produites sont donc **plus exhaustives** que celles reposant sur des bases propriétaires limitées ou des revues manuelles.

Ainsi, Trial Balancer permet de produire des analyses BRA plus rapidement, à moindre coût et sur un périmètre de données plus large que les solutions existantes. Cette combinaison positionne ArcaScience comme la solution la plus performante du marché pour industrialiser l'analyse bénéfice-risque au sein des laboratoires pharmaceutiques.

Environnement Concurrentiel de BR-Predict

Le module **BR-Predict** se positionne en amont de ces phases avec l'objectif de devenir **un outil d'aide à la décision pour les entreprises disposant de pipelines précliniques et cliniques**.

Bien que les CRO mentionnées et ArisGlobal soient solidement implantées sur le marché des **BRA**, leur repositionnement vers ce segment amont reste limité par plusieurs contraintes opérationnelles et techniques :

- **Le coût des BRA**, estimé aujourd'hui à près de **1,2 million de dollars par molécule**, est trop élevé pour des actifs aussi précoces. Les entreprises pharmaceutiques ne peuvent pas appliquer ce type d'analyse à l'ensemble de leurs pipelines précliniques.
- **Les méthodes actuelles restent majoritairement manuelles et lentes**, et reposent principalement sur des données d'efficacité et de sécurité cliniques. Avant la phase 2, ces données sont fragmentées et proviennent souvent de modèles animaux dont la transposabilité à l'humain est limitée. Les données disponibles sont donc insuffisantes pour produire une BRA robuste avec les approches traditionnelles.

Dans ce contexte, ces solutions ne constituent pas une concurrence directe pour **BR-Predict**.

ArcaScience se trouve davantage confrontée aux **solutions d'IA d'aide à la décision en phase préclinique**, qui visent à interpréter des données telles que la pharmacocinétique, la pharmacodynamique ou les propriétés ADME. Deux catégories d'acteurs se distinguent :

Les laboratoires pharmaceutiques eux-mêmes. Chaque grand laboratoire développe progressivement ses propres workflows internes afin d'améliorer la prédiction de l'efficacité et de la sécurité des candidats médicaments. Toutefois, ces capacités restent souvent fragmentées.

Sociétés développant des plateformes spécialisées : Ces acteurs proposent des solutions clés en main couvrant principalement les phases amont du développement, telles que **l'identification de cibles thérapeutiques**, la **détection de hits** ou **l'optimisation de leads**. Certains élargissent désormais leur positionnement vers des services à plus forte valeur stratégique, en accompagnant les laboratoires dans l'optimisation du design clinique ou dans l'évaluation prédictive de certaines caractéristiques des candidats médicaments.

Ces offres visent à fluidifier l'accès aux données et à renforcer la conformité opérationnelle, mais **elles ne proposent pas nativement une BRA comparative complète, explicable et reproductible par rapport au standard of care**.

Enterprise	Pays	Activité principale
nference [®]	Etats-Unis	Parmi les capacités revendiquées par la plateforme, nference met en avant l'analyse de trajectoires patients à partir de données hospitalières structurées et non structurées (EHR, biologie, comptes rendus cliniques). Les cas d'usage incluent l'enrichissement de protocoles cliniques, l'identification de sous-groupes de patients et l'analyse rétrospective de populations pour documenter des signaux cliniques.
"TEMPUS	Etats-Unis	Parmi les capacités revendiquées par la plateforme, Tempus met en avant des études translationnelles et des analyses clinico-génomiques

		destinées à orienter la sélection des patients dans les essais cliniques, principalement en oncologie.
 OWKIN	Etats-Unis	Parmi les capacités revendiquées par la plateforme, Owkin développe des modèles d'apprentissage automatique appliqués à des données multimodales (imagerie, données cliniques, données moléculaires), souvent dans un cadre d'apprentissage fédéré. Les cas d'usage mis en avant incluent l'identification de biomarqueurs associés à des issues cliniques, l'analyse de facteurs corrélés à la réponse observée dans des cohortes existantes et l'optimisation du design d'essais cliniques (enrichissement de population, définition d'endpoints).
 Benevolent^{AI}	Royaume - Uni	Parmi les capacités revendiquées par la plateforme, BenevolentAI se positionne sur la priorisation de candidats médicaments en phase préclinique via l'analyse intégrée de données biologiques, chimiques et issues de la littérature scientifique. Société internationale spécialisée en affaires réglementaires, pharmacovigilance, compliance et services réglementaires globaux.

Finalement, les solutions positionnées sur le segment de développement préclinique demeurent complémentaires à l'approche portée par le nouveau module d'ArcaScience. Là où ces outils optimisent l'identification et la conception des candidats, BR-Predict intervient en aval pour **structurer et anticiper leur profil BRA** dans une logique décisionnelle globale.

La solution s'inscrit ainsi en continuité des molécules conçues par IA, dont la probabilité de succès est déjà optimisée en phase de découverte. Elle permet de capitaliser sur ces actifs en apportant une couche d'analyse stratégique supplémentaire, orientée vers la priorisation clinique et la sécurisation des choix d'investissement. Par ailleurs, le module est conçu pour **s'intégrer avec d'autres outils d'aide à la décision**, renforçant une approche combinée et cohérente du développement pharmaceutique.

Cependant, si ces plateformes ne sont pas aujourd'hui positionnées explicitement sur le segment de la **BRA prédictive**, elles disposent d'atouts structurels susceptibles d'en faire des concurrents directs à moyen terme.

Elles adressent la même clientèle cible et les mêmes **problématiques de R&D et de translation clinique** des laboratoires pharmaceutiques. De plus, les plateformes développées par ces sociétés suivent la même dynamique en cherchant à devenir des outils de plus en plus exhaustifs pour ces entreprises pharmaceutiques. Également au niveau technique, elles se basent sur des **données d'entrée** et mobilisent des expertises techniques similaires en matière de **modélisation IA**, d'**ingénierie des données** et d'**intégration multimodale**.

Les barrières technologiques à l'entrée sur le segment spécifique de la **BRA prédictive** restent donc modérées pour ces acteurs. Une extension fonctionnelle de leurs plateformes vers ce cas d'usage serait cohérente avec leur positionnement stratégique actuel, notamment dans une logique d'intégration verticale de la chaîne décisionnelle en développement clinique.

À ce stade, ArcaScience demeure toutefois le seul acteur spécialisé et structuré autour d'une **BRA automatisée, comparative et industrialisable**. Cette spécialisation constitue un avantage différenciant clair.

1.5.4. DEPLOIEMENT DE BARRIERES A L'ENTREE DU MARCHE

La stratégie d'ArcaScience vise précisément à transformer cette avance technologique en barrière à l'entrée marché durable :

- **Barrière technologique** : La première barrière à l'entrée repose sur l'avance technologique d'ArcaScience dans le développement d'architectures logicielles dédiées à la BRA des candidats médicaments. La plateforme combine une architecture logicielle complexe, des capacités

d'intégration de données biomédicales hétérogènes et des modèles d'intelligence artificielle avancés, incluant notamment des approches de type LLM adaptées à ce cas d'usage spécifique. Bien que certains acteurs du secteur disposent en théorie des compétences techniques nécessaires pour développer des solutions similaires, leur temps de développement serait particulièrement long en raison des besoins d'accès aux données, de structuration des ontologies, d'entraînement des modèles et de validation scientifique. Cette avance technologique permet à ArcaScience de déployer progressivement des modèles spécialisés sur un nombre croissant de pathologies. En maintenant un rythme d'innovation continu au-delà du programme i-Démo, l'entreprise pourra consolider cette avance et couvrir un large périmètre d'indications avant que d'éventuels concurrents ne puissent développer des solutions comparables.

- **Barrière de marché** : Une seconde barrière repose sur la dynamique d'adoption progressive de la plateforme par les entreprises pharmaceutiques, les biotechnologies et les CRO. La solution d'ArcaScience se caractérise par une forte polyvalence et peut être utilisée sur un large éventail d'actifs thérapeutiques et de pathologies. À mesure que la société déploie sa plateforme auprès d'un nombre croissant d'acteurs industriels, elle renforce sa présence sur un marché très large. Dans ce contexte, de nouveaux entrants auraient des difficultés à s'imposer sur l'ensemble du segment. Leur stratégie consisterait probablement à cibler des niches thérapeutiques ou des cas d'usage spécifiques afin de proposer des solutions plus spécialisées. Toutefois, ArcaScience conserverait un avantage en tant que solution généraliste capable de couvrir un grand nombre de pathologies et de types d'actifs, ce qui lui permettrait de rester la plateforme de référence pour les analyses bénéfice-risque polyvalentes.
- **Barrière liée au modèle économique et au SaaS** : Le modèle économique d'ArcaScience contribue également à renforcer les barrières à l'entrée. La plateforme est déployée directement chez les clients en mode SaaS et intégrée dans leurs processus internes d'évaluation des candidats médicaments. Une fois la solution installée, les entreprises disposent d'une licence leur permettant d'analyser de nouvelles molécules dans leurs pipelines de développement. Dans ce contexte, le coût organisationnel et financier d'un changement de solution devient significatif. Tant que les exigences réglementaires associées aux analyses bénéfice-risque restent stables, les laboratoires ont peu d'incitation à adopter une solution concurrente nécessitant un nouvel investissement et une réintégration dans leurs workflows internes. Cette dynamique favorise l'installation de relations contractuelles durables entre ArcaScience et ses clients.
- **Barrière liée à la propriété intellectuelle** : Enfin, ArcaScience met en place une stratégie de propriété intellectuelle visant à protéger certaines briques technologiques développées dans le cadre du projet. Les innovations méthodologiques associées aux modules Trial Balancer et BR-Predict font l'objet de dépôts de brevets couvrant notamment certaines approches de structuration et d'analyse des données biomédicales. Si la protection d'un logiciel dans son ensemble reste limitée, ces dépôts permettent de sécuriser plusieurs innovations clés et de limiter la reproduction directe de certaines méthodes par des concurrents. Cette stratégie de protection vient ainsi compléter les autres barrières technologiques et commerciales développées par l'entreprise.

ArcaScience sera en mesure d'ancrer un positionnement différenciant et défendable, limitant significativement la capacité d'acteurs généralistes à pénétrer ce segment sans investissements lourds et réorientation stratégique majeure.

Enfin, ArcaScience est la solution la plus avancée pour développer ce module répondant parfaitement aux besoins des entreprises pharmaceutiques. Les analyses manuelles sont longues, coûteuses et pas assez exhaustives ni avancées technologiquement. Les solutions d'aides à la prise de décisions de développement ne couvrent que certains aspects encore trop ciblés de tous les éléments nécessaires à prendre en compte pour établir un choix de développement éclairé.

2. OBJECTIFS ET CONTEXTE TECHNICO-ECONOMIQUE

2.1. RESUME DU PROJET

Aujourd'hui, ArcaScience développe une plateforme d'intelligence artificielle dédiée à l'analyse bénéfice-risque des médicaments. Cette solution agrège et structure un large volume de données scientifiques, cliniques et biomédicales afin de produire des analyses comparatives entre un candidat médicament et les traitements de référence.

Ce socle technologique constitue le module actuellement déployé, **Trial Balancer**, qui permet d'exploiter des données cliniques issues des essais thérapeutiques, des données de référence sur les traitements standards ainsi que des données ontologiques biomédicales. La plateforme structure ces informations afin de produire des évaluations comparatives du profil bénéfice-risque d'un candidat médicament et de générer des analyses exploitables par les équipes cliniques et réglementaires. L'architecture développée permet également de mettre à jour ces analyses lorsque de nouvelles données deviennent disponibles.

Le programme **i-Démo BR-Predict** vise à exploiter cette architecture existante afin de développer un nouveau module capable de produire des **BRA prédictives dès les phases précoces du développement des médicaments**. Ce module étendra les capacités actuelles de la plateforme en intégrant de nouvelles typologies de données, notamment des données moléculaires, précliniques, génomiques et de vie réelle.

Ces données seront utilisées pour modéliser les relations entre mécanisme d'action, profils biologiques, réponse clinique et événements indésirables. Le projet prévoit ainsi le développement de nouveaux modèles d'intelligence artificielle capables d'exploiter ces données multimodales afin d'identifier des signaux prédictifs du profil bénéfice-risque d'un candidat médicament avant son entrée en clinique.

À l'issue du programme i-Démo, la plateforme ArcaScience disposera ainsi d'un **module BR-Predict** capable de produire des BRA prédictives en amont des premières phases cliniques. Le programme permettra également de développer **un démonstrateur appliqué au cancer du poumon non à petites cellules**, afin de valider la capacité du module à exploiter ces nouvelles données et à produire des évaluations prédictives dans un contexte thérapeutique réel.

2.2. AMBITION STRATEGIQUE DU PROJET

2.2.1. PROBLEMATIQUE DANS LE SUCCES DES ESSAIS CLINIQUES

Le développement clinique d'un médicament représente aujourd'hui l'un des processus industriels les plus longs, les plus capitalistiques et les plus incertains du secteur de la santé. Depuis le début du XXI^e siècle, **l'investissement moyen nécessaire pour conduire un candidat jusqu'à la commercialisation est estimé entre 1 et 2 milliards de dollars. La durée moyenne des essais cliniques atteint désormais près de huit ans par molécule.**

Malgré ce niveau d'engagement financier et humain considérable, la performance globale demeure faible. En pratique, **moins de 10 % des molécules Fentrant en développement atteignent effectivement le marché** (Thomas et al., 2016), (Pfizer France), (Sun et al., 2022). Ce décalage entre l'intensité des investissements et le taux de succès constitue un enjeu industriel majeur.

L'analyse des causes d'échec met en évidence un point central. Entre **40 et 54 % des échecs** sont attribués à un **manque d'efficacité démontrée**, tandis que **17 à 30 %** sont liés à des **problèmes de toxicité** (Patsnap, 2023), (Fogel, 2018), (Sun et al., 2022). Autrement dit, dans près de deux tiers des cas, l'échec ne résulte pas d'un défaut d'exécution opérationnelle de l'essai, mais d'une inadéquation scientifique entre le mécanisme d'action du candidat, la population ciblée et l'effet clinique réellement observé.

En outre, l'industrie pharmaceutique s'oriente de plus en plus vers l'exploration de nouveaux mécanismes d'action, délaissant les cibles biologiques bien documentées au profit de territoires thérapeutiques moins balisés (Zhou et al., 2025). Cette évolution n'est pas anodine sur le plan du risque : **les médicaments first-in-class affichent un taux de succès clinique d'environ 5%, contre 8% pour les molécules s'appuyant sur**

des cibles déjà validées (Pharma's Almanac, 2024). À mesure que les programmes s'aventurent dans des indications nouvelles, la difficulté de valider des cibles inédites s'accroît mécaniquement (Norstella, 2024). À ces abandons s'ajoute une instabilité significative des protocoles. En moyenne, deux à trois amendements sont réalisés par protocole en phase avancée dont **45 % sont évitables**. Ces modifications interviennent souvent en réaction à l'apparition de nouvelles informations de sécurité, à des demandes de modification stratégique, à une mauvaise conception initiale du protocole ou à des difficultés de recrutement. Cette instabilité se traduit par des retards importants : près de **85 % des dossiers accusent des délais supplémentaires**, associés à des **surcoûts** évitables estimés en moyenne à **535 000 dollars** par dossier (Intuition Labs), (Getz et al., 2016).

Les améliorations méthodologiques récentes, designs adaptatifs, enrichissement de population, meilleure sélection des patients n'ont pas permis d'améliorer de manière significative les taux de réussites des essais cliniques

2.2.2. L'ANALYSE BÉNÉFICE RISQUE COMME UNE SOLUTION VIABLE

Dans ce contexte, la question stratégique devient évidente : si l'échec est majoritairement lié à une évaluation insuffisamment robuste de l'efficacité attendue ou des risques associés, alors l'enjeu prioritaire n'est pas uniquement d'optimiser l'exécution des essais, mais d'améliorer la capacité d'anticipation du bénéfice/risque en amont de la réalisation de ces essais. À ces défis s'ajoute un troisième pilier tout aussi déterminant : le **choix des populations cibles**, qui conditionne la capacité à démontrer un effet thérapeutique significatif et à construire un profil bénéfice/risque solide.

Une analyse bénéfice/risque structurée et prédictive, conduite le plus tôt possible dans le processus de développement, permettrait de transformer profondément la logique décisionnelle du développement pharmaceutique. Elle offrirait la possibilité **d'identifier précocement les candidats insuffisamment différenciés, de détecter les risques mécanistiques de toxicité avant l'exposition massive de patients, d'ajuster le design clinique en cohérence avec le mécanisme d'action, et de cibler les populations les plus susceptibles de répondre au traitement**. Elle constituerait ainsi un levier direct de réduction des abandons tardifs, des amendements de protocoles et des retards associés.

Au-delà de la réduction du risque financier, l'enjeu est également scientifique et éthique. Anticiper plus finement le profil bénéfice/risque permettrait de limiter l'exposition inutile de sujets sains et de patients à des candidats insuffisamment prometteurs, tout en réallouant plus rapidement les ressources vers des molécules à plus fort potentiel thérapeutique.

2.2.3. LA PLACE DU BRA DANS LE DÉVELOPPEMENT DE MÉDICAMENT

Aujourd'hui, l'analyse bénéfice/risque occupe une place centrale dans le cadre réglementaire. Elle structure l'évaluation des autorités sanitaires et constitue l'un des piliers du dossier d'autorisation de mise sur le marché. Elle est également déterminante dans les discussions relatives au remboursement et à la valeur médico-économique.

Cependant, dans la pratique industrielle, cette analyse est principalement mobilisée dans une logique descriptive et justificative. Elle consolide les données générées au cours du développement afin de démontrer que les bénéfices observés surpassent les risques identifiés. Elle intervient donc essentiellement à un stade où les choix structurants ont déjà été réalisés et où les investissements majeurs ont été engagés. Cette approche limite fortement son impact stratégique.

L'analyse bénéfice/risque actuelle ne constitue pas un outil prédictif intégré permettant de modéliser différents scénarios de développement, d'anticiper la probabilité de succès clinique ou d'évaluer quantitativement la robustesse d'un positionnement thérapeutique face aux traitements sur le marché.

2.2.4. LIMITES ACTUELLES DU PROCESSUS D'UTILISATION DU BRA POUR L'AIDE AU DEVELOPPEMENT DE MEDICAMENTS

Si l'analyse bénéfice/risque apparaît comme un levier stratégique évident pour améliorer le succès des essais cliniques, sa mise en œuvre en amont du développement se heurte aujourd'hui à des contraintes technologiques majeures.

En pratique, une évaluation complète du profil bénéfice/risque nécessite près d'un an de travail pour une seule molécule. Ce délai est incompatible avec les rythmes décisionnels des phases précoces, où les arbitrages doivent être réalisés rapidement pour sélectionner, prioriser ou arrêter des candidats. L'analyse est mobilisable en aval, dans une logique réglementaire, mais pas dans une logique dynamique d'aide à la décision.

Cette lourdeur opérationnelle s'explique en partie par la complexité intrinsèque du travail. L'exercice requiert une expertise clinique et réglementaire approfondie, mobilisant des équipes pluridisciplinaires capables d'interpréter des données hétérogènes, de qualifier les niveaux de preuve et de contextualiser les résultats au regard de la population cible. Cette dépendance forte à l'expertise humaine limite la scalabilité de l'approche et en renchérit le coût.

Par ailleurs, les analyses actuelles reposent largement sur des données non structurées issues de publications scientifiques, de rapports d'essais cliniques, de bases publiques ou de documents réglementaires. L'exploitation de ces sources nécessite un travail manuel de lecture, d'extraction et de consolidation, ce qui rend le processus long, partiellement reproductible et difficilement industrialisable.

L'enjeu est d'autant plus complexe que le volume de données disponibles a explosé ces dernières années. Les informations pertinentes sont distribuées entre données précliniques, essais cliniques, littérature académique, bases de pharmacovigilance, données génomiques et, de plus en plus, données de vie réelle. Cette hétérogénéité rend l'intégration systémique particulièrement difficile. En pratique, les analyses actuelles n'exploitent qu'une partie des données disponibles, faute d'outils permettant de les agréger et de les structurer à grande échelle.

À ces défis structurels s'ajoute une tendance de fond qui vient encore accentuer la difficulté : l'industrie pharmaceutique s'oriente de plus en plus vers l'exploration de nouveaux mécanismes d'action, pour lesquels les données épidémiologiques et cliniques historiques sont rares ou inexistantes. Là où les approches traditionnelles pouvaient s'appuyer sur un corpus de données établi, ces nouveaux actifs évoluent dans un environnement de données raréfiées, rendant l'évaluation du bénéfice/risque particulièrement difficile à fonder sur des évidences directes. Dans ce contexte, les capacités prédictives deviennent une nécessité opérationnelle : c'est la modélisation et l'anticipation qui doivent suppléer au manque d'évidence empirique.

Cette combinaison de complexité technique et d'intensité humaine se traduit par un coût élevé. Le coût estimé d'une analyse complète avoisine 1,2 million d'euros par molécule. Un tel niveau d'investissement rend impossible une utilisation systématique sur des portefeuilles larges de candidats en phase précoce.

2.2.5. LES BESOINS DU BRA

Au regard des contraintes techniques et opérationnelles de l'utilisation des analyses bénéfice-risque dans un contexte de développement de candidats médicament, plusieurs besoins sont mis en évidence :

- Le premier besoin concerne la **précision des analyses**. Les industriels doivent pouvoir mieux orienter leurs décisions sur les actifs à développer, prioriser ou repositionner dans le schéma de prise en charge. Il s'agit d'évaluer plus finement la cohérence entre le mécanisme d'action, l'efficacité attendue et les risques, tout en comparant les résultats de l'actif analysé aux thérapies déjà sur le marché.

- Le second besoin concerne la capacité à étendre ces analyses à des mécanismes d'action de plus en plus variés et complexes. Les nouveaux candidats médicaments reposent sur des approches biologiques et thérapeutiques diversifiées, ce qui nécessite d'intégrer et d'exploiter des volumes importants de données hétérogènes. Les données pertinentes sont nombreuses, distribuées et de nature très différente. Les industriels ont donc besoin d'outils capables de structurer, annoter et croiser ces jeux de données afin de produire des analyses cohérentes et adaptées à ces nouveaux mécanismes thérapeutiques.
- Un troisième besoin concerne la **réduction des délais et des coûts d'analyse**. Les processus actuels sont longs et coûteux. Pour être réellement décisionnelle, l'analyse bénéfice/risque doit devenir plus rapide, standardisée et industrialisable.

Ces besoins convergent vers une même exigence : rendre l'analyse bénéfices-risques plus précise et capable d'intégrer un périmètre de données plus large. À terme, ces améliorations permettront de faire évoluer ces analyses vers une approche prédictive.

2.2.6. LA PLATEFORME ARCASCIENCE

ArcaScience a développé la **première plateforme capable de construire automatiquement une analyse bénéfice/risque complète à partir d'un volume massif de données scientifiques et cliniques**. La solution extrait, structure et harmonise des données issues de sources multiples (publications, essais cliniques, bases biomédicales), puis analyse le profil bénéfice/risque d'un candidat médicament.

L'architecture de la plateforme repose sur une **infrastructure de donnée unifiée** permettant l'ingestion multi-source, la structuration automatisée et la normalisation à grande échelle. L'ensemble du workflow (extraction, annotation, classification et hiérarchisation des signaux) est automatisé, rendant l'analyse plus rapide, plus exhaustive et reproductible que les approches manuelles.

Plus en détail, une requête lancée par l'utilisateur sur la plateforme déclenche une recherche parmi les documents indexés dans Elasticsearch, qui repose sur un système hybride combinant recherche par mots-clés (BM25), recherche vectorielle et expansion de requêtes via des ontologies reconnues (MedDRA, ATC, SNOMED-CT). Un LLM d'appraisal évalue ensuite la pertinence de chaque document retrouvé par rapport à la question posée. Lorsque l'évaluation du corpus révèle des lacunes (comparateurs manquants, critères non couverts), le système relance automatiquement une recherche ciblée.

Les documents retenus, accompagnés de métadonnées pour chacun, sont déjà traités par plus de 20 modèles d'intelligence artificielle propriétaires de type SLM (Small Language Models), incluant des modèles NER, de classification et d'extraction de relations, couplés à une normalisation par ontologies pour l'harmonisation et le codage des entités (Pre-indexation). Chacun de ces modèles est entraîné pour une problématique spécifique de l'analyse bénéfice/risque, telle que la caractérisation des patients, des modalités de traitement, des caractéristiques de risque, des critères d'évaluation, des caractéristiques des effets bénéfiques, ou encore la caractérisation des pathologies.

Le résultat de cette requête est une base de données structurée et harmonisée couvrant l'indication d'intérêt, le candidat médicament, ainsi qu'un nombre exhaustif de traitements testés ou utilisés dans cette indication. L'ajout de nouvelles données clients (hors pipeline habituel) implique une indexation à la demande de ces données par nos modèles propriétaires, mais sur le serveur du client lui-même, ce qui limite la fuite de données sensibles. Ces résultats sont ensuite ajoutés à la base de données déjà décrite.

Ces informations sont ensuite mises à disposition de l'utilisateur via une plateforme qui structure, pour la première fois, le processus complet d'analyse bénéfice/risque en respectant l'un des frameworks les plus couramment utilisés dans le domaine (Benefit-Risk Action Team) ainsi que les exigences réglementaires en vigueur.

Les fonctionnalités de la plateforme incluent la disposition des informations en relation avec la pathologie et les options thérapeutiques disponibles, la sélection intelligente des critères d'évaluation et des risques

à atténuer, l'évaluation et la comparaison des points de critères et des risques pour le benchmark thérapeutique, ainsi que l'évaluation des points d'incertitude. Elle permet également la génération de visualisations de données spécifiques au BRA, comme le Benefit-Risk Tree, les forest plots et les tableaux comparatifs, l'introduction d'un système de pondération intégrant la voix des patients et d'autres considérations, la réalisation de calculs biostatistiques, ainsi que la génération de documents à usage interne ou réglementaire.

La plateforme délivre ainsi à l'utilisateur un outil d'aide à la décision couvrant plusieurs dimensions clés : la compréhension de la population cible et de son unmet need, le choix du comparateur, la sélection de l'ensemble des critères du protocole clinique, un outil de caractérisation des bénéfices et des risques sans limitation du nombre de comparateurs ni de critères d'évaluation, ainsi qu'un outil de génération de documents directement utilisables auprès des autorités réglementaires (BRAD, PBRER, eCTD) en utilisant des modèles LLM.

Au niveau des performances et de la maintenance de ces modèles, ceux-ci subissent une réévaluation tous les 3 à 6 mois (selon le niveau de criticité du modèle). Ce rythme de réévaluation tient compte du fait que l'intégration continue de nouvelles données peut induire un data drift progressif, susceptible de dégrader silencieusement les performances. Un réentraînement est déclenché lorsque les résultats des évaluations révèlent une dégradation significative (hausse du micro-F1 de +5 à 10 %). En général, les modèles SLM utilisés obtiennent un F1 compris entre 80 % et 95 %, selon le modèle. Le modèle d'appraisal montre une précision entre 80 % et 95 %, qui dépend de la complexité de la question d'intérêt ainsi que de la complexité du sujet.

Ce qui différencie la plateforme au niveau technique, c'est que les traitements d'extraction et de structuration reposent sur des SLM propriétaires, entraînés pour des tâches spécifiques, dont nous maîtrisons la performance, garantissant reproductibilité, traçabilité et fiabilité. Les LLM interviennent uniquement pour le raisonnement métier (appraisal de pertinence) et la génération de résumés, où le risque d'hallucination est encadré par le système de RAG : chaque sortie s'appuie sur des extraits sourcés et des documents vérifiables.

L'actualisation continue des données dans la plateforme constitue également un point différenciant, notamment par rapport au travail manuel et aux approches impliquant des CRO. Dès le lancement du projet, nos technologies ajoutent de nouvelles informations dans la base de données associée au projet et notifient l'utilisateur de manière continue si ces informations nécessitent son attention.

De plus, ce qui distingue la plateforme, c'est qu'elle a été conçue avec des experts en développement clinique, en pharmacovigilance et en affaires réglementaires, ce qui la rend capable de répondre aux « pain points » de chacun tout en restant alignée avec les normes du métier.

Aujourd'hui, la plateforme est principalement utilisée dans une logique réglementaire et comparative. Toutefois, elle répond déjà aux principaux besoins techniques et opérationnels nécessaires à une analyse prédictive : exploitation harmonisée de données massives et hétérogènes, vision systémique du profil bénéfice/risque et capacité d'industrialisation à grande échelle.

Elle constitue ainsi la base technologique naturelle pour évoluer vers une analyse bénéfice/risque prédictive en amont du développement clinique, objectif central du projet BR-Predict.

2.2.7. PROPOSITION DE VALEUR


La plateforme ArcaScience a été conçue précisément pour répondre à ces points de friction. Le tableau ci-dessous synthétise la correspondance entre les principaux “pain points” du développement clinique et les bénéfices opérationnels et stratégiques apportés par la solution.

Pain point industriel identifié	Bénéfice apporté par la solution ArcaScience
Temps d’analyse long (jusqu’à 18 mois)	Réalisation de l’équivalent de 18 mois de travail en quelques semaines, permettant une intégration dans les cycles décisionnels précoces
Coût élevé d’une analyse complète (~1,2 M€ via CRO)	Réduction drastique des coûts (environ 125 k€), rendant l’analyse scalable sur un portefeuille large de candidats
Données massives non exploitées, hétérogènes et majoritairement non structurées	- Intégration de jeux de données 10 à 100 fois plus volumineux que les approches traditionnelles. - Architecture data unifiée permettant ingestion multi-source, structuration automatisée et harmonisation clinique - Comparaisons illimitées avec les traitements testés ou commercialisés pour identifier la différenciation et le positionnement optimal du candidat.
Processus non structuré, dépendant de plusieurs acteurs et plusieurs livrables	Une plateforme unique où tous les acteurs sont connectés, travaillent sur des livrables communes dans un framework structuré, garantissant qu'aucune information n'est oubliée ou perdue.
Mise à jour continue du projet et système de notifications	Une plateforme qui intègre de manière continue les données pertinentes et les ajoute à la base de données du projet, sans ajout manuel, sans temps de latence et sans traitement tardif des informations.

La solution ArcaScience ne constitue pas une simple optimisation incrémentale des pratiques existantes. Elle modifie la nature même de l’analyse bénéfice/risque en la rendant plus rapide, plus exhaustive, plus structurée et économiquement scalable.

2.3. AMBITION TECHNOLOGIQUE

2.3.1. WORKFLOW DE LA PLATEFORME ARCASCIENCE



La plateforme ArcaScience repose sur un workflow structuré en cinq étapes successives, permettant de transformer des données hétérogènes et massives en une analyse bénéfice/risque exploitable.

1. Récupération des données

La première étape repose sur l'alimentation de la base de données. Cette dernière agrège et structure plusieurs sources, incluant des publications scientifiques (PubMed, Medline), des registres d'essais cliniques (ClinicalTrials.gov), des bases biomédicales publiques, des données partenaires ainsi que des bases de données d'ontologies médicales.

Nous stockons cette masse importante de données dans un **data lake** afin de permettre un stockage efficace, la sécurité des données et une récupération rapide des sources brutes.

L'objectif de cette étape est de créer une base de données exhaustive sur laquelle nos traitements IA seront appliqués.

2. Harmonisation et structuration des données

La seconde étape repose sur un **Framework IA** constitué de plus de **20 SLMs** de structuration qui constituent la fondation du système.

Ces modèles traitent les documents bruts (PDF, XML, rapports d'essais, publications) afin de transformer des données majoritairement non structurées en un format standardisé, normalisé et exploitable.

Cette phase comprend :

- La conversion des documents,
- L'annotation sémantique,
- L'identification des concepts et ontologies,
- L'agrégation inter-sources,
- La suppression des doublons.

Elle exploite notamment des modèles (liste non-exhaustive) comme :

- **Arca Efficacy**, dédié à l'extraction automatisée des caractères d'efficacité (temps jusqu'à l'effet, importance de l'effet, odds ratios, etc.) ;
- **Arca PV**, focalisé sur l'identification et la caractérisation des risques ainsi que des informations de toxicité (gravité, grade, délai avant survenue, etc.) ;
- **Arca Patient Profile**, structurant les caractéristiques démographiques et cliniques des cohortes afin de permettre une analyse stratifiée et contextualisée.

Les autres modèles incluent des modèles d'extraction, de clustering et de classification des points d'évaluation, des modèles de classification des publications, ainsi que des modèles de caractérisation des modalités de traitement.

Cette étape permet de transformer un corpus documentaire fragmenté en une base de données harmonisée et interopérable, regroupant **100 milliards** de points de données issus de sources hétérogènes.

3. Stockage, indexation et recherche sémantique

Les données structurées sont ensuite stockées dans une architecture centralisée (ElasticSearch). Les documents sont également convertis en **embeddings vectoriels**, permettant une recherche sémantique rapide et précise. Cette capacité d'indexation constitue un levier clé pour explorer des volumes documentaires massifs et effectuer des requêtes complexes grâce à un système hybride combinant recherche par mots-clés (BM25), recherche vectorielle et expansion de requêtes via des ontologies reconnues (MedDRA, ATC, SNOMED-CT...).

L'infrastructure technique repose sur une **stack DevOps** industrialisée : Docker pour la containerisation, Kubernetes pour l'orchestration, Ansible pour l'automatisation des déploiements. La sécurité est assurée par des protocoles de chiffrement avancés (AES 256-bit), le respect de standards industriels comme HIPAA, et un monitoring continu via Prometheus et Grafana. La gestion de version et la qualité logicielle sont pilotées par GitLab et SonarQube.

4. Mise à jour continue des connaissances

La plateforme intègre un mécanisme de veille automatisée. Les nouveaux contenus scientifiques sont détectés automatiquement, analysés et intégrés dans la base. Les modèles mettent à jour les signaux d'efficacité et de risque en continu, assurant une actualisation dynamique du référentiel.

Cette fonctionnalité est particulièrement structurante pour une plateforme SaaS. Une fois installée chez le client et correctement mise en place, celle-ci peut générer un rapport bénéfice-risque d'une année à l'autre sans devoir retravailler la solution.

5. Analyse étendue et construction du profil bénéfice/risque

La dernière étape mobilise l'ensemble du framework "Ensemble Model".

Les données harmonisées sont exploitées pour :

- Analyser le contexte thérapeutique,
- Examiner les critères d'évaluation (endpoints),
- Contextualiser les résultats au regard des autres traitements.
- Évaluer les risques potentiels ou identifiés,
- Caractériser les effets bénéfiques d'intérêt

La plateforme qui reçoit ces informations propose des fonctionnalités de visualisation des données, de synthèse et de filtrage, ce qui permet la production d'une analyse bénéfice/risque complète, comparative et traçable.

Le workflow technologique d'ArcaScience permet aujourd'hui de transformer un volume massif de données biomédicales hétérogènes en une analyse bénéfice/risque structurée, comparative et traçable, dans des délais et à des coûts compatibles avec un usage industriel.

2.3.2. DONNEES ANTERIEURES

La genèse d'ArcaScience remonte à 2016, avec la structuration d'un comité scientifique autour d'une ambition claire : utiliser l'intelligence artificielle pour objectiver et structurer l'analyse bénéfice/risque en santé.

Entre 2018 et 2021, les premiers modèles d'IA ont été développés pour classer les sujets liés aux bénéfices et aux risques, puis pour détecter les modalités de traitement et les caractéristiques patients via des briques NLP spécialisées. Cette phase a permis de poser les bases méthodologiques de structuration de données biomédicales non structurées.

À partir de 2023, les développements se sont accélérés avec :

- La création de modèles dédiés à l'extraction des points d'évaluation et à la caractérisation des effets bénéfiques
- La classification des publications,
- La caractérisation des risques (grading, sévérité, temporalité),
- Le développement d'algorithmes de génération automatique de rapports.

En 2024, les modèles d'extraction de relations ont permis d'identifier les liens entre biomarqueurs, mécanismes d'action et pathologies spécifiques. C'est lors de cette année que le partenariat avec Sanofi a débuté.

En 2025 la plateforme a atteint le niveau d'architecture présenté précédemment. Un cas d'usage structurant a été conduit avec Sanofi avec les données de phase 2 clinique d'un médicament biologique comparé à un actif déjà commercialisé avec des données cliniques et RWD disponibles, dans une pathologie dermatologique inflammatoire.

Les modèles spécialisés ont alors réalisé une analyse bénéfices risques à partir des résultats cliniques et des données agrégées. Les résultats ont été évalués selon des métriques standardisées (F1-score et taux de couverture des données) et comparé avec la méthode actuelle de Sanofi :

Extraction de biomarqueurs	
Validation avec un Golden standard : F1	90.05%
Validation externe (Disgenet): taux de couverture des données	92% pour top 30 biomarqueurs
Extraction des Risques	
Validation avec un Golden standard: F1	88.1%
Validation externe (Sanofi) : taux de couverture des données	96%
Extraction des benefices	
Validation avec un Golden standard: F1	92%
Validation externe (Sanofi) : taux de couverture des données	97%

Ces résultats confirment la robustesse des briques d'extraction et la capacité de la plateforme à structurer des données biomédicales complexes provenant de plus de 25 000 publications avec un haut niveau de précision. De plus, les étapes respectent les exigences des frameworks BRAT et FDA pour la conception du BRA.

Cette analyse a permis de réaliser en deux mois l'équivalent de près de 18 mois de travail. De plus, l'analyse produite par la solution ArcaScience a mis en lumière certains risques, ce qui a conduit à un ajustement du protocole de phase 3 du médicament analysé.

Les résultats ont ensuite été comparés aux travaux internes réalisés par Sanofi lors de la conception de la phase 1, afin de vérifier si les outputs de notre pipeline étaient comparables à ceux produits par l'équipe en amont :

Extraction des Risques potentiels	
Nombre de risques à considerer identifiés jamais documentés	5
Validation externe (Sanofi) : taux de couverture des données	72.1%

Extraction des bénéfices potentiels

Validation externe (Sanofi) : taux de couverture des données	40%
--	-----

Finalement, la solution a montré une capacité prédictive limitée dans ce contexte spécifique. Toutefois, celle-ci n'ayant pas été initialement conçue pour réaliser ce type d'analyse prospective, les résultats obtenus, bien que partiels, mettent en évidence un potentiel particulièrement élevé.

C'est finalement grâce à cette démonstration que les membres de l'équipe d'ArcaScience ont pu mettre en place un programme de développement visant à renforcer cette capacité innovante de la plateforme. Cette innovation sera portée par le programme i-Démo.

À ce stade, la plateforme ArcaScience est en capacité d'extraire et d'agrèger automatiquement des données issues de multiples bases biomédicales, incluant notamment les essais cliniques, puis de les harmoniser afin de permettre des comparaisons robustes entre traitements. Elle facilite l'analyse du contexte clinique d'un candidat médicament, contribue à la structuration et à l'optimisation des protocoles d'essais, réalise des évaluations bénéfice-risque entièrement sourcées et traçables, et intègre l'analyse des interactions médicamenteuses afin d'affiner l'appréciation globale du profil de sécurité et d'efficacité.

2.3.2.1. INNOVATION PORTE PAR LE PROGRAMME I-DEMO : MODULE BR-PREDICT

État de l'art des solutions existantes

À l'échelle internationale, plusieurs catégories d'outils mobilisent l'intelligence artificielle pour optimiser le développement pharmaceutique. Les solutions de chimie computationnelle permettent de prédire certaines propriétés physico-chimiques ou d'interaction cible. D'autres approches exploitent les données génomiques pour affiner la stratification patient ou prédire des réponses thérapeutiques.

[À compléter par références sectorielles récentes.]

Toutefois, ces approches demeurent largement segmentées. Les outils de prédiction moléculaire ne sont généralement pas intégrés de manière native aux modèles toxicologiques ou aux analyses cliniques comparatives. Les modèles génomiques restent souvent découplés des données précliniques et des résultats d'essais. **À ce jour, il n'existe pas de solution industrialisée capable d'orchestrer simultanément, dans une architecture unifiée, l'ensemble des dimensions moléculaires, précliniques, génétiques, cliniques et comparatives dans une logique dédiée à l'anticipation structurée du profil bénéfice/risque.**

Maturité technologique actuelle d'ArcaScience

A date, la société dispose d'une plateforme opérationnelle, commercialisée et validée en contexte industriel réel. Cette plateforme produit déjà des analyses bénéfice-risque comparatives, sourcées et traçables.

La robustesse du socle technologique a été démontrée auprès d'acteurs pharmaceutiques de premier plan, notamment Sanofi, dans des cas d'usage ayant conduit à des ajustements stratégiques documentés sur des actifs en développement. Les briques existantes atteignent des performances élevées, avec des F1 supérieurs à 90 % pour plusieurs modèles critiques d'extraction et de structuration.

La plateforme maîtrise aujourd'hui :

- l'agrégation multi-sources (publications scientifiques, essais cliniques, bases réglementaires),
- L'harmonisation des données cliniques,
- L'extraction structurée des signaux d'efficacité et de sécurité,
- La comparaison au standard of care,
- La production d'analyses bénéfice-risque traçables et explicables.

Le module **BR-Predict** s'inscrit donc dans une logique **d'extension d'une architecture déjà éprouvée**. Il réutilise les briques validées et vise à intégrer de manière systémique de nouvelles catégories de données:

- Données de structures moléculaires et d'interaction cible,
- Données toxicologiques et pharmacodynamiques précliniques,
- Informations sur les polymorphismes génétiques et biomarqueurs,
- Données de vie réelle.

Ce nouveau module intégrera l'entièreté de ces nouvelles données dans un **World Model** simplifiant l'utilisation de la solution et assurant la qualité des livrables produits. L'objectif est de **transformer une analyse enrichie descriptive en une capacité véritablement prédictive du profil bénéfice/risque**.

Verrou technologique n°1 : accès et disponibilité des données

Le premier verrou concerne l'accès structuré et exploitable aux différentes catégories de données nécessaires au modèle prédictif. Certaines données moléculaires et précliniques sont fragmentées. Les données génétiques et de vie réelle peuvent être soumises à des contraintes d'accès, de format ou de conformité réglementaire.

La stratégie d'ArcaScience repose sur l'exploitation prioritaire de données publiques structurées, la mobilisation de partenariats data existants et une architecture permettant l'intégration directe des données clients sur leur infrastructure, garantissant conformité et souveraineté.

Verrou technologique n°2 : traitement et normalisation de données hétérogènes

Les nouvelles données à intégrer diffèrent en nature, granularité et format. Leur traitement nécessite des pipelines spécialisés et une harmonisation sémantique robuste afin d'éviter les biais et incohérences.

ArcaScience s'appuie sur son framework existant de modèles de structuration et d'extraction, déjà validé sur des volumes massifs de données non structurées. Le projet prévoit l'extension de ces pipelines vers les données moléculaires et précliniques et leur intégration dans un knowledge graph unifié structurant les relations mécanistiques.

Verrou technologique n°3 : orchestration multimodale et cohérence prédictive

Le défi central réside dans l'analyse conjointe de ces dimensions multiples. L'agrégation directe de modèles indépendants peut générer incohérences, conflits d'interprétation et perte de traçabilité.

Le développement d'un "World Model" permettra d'orchestrer les sorties des modèles spécialisés dans une architecture unifiée. Cette approche vise à construire une représentation causale intégrant mécanisme d'action, profil biologique, données comparatives et signaux cliniques, avec quantification explicite des incertitudes.

Ambition technologique et KPI du programme i-Démo

L'ambition du programme est d'atteindre :

- Une performance prédictive proche de 80 % pour une plateforme générique indépendante de la pathologie,
- Une performance proche de 90 % dans un contexte pathologie-spécifique.

Ces performances seront évaluées via des validations rétrospectives comparant les prédictions aux résultats cliniques observés en efficacité et en sécurité.

Le cancer du poumon comme preuve de concept structurante

Le cancer du poumon constitue un cas d'usage structurant en raison de la richesse des données disponibles, de la forte stratification biomarqueur, de l'équilibre complexe entre bénéfice de survie et toxicités significatives, et de l'intensité concurrentielle du segment.

Il offre un environnement scientifique exigeant, un intérêt industriel immédiat et une transférabilité méthodologique vers d'autres indications oncologiques à l'issue du programme.

Innovation : Développement d'un module prédictif multimodal (BR-Predict) capable d'anticiper le profil bénéfice/risque d'un candidat médicament à partir de données moléculaires, précliniques, génétiques, cliniques et comparatives intégrées dans une architecture unifiée.

État de l'art et limites des solutions actuelles

Les solutions existantes exploitent l'IA pour prédire des propriétés moléculaires, des signaux toxicologiques ou des réponses cliniques spécifiques, mais de manière segmentée. Les modèles restent développés en silos (chimie computationnelle, toxicologie in silico, génomique, RWE), sans orchestration intégrée dédiée à l'anticipation structurée du profil bénéfice/risque. Il n'existe pas de solution industrialisée combinant simultanément ces dimensions dans une logique décisionnelle globale.
Obstacles techniques à franchir • Accès structuré et interopérable à des données hétérogènes (moléculaires, précliniques, génétiques, RWE). • Harmonisation et normalisation de données multimodales de granularité variable. • Orchestration cohérente de modèles spécialisés hétérogènes sans perte de traçabilité ni incohérence prédictive. • Construction d'une architecture capable de produire une prédiction explicable et quantifiée en incertitude dans un cadre réglementaire exigeant.
Ambition de performances attendues dans le cadre du projet I-démo • Atteindre une performance prédictive ≥ 80 % pour une plateforme générique indépendante de la pathologie. • Atteindre une performance ≥ 90 % dans un contexte pathologie-spécifique (preuve de concept sur le cancer du poumon). • Maintenir une traçabilité complète des prédictions et une conformité aux exigences réglementaires en matière d'IA explicable.
Solutions choisies • Extension du socle technologique existant validé industriellement. • Intégration des nouvelles briques de données au sein d'un knowledge graph unifié. • Développement d'un "World Model" orchestrant les sorties des modèles spécialisés dans une représentation causale cohérente. • Validation rétrospective sur indications à forte densité de données (cancer du poumon) avant généralisation multi-pathologies.

3. PLAN DE TRAVAIL

3.1. STRUCTURATION DU PLAN DE TRAVAIL

Le projet se décline en **6 lots sur une période de 36 mois** résumés dans le diagramme de Gantt ci-après.

- Le premier lot a pour objectif de prédire les bénéfices et les risques potentiels associés à une molécule en se basant uniquement sur sa structure chimique. La validité de cette approche sera évaluée par le taux de précision obtenu sur des molécules déjà commercialisées.
- Le lot 2 vise à prédire les bénéfices et les risques potentiels d'une intervention à partir des données in vivo disponibles et des études toxicologiques de la littérature, tout en intégrant un score de fiabilité par pathologie pour chaque modèle préclinique.
- Le lot 3 vise à prédire les bénéfices et risques d'une molécule à partir de ses effets sur les biomarqueurs de la pathologie, de sa cible moléculaire et des polymorphismes génétiques associés. La prédiction est évaluée par sa précision sur des molécules commercialisées.
- Le lot 4 vise à développer des modèles prédictifs de bénéfices et de risques basés sur les données de vie réelle, intégrant :
 - Les conditions d'utilisation en pratique,
 - Les populations non sélectionnées,
 - Les comorbidités, la polymédication,
 - Les facteurs socio-démographiques
- Le lot 5 vise à créer un cadre de connaissances structuré et interopérable qui intègre de multiples sources de données hétérogènes (structures moléculaires, résultats précliniques, données génomiques, données de vie réelle) dans une couche sémantique unifiée. Ce « paysage de connaissances » sert d'ontologie fondamentale et d'architecture de données permettant de contextualiser, comparer et combiner les prédictions des tâches du lot 4.
- Le lot 6 intègre tous les modèles prédictifs (lot 4) avec le paysage de connaissances (lot 5) pour créer un « **World model** » capable de simuler des profils bénéfice-risque pour n'importe quelle molécule. Ce modèle prédit les résultats au niveau individuel, les interactions médicamenteuses et les risques spécifiques au contexte en apprenant les relations causales entre les propriétés moléculaires, les mécanismes biologiques et les caractéristiques des patients.

Lot	Date prévisionnelle	Livrables attendus (Référence / mois de disponibilité / intitulé)
Lot 1 : Rapport de validation du modèle chimique (prédiction B/R depuis la structure)	T0 + 15 mois (Mars 2027)	- T1.1. (T0 + ZZ mois) Qualification des sources de données Identifier, évaluer et qualifier les bases de données pertinentes (NCGC qHTS cytotoxicity, ChEMBL, ToxCast, etc.) - T1.2. (T0 + ZZ mois) Construction et curation de la base de données Constituer un dataset consolidé de molécules commercialisées, adjuvants et protéines avec profils bénéfice-risque documentés. - T1.3. (T0 + ZZ mois) Représentation moléculaire & calcul des descripteurs Transformer les structures chimiques en représentations numériques descriptives et exploitables pour la modélisation

		- T1.4. (T0 + ZZ mois) Développement de modèles QSAR Construire des modèles prédictifs d'efficacité thérapeutique à partir de la structure (approches ML plutôt que QSAR classiques) - T1.5. (T0 + ZZ mois) Développement de modèles QSTR Construire des modèles prédictifs de toxicité et de risques de sécurité (également basés ML) - T1.6. (T0 + ZZ mois) Intégration & validation Contrôle qualité des données, validation des résultats et évaluation des performances des modèles.
Lot 2 : Rapport de validation du pipeline in vivo (prédiction B/R depuis les résultats des modèles précliniques)	T0 + 18 mois (Décembre 2027)	- T2.1. (T0 + ZZ mois) Préparation de l'infrastructure Étape commune aux WP2, WP3 et WP4, visant à tester les architectures de modèles et l'infrastructure optimale pour la réalisation de ces workpackages - T2.2. (T0 + ZZ mois) Qualification des sources de données in vivo Identification et sélection des études d'efficacité et de toxicité + littérature générale. - T2.3. (T0 + ZZ mois) Extraction et structuration des données (NLP) Extraction automatique des informations relatives aux modèles in vivo et structuration des données. - T2.4. (T0 + ZZ mois) Création d'une base de données curée et standardisée Consolidation des données extraites en une base fiable et exploitable. - T2.5. (T0 + ZZ mois) Modèles ML pour la prédiction de l'efficacité Prédiction du succès clinique à partir des résultats in vivo au niveau de la pathologie / aspect spécifique de la pathologie, incluant un score de fiabilité des modèles précliniques. - T2.6. (T0 + ZZ mois) Modèles ML pour la prédiction du risque Prédiction des risques toxiques humains à partir de données animales. - T2.7. (T0 + ZZ mois) Validation et intégration Évaluation des performances, cohérence des données, intégration dans les pipelines internes.
Lot 3 : Rapport de validation du modèle génomique (prédiction B/R à partir du polymorphisme génétique de la cible et de son impact sur des biomarqueurs contextuels)	T0 + 18 mois (Décembre 2027))	- T3.1. (T0 + ZZ mois) Qualification des sources • Biomarqueurs/pathologie • Variants génétiques des cibles - T3.2. (T0 + ZZ mois) Extraction et structuration des données (NLP) • Extraction automatique des polymorphismes génétiques • Structuration des effets fonctionnels - T3.3. (T0 + ZZ mois) Construction d'une base de données intégrée • Molécule →Biomarqueurs/génomique →Pathologie • Molécule→Cible →variants génétiques →impacts fonctionnels - T3.5. (T0 + ZZ mois) Modèle ML – Risque • Input: génotype de la target +mécanisme d'action du traitement • Output: prédiction de risque - T3.6. (T0 + ZZ mois) Validation &Intégration • Évaluation des performances • Harmonisation et intégration dans les pipelines internes
Lot 4 : Rapport de validation du pipeline RWE (prédictions cliniques en vie réelle)	T0 + 18 mois (Décembre 2027)	- T4.1. (T0 + ZZ mois) Qualification des sources RWE Identifier, évaluer et qualifier les bases FAERS, EDS, EHDS et autres sources utilisables. - T4.2. (T0 + ZZ mois) Extraction &structuration des données RWE Extraction, harmonisation et standardisation des données de sécurité et d'efficacité.

		- T4.3. (T0 + ZZ mois) (T0 + ZZ mois) Modèles prédictifs RWE – Bénéfices Entraînement de modèles ML prédictifs du bénéfice clinique en conditions réelles. - T4.4. (T0 + ZZ mois) Modèles prédictifs RWE – Risques Entraînement de modèles ML prédictifs des risques/ADRs en vie réelle. - T4.5. (T0 + ZZ mois) Validation & calibration Calibration externe, évaluation robuste (AUC, accuracy, calibration plots), comparaison aux modèles L1–3.
Lot 5 : Modèle ontologique validé + rapport de conformité du knowledge graph	T0 + 12 mois (Juin 2028)	- T5.1. (T0 + ZZ mois) Conception et Sélection de l'Ontologie Identifier et adopter des ontologies standard (MedDRA, SNOMED CT, ChEBI, Disease Ontology) et définir les relations entre entités moléculaires, biologiques et cliniques - T5.2. (T0 + ZZ mois) Harmonisation des Données et Cartographie des Entités Associer les résultats des L1-4 à des terminologies standardisées et créer des références croisées entre sources de données et résultats - T5.3. (T0 + ZZ mois) Construction du Graphe de Connaissances Construire la structure de la base de données graphe (nœuds = entités, arêtes = relations) et la peupler avec les données intégrées des L1-4 - T5.4. (T0 + ZZ mois) Extraction et Validation des Relations Utiliser le traitement automatique du langage naturel pour extraire des relations supplémentaires de la littérature, valider les relations par rapport aux associations connues médicament-maladie-résultat, et attribuer des scores de confiance aux relations - T5.5. (T0 + ZZ mois) Développement de l'Interface de Requête et de l'API Créer un langage de requête pour les questions complexes multi-niveaux, développer une API permettant au L6 d'accéder au graphe de connaissances, et implémenter la mise en cache pour les requêtes fréquentes
Lot 6 : Rapport de validation du modèle unifié + démonstrateur interactif	T0+24 mois (Décembre 2028)	- T6.1. (T0 + ZZ mois) Conception de l'Architecture du Modèle Concevoir une architecture de réseau neuronal pour intégrer les prédictions des L1-4, implémenter des mécanismes d'attention pour pondérer les preuves de différentes sources, et construire un module de dynamique temporelle pour les prédictions dépendantes du temps - T6.2. (T0 + ZZ mois) Intégration en Ensemble des L1-4 Combiner les prédictions en utilisant des pondérations apprises (pas une simple moyenne), gérer les contradictions (par ex., L2 prédit une toxicité, L4 données de vie réelle montrent une sécurité), et implémenter la résolution de conflits avec propagation de l'incertitude - T6.3. (T0 + ZZ mois) Modélisation Causale et Prédiction des Interactions Entraîner des modèles pour prédire les interactions médicament-médicament en utilisant les données moléculaires + données de vie réelle, modéliser les interactions gène-médicament pour les prédictions pharmacogénomiques, et simuler les relations dose-réponse et temps jusqu'à l'événement - T6.4. (T0 + ZZ mois) Quantification de l'Incertainité Implémenter des approches bayésiennes ou d'ensemble pour les intervalles de confiance, signaler les prédictions avec faible confiance en raison de données éparées, et fournir des explications interprétables des sources d'incertitude

		- T6.5. (T0 + ZZ mois) Interface de Visualisation (Carte Mentale) Visualisation interactive du réseau bénéfice-risque (molécule → cibles → voies métaboliques → résultats), permettre l'exploration approfondie du résumé de haut niveau aux preuves sources, et afficher les scores de confiance et la provenance des données - T6.6. (T0 + ZZ mois) Validation et Calibration Validation rétrospective sur les médicaments retirés du marché (le modèle peut-il prédire les échecs ?), suivi prospectif des prédictions pour les molécules en développement, et graphiques de calibration pour s'assurer que les probabilités prédites correspondent aux fréquences observées
--	--	--

3.2. GANTT

Cf excel

3.3. SYNTHÈSE DES PRINCIPAUX JALONS DECISIONNELS DU PROJET ET DE LEURS INDICATEURS DE SUCCÈS ASSOCIÉS

Le programme se structure en 3 étapes clés lesquelles aboutissant à l'atteinte d'un jalon créateur de valeur, permettant le refinancement du projet :

Date prévisionnelle	Description du jalon	Indicateurs de succès du jalon
EC1 : 0 + 15 mois (03/2027)	MS1 : Prédiction basée sur la structure chimique : AUC > 0,6 (générique).	Seuil de validation : AUC>0.65
EC2 : 0 + 24 mois (12/2027)	MS2 : Prédiction intégrant les données précliniques et le MOA : AUC > 0,75 (générique).	Précision des prédictions pour des molécules déjà commercialisées, supérieure à celle obtenue dans le L1 Cette prédiction est évaluée par sa précision sur des molécules déjà commercialisées. Précision des modèles RWE supérieure à celle obtenue via L1/2/3
EC3 : 0 + 36 mois (12/2028)	MS3 : Architecture complète intégrant le knowledge graphe et les données en vie réelles	Intégration réussie de ≥90% des entités de données des L1-4 dans un graphe de connaissances standardisé avec des relations sémantiques validées. Temps de réponse aux requêtes < 2 secondes pour les requêtes complexes multi-sources
EC3 : 0 + 36 mois (12/2028)	MS4 : Modèles finalisés : AUC > 0,8 (générique) et AUC > 0,9 (spécifique poumon).	Sensibilité et spécificité élevées pour la prédiction d'événements indésirables graves sur des molécules de test Capacité à générer des profils bénéfice-risque cohérents incluant ≥3 sources de données indépendantes

		Validation utilisateur : ≥70%des experts évaluateurs jugent les prédictions comme « cliniquement plausibles »
--	--	---

3.4. RISQUES IDENTIFIES ET PLAN DE SUIVI

Les risques du projet ont été détaillés par étape clé comme indiqués dans le tableau ci-dessous :

Verrous	Risques	Probabilité Gravité	Plan de contingence
EC1 (03/2027)	Les modèles QSAR ne couvrent pas tout l'espace chimique	[P] Modérée [G] Elevée	Développer des modèles hybrides combinant ML et approches mécanistiques pour améliorer la généralisation.
EC1 (03/2027)	Les modèles avancés comme DNN ou GNN montrent des performances variables selon les données d'entraînement.	[P] Modérée [G] Modérée	Enrichir les jeux de données avec des molécules diversifiées et effectuer une validation croisée rigoureuse
EC2 (12/2027)	Certaines données critiques sont sous paywall ou inaccessibles.	[P] Elevée [G] Elevée	Collaborer avec des partenaires industriels pour obtenir des licences ou utiliser des données publiques alternatives.
EC2 (12/2027)	Les biais dans les études publiées peuvent affecter la qualité des modèles	[P] Modérée [G] Modérée	Mettre en place des algorithmes pour détecter et corriger les biais dans les données
EC3 (12/2028)	Les nouvelles cibles ou maladies rares peuvent ne pas être bien représentées.	[P] Modérée [G] Modérée	Collaborer avec des experts pour enrichir les ontologies utilisées.
EC3 (12/2028)	Maintenir la cohérence avec l'arrivée de nouvelles données peut être complexe.	[P] Modérée [G] Modérée	Mettre en place une curation continue des données et des relations
EC3 (12/2028)	Les données pour de nouveaux squelettes moléculaires peuvent être insuffisantes.	[P] Elevée [G] Elevée	Utiliser des approches bayésiennes pour gérer l'incertitude et intégrer des données simulées.
EC3 (12/2028)	Les mécanismes nouveaux peuvent ne pas être détectés par les modèles.	[P] Modérée [G] Elevée	Mettre en place des mécanismes d'apprentissage actif pour intégrer de nouvelles informations

3.5. BUDGET ET PRINCIPAUX POSTES DE SOUS-TRAITANCE DU PROJET

Budget

PARTIE 2 : DESCRIPTION DETAILLEE DES LOTS

4. LOTS DETAILLES

4.1. LOT 1

Lot n°:	1	Durée :	15 mois (01/26 – 03/27)
Intitule du lot :	Rapport de validation d'un modèle chimique (prédiction B/R depuis la structure)		
Nature du lot :	DE		
Coût total du lot :	650 k€		
Objectifs			
L'objectif de ce lot est de prédire les bénéfices et les risques potentiels associés à une molécule en se basant uniquement sur sa structure chimique. La validité de cette approche sera évaluée par le taux de précision obtenu sur des molécules déjà commercialisées.			
Travaux réalisés			
Tâche 1.1 (Mx – My) : Qualification des sources de données Cette tâche a pour but d'identifier, d'évaluer et de qualifier les bases de données pertinentes (NCGC qHTS cytotoxicity, ChEMBL, ToxCast , etc.)			
Tâche 1.2 (Mx – My) : Construction et curation de la base de données Cette tâche a pour but de constituer un dataset consolidé de molécules commercialisées, adjuvants et protéines avec profils bénéfice–risque documentés.			
Tâche 1.3 (Mx – My) : Représentation moléculaire & calcul des descripteurs Cette tâche a pour but de transformer les structures chimiques en représentations numériques descriptives et exploitables pour la modélisation			
Tâche 1.4 (Mx – My) : Développement de modèles QSAR Cette tâche a pour but de construire des modèles prédictifs d'efficacité thérapeutique à partir de la structure (approches ML plutôt que QSAR classiques).			
Tâche 1.5 (Mx – My) : Développement de modèles QSTR Cette tâche a pour but de construire des modèles prédictifs de toxicité et de risques de sécurité (également basés ML).			
Tâche 1.6 (Mx – My) : Intégration & validation Cette tâche a pour but de contrôler la qualité des données et de valider des résultats et évaluation des performances des modèles.			

Livrables	
L1.1 (T0 + XX mois) : Modèles de prédiction QSAR et QSTR validés	
Description des dépenses	
Dépenses de sous-traitance	- XX, d'un coût de XX k€ pour assurer le développement XXX - XX
Dépenses des achats	xx
Contribution aux amortissements	xx

4.2. LOT 2

Lot n°:	2	Durée :	18 mois (06/26 – 12/27)
Intitule du lot :	Rapport de validation du pipeline in vivo (prédiction B/R depuis les résultats des modèles précliniques)		
Nature du lot :	DE		
Coût total du lot :	750 k€		
Objectifs			
L'objectif de ce lot est de prédire les bénéfices et les risques potentiels d’une intervention à partir des données in vivo disponibles et des études toxicologiques de la littérature, tout en intégrant un score de fiabilité par pathologie pour chaque modèle préclinique.			
Travaux réalisés			
Tâche 2.1 (Mx – My) : Préparation de l’infrastructure Étape commune aux WP2, WP3 et WP4, visant à tester les architectures de modèles et l’infrastructure optimale pour la réalisation de ces workpackages.			
Tâche 2.2 (Mx – My) : Qualification des sources de données in vivo Identification et sélection des études d’efficacité et de toxicité + littérature générale.			
Tâche 2.3 (Mx – My) : Extraction et structuration des données (NLP) Extraction automatique des informations relatives aux modèles in vivo et structuration des données.			
Tâche 2.4 (Mx – My) : Création d’une base de données curée et standardisée Consolidation des données extraites en une base fiable et exploitable.			
Tâche 2.5 (Mx – My) : Modèles ML pour la prédiction de l’efficacité Prédiction du succès clinique à partir des résultats in vivo au niveau de la pathologie / /aspect spécifique de la pathologie, incluant un score de fiabilité des modèles précliniques.			
Tâche 2.6 (Mx – My) : Modèles ML pour la prédiction du risque Prédiction des risques toxiques humains à partir de données animales.			

Tâche 2.7 (Mx – My) : Validation et intégration

Évaluation des performances, cohérence des données, intégration dans les pipelines internes.

Livrables

L2.1 (T0 + XX mois) : Modèle NLP fonctionnel pour extraction d'informations in vivo.

L2.2 (T0 + XX mois) : Score de fiabilité par modèle préclinique et par pathologie/aspect.

L2.3 (T0 + XX mois) : Modèles ML prédictifs des bénéfices et risques basés sur données in vivo

L2.4 (T0 + XX mois) : Capacité finale : prédire les bénéfices et risques potentiels pour une structure donnée.

Description des dépenses

Dépenses de sous-traitance	- XX, d'un coût de XX k€ pour assurer le développement XXX - XX
Dépenses des achats	xx
Contribution aux amortissements	xx

4.3. LOT 3

Lot n°:	3	Durée :	18 mois (06/26 – 12/27)
Intitule du lot :	Rapport de validation du modèle génomique (prédiction B/R à partir du polymorphisme génétique de la cible et de son impact sur des biomarqueurs contextuels).		
Nature du lot :	DE		
Coût total du lot :	850 k€		
Objectifs			
L'objectif de ce lot est de prédire les bénéfices et risques d'une molécule à partir de ses effets sur les biomarqueurs de la pathologie, de sa cible moléculaire et des polymorphismes génétiques associés. La prédiction est évaluée par sa précision sur des molécules commercialisées.			
Travaux réalisés			
Tâche 3.1 (Mx – My) : Qualification des sources			
Biomarqueurs/pathologie			
Variants génétiques des cibles			
Tâche 3.2 (Mx – My) : Extraction et structuration des données (NLP)			
Extraction automatique des polymorphismes génétiques			
Structuration des effets fonctionnels			
Tâche 3.3 (Mx – My) : Construction d'une base de données intégrée			
Molécule →Biomarqueurs/génomique →Pathologie			

Molécule → Cible → variants génétiques → impacts fonctionnels

Tâche 3.4 (Mx – My) : Modèle ML – Bénéfice

Input : biomarqueurs/génomique de la pathologie + Cible

Output : prédiction de bénéfice

Tâche 3.5 (Mx – My) : Modèle ML – Risque

Input : génotype de la target + mécanisme d'action du traitement

Output : prédiction de risque

Tâche 3.6 (Mx – My) : Validation & Intégration

Évaluation des performances

Harmonisation et intégration dans les pipelines internes

Livrables

L3.1 (T0 + XX mois) : Modèle NLP fonctionnel pour extraction des informations génétiques

L3.2 (T0 + XX mois) : Base de données : cibles biomarqueurs pathologie variants génétiques

L3.3 (T0 + XX mois) : Modèles ML prédictifs : bénéfices & risques basés sur la génétique

L3.4 (T0 + XX mois) : Capacité finale : prédire bénéfices et risques pour une structure donnée via génomique + cible

Description des dépenses

Dépenses de sous-traitance	- XX, d'un coût de XX k€ pour assurer le développement XXX - XX
Dépenses des achats	xx
Contribution aux amortissements	xx

4.4. LOT 4

Lot n°:	4	Durée :	18 mois (06/26 – 12/27)
Intitulé du lot :	Rapport de validation du pipeline RWE (prédictions cliniques en vie réelle).		
Nature du lot :	DE		
Coût total du lot :	1 100 k€		
Objectifs			
L'objectif de ce lot est l'extraction des données patients ainsi que des données de sécurité et d'efficacité issues de bases de vie réelle (FAERS, EDS, EHDS...) permet de valider et renforcer les relations identifiées entre structure moléculaire, modèles précliniques, cible thérapeutique, bénéfices et risques. Le L4 vise à développer des modèles prédictifs de bénéfices et de risques basés sur les données de vie réelle, intégrant : les conditions d'utilisation en pratique ; les populations non sélectionnées ; les comorbidités, la polymédication ; les facteurs socio-démographiques.			
Travaux réalisés			

Tâche 4.1 (Mx – My) : Qualification des sources RWE

Identifier, évaluer et qualifier les bases FAERS, EDS, EHDS et autres sources utilisables

Tâche 4.2 (Mx – My) : Extraction & structuration des données RWE

Extraction, harmonisation et standardisation des données de sécurité et d'efficacité.

Tâche 4.3 (Mx – My) : Modèles prédictifs RWE – Bénéfices

Entraînement de modèles ML prédictifs du bénéfice clinique en conditions réelles.

Tâche 4.4 (Mx – My) : Modèles prédictifs RWE – Risques

Entraînement de modèles ML prédictifs des risques/ADRs en vie réelle.

Tâche 4.5 (Mx – My) : Validation & calibration

Calibration externe, évaluation robuste (AUC, accuracy, calibration plots), comparaison aux modèles L1–3.

Livrables

L4.1 (T0 + XX mois) : Modèles ML prédictifs basés sur données RWE (bénéfices et risques).

L4.2 (T0 + XX mois) : Pipeline complet d'extraction, standardisation et analyse des données RWE.

L4.3 (T0 + XX mois) : Modèle généralisable intégrant facteurs cliniques réels + données moléculaires + données de pathologie (L1–3 + L4)

Description des dépenses

Dépenses de sous-traitance	- XX, d'un coût de XX k€ pour assurer le développement XXX - XX
Dépenses des achats	xx
Contribution aux amortissements	xx

4.5. LOT 5

Lot n°:	5	Durée :	12 mois (06/27 – 06/28)
Intitule du lot :	Modèle ontologique validé + rapport de conformité du knowledgegraph.		
Nature du lot :	DE		
Coût total du lot :	550 k€		
Objectifs			
L'objectif de ce lot est de créer un cadre de connaissances structuré et interopérable qui intègre de multiples sources de données hétérogènes (structures moléculaires, résultats précliniques, données génomiques, données de vie réelle) dans une couche sémantique unifiée. Ce « paysage de connaissances » sert d'ontologie fondamentale et d'architecture de données permettant de contextualiser, comparer et combiner les prédictions des L1-4.			
Travaux réalisés			
Tâche 5.1 (Mx – My) : Conception et Sélection de l'Ontologie			
Identifier et adopter des ontologies standard (MedDRA, SNOMED CT, ChEBI, Disease Ontology) et définir les relations entre entités moléculaires, biologiques et cliniques			

Tâche 5.2 (Mx – My) : Harmonisation des Données et Cartographie des Entités

Associer les résultats des WP1-4 à des terminologies standardisées et créer des références croisées entre sources de données et résultats

Tâche 5.3 (Mx – My) : Construction du Graphe de Connaissances

Construire la structure de la base de données graphe (nœuds = entités, arêtes = relations) et la peupler avec les données intégrées des L1-4

Tâche 5.4 (Mx – My) : Extraction et Validation des Relations

Utiliser le traitement automatique du langage naturel pour extraire des relations supplémentaires de la littérature, valider les relations par rapport aux associations connues médicament-maladie-résultat, et attribuer des scores de confiance aux relations)

Tâche 5.5 (Mx – My) : Développement de l'Interface de Requête et de l'API

Créer un langage de requête pour les questions complexes multi-niveaux, développer une API permettant au WP6 d'accéder au graphe de connaissances, et implémenter la mise en cache pour les requêtes fréquentes

Livrables

L5.1 (T0 + XX mois) : Graphe de connaissances peuplé avec >100K entités et >1M relations

L5.2 (T0 + XX mois) : Tables de correspondance validées entre différentes terminologies

L5.3 (T0 + XX mois) : API de requête avec documentation

L5.4 (T0 + XX mois) : Rapport de qualité des données montrant la couverture et les scores de confiance

Description des dépenses

Dépenses de sous-traitance	- XX, d'un coût de XX k€ pour assurer le développement XXX - XX
Dépenses des achats	xx
Contribution aux amortissements	xx

4.6. LOT 6

Lot n°:	6	Durée :	24 mois (01/27 – 12/28)
Intitule du lot :	Rapport de validation du modèle unifié + démonstrateur interactif.		
Nature du lot :	DE		
Coût total du lot :	1 300 k€		
Objectifs			
L'objectif de ce lot est d'intégrer tous les modèles prédictifs (L1-4) avec le paysage de connaissances (L5) pour créer un « modèle du monde » capable de simuler des profils bénéfice-risque pour n'importe quelle molécule. Ce modèle prédit les résultats au niveau individuel, les interactions médicamenteuses et les risques spécifiques au contexte en apprenant les relations causales entre les propriétés moléculaires, les mécanismes biologiques et les caractéristiques des patients			

Travaux réalisés

Tâche 6.1 (Mx – My) : Conception de l'Architecture du Modèle

Concevoir une architecture de réseau neuronal pour intégrer les prédictions des L1-4, implémenter des mécanismes d'attention pour pondérer les preuves de différentes sources, et construire un module de dynamique temporelle pour les prédictions dépendantes du temps

Tâche 6.2 (Mx – My) : Intégration en Ensemble des L1-4

Combiner les prédictions en utilisant des pondérations apprises (pas une simple moyenne), gérer les contradictions (par ex., L2 prédit une toxicité, L4 données de vie réelle montrent une sécurité), et implémenter la résolution de conflits avec propagation de l'incertitude

Tâche 6.3 (Mx – My) : Modélisation Causale et Prédiction des Interactions

Entraîner des modèles pour prédire les interactions médicament-médicament en utilisant les données moléculaires + données de vie réelle, modéliser les interactions gène-médicament pour les prédictions pharmacogénomiques, et simuler les relations dose-réponse et temps jusqu'à l'événement

Tâche 6.4 (Mx – My) : Quantification de l'Incertainité

Implémenter des approches bayésiennes ou d'ensemble pour les intervalles de confiance, signaler les prédictions avec faible confiance en raison de données éparées, et fournir des explications interprétables des sources d'incertitude

Tâche 6.5 (Mx – My) : Interface de Visualisation (Carte Mentale)

Visualisation interactive du réseau bénéfice-risque (molécule → cibles → voies métaboliques → résultats), permettre l'exploration approfondie du résumé de haut niveau aux preuves sources, et afficher les scores de confiance et la provenance des données

Tâche 6.6 (Mx – My) : Validation et Calibration

Validation rétrospective sur les médicaments retirés du marché (le modèle peut-il prédire les échecs ?), suivi prospectif des prédictions pour les molécules en développement, et graphiques de calibration pour s'assurer que les probabilités prédites correspondent aux fréquences observées

Livrables

L6.1 (T0 + XX mois) : Modèle du monde intégré combinant les résultats des L1-5

L6.2 (T0 + XX mois) : Module de prédiction des interactions

L6.3 (T0 + XX mois) : Interface de visualisation interactive sous forme de carte mentale

L6.4 (T0 + XX mois) : Rapport de validation sur 200+ molécules commercialisées et retirées du marché

L6.5 (T0 + XX mois) : Documentation utilisateur et supports de formation

L6.6 (T0 + XX mois) : Système prêt au déploiement avec quantification de l'incertitude

Description des dépenses

Dépenses de sous-traitance	- XX, d'un coût de XX k€ pour assurer le développement XXX - XX
Dépenses des achats	xx
Contribution aux amortissements	xx

Lot n°:	7	Durée :	36 mois
Intitule du lot :	Management du projet		
Nature du lot :			
Coût total du lot :	XX€		
Objectifs			
Ce work package vise à assurer la coordination globale du projet, le suivi administratif et scientifique, la diffusion des résultats, le développement des partenariats industriels nécessaires aux phases de test, ainsi que la gestion de la propriété intellectuelle issue des travaux de R&D.			
Travaux réalisés			
Tâche 7.1 (M1 – M36) : Reporting et suivi du projet			
ArcaScience assurera la coordination globale du projet et le suivi de son avancement scientifique, technique et financier. Cette tâche comprend la préparation des rapports périodiques à destination de l’organisme financeur, le suivi des jalons et des livrables, ainsi que la consolidation des contributions des différents work packages. Des réunions de pilotage régulières seront organisées afin de suivre l’avancement des travaux, identifier les éventuels écarts par rapport au planning initial et mettre en place les actions correctives nécessaires.			
Tâche 7.2 (M1 – M36) : Dissémination et valorisation scientifique			
ArcaScience assurera la diffusion des résultats scientifiques et technologiques issus du projet. Cette dissémination passera notamment par la participation à des congrès internationaux et à des conférences scientifiques dans les domaines de l’intelligence artificielle et de la recherche biomédicale. L’objectif est de présenter les avancées méthodologiques développées dans le cadre du projet et de renforcer la visibilité de la solution auprès de l’écosystème académique et industriel.			
Tâche 7.3 (M1 – M24) : Discussions partenariales avec l’industrie pharmaceutique			
ArcaScience mènera des discussions avec des entreprises pharmaceutiques et des sociétés de biotechnologie afin d’identifier des partenaires industriels pour les phases de test prévues dans le WP6. Ces échanges permettront de sélectionner des actifs pertinents pour l’évaluation de la plateforme et de définir les modalités de collaboration, notamment en ce qui concerne l’accès aux données et les conditions d’évaluation des analyses produites.			
Tâche 7.4 (M1 – M36) : Gestion de la propriété intellectuelle			
ArcaScience mettra en œuvre les actions nécessaires à la protection des innovations développées dans le cadre du projet. En cohérence avec la stratégie de propriété intellectuelle de l’entreprise, cette tâche comprendra la veille permanente afin de garantir la liberté d’exploitation tout au long du projet, la préparation des éléments techniques et scientifiques nécessaires, ainsi que la rédaction des dossiers de dépôt. Ces travaux viseront à permettre le dépôt des trois brevets correspondant aux principales innovations développées dans le cadre du projet.			
Livrables			
L6.1 (T0 + 6 mois) ; : Rapports de suivi du projet			
L6.2 (T0 + XX mois) : Synthèse des actions de diffusion			
L6.4 (T0 + XX mois) : Brevet			
Description des dépenses			
Dépenses de sous-traitance	- XX, d’un coût de XX k€ pour assurer le développement XXX - XX		
Dépenses des achats	xx		

Contribution aux amortissements	xx
---------------------------------	----

PARTIE 3 : RETOMBEES ECONOMIQUES

5. EXPLOITATION INDUSTRIELLE ET COMMERCIALE DES RESULTATS DU PROJET

5.1. STRATEGIE D'INDUSTRIALISATION DES RESULTATS DU PROJET

5.1.1. STRATEGIE DE DEVELOPPEMENT TECHNOLOGIQUE

Le programme i-Démo se terminera le **31 décembre 2028**. À cette date, ArcaScience aura démontré les capacités de sa plateforme au moyen d'un cas d'usage portant sur le cancer du poumon.

La société structurera les résultats obtenus à la fin du projet i-Démo afin d'explicitier une preuve de concept concrète, permettant d'engager des discussions avec des partenaires pharmaceutiques.

Une fois l'ancrage comme outils d'aide aux développements des médicaments sécurisés auprès des entreprises pharmaceutiques, **ArcaScience** continuera ses travaux de R&D sur deux axes complémentaires :

- **L'intégration de nouveaux modules**, afin d'étendre les cas d'usage couverts par la plateforme pour se rapprocher d'un accompagnement de plus en plus complet
- **L'intégration de nouvelles sources de données**, permettant de développer de nouveaux modèles ou d'élargir les aires thérapeutiques prises en charge par la solution.

A long terme, la plateforme doit converger vers deux livrables majeurs : une stratégie "tout oncologie" opérationnelle et un module immuno-inflammation prêt à l'exploitation. La roadmap positionne l'extension de **BR-Predict à l'ensemble des segments oncologiques entre 2029 et 2031**, puis l'extension en **immuno-inflammation entre 2030 et 2032**, jalonnant la montée en maturité depuis le démonstrateur jusqu'à la couverture de portefeuilles larges, avec une ouverture à **d'autres aires thérapeutiques** à partir de **2029** par enrichissements incrémentaux de sources et activation de briques spécialisées lorsque la valeur clinique le justifie.

En parallèle, la stratégie consiste à étendre les cas d'usage en développant des modules additionnels le long du schéma de développement des médicaments notamment les essais cliniques in silico en amont pour éclairer les choix de protocole et la priorisation d'actifs. Cette extension modulaire, permet d'industrialiser l'usage "molécule par molécule" via contrats-cadres, d'abord en oncologie et en immuno-inflammation, puis par diffusion graduée aux aires thérapeutiques à forte dynamique, sans refonte d'architecture grâce au socle générique stabilisé en 2026–2028.

5.1.2. STRATEGIE ET CONDITIONS REGLEMENTAIRES D'ACCES

La **récupération des données** par la plateforme **ArcaScience** s'effectue dans un **cadre conforme au RGPD** et aux exigences applicables aux données de santé. Les sources sont identifiées et documentées, les finalités définies en amont et limitées aux cas d'usage validés. Les données sont pseudonymisées dès l'ingestion et intégrées selon une logique de minimisation. Lorsque la plateforme est déployée on premises chez le client, la souveraineté et la maîtrise des flux restent intégralement sous son contrôle.

La transformation des données, cœur technologique de la plateforme, repose sur des modèles de structuration et d'extraction garantissant intégrité, traçabilité et auditabilité. Les traitements sont compatibles avec les exigences de 21 CFR Part 11 et respectent les principes ALCOA+. Les analyses produites s'alignent sur les standards ICH E6 et ICH E9, et les modules d'IA intègrent des mécanismes d'explicabilité et de documentation des performances, en cohérence avec les attentes des autorités concernant l'usage de l'IA en support décisionnel.

Le stockage et la sécurisation des données sont assurés par un chiffrement en transit et au repos, ainsi que par une gestion stricte des habilitations et des journaux d'accès. L'hébergement peut être réalisé sur des infrastructures conformes aux exigences HDS ou directement sur les serveurs du client. Les durées de conservation sont définies en fonction des finalités analytiques, avec des mécanismes de purge maîtrisés.

Le déploiement de la plateforme chez les clients intègre un niveau de sécurité conforme aux standards industriels internationaux applicables aux données de santé. Les données sont chiffrées en transit (TLS 1.2 ou supérieur) et au repos via un chiffrement de type AES-256. Les environnements sont cloisonnés par conteneurisation et orchestrés via Kubernetes, avec gestion fine des habilitations, journalisation des accès et revues périodiques des droits.

L'architecture est conçue pour s'aligner avec les exigences réglementaires applicables aux marchés adressés. En Europe, la conformité RGPD et, le cas échéant, l'hébergement HDS sont assurés. Dans une perspective de déploiement aux États-Unis, l'infrastructure est compatible avec les exigences HIPAA relatives à la protection des données de santé (PHI), notamment en matière de contrôle d'accès, d'auditabilité, de chiffrement et de gestion des incidents.

La solution peut être déployée on premises sur l'infrastructure du client ou dans un environnement cloud sécurisé conforme aux standards du secteur, garantissant souveraineté, traçabilité et maîtrise complète des flux de données par le client.

Les livrables générés par Trial Balancer et BR-Predict sont structurés pour être directement exploitables dans le cadre réglementaire du développement du médicament. L'analyse bénéfice/risque suit une approche formalisée compatible avec le cadre BRAT et avec la structuration attendue dans le CTD. En pharmacovigilance, l'identification des signaux est alignée avec les Bonnes Pratiques de Pharmacovigilance. La plateforme intervient ainsi comme outil d'aide à la décision, en renforçant la conformité, la traçabilité et la qualité documentaire sans modifier les protocoles imposés par les autorités.

5.1.3. STRATEGIE DE PROTECTION INTELLECTUELLE

À la clôture du programme i-DÉMO (période projet 2026-2028), ArcaScience aura constitué un portefeuille PI articulé autour de **deux dépôts de brevets**, couvrant d'une part le pipeline clinique holistique et ses 24 modèles d'IA, et d'autre part le Large World Model (LWM) et ses déclinaisons Latent World Models, conformément à la trajectoire technique prévue et aux jalons de performance atteints pendant le projet.

Le **premier brevet** concerne le **pipeline clinique holistique et architecture multi-modèles** (cible **2026-2027**). Ce premier dépôt sécurise l'antériorité et le périmètre des revendications sur l'intégration/normalisation des données, le protocole d'annotation, les logiques de prédiction et les outils d'aide à l'évaluation bénéfice/risque couvrant l'architecture des **24 modèles d'IA**. Le dépôt interviendra dès que les preuves de fonctionnement et validations génériques seront franchies (MS1 AUC > 0,6 ; MS2 AUC > 0,75), puis une extension géographique sera engagée en **phase d'industrialisation (2027-2028)** pour couvrir les marchés cibles prioritaires.

Le **second dépôt** protégera l'originalité algorithmique du **LWM** et des **Latent World Models**, distincte des modèles IA « classiques ». Il sera engagé lorsque l'architecture complète intégrant le knowledge graph et les données de vie réelle sera stabilisée (MS3) et que les modèles unifiés atteindront les niveaux de performance visés (MS4).

La base de données propriétaire (architecture/structure) est protégée par le droit d'auteur, et les éléments non brevetables à haute valeur, architecture interne du pipeline, mécanismes de cohérence des données, paramètres et workflows d'inférence des 24 modèles, relèvent d'un secret d'affaires documenté (politiques d'accès, procédures internes, journalisation). Un **escrow privé annuel** est maintenu pour le code et les modèles (2026, 2027, 2028), garantissant l'opposabilité et la continuité d'exploitation. Les déploiements **on-premises** limitent le risque de fuite d'actifs PI et renforcent la souveraineté des données chez les clients.

5.2. STRATEGIE DE COMMERCIALISATION ET PROJECTION DE REVENUS

5.2.1. STRATEGIE D'ACCES MARCHÉ

Stratégie de commercialisation

ArcaScience s'inscrit pleinement dans l'évolution actuelle du marché pharmaceutique en proposant une évaluation du bénéfice/risque à la fois rapide, structurée et stratégique. La plateforme accompagne la prise de décision tout au long du cycle de développement en permettant une priorisation plus rapide des molécules, la définition de stratégies de repositionnement pour des actifs existants et l'augmentation de la probabilité de succès des programmes cliniques.

La stratégie d'accès au marché est conçue pour s'intégrer étroitement aux modes de fonctionnement des organisations pharmaceutiques. **ArcaScience** ne vise pas à remplacer les outils existants au sein des directions R&D. La solution apporte des **analyses complémentaires** qui **s'insèrent naturellement dans les workflows actuels** et dans les processus décisionnels déjà en place. Cette approche limite les frictions organisationnelles et facilite l'adoption.

Initialement positionnée auprès des CRO et des grandes entreprises pharmaceutiques, la société capitalisera sur les capacités de son nouveau module, agissant sur des phases plus en amont dans le développement du médicament, pour développer son positionnement auprès de **l'ensemble des entreprises** disposant d'un **portefeuille d'actifs étendu dans les aires thérapeutiques couvertes par la solution** :

- Renforcement de son positionnement auprès des grandes entreprises pharmaceutiques ;
- Accès au marché des entreprises pharmaceutiques de taille intermédiaire et des grandes entreprises de biotechnologie.

La stratégie de commercialisation de la société consiste à capitaliser sur le module Trial Balancer, déjà positionné auprès de grandes entreprises pharmaceutiques comme Sanofi et AstraZeneca. ArcaScience renforcera ces partenariats en parallèle du programme i-Démo afin de faire levier pour promouvoir son nouveau module BR-Predict.

En parallèle du **renforcement des partenariats existants**, ArcaScience mènera des actions de dissémination ciblées auprès d'un périmètre élargi d'industriels, notamment lors de congrès spécialisés et au sein de l'écosystème Future4Care. Cette approche vise à **accroître la visibilité** de la plateforme au-delà des clients existants, et notamment auprès d'une cible de clients biotech encore non adressée par le module actuel d'ArcaScience.

La société proposera initialement à ses clients actuels et futurs de réaliser un **POC sous forme de prestation de services à prix réduit, avant de proposer l'installation de sa solution SaaS**. Cette approche par étapes facilite l'alignement interne des équipes cliniques, réglementaires et stratégiques, et ouvre la voie à la mise en place d'accords-cadres, notamment pour l'intégration du module **BR-Predict**. La mise en place de ces accords-cadres favorisera la diffusion de l'approche ArcaScience et permettra de capter de nouveaux clients.

En parallèle, l'exploitation du modèle pathogénérique de la plateforme permettra de se développer sur de nouvelles aires thérapeutiques à très forte dynamique, notamment en oncologie et en immuno-inflammatoire.

La progression sur les plans technologique et commercial permettra à la société d'étendre son champ d'action, avec une expansion internationale. ArcaScience visera en priorité les **États-Unis** afin d'y établir plusieurs contrats-cadres.

5.2.2. MODELE ECONOMIQUE ET PRICING

La stratégie économique d'**ArcaScience** repose sur la signature de contrats cadres avec les sociétés pharmaceutiques et biotechnologiques clientes. L'objectif est d'installer directement chez ces acteurs une plateforme logicielle opérée en mode **SaaS**, déployée sur leur propre infrastructure afin de garantir la

souveraineté et la confidentialité des données. Cette plateforme est mise à disposition sans coût d'installation initial. Les clients acquittent ensuite une **licence par molécules analysées** leur permettant de réaliser autant d'analyses bénéfice-risque que nécessaire sur ladite molécule

En amont de l'installation de la plateforme, **ArcaScience** propose une offre de service permettant au client de tester concrètement la valeur scientifique et opérationnelle de la solution. Cette phase correspond à un proof of concept visant à **démontrer la capacité de la plateforme à analyser un type d'actif donné** (par exemple petites molécules, biologiques ou thérapies cellulaires) dans un contexte pathologique proche. L'objectif n'est donc pas d'évaluer une molécule isolée, mais de démontrer la pertinence de la plateforme pour une classe d'actifs et une famille de pathologies. Par exemple, dans le domaine de l'immunologie, un proof of concept peut être réalisé sur des pathologies proches comme la maladie de Crohn et la rectocolite hémorragique pour des petites molécules. Si les résultats sont jugés probants, le client peut décider d'installer la plateforme en mode SaaS et de l'intégrer dans ses processus décisionnels.

Le module Trial Balancer constitue la base de la solution ArcaScience. Il permet de réaliser les analyses bénéfice-risque comparatives nécessaires à l'évaluation d'un candidat médicament. Une première phase de proof of concept est proposée pour un montant de **75 k€**, permettant de démontrer la pertinence de ces analyses dans un contexte donné. Une fois la valeur démontrée et la plateforme déployée, la tarification s'établit à environ **125 k€** par licence annuelle.

Le module **BR-Predict** vient s'ajouter à cette base logicielle. Il introduit une couche supplémentaire de données et d'analyses permettant d'anticiper plus précocement le profil bénéfice-risque des candidats médicaments. Ce module ne peut fonctionner qu'en **complément du module Trial Balancer**, dont il utilise l'ensemble des briques logicielles et analytiques. Il est donc proposé comme un add-on à la solution existante pour un montant supplémentaire de **125 k€**. Le coût total d'utilisation du module BR-Predict s'élève ainsi à environ **250 k€** par molécule analysée.

Ce modèle économique présente un caractère fortement structurant pour la croissance d'ArcaScience. Les proof of concept permettent de démontrer la pertinence de la plateforme pour une classe d'actifs et un ensemble de pathologies proches. Une fois cette étape franchie, les industriels peuvent déployer la solution et l'utiliser directement sur plusieurs molécules de leur portefeuille. Dans ce modèle, chaque molécule analysée correspond à une licence, ce qui crée une dynamique d'usage récurrent et potentiellement pluriannuelle au sein des mêmes organisations.

Willigness to pay

Les laboratoires pharmaceutiques doivent en permanence arbitrer entre plusieurs actifs à faire entrer en clinique et décider où concentrer leurs ressources financières et humaines afin de maximiser leurs probabilités de succès. Ces choix structurants reposent aujourd'hui sur des analyses longues, coûteuses et parfois fragmentées, alors même que chaque décision d'engagement en phase II ou III représente plusieurs dizaines à centaines de millions d'euros d'exposition au risque.

Dans ce contexte, la disposition à payer des industriels repose sur un raisonnement économique direct : **tout outil capable d'améliorer la priorisation des molécules, de sécuriser le positionnement clinique et d'augmenter la probabilité de succès d'un programme génère une valeur immédiatement mesurable**. Une meilleure sélection des actifs en amont permet d'éviter des essais non pertinents, d'optimiser les protocoles et de réduire les amendements tardifs, avec un impact significatif sur les coûts et les délais.

La solution ArcaScience répond précisément à cette attente en fournissant une évaluation bénéfice/risque rapide, structurée et stratégique, complémentaire des outils déjà en place au sein des directions R&D. Elle ne se substitue pas aux systèmes existants mais apporte une couche décisionnelle supplémentaire, directement exploitable dans les comités de priorisation et les revues de pipeline.

Le modèle commercial, progressif et modulaire, renforce cette disposition à payer. La possibilité de démarrer par un proof of concept limite le risque d'adoption et permet aux industriels d'évaluer concrètement la valeur générée avant un déploiement élargi. La tarification par molécule analysée est

cohérente avec les budgets déjà alloués aux analyses stratégiques et reste marginale au regard des montants engagés dans un programme clinique.

En permettant un développement plus ciblé, plus rapide et moins risqué, la plateforme génère une valeur économique directe pour les industriels. Cette création de valeur tangible constitue le principal moteur de la traction commerciale observée auprès des grands acteurs pharmaceutiques.

5.2.3. PROJECTION DE REVENUS ET CONSTRUCTION DU CHIFFRE D'AFFAIRES

Construction du Chiffre d'affaires

Années	2025	2026	2027	2028	2029	2030	2031	2032
Module Trial Balancer								
Nombre de PoC		4	9	18	26	34		
Nombre de molécule		7	14	22	32	62		
CA PoC (en K€)		300	675	1 350	1 950	2 550		
CA Trial Balancer (en K€)		625	1 312	2 250	3 375	5 875		
CA Total (en K€)		925	1 987	3 600	5 325	8 425		
Module BR-Predict								
Nombre de PoC				2	10	46		
Nombre de molécule			1	2	9	22		
CA molecule (en K€)				125	750	3 500		
CA projet (en K€)			75	225	825	2 325		
CA BR-Predict (en K€)			75	350	1 575	5 825		
CA Total (en K€)		925	2 062	3 950	6 900	14 250		

L'évolution du chiffre d'affaires prévisionnel d'ArcaScience reflète une stratégie de déploiement progressive de la plateforme et de ses modules analytiques. Les revenus passent ainsi de **0,5 M€ en 2025 à 4,3 M€ en 2028**, période durant laquelle la croissance est principalement portée par l'adoption du module Trial Balancer et par l'élargissement progressif de la base clients. À partir de **2029**, le lancement commercial du module **BR-Predict** entraîne une accélération de la croissance, avec un chiffre d'affaires atteignant **8,3 M€ en 2029 puis 19,1 M€ en 2030**. La trajectoire se poursuit ensuite avec une montée en puissance des licences logicielles, conduisant à un chiffre d'affaires de **32,1 M€ en 2031 puis 51,5 M€ en 2032**.

La première phase de croissance repose principalement sur le module Trial Balancer, qui cible des molécules plus matures dans les portefeuilles R&D. Ces actifs étant moins nombreux, la stratégie consiste d'abord à élargir progressivement la base clients en adressant les grandes biotechs, les mid-pharmas et les grands groupes pharmaceutiques. Cette dynamique commerciale permet d'**augmenter progressivement le nombre de molécules analysées**, qui passe **de 3 en 2025 à 20 en 2028**.

La seconde phase de croissance débute en 2029 avec le lancement commercial du module **BR-Predict** à l'issue du programme i-Démo. Avant cette date, les travaux correspondent principalement à des proof of

concept et à des phases de validation technologique. À partir de **2029**, le module peut être intégré dans les **processus décisionnels** des laboratoires pour **l'évaluation précoce des candidats médicaments**, ce qui explique la montée progressive du nombre de licences sur la période 2029-2030.

La croissance s'accélère ensuite à partir de **2031** avec l'extension des aires thérapeutiques couvertes par la plateforme. À cette échéance, **ArcaScience** prévoit de disposer de modules analytiques opérationnels pour plusieurs indications majeures en **oncologie** ainsi que de premiers modèles en **immunologie** et dans les pathologies inflammatoires. Cet élargissement augmente fortement le nombre de molécules éligibles à l'analyse et se traduit par une hausse significative du nombre de licences associées au module BR-Predict.

Enfin, l'évolution du nombre de proof of concept reflète la maturation progressive du marché. Dans les premières années, ces POC jouent un rôle central pour démontrer la valeur scientifique et opérationnelle de la plateforme. À mesure que la crédibilité technologique d'ArcaScience s'installe, les laboratoires devraient installer directement la plateforme pour leurs nouvelles molécules d'intérêt, chaque actif analysé donnant lieu à une licence d'utilisation. Les POC resteront toutefois nécessaires pour certaines extensions fonctionnelles, notamment lors de l'ouverture de nouvelles aires thérapeutiques.

5.3. IMPACTS SOCIÉTAUX ET ENVIRONNEMENTAUX

5.3.1. RETOMBÉES SOCIALES, SOCIÉTALES POUR LE TERRITOIRE NATIONAL

Le projet porté par ArcaScience présente un impact socio-économique structurant, à la fois sur l'accélération de l'innovation thérapeutique, sur l'organisation du développement clinique et sur la dynamique industrielle du territoire.

En permettant d'identifier plus précocement les candidats médicaments les plus prometteurs, la solution contribue à accélérer l'arrivée de thérapies innovantes sur le marché, en particulier pour des **populations médicalement délaissées**. En améliorant la priorisation des actifs et la robustesse des décisions en amont, le module BR-Predict participe à **réduire les délais de développement et à renforcer la probabilité de succès des programmes**. Cet effet d'accélération a un impact direct sur l'accès aux soins et sur l'amélioration de la qualité de vie des patients.

Le projet a également un impact sociétal fort en matière d'éthique des essais cliniques. Un essai de phase I mobilise généralement entre 10 et 50 volontaires sains, tandis qu'un essai de phase II peut inclure entre 50 et 300 patients, parfois davantage selon l'indication. En améliorant la sélection des candidats en amont, chaque essai évité grâce à une meilleure anticipation du profil bénéfice/risque peut permettre **d'épargner entre 10 et 300 personnes**, volontaires et patients confondus. La solution contribue ainsi à un développement pharmaceutique plus responsable, en limitant l'exposition inutile à des traitements à faible probabilité de succès.

Sur le plan économique et territorial, le projet prévoit la création directe de **27 emplois qualifiés**, incluant des ingénieurs en intelligence artificielle, des bioinformaticiens, des chefs de projet R&D et des profils spécialisés en affaires réglementaires. Il inclut également l'intégration de **4 doctorants** et la formation de **8 stagiaires par an** (alternants, jeunes diplômés). Au-delà de ces emplois directs, des retombées indirectes sont attendues auprès des sous-traitants technologiques et scientifiques, contribuant au renforcement de l'écosystème local en santé numérique et en intelligence artificielle appliquée au médicament.

Enfin, l'impact filière est significatif. En repositionnant l'analyse bénéfice/risque au cœur de la décision stratégique, ArcaScience transforme une contrainte historiquement perçue comme réglementaire en un levier industriel structurant. La solution offre aux entreprises pharmaceutiques une capacité renforcée de priorisation de leurs portefeuilles, contribuant à une allocation plus efficace des ressources R&D. Ce changement de paradigme favorise un développement pharmaceutique plus efficient, plus durable et plus compétitif à l'échelle internationale.

Ainsi, le projet s'inscrit dans une logique de transformation du modèle de développement du médicament, au bénéfice des patients, des professionnels de santé, des industriels et du système de santé dans son ensemble.

5.3.2. IMPACT ENVIRONNEMENTAL

Le projet BR-Predict génère des impacts environnementaux structurants. Il contribue d'une part à une rationalisation du développement pharmaceutique, qui permet de réduire les ressources mobilisées pour des projets à faible probabilité de succès, et d'autre part il facilite l'adaptation au changement climatique du système de santé en permettant de raccourcir les temps de développement des traitements.

Rationalisation du développement pharmaceutique et réduction des expérimentations inutiles

Le développement des médicaments est un processus long et fortement consommateur de ressources, mobilisant infrastructures de laboratoire, équipements analytiques, réactifs chimiques et consommables biologiques. Une part importante des candidats échoue à un stade avancé après des investissements expérimentaux significatifs. En permettant d'identifier plus précocement les candidats présentant un profil bénéfice/risque défavorable ou une probabilité de succès limitée, la plateforme BR-Predict contribue à **limiter la poursuite de projets peu viables**. Par ailleurs, l'exploitation et l'analyse de données scientifiques existantes permettent de **réduire la duplication d'études expérimentales déjà réalisées**. Cette capacité de priorisation et de valorisation des données contribue à concentrer les efforts sur les candidats réellement prometteurs et à éviter la mobilisation de ressources pour des programmes à faible probabilité de succès.

- **Réduction de la consommation de ressources et des déchets expérimentaux**

La rationalisation du développement thérapeutique se traduit ainsi par **une réduction des ressources nécessaires aux activités de R&D pharmaceutique**. Les phases précliniques et cliniques mobilisent en effet des volumes importants de **matières premières, de réactifs chimiques, de consommables plastiques et biomédicaux** ainsi que des infrastructures expérimentales énergivores. En limitant les expérimentations peu pertinentes, la solution contribue à réduire la consommation de ces ressources. Chaque étude préclinique ou essai clinique génère également des **déchets spécialisés importants (plastiques, réactifs, matériaux biologiques ou dispositifs médicaux à usage unique)**. En identifiant plus tôt les candidats non viables, la plateforme contribue indirectement à **limiter ces flux de déchets** dans les laboratoires et les centres d'investigation clinique.

- **Réduction de l'empreinte carbone de la R&D pharmaceutique**

Les programmes de développement mobilisent des essais multicentriques, des transports d'échantillons biologiques et des échanges logistiques entre partenaires scientifiques et industriels, **générant des émissions significatives**. Les analyses du cycle de vie estiment qu'un essai clinique multicentrique peut représenter de l'ordre de **1 000 à 10 000 tCO₂e** selon son ampleur et le nombre de sites impliqués (NHS Sustainable Development Unit ; Lancet Planetary Health). En améliorant la sélection des candidats médicaments et en limitant les projets poursuivis jusqu'à des phases avancées, la plateforme peut contribuer à éviter certaines de ces activités et les émissions associées. À l'inverse, l'empreinte carbone liée au fonctionnement des modèles d'intelligence artificielle reste généralement de l'ordre de **quelques tonnes de CO₂e par an** pour des modèles d'apprentissage automatique utilisés en bioinformatique (Patterson et al., 2021 ; Lacoste et al., 2019). Ainsi, si la plateforme permet d'éviter ou d'interrompre plus précocement ne serait-ce qu'un seul programme de développement à faible probabilité de succès, le gain environnemental potentiel pourrait largement dépasser l'empreinte carbone associée au fonctionnement de l'IA.

- **Réduction du recours aux modèles animaux**

L'analyse prédictive des profils de sécurité et d'efficacité des candidats médicaments peut également contribuer à **orienter plus efficacement les programmes de recherche et à concentrer les études expérimentales sur les molécules les plus prometteuses**. Cette approche peut conduire à limiter certains

essais exploratoires, notamment les études animales en phase préclinique. Elle s'inscrit dans la logique des principes internationaux des « 3R » (Reduce, Replace, Refine) visant à réduire le recours aux modèles animaux lorsque cela est scientifiquement possible.

- **Réduction des résidus pharmaceutiques liés aux médicaments inefficaces ou abandonnés tardivement**

En améliorant la sélection des candidats médicaments et leur profil bénéfice/risque, la plateforme peut contribuer à éviter le développement ou la mise sur le marché de molécules présentant un profil défavorable, y compris en termes de toxicité. Une meilleure sélection en amont peut donc limiter la diffusion de substances pharmaceutiques dans les milieux aquatiques via les effluents hospitaliers et domestiques.

Contribution indirecte à l'adaptation du système de santé aux évolutions environnementales

Enfin, en améliorant la capacité d'analyse et de décision dans les phases précoces du développement thérapeutique, la plateforme peut contribuer à accélérer l'identification et l'évaluation de nouveaux candidats médicaments. Cette accélération du processus de développement peut renforcer la capacité du système de santé à répondre plus rapidement à l'évolution des pathologies et aux nouveaux besoins de santé, dont certains peuvent être influencés par les transformations environnementales et climatiques. La solution participe ainsi indirectement à la capacité d'adaptation du développement pharmaceutique face aux évolutions sanitaires liées au changement climatique.

En synthèse, le projet BR-Predict génère des impacts positifs liés à l'optimisation du processus de développement pharmaceutique. En réduisant le nombre d'expérimentations inutiles, en limitant la consommation de ressources expérimentales, en diminuant les volumes de déchets associés aux activités de recherche et en contribuant à rationaliser les programmes de développement, la solution participe à l'émergence d'un modèle de recherche pharmaceutique plus efficient et plus responsable sur le plan environnemental.

6. ELEMENTS FINANCIERS

6.1. IMPACT SUR LE COMPTE DE RESULTATS PREVISIONNEL

Raison sociale : ArcaScience	MONTANTS EN MILLIERS D'EUROS				
	2026	2027	2028	2029	2030
Chiffre d'affaires (HT) total de l'entreprise	925	2063	3950	6900	14250
dont chiffre d'affaires généré par les résultats du projet	0	75	350	1575	5825
dont ventes à l'exportation					
+ production immobilisée	1172	2131	3501	4652	6653
+ production stockée					
A. TOTAL DES PRODUITS D'EXPLOITATION	2097	4194	7451	11552	20903
Achat de matières premières et marchandises					
+/- Variation de stock de matières et marchandises					
+ Autres achats et charges externes	722	1124	1604	2206	3285

dont COGS	24	206	395	690	1425
dont Marketing	191	248	322	419	545
dont Saas & Tools	83	112	152	205	276
dont Loyer	116	176	267	328	363
dont IT (security)	20	30	40	50	60
dont frais de structure	288	351	428	514	615
B. TOTAL CONSOMMATION EN PROVENANCE DE TIERS	722	1124	1604	2206	3285
C. VALEUR AJOUTEE (A-B)	1376	3070	5847	9346	17618
+ Subvention d'exploitation (hors aide envisagée)					
- Impôts et taxes	35	55	84	102	113
- Charges de personnel	2717	4191	6136	7441	8205
D. EXCEDENT BRUT D'EXPLOITATION	-1377	-1176	-372	1803	9300
- Dotation aux amortissements	161	551	1262	2268	3428
- Autres charges d'exploitation					
+ Autres produits d'exploitation					
E. RESULTAT D'EXPLOITATION	-1537	-1728	-1634	-466	5872
+ Produits financiers					
- Charges financières	34	43	41	34	25
F. RESULTAT COURANT AVANT IMPOTS	-1571	-1771	-1675	-499	5847
+ Produits exceptionnels					
- Charges exceptionnelles					
- Participation des salariés					
- Impôts sur les bénéfices (avec CIR)	-340	-569	-919	-1173	-89
G. RESULTAT DE L'EXERCICE	-1232	-1202	-756	674	5936
Effectifs	23	35	53	65	72
CAPACITE D'AUTOFINANCEMENT (G + amortissements + ou - résultats exceptionnels)	-1071	-651	506	2942	9364
Montant du projet passé en charges d'exploitation					

Montant du projet					
Les dépenses du projet peuvent être immobilisées et amorties (ligne 12 de l'onglet "Plan de financement"), ou bien passées pour tout ou partie en charges d'exploitation.					
Surlignement automatique en rouge en cas de différence entre "Montant du projet" et ["Montant du projet passé en charges d'exploitation" + "Immobilisation des dépenses du projet proposé"] : correction nécessaire					

6.2. PLAN DE FINANCEMENT

6.2.1. PLANIFICATION DE DEPENSES ESTIMEES

Les besoins de financement d'ArcaScience sur les trois prochaines années correspondent principalement aux investissements nécessaires au développement technologique de la plateforme, au renforcement de l'équipe scientifique et technique et à la structuration progressive de l'activité commerciale.

Sur la période du projet, il est estimé à **11 608 M€**, la structure des dépenses se répartit selon les grandes catégories suivantes :

- **Ressources humaines : 8 663 K€ – 75 %** : Cette catégorie constitue la part principale des dépenses. Elle correspond au recrutement progressif de profils scientifiques, techniques et data nécessaires au développement des différents modules de la plateforme, ainsi qu'au renforcement des équipes d'ingénierie logicielle et d'intelligence artificielle.
- **Activité de marketing : 761 K€ – 6 %** : Ce coût évolue graduellement tout au long du projet avec le scale-up de l'activité marketing, en adéquation avec la stratégie de mise sur le marché et d'expansion de la clientèle.
- **Autres dépenses opérationnelles : 2 184 K€ – 19 %** : Cette catégorie regroupe les dépenses de fonctionnement nécessaires à l'activité de l'entreprise, notamment les coûts liés au développement logiciel, aux outils technologiques, aux frais de structure ainsi qu'aux activités de développement commercial et marketing associées à la mise sur le marché progressive de la solution.

L'évolution de ces besoins de financement est principalement liée à la croissance de l'équipe au cours des prochaines années. Les dépenses de ressources humaines augmentent progressivement afin de soutenir les activités de R&D et l'industrialisation de la plateforme. Par ailleurs, les dépenses liées au marketing et au développement commercial augmentent à mesure que la stratégie de go-to-market se déploie et que l'entreprise élargit sa base de clients. Les autres dépenses restent principalement liées aux besoins opérationnels de l'activité et au maintien de l'infrastructure technologique.

6.2.2. STRATEGIE DE FINANCEMENT SUR LA DUREE DU PROGRAMME

La stratégie de financement d'ArcaScience repose sur une combinaison de subventions publiques, d'une levée de fonds privée et de la montée progressive des revenus générés par l'activité commerciale de la plateforme. L'objectif est de sécuriser les ressources financières nécessaires au développement technologique et au déploiement commercial de la solution jusqu'à l'atteinte du point d'équilibre financier prévu à l'horizon **2030**.

Subventions publiques

Les financements publics constituent un levier structurant pour soutenir les activités de recherche et développement de la plateforme au cours des premières années.

Dans ce cadre, ArcaScience bénéficie tout d'abord du dispositif **Innov'Up**, qui contribue au financement des premières briques technologiques du projet.

- **Innov'Up – solde : [montant] € – versée en [année / mois]**

@Le projet bénéficie également du financement **i-Démo**, qui soutient le développement des modules avancés de la plateforme et leur industrialisation.

- **i-Démo – acompte : 325 K€** – acompte versé lors de la validation du programme i-démo. Cette première tranche aura pour objectif de financer la première étape clés du programme afin de valider la Prédiction basée sur la structure chimique à AUC > 0,6 (générique).
- **i-Démo – tranche 2 : 1 350 K€** – versée début Q2 2027 afin de financer les Workpackage 2, 3 et 4 et d'atteindre Prédiction intégrant les données précliniques et le MOA : AUC > 0,75 (générique).
- **i-Démo – solde : 1 005k €** – La dernière tranche du programme i-démo sera versée début Q1 2028 afin de financer la finalisation du programme et l'atteinte des résultats.

Ces subventions permettent de financer une part significative des travaux de R&D et de réduire le risque technologique associé au développement de la solution.

Levée de fonds

En complément des financements publics, ArcaScience prévoit la réalisation d'une levée de fonds auprès d'investisseurs afin de soutenir l'accélération du développement de l'entreprise.

Cette levée de fonds fera suite celle de **4,65M €** réalisé lors de la fin de l'année **2025**. Elle sera de **20M €** prévu pour **2028**. Elle permettra principalement de financer la croissance des équipes techniques et scientifiques, ainsi que la structuration des activités commerciales nécessaires au déploiement de la plateforme auprès des acteurs pharmaceutiques et biotechnologiques.

Contribution des revenus

À mesure que la solution sera déployée chez les partenaires industriels, les revenus issus des licences d'utilisation de la plateforme contribueront progressivement au financement de l'activité de l'entreprise. La croissance du chiffre d'affaires repose notamment sur l'adoption progressive des modules Trial Balancer et BR-Predict et sur l'augmentation du nombre de molécules analysées par les partenaires industriels.

La combinaison des subventions publiques, de la levée de fonds et des premiers revenus commerciaux doit permettre à ArcaScience de financer son développement technologique et commercial jusqu'à l'atteinte du **break-even prévu en 2030**. À partir de cette échéance, la croissance du chiffre d'affaires devrait permettre de soutenir de manière autonome l'activité de l'entreprise.

7. JUSTIFICATION DE L'AIDE

7.1. ACTIVITES QUI SERAIENT DEPLOYEES EN L'ABSENCE DE L'AIDE

En l'absence du soutien i-Démo, ArcaScience ne disposerait pas des capacités financières nécessaires pour développer le module BR-Predict dans les délais compatibles avec l'opportunité de marché identifiée. Les recrutements prévus d'ArcaScience pour réaliser ces deux activités en parallèle ne seraient possible qu'avec l'aide i-Démo.

Le **financement sollicité** est, en effet, destiné principalement au **recrutement de profils techniques hautement qualifiés**, indispensables au développement du nouveau module prédictif, tout en maintenant la continuité des activités commerciales existantes. Sans cette aide, l'entreprise ne pourrait pas mobiliser simultanément des ressources sur la R&D avancée et sur la structuration commerciale.

La société serait contrainte de concentrer ses ressources humaines et financières sur le déploiement commercial du module Trial Balancer afin d'assurer la consolidation de son chiffre d'affaires et sa présence sur le marché.

Par ailleurs, la société ne peut interrompre ou ralentir le développement du module Trial Balancer au profit exclusif de BR-Predict. **Trial Balancer constitue aujourd'hui la porte d'entrée stratégique sur le marché pharmaceutique et le socle de reconnaissance d'ArcaScience au sein de l'écosystème du développement du médicament.** Abandonner ou fragiliser cette activité compromettrait la crédibilité industrielle et la traction commerciale nécessaires au lancement ultérieur du module prédictif.

7.2. BÉNÉFICES NOUVEAUX PERMIS PAR L'AIDE

Le soutien i-Démo permettrait à ArcaScience d'accélérer significativement la mise sur le marché du module BR-Predict, dans un contexte où le timing concurrentiel est particulièrement favorable. La société dispose déjà d'une plateforme reconnue pour ses gains de temps, de coût et de qualité dans l'analyse bénéfice/risque réglementaire. **À ce stade, aucun acteur de l'analyse bénéfice risque ne possède la technologie pour aller sur le segment prédictif.**

De plus les sociétés développant des plateformes IA d'aide aux développements de médicaments n'ont pas encore essayé de se positionner sur ce segment.

Le **financement i-Démo** permettra de **lever les incertitudes techniques identifiées**, notamment autour du World Model et de l'intégration multi-niveaux des données, afin de **sécuriser le développement d'un module prédictif** robuste avant l'arrivée de concurrents sur ce marché.

Cette avance stratégique renforcera la probabilité que **BR-Predict** devienne une **référence dans l'aide à la décision en développement pharmaceutique**, d'abord en France et aux États-Unis, puis à l'international. Elle offrira également à **ArcaScience** la capacité d'étendre progressivement sa **gamme de modules pour couvrir davantage de phases de développement et d'aires thérapeutiques**, consolidant ainsi sa position comme outil structurant du développement du médicament.

7.3. AVANTAGES SUPPLÉMENTAIRES POUR LE CLIENT FINAL

Le module BR-Predict apportera aux entreprises pharmaceutiques et aux grandes biotechnologies un **outil inédit capable d'anticiper le profil bénéfice/risque de leurs candidats médicaments en amont des phases cliniques avancées.**

Les clients disposeront ainsi d'un niveau d'information supérieur à celui offert par les approches actuelles, leur permettant de prendre des décisions plus éclairées et plus structurées. L'identification précoce des bénéfices probables et des risques potentiels contribuera à :

- **Prioriser les actifs** à engager en développement clinique ;
- Concevoir des **protocoles cliniques mieux adaptés** au mécanisme d'action et au profil patient ciblé ;
- **Réduire l'exposition inutile de volontaires sains et de patients** à des candidats à faible probabilité de succès.

Cette capacité prédictive constitue un avantage différenciant majeur par rapport aux offres existantes, qui restent principalement descriptives ou segmentées.

7.4. RETOMBÉES POUR LA FILIÈRE INDUSTRIELLE ET LES STANDARDS

À l'échelle de la filière pharmaceutique, le projet contribuera à faire évoluer l'utilisation des analyses bénéfice/risque dans les processus de développement des médicaments. Aujourd'hui, ces analyses sont principalement mobilisées par les équipes de pharmacovigilance dans une logique de surveillance et de conformité réglementaire. À l'inverse, les équipes de développement disposent encore de peu d'outils structurés leur permettant d'anticiper de manière intégrée le profil bénéfice/risque des candidats médicaments lors des choix stratégiques de développement.

La plateforme développée dans le cadre du projet permettra d'intégrer ces analyses beaucoup plus en amont dans les processus de décision R&D. En exploitant à grande échelle des données scientifiques, cliniques et centrées patient, elle permettra aux équipes de développement **d'évaluer plus**

systématiquement le potentiel d'un candidat médicament, notamment en comparant ses performances attendues en termes d'efficacité et de sécurité au standard thérapeutique existant.

À l'échelle de la filière, cette capacité d'anticipation pourrait **améliorer la robustesse scientifique des stratégies de développement pharmaceutique**. L'identification plus précoce de signaux d'efficacité, de toxicité ou de différenciation clinique permettra aux industriels d'ajuster plus rapidement leurs programmes de développement, de mieux cibler les populations de patients et d'optimiser la conception des essais cliniques. Cela contribuera à **réduire le risque d'échec tardif des essais et à améliorer l'efficacité globale des investissements en R&D**.

Le projet contribuera également à structurer une nouvelle catégorie d'outils industriels dédiés à l'analyse intégrée des données biomédicales pour la prise de décision stratégique. Aujourd'hui, les acteurs du secteur s'appuient majoritairement sur des analyses manuelles ou sur des prestations de conseil ponctuelles pour évaluer le positionnement d'un candidat médicament. En proposant une plateforme capable d'automatiser et de systématiser ces analyses à grande échelle, **ArcaScience contribuera à faire évoluer les pratiques de la filière vers des approches davantage data-driven**.

Cette évolution pourrait bénéficier particulièrement aux sociétés de biotechnologie, qui disposent souvent de ressources limitées pour conduire des analyses stratégiques approfondies sur leurs actifs. L'accès à ce type d'outil permettra de renforcer la qualité scientifique des programmes de développement et de faciliter les interactions avec les partenaires industriels, les investisseurs et les autorités réglementaires.

Enfin, en développant ces capacités en France, le projet contribue à structurer un écosystème technologique associant intelligence artificielle, exploitation de données biomédicales et expertise pharmaceutique. **Cette infrastructure analytique participe au renforcement de la compétitivité de la filière européenne dans le domaine de l'IA appliquée au développement des médicaments**.