

WP1 : Modèles prédictifs QSAR/QSTR pour l'estimation du rapport bénéfice-risque à partir de la structure moléculaire seule.

L'objectif de ce lot est de démontrer qu'il est possible, dès la phase de criblage chimique, de produire une estimation quantitative du profil bénéfice-risque (B-R) d'un candidat-médicament à partir de sa seule représentation structurale. Ce lot constitue la couche prédictive la plus précoce de BR-PREDICT : il intervient en amont de toute donnée biologique ou clinique et vise à réduire le taux d'attrition (aujourd'hui de 92 % entre la phase préclinique et la mise sur le marché) en identifiant, dès la conception moléculaire, les signaux d'efficacité potentielle et les alertes de toxicité structurelle.

Cadre scientifique & périmètre

L'hypothèse fondatrice est que la structure chimique d'une molécule pharmacologique (ou drogue) encode une information suffisante pour prédire, avec une incertitude contrôlée, à la fois son activité pharmacodynamique(volet bénéfice) et sa propension à induire des effets toxiques (volet risque). Ces deux effets sont déterminés par une activité biologique sur des cibles spécifiques (on-target) ou sur des cibles collatérales (off-target). Cette hypothèse repose sur les principes fondamentaux de la relation structure-activité quantitative (QSAR) et de la relation structure-toxicité quantitative (QSTR), validés dans la littérature sur des périmètres restreints. Le périmètre couvre les petites molécules organiques. Les biothérapies ou "biologics" (anticorps, protéines recombinantes) sont explicitement hors champ pour ce lot, leur profil B-R relevant davantage des WP2 et WP3. La pathologie d'ancrage pour la validation est le cancer du poumon, conformément à la stratégie projet.

Méthodologie technique détaillée

- **T1.1 - Qualification des sources.** Trois corpus de référence sont exploités Le corpus d'entraînement s'appuie sur ChEMBL 34 (~2,4M composés avec données de bioactivité sur des milliers de cibles), ToxCast (~10K composés sur ~600 endpoints de toxicité haut débit) et NCGC qHTS (~300K composés en criblage de cytotoxicité). Chaque molécule est représentée par un vecteur de ~2 250 features (fingerprints Morgan/ECFP en 2 048 dimensions + ~200 descripteurs physicochimiques RDKit), complété par des graphes moléculaires pour les architectures GNN. Les modèles QSAR de bénéfice sont entraînés sur l'ensemble des cibles disposant de données suffisantes dans ChEMBL ; les modèles QSTR de risque couvrent l'ensemble des endpoints de ToxCast et NCGC. Pour la validation sur le cancer du poumon, un panel prioritaire de cibles (EGFR, ALK, KRAS, PD-L1) et d'endpoints de toxicité (hERG, AMES, DILI) est utilisé. Chaque source fait l'objet d'un audit de couverture, de cohérence et de biais de publication avant intégration dans la Profiling Base.

- **T1.2 - Construction et traitement (“curation”) de la base de données.** Une base dédiée est constituée, regroupant les molécules pharmacologiques commercialisées, disposant d'un profil B-R documenté, soit une estimation de 4500 molécules (d'après la version ChEMBL35). Afin d'étendre la base de données, nous incluons également certaines molécules en phase clinique suffisamment avancée (phase 2 ou 3) ayant un profil B-R documenté (à sélectionner parmi les 15000 molécules de ChEMBL ayant atteint une phase clinique). La curation inclut la normalisation des identifiants chimiques (InChI, SMILES canoniques), des composés chimiques (tautomère, forme saline, stéréochimie, état de protonation) en via MolVS/ChEMBL standardizer RDKit Standardize, la déduplication, et l'annotation croisée avec les données réglementaires (RCP, rapports PSUR) disponibles dans la Profiling Base 100B d'ArcaScience, complétée par les informations réglementaires publiques (labels FDA, rapports d'évaluation de l'EMA, DailyMed).
- **T1.3 - Représentation moléculaire et calcul de descripteurs.** Chaque molécule est convertie en vecteurs de descripteurs exploitables par les modèles ML : fingerprints moléculaires (Morgan/ECFP, MACCS), descripteurs physicochimiques (RDKit), et représentations par graphes moléculaires pour les architectures GNN. L'objectif est de disposer de représentations complémentaires permettant d'alimenter plusieurs familles d'algorithmes.
- **T1.4 - Développement des modèles QSAR (bénéfice).** Plusieurs approches ML sont entraînées et comparées : Random Forest, Gradient Boosting, et réseaux de neurones sur graphes (GNN). Un domaine d'applicabilité est défini pour chaque modèle afin de quantifier la confiance de la prédiction en fonction de la distance au jeu d'entraînement. La base ChEMBL (v35) compile plus de 21 millions de points de bioactivité (IC50, EC50, Ki, Kd) pour plus de 2,4 millions de composés sur plus de 17 000 cibles protéiques, EGFR étant parmi les mieux documentées (>8 200 mesures d'IC50). ToxCast/Tox21 couvre environ 10 000 substances, testées sur plus de 700 essais ciblant plus de 300 voies de signalisation. En entrée : chaque molécule est représentée par un vecteur de descripteurs (estimé entre 500 et 2000 variables) combinant fingerprints moléculaires (Morgan/ECFP, MACCS), descripteurs physicochimiques (RDKit) et représentation par graphe (pour les GNN). En sortie : Le modèle QSAR génère un score d'activité prédite (type pIC50/pEC50/pKi) et un score de confiance pour chaque cible du panel oncologie pulmonaire (EGFR, ALK, KRAS, PD-L1, etc.). Ces 8 à 10 prédictions sont ensuite agrégées en un score de bénéfice composite. Les modèles sont entraînés sur l'ensemble des données d'activité, incluant pour incluant les cibles pertinentes en oncologie pulmonaire (EGFR, ALK, KRAS, PD-L1, etc.).
- **T1.5 - Développement des modèles QSTR (risque).** Selon une architecture parallèle, des modèles ML sont entraînés sur les données de toxicité pour produire un score de risque structurel. Les données ToxCast et NCGC alimentent ces modèles, ainsi que les données dérivées du développement clinique et post-AMM. Les modèles QSTR (toxicité) s'appuient sur plusieurs sources de données : ToxCast/Tox21 (~10 000 substances testées sur >700 essais haute débit pour la cytotoxicité, génotoxicité, etc.), NCGC (cytotoxicité pour >8 000 composés) et ChEMBL (cardiotoxicité hERG et hépatotoxicité). Ces données sont complétées par des informations cliniques/post-AMM (RCP, PSUR) pour 2 000 à 3 000 molécules commercialisées. Au total, l'entraînement utilise environ 15 000 à 20 000 couples {structure/profil de risque}, avec une couverture variable selon l'endpoint :

- Cytotoxicité : ~10 000 composés
- Cardiotoxicité hERG : ~10 000-15 000 composés
- Génotoxicité : ~5 000-8 000 composés
- Hépatotoxicité : ~3 000-5 000 composés

Une attention particulière est portée au déséquilibre de classes, traité par pondération des pertes et ajustement du seuil de décision (threshold tuning), afin de maximiser la performance prédictive tout en maintenant une calibration rigoureuse.

- **T1.6 - Intégration et validation.** Les scores QSAR (bénéfice) et QSTR (risque) sont intégrés dans un score B-R composite, calibré sur des molécules commercialisées ou ayant atteint des phases cliniques avancées dont le profil B-R est connu. Les scores sont combinés via un méta-modèle calibré (régression logistique ou stacking) entraîné sur les issues réglementaires (approbation, retrait) pour trouver la pondération optimale bénéfice/risque. La confiance de la prédiction est rapportée séparément, basée sur le domaine d'applicabilité et la variance inter-modèles, afin de distinguer la prédiction de sa fiabilité. La validation repose sur trois piliers : 1) une validation croisée stratifiée, 2) un test sur un sous-ensemble de molécules à B-R connu tenues à l'écart, et 3) une validation externe sur la base de données multi-thérapeutique WITHDRAWN (incluant des retraits pour motifs de sécurité) et des molécules sous avertissement encadré de la FDA (boxed warnings). L'approche structurale du WP1 étant indépendante de la pathologie, cet élargissement permet de pallier la rareté des retraits pour motif de sécurité spécifiquement en oncologie et de garantir une évaluation robuste du volet risque.. Le jeu de test externe pour le risque utilise la base mondiale de 578 médicaments retirés au lieu de se limiter aux retraits en oncologie pulmonaire. Ce choix est cohérent avec le caractère pathologie-agnostique des modèles QSTR et est complété par des molécules commercialisées portant un avertissement encadré (boxed warning) de la FDA.

Tâches & articulation avec les autres WPs

Le WP1 fournit la couche prédictive structurelle qui constitue le premier niveau d'entrée du moteur BR-PREDICT. Ses scores alimentent directement le WP5 (intégration multi-échelle) et servent de baseline pour mesurer le gain incrémental apporté par les données *in vivo* (WP2) et génomiques (WP3). Les partenaires Sanofi, Cedars-Sinai et Mayo Clinic contribuent à la validation en confrontant les prédictions WP1 à des cas réels de leur pipeline. Le calendrier s'étend de Q1 2026 à Q1 2027.

Livrables & Jalons

- **L1.1** : Base de données traitée structure-activité-toxicité (M6).
- **L1.2** : Modèles QSAR validés sur les cibles d'intérêt en oncologie pulmonaire (M9).
- **L1.3** : Modèles QSTR validés sur les endpoints toxicologiques prioritaires (M9).
- **L1.4** : Score B-R composite intégré et rapport de validation (M12).
- **Jalon EC1** (fin 2026) : démonstration de la capacité à prédire le profil B-R à partir de la structure chimique seule, avec incertitude quantifiée.

KPI & protocole d'évaluation

L'objectif cible est une AUC > 0,75 sur le jeu de validation externe, seuil cohérent avec l'état de l'art QSAR sur des espaces chimiques diversifiés. La précision est mesurée par AUC-ROC pour les modèles de classification et par R²/RMSE pour les modèles de régression. Le protocole inclut une validation croisée 5-fold sur le jeu d'entraînement et une évaluation finale sur un jeu de test externe strictement disjoint. Les résultats sont stratifiés par famille chimique pour identifier les zones de confiance et les zones de faiblesse du domaine d'applicabilité.

Risques, verrous, et plans de mitigation

- **Domaine d'applicabilité limité** : aucun modèle QSAR unique ne couvre l'intégralité de l'espace chimique. Mitigation : définition explicite du domaine d'applicabilité par modèle, combinaison de modèles spécialisés, et score de confiance associé à chaque prédiction.
- **Dégradation de précision sur scaffolds dissimilaires** : les performances des GNN et Random Forest chutent significativement sur les structures éloignées du jeu d'entraînement. Mitigation : enrichissement itératif de la base d'entraînement, apprentissage par transfert, et signalisation explicite des prédictions hors domaine.
- **Exclusion des biothérapies** : le WP1 ne couvre pas les anticorps et protéines thérapeutiques. Mitigation : cette limitation est compensée par les WP2 et WP3 qui traitent ces modalités via des données biologiques et génomiques.

Contribution à la répétabilité multi-pathologies & à l'industrialisation

Les modèles QSAR/QSTR développés dans le WP1 ne sont pas spécifiques à une pathologie : ils s'appuient sur la structure chimique et des endpoints biologiques/toxicologiques génériques. L'expansion à l'ensemble des pathologies connues ne nécessitera que la redéfinition du panel de cibles et du jeu de validation, sans réentraînement de l'architecture. Ce design modulaire contribue directement à l'objectif d'industrialisation de BR-PREDICT comme plateforme générique de prédiction B-R.

WP2 : Modèles prédictifs de transposition préclinique-clinique pour l'estimation du rapport bénéfice-risque à partir des données *in vivo*.

L'objectif de ce lot est de construire une couche prédictive qui exploite les données d'études précliniques (efficacité pharmacologique *in vivo*, toxicologie réglementaire, pharmacocinétique animale) pour prédire le profil B-R chez l'humain. Le WP2 introduit une innovation majeure : un **score de fiabilité par modèle préclinique et par pathologie**. Ce lot se situe en aval du WP1 (structure chimique) et constitue le deuxième niveau de résolution prédictive de BR-PREDICT, mobilisable dès la fin des études précliniques réglementaires et pendant les phases I/II.

Cadre scientifique & périmètre

La méthode appliquée établit que les données précliniques *in vivo*, bien que soumises à des biais de transposition inter-espèces bien documentés, contiennent un signal prédictif d'efficacité ou toxicité exploitable lorsqu'elles sont pondérées par la fiabilité historique du modèle animal utilisé, définie comme le taux de concordance observé rétrospectivement entre les résultats précliniques et les issues cliniques humaines pour chaque combinaison {modèle animal × pathologie}. Cette approche est motivée par l'hétérogénéité documentée de la transposabilité selon le type de modèle : la concordance en toxicité varie de 43 % pour les rongeurs seuls à 71 % en combinant rongeurs et non-rongeurs (Olson et al., 2000), tandis qu'en efficacité oncologique, les xénogreffes dérivées de patients (PDX) atteignent ~87 % de concordance thérapeutique (PPV 85 %, NPV 91 % ; Izumchenko et al., 2017) contre un pouvoir prédictif quasi nul pour les allogreffes murines classiques (Voskoglou-Nomikos et al., 2003). L'état de l'art confirme cette hypothèse : les approches hybrides ML + modélisation mécanistique PK ont atteint 64 % de précision pour la clairance et 62 % pour le volume de distribution, dans une marge d'erreur de facteur 2 (Lombardo et al.). Le périmètre couvre les petites molécules et les biothérapies, ces derniers faisant l'objet d'un traitement spécifique compte tenu des limites connues de transposabilité (immunogénicité, modèles substitutifs). La pathologie d'ancrage reste l'oncologie pulmonaire.

Méthodologie technique détaillée

- **T2.1 - Préparation de l'infrastructure (tâche mutualisée WP2/WP3/WP4).** Déployée en Q2 2026, cette tâche met en place l'infrastructure commune de stockage, d'indexation et de requêtage de la Profiling Base dédiée à BR-PREDICT. Elle comprend l'extension du graphe de connaissances existant (100 milliards de points de données/relations), le déploiement des pipelines ETL pour les nouvelles sources partenaires et multimodales, et la configuration des environnements d'entraînement ML (GPU, versioning des modèles, traçabilité des expériences via MLflow).
- **T2.2 - Qualification des sources de données pré-cliniques *in vivo*.** Trois catégories de sources sont qualifiées : (i) données d'efficacité préclinique (modèles xénogreffe, PDX, modèles transgéniques, données pharmacodynamiques), (ii) données toxicologiques réglementaires (études de dose-réponse, études de toxicité à doses répétées, études de génotoxicité, études de carcinogénicité), (iii) littérature générale rapportant des résultats *in vivo* avec issue clinique connue. Chaque source est évaluée selon sa couverture, sa standardisation, et ses biais potentiels (biais de publication, sous-déclaration des résultats négatifs).
- **T2.3 - Extraction NLP et structuration.** Les Contextualizing SLMs d'ArcaScience (24 modèles spécialisés -classifieurs de phrases, modèles NER, modèles d'embedding, modules hybrides règles+modèles - entraînés sur données annotées selon des guides définis avec des cliniciens sont adaptés pour extraire, à partir de la littérature et des rapports d'études, les données structurées nécessaires : espèce, souche,

modèle pathologique, doses, schéma posologique, endpoints d'efficacité (TGI, survie, réponse tumorale), endpoint extraction est validée par confrontation avec des données manuellement annotées (précision démontrée > 90 %). Elle reposera sur trois indicateurs de toxicité (NOAEL, LOAEL, organes cibles, sévérité), et paramètres PK (C_{max}, AUC, t_{1/2}, clairance). Les métriques de performance : (1) le F1-score par entité sur un jeu de test indépendant (cible > 0,85 par champ), (2) le taux de complétude par enregistrement pour évaluer l'absence d'erreurs cumulées (cible > 0,70), et (3) l'impact en aval sur le modèle de machine learning. Ce dernier sera mesuré par l'écart d'AUC entre le modèle WP2 entraîné sur données manuelles et celui entraîné sur données NLP, la qualité d'extraction étant jugée suffisante si cet écart est inférieur à 0,02.

- **T2.4 - Création de la base traitée et structurée.** Les données extraites sont intégrées dans une base relationnelle liant chaque molécule à ses résultats précliniques (efficacité + toxicité), au modèle animal utilisé, et à l'issue clinique connue (pour les molécules commercialisées ou ayant échoué en développement clinique). Cette base constitue le corpus d'entraînement et de validation des modèles ML. Une première estimation réalisée à partir de nos outils suggère entre 5 000 et 8 000 composés pharmacologiques avec des données précliniques d'efficacité et/ou de toxicologie accessibles publiquement de façon utile, en fonction du paramétrage de la recherche. Ceci garantit la faisabilité des étapes suivantes de modélisation même sur la limite basse de cette estimation.
- **T2.5 - Modèle ML de prédiction d'efficacité avec score de fiabilité.** Un modèle ML est entraîné pour prédire l'efficacité clinique à partir des données précliniques. L'innovation clé réside dans l'intégration d'un score de fiabilité par modèle préclinique et par pathologie, calculé à partir de la concordance historique entre résultats précliniques et issues cliniques pour chaque combinaison {modèle animal x pathologie}. Les données de la littérature indiquent une concordance globale de l'ordre de 57 % (IC 95 % : 51–63 %) pour les modèles murins standard, et de 67 % (IC 95 % : 58–75 %) pour les modèles PDX, justifiant la différenciation du score de fiabilité par type de modèle (Gao et al., 2015 ; Hutchinson & Kirk, 2011 ; Ghosh A. et al., 2024). Ce score pondère la prédiction et permet de quantifier la confiance accordée à chaque donnée d'entrée. En oncologie pulmonaire, par exemple, les modèles PDX EGFR-mutés auront un score de fiabilité distinct de celui des xénogreffes sous-cutanées sur lignées cellulaires (Gandara et al., 2016).
- **T2.6 - Modèle ML de prédiction de risque.** Un modèle parallèle, basé sur une architecture XGBoost adaptée à la tâche, exploitant des descripteurs tabulaires, est entraîné pour prédire les risques toxiques humains. Les entrées sont organisées en trois catégories : les paramètres dose-réponse (NOAEL/LOAEL, marges de sécurité HED/MRHD), les données toxicologiques qualitatives (organes cibles, signaux de toxicité fonctionnelle) et les variables de contexte. Le modèle apprend ainsi les facteurs de transposition inter-espèces et les patterns de toxicité clinique historiquement non détectés en préclinique. Contrairement aux prédictions d'efficacité ou de propriétés moléculaires pour lesquelles des corpus pré-entraînés de grande taille sont disponibles, les données de transposition préclinique-clinique en toxicologie sont structurellement peu nombreuses, hétérogènes et fortement tabulaires. Dans ce régime de faible volumétrie, les modèles gradient boosting surpassent systématiquement les architectures neuronales profondes, qui requièrent

un volume de données d'entraînement bien supérieur pour converger et s'adapte mieux aux contextes réglementaires d'interprétabilité des décisions.

- T2.7 - Validation et intégration. Les modèles sont validés selon le même principe que le WP1: 1) validation croisée, 2) validation sur un dataset indépendant (environ 30% du dataset global, non utilisé pour l'entraînement du modèle), 3) validation sur des molécules commercialisées en oncologie pulmonaire et sur des molécules ayant échoué en développement (attrition pour efficacité insuffisante ou toxicité inacceptable).

Ce protocole de validation est conçu pour garantir une évaluation rigoureuse et sans biais : il s'appuie exclusivement sur des molécules dont l'issue clinique est définitivement connue (approbation réglementaire ou arrêt documenté pour échec), ce qui constitue le standard le plus exigeant en matière de validation rétrospective. Les performances de WP1 et WP2 seront comparées à leur combinaison (WP1+WP2) sur un socle de tests commun, ce qui permettra de quantifier le gain de précision issu des données *in vivo* par un test de DeLong (AUC appariée) comparant le modèle global au WP1 seul.

La crédibilité du protocole de validation est renforcée par la définition anticipée d'un panel de référence en oncologie pulmonaire, constitué de molécules dont le profil B-R clinique est documenté de façon irréfutable. Ce panel inclut notamment : des succès thérapeutiques majeurs (osimertinib, alectinib, lorlatinib) dont le bénéfice clinique est solidement établi, ainsi que des molécules ayant échoué pour toxicité inacceptable (buparlisib, idelalisib) ou efficacité insuffisante (selumetinib en monothérapie, vandetanib en 2e ligne).

Tâches & articulation avec les autres WPs

Le WP2 s'appuie sur l'infrastructure commune déployée en T2.1, partagée avec WP3 et WP4 dans une logique d'efficacité maximale des ressources. Les quatre WPs de modélisation (WP1 à WP4) sont développés en parallèle et de façon pleinement indépendante : cette architecture garantit que chaque couche prédictive produit ses scores sans dépendance opérationnelle aux autres, préservant l'intégrité statistique de la validation finale et permettant de mesurer la contribution propre de chaque source de données. La convergence des prédictions intervient exclusivement au niveau du WP6, où le moteur d'intégration multi-échelle apprendra à pondérer et réconcilier ces sources hétérogènes. Les partenaires Sanofi et Cedars-Sinai contribuent à la validation clinique ; Mayo Clinic fournit des données longitudinales pour l'évaluation rétrospective. Le calendrier s'étend de Q2 2026 à Q4 2027, avec une phase d'infrastructure commune en 21 2026.

Livrables & Jalons

- **L2.1** : Infrastructure commune opérationnelle (M3, partagée avec WP3/WP4).
- **L2.2** : Modèle NLP fonctionnel pour l'extraction de données *in vivo* (M9).
- **L2.3** : Score de fiabilité par modèle préclinique et par pathologie, calibré sur l'oncologie pulmonaire (M12).

- **L2.4** : Modèles ML prédictifs Bénéfits d'un côté et Risks de l'autre, basés sur les données *in vivo*, validés (M18).
- **Jalon EC1** (fin 2026) : objectifs de précision définis par périmètre (spécifique/non spécifique).

KPI & protocole d'évaluation

Les objectifs de précision sont définis séparément pour le volet bénéfice et le volet risque. Pour le risque, l'objectif cible est une AUC > 0,70 sur le jeu de validation externe. Pour le bénéfice, la performance est évaluée par la corrélation entre le score de fiabilité et la concordance préclinique-clinique observée, démontrant la contribution propre et complémentaire des données précliniques *in vivo* : WP1 et WP2 constituent deux axes prédictifs indépendants dont la pleine valeur sera révélée par leur intégration dans le WP6. Le protocole d'évaluation repose sur une validation rétrospective : les modèles sont entraînés sur des molécules dont le profil B-R clinique est connu, puis testés sur un jeu de validation externe. La précision du score de fiabilité est évaluée par la corrélation entre le score attribué et la concordance préclinique-clinique observée pour l'efficacité et le risque, respectivement. Les résultats sont stratifiés par type de modèle animal et par sous-type de pathologie pulmonaire.

Risques, verrous, et plans de mitigation

- **Données propriétaires derrière des paywalls** : une part significative des données précliniques est publiée dans des revues à accès restreint ou détenue en interne par les laboratoires. Mitigation : exploitation prioritaire des bases ouvertes (PubChem BioAssay, EPA ToxCast, littérature en accès libre), complétée par les données partenaires (Sanofi, Cedars-Sinai, Mayo Clinic) dans le cadre d'accords de partage.
- **Biais de publication** : les résultats négatifs en préclinique sont quasi absents de la littérature publiée, ce qui constitue une donnée structurelle de la modélisation plutôt qu'un simple risque. Cela affecte en particulier la valeur prédictive négative du modèle sur le volet efficacité. Mitigation : quantification explicite du taux de couverture des échecs dans le corpus ; calibration du score de fiabilité sur des registres d'études intégrant les résultats négatifs (ClinicalTrials, Citeline) ; déclaration transparente de cette limitation dans les sorties du modèle.
- **Limites spécifiques aux biothérapies** : immunogénicité spécifique à l'espèce, faible transposabilité des modèles substitutifs. Mitigation : traitement séparé des biothérapies avec des modèles dédiés intégrant les facteurs de correction inter-espèces connus ; signalisation explicite de l'incertitude accrue pour cette classe thérapeutique.
- **Biais structurel de sélection sur le volet efficacité** : les données précliniques d'efficacité disponibles publiquement sont quasi exclusivement issues de molécules ayant démontré un signal positif dans au moins un modèle animal — condition implicite pour accéder à la phase I. Le scénario « préclinique négatif / efficacité clinique positive » est donc structurellement absent du corpus d'entraînement, ce qui affecte la valeur prédictive négative du modèle sur ce volet. Mitigation : déclaration explicite de cette limitation dans les sorties du modèle de bénéfice ; calibration du

score de fiabilité sur des cohortes intégrant des molécules ayant échoué en phase I/II pour efficacité insuffisante (bases Citeline, ClinicalTrials) ; interprétation des prédictions d'efficacité comme un signal de probabilité relative plutôt qu'une valeur absolue.

Contribution à la répétabilité multi-pathologies & à l'industrialisation

Le score de fiabilité par modèle préclinique et par pathologie est, par conception, extensible à d'autres aires thérapeutiques : il suffit de calculer le score de fiabilité {modèle animal × pathologie} sur les données disponibles pour chaque nouvelle indication, défini comme le taux de concordance observé rétrospectivement entre résultats précliniques et issues cliniques humaines pour chaque combinaison, pondéré par le volume et la qualité des données disponibles. L'architecture NLP d'extraction est entraînée sur des structures textuelles génériques (protocoles d'études, résultats d'efficacité et de toxicité) et son adaptation à une nouvelle aire thérapeutique ne requiert qu'un réglage fin des entités nommées spécifiques (~10 % des paramètres de classification) pour intégrer le vocabulaire médical propre à la pathologie. Ce design assure la portabilité de la couche WP2 vers les futures extensions de BR-PREDICT au-delà de l'oncologie pulmonaire.

WP3 : Modèles prédictifs pharmaco-génomiques pour l'estimation du rapport bénéfice-risque par intégration des biomarqueurs, cibles thérapeutiques et variants génétiques.

L'objectif de ce lot est de construire la couche prédictive la plus granulaire de BR-PREDICT, exploitant les relations entre une drogue, ses cibles moléculaires, les biomarqueurs génomiques associés à une pathologie, et les polymorphismes génétiques influençant la réponse thérapeutique et la survenue d'effets indésirables. Le WP3 constitue un axe d'innovation avancé du projet : si les approches de pharmacogénomique ont démontré des précisions élevées sur des périmètres restreints (UGenome, 2025 : jusqu'à 99 % de précision sur certains panels), elles n'ont jamais été déployées à l'échelle d'une plateforme systématique de prédiction B-R intégrant simultanément structure moléculaire, profil génomique et contexte pathologique. Ce lot s'applique à toutes les modalités thérapeutiques (petites molécules, biologiques, thérapies ciblées) et pose les fondations de la médecine personnalisée prédictive dans BR-PREDICT.

Cadre scientifique & périmètre

Trois cadres guident ce lot. Premièrement, le profil génomique du patient (polymorphismes des gènes codant pour les cibles thérapeutiques, les enzymes métaboliques, et les transporteurs) module significativement le rapport B-R individuel d'un traitement donné.

Deuxièmement, les relations entre biomarqueurs génomiques prédictifs et issues cliniques, aujourd'hui dispersées dans la littérature et les bases de données spécialisées, peuvent être extraites, structurées et modélisées par apprentissage automatique pour produire des prédictions exploitables. Troisièmement, l'intégration du mécanisme d'action (MoA) de la molécule avec les variants génétiques des enzymes métaboliques et des transporteurs permet de prédire non seulement l'efficacité mais aussi le profil de risque spécifique au patient, notamment les effets indésirables liés aux polymorphismes pharmacogénomiques. L'état de l'art soutient ces cadres: Park et al. (2023) ont démontré la capacité de modèles ML/DL à prédire l'IC50 à partir de profils moléculaires ; Miranda et al. (2021) ont montré que l'intégration de polymorphismes et de variables cliniques contextuelles (âge, comorbidités, co-médications) améliore la prédiction de la réponse thérapeutique et des effets indésirables. Dans BR-PREDICT, ces variables cliniques sont traitées dans le WP4 (données de vie réelle) et intégrées au niveau du WP6, préservant la cohérence du périmètre sémantique de chaque lot. Le périmètre du WP3 est volontairement transversal : il couvre toutes les classes thérapeutiques et toutes les pathologies, avec une validation prioritaire en oncologie pulmonaire.

Méthodologie technique détaillée

Le WP3 traite deux types de données complémentaires : (i) des données **omiques** (variants génétiques constitutionnels, mutations somatiques tumorales, variants des cibles thérapeutiques) issues de bases de données spécialisées et de la littérature biomédicale ; (ii) des données **sémantiques** extraites par NLP à partir de publications et de rapports cliniques, structurées sous forme de triplets {variant ; effet fonctionnel ; issue clinique}.

- **T3.1 - Qualification des sources.** Deux axes de sources sont qualifiés, correspondant aux deux composantes du rapport B-R : (i) les bases de données biomarqueurs génomiques–pathologie (PharmGKB, ClinVar, COSMIC, OncoKB, cBioPortal), qui alimentent le volet efficacité en reliant profils génomiques et réponse thérapeutique ; (ii) les bases de données de variants génétiques des enzymes de métabolisation et des cibles thérapeutiques (UniProt variants, gnomAD, dbSNP, ClinGen, CPIC), exploités prioritairement pour les variants à perte de fonction dont l'impact sur la pharmacocinétique et la toxicité est documenté de façon cliniquement actionnable, et qui alimentent le volet risque en caractérisant les polymorphismes modulant la toxicité.
- **T3.2 - Extraction NLP des polymorphismes génétiques et structuration fonctionnelle.** Les *Contextualizing SLMs* sont entraînés pour extraire de la littérature biomédicale les variants génétiques organisés en trois catégories distinctes : (i) polymorphismes constitutionnels (variants germinaux modulant la pharmacocinétique et la toxicité, notation HGVS) ; (ii) variants et mutations somatiques tumoraux (mutations driver, amplifications, fusions géniques, spécifiques à l'oncologie) ; (iii) variants génétiques des cibles thérapeutiques (modifications d'affinité, résistance acquise). Pour chaque catégorie, le niveau de preuve est explicitement tracé et conditionne l'intégration dans le modèle. On y retrouve l'effet fonctionnel rapporté (perte/gain de fonction, modification d'affinité, altération métabolique), l'association à

une réponse thérapeutique ou à un effet indésirable, et le niveau de preuve (étude de cas, cohorte, essai contrôlé). Seuls les variants de niveau de preuve 1 et 2 (PharmGKB) sont intégrés dans les modèles prédictifs, garantissant la robustesse clinique des associations exploitées. Comme pour les WP précédents, nous estimons les variables utiles pour la modélisation à plusieurs milliers. A titre d'exemple, les variants géniques ayant un impact sur l'efficacité ou la toxicité d'une drogue peuvent être estimés à 100-300 pour une preuve de niveau 1 (cliniquement actionnables) et à 10000 pour les variants avec preuve de niveau 2 (PharmGKB). Nous excluons de notre projet les preuves de niveau 3 (variants identifiés par des études GWAS sur la base d'associations significatives) en raison d'une trop grande incertitude sur l'implication de ces variants.

- T3.3 - Base de données intégrée multi-dimensionnelle.** La base de données du WP3 structure deux graphes relationnels complémentaires : (i) Drogue $\Rightarrow$ Biomarqueurs génomiques $\Rightarrow$ Pathologie, reliant chaque drogue à ses biomarqueurs prédictifs de réponse (mutations driver, amplifications, fusions géniques) et aux pathologies concernées, avec le niveau de preuve clinique associé à chaque relation, reliant chaque drogue à ses biomarqueurs de réponse et aux pathologies concernées ; (ii) Drogue $\Rightarrow$ Cible $\Rightarrow$ Variants $\Rightarrow$ Impacts fonctionnels, reliant chaque drogue à ses cibles thérapeutiques, aux variants connus de ces cibles, et aux conséquences toxicologiques et fonctionnelles documentées, notamment les variants modulant la pharmacocinétique (métabolisation, élimination) et ceux associés à des effets indésirables graves (cardiotoxicité, hépatotoxicité, neurotoxicité). Ces deux graphes sont intégrés dans la Profiling Base existante et indexés pour le requêtage par les modèles ML.
- T3.4 - Modèle ML de prédiction du bénéfice.** Le modèle de bénéfice prend en entrée le profil génomique du patient (variants germinaux, mutations somatiques driver, statut d'amplification et fusions géniques) ainsi que les caractéristiques de la cible thérapeutique, et produit en sortie une prédiction de bénéfice (probabilité de réponse, durée de réponse estimée). L'architecture repose sur un réseau à attention sur graphe (GAT ou Relational Graph Transformer) opérant directement sur le sous-graphe {molécule-cibles-biomarqueurs-pathologie}. Les nœuds, initialisés par des embeddings pré-entraînés (RotatE/ComplEx), sont affinés par des couches d'attention lors de l'entraînement supervisé. Ce processus génère des représentations contextualisées où le poids de chaque biomarqueur est dynamiquement ajusté en fonction de la structure complète du sous-graphe. En oncologie (incluant l'oncologie pulmonaire), le modèle est entraîné sur les associations connues : par exemple, mutations EGFR et réponse aux TKI, réarrangements ALK/ROS1 et réponse au crizotinib/lorlatinib, expression PD-L1 et réponse aux anti-PD-1/PD-L1, charge mutationnelle tumorale et réponse à l'immunothérapie. Ce panel repose sur une centaine d'associations de niveau de preuve 1 (statut FDA reconnu, PharmGKB 1A/1B), volume suffisant pour entraîner et valider les architectures de graphes retenues, comme démontré dans la littérature sur des périmètres comparables (Park et al., 2023 ; UGenome, 2025). Ceci inclut une centaine de biomarqueurs avec impact clinique démontré (preuve de niveau 1, statut FDA reconnu).
- T3.5 - Modèle ML de prédiction du risque.** Le modèle de risque prend en entrée les polymorphismes pharmacogénomiques constitutionnels (enzymes de métabolisation, transporteurs) et le mécanisme d'action de la molécule, et produit en

sortie une prédiction de risque (probabilité et sévérité des effets indésirables). Le génotype de la cible thérapeutique contribue au volet efficacité (T3.4) ; le volet risque s'appuie prioritairement sur les variants modulant la pharmacocinétique et l'exposition systémique. Ce modèle exploite les relations connues entre polymorphismes pharmacogénomiques et toxicité, par exemple variants CYP2D6 et toxicité des métaboliseurs lents, variants DPYD et toxicité au 5-fluorouracile, variants UGT1A1 et toxicité à l'irinotécan (10000 variants estimés, cf T3.2). L'objectif est de généraliser ces relations à l'ensemble des couples {cible x molécule} par apprentissage sur les données historiques.

- **T3.6 - Validation et intégration.** La validation suit un protocole en deux temps : (i) validation rétrospective sur des cohortes de patients avec profil génomique et issue clinique connus (données Cedars-Sinai, Mayo Clinic, ICM), dont la taille et la couverture en variables génomiques seront caractérisées dès T3.1 pour garantir la puissance statistique suffisante à chaque niveau de preuve ciblé ; (ii) confrontation croisée avec les prédictions WP1 et WP2 pour évaluer la complémentarité et le gain incrémental de la couche génomique. Les résultats sont intégrés dans le moteur BR-PREDICT via le WP5.

Tâches & articulation avec les autres WPs

Le WP3 partage l'infrastructure commune déployée en T2.1 (WP2). Ils inscrit dans la continuité du WP2 les corrélations efficacité-biomarqueurs observées *in vivo* et fournit au WP5 les scores prédictifs génomiques pour l'intégration multi-échelle. Le WP3 entretient un lien étroit avec le WP4 (données cliniques) qui fournit les cohortes de validation avec profils génomiques annotés. Les partenaires Institut du Cerveau (ICM), Cedars-Sinai et Mayo Clinic contribuent aux données de cohortes génomiques ; Sanofi valide les prédictions sur des candidats en développement. Le calendrier s'étend de Q2 2026 à Q3 2027.

Livrables & Jalons

- **L3.1 : L3.1** : Pipeline opérationnel combinant (i) des modèles NLP pour l'extraction et la structuration sémantique d'informations génétiques et pharmacogénomiques à partir de la littérature biomédicale et des bases spécialisées, et (ii) des modèles statistiques dédiés au traitement des données omiques structurées (matrices d'expression, profils de variants, données CNV), reposant sur des approches de réduction dimensionnelle supervisée et de sélection de features à haute dimensionnalité (LASSO, elastic net, méthodes d'importance par permutation) adaptées aux spécificités des données génomiques (M9).
- **L3.2** : Base de données intégrée cibles <-> biomarqueurs <-> pathologie <-> variants génétiques (M12).
- **L3.3a** : Modèle ML prédictif de bénéfice basé sur les biomarqueurs génomiques et les associations cibles-pathologie, validé (M18).
- **L3.3b** : Modèle ML prédictif de risque basé sur les polymorphismes pharmacogénomiques, validé (M18).
- **L3.4** : Démonstration quantifiée de la capacité de prédiction B-R pour une drogue donnée via son profil génomique et les caractéristiques de sa cible, avec objectifs de performance explicites : AUC > 0,80 pour les associations de niveau de preuve

1A/1B, AUC > 0,75 pour les associations émergentes (niveau 2), mesurés sur les cohortes partenaires (M18).

- **Jalon EC2** (mi-2027) : objectifs de précision atteints pour un modèle généralisable par cible et par pathologie.

KPI & protocole d'évaluation

La précision de prédiction est mesurée sur les molécules commercialisées disposant de données pharmacogénomiques validées. La taille des cohortes sera caractérisée dès T3.1 ; une estimation conservatrice à partir de PharmGKB et CPIC suggère un panel de 150 à 300 molécules avec associations de niveau de preuve 1, volume suffisant pour une évaluation statistiquement robuste. Les objectifs cibles de précision sont définis par périmètre : pour les associations pharmacogénomiques bien établies (niveau de preuve 1A/1B PharmGKB), l'objectif cible est une AUC > 0,80, cohérent avec les performances rapportées sur des périmètres comparables (UGenome, 2025) ; pour les associations émergentes (niveau de preuve 2), l'objectif cible est une AUC > 0,65, reflétant l'incertitude inhérente à ces associations tout en démontrant leur exploitabilité prédictive.

Le protocole inclut une validation croisée sur les données d'entraînement et une évaluation externe sur les cohortes partenaires. La valeur ajoutée du WP3 est mesurée par le gain de précision par rapport aux prédictions combinées WP1+WP2 seules.

Risques, verrous, et plans de mitigation

- **Hétérogénéité et incomplétude des données génomiques** : les cohortes disponibles présentent des biais de représentation ethnique et des taux de couverture variables selon les gènes. Mitigation : stratification des modèles par population, signalisation explicite des sous-groupes insuffisamment représentés, enrichissement progressif via les cohortes partenaires internationales (Cedars-Sinai, Mayo Clinic).
- **Variants de signification incertaine (VUS)** : conformément aux recommandations de Vassili Soumelis et à la stratégie de maîtrise du bruit, les VUS et les variants identifiés par études GWAS (niveau de preuve 3) sont explicitement exclus du périmètre de modélisation. Seuls les variants de niveaux de preuve 1 et 2 (PharmGKB) sont intégrés, garantissant que chaque association exploitée repose sur une évidence clinique ou fonctionnelle solide.
- **Passage à l'échelle non testé** : la pharmacogénomique prédictive n'a jamais été déployée à l'échelle systématique d'une plateforme B-R couvrant simultanément toutes les cibles et toutes les pathologies. Mitigation : approche incrémentale, validation d'abord sur les associations bien établies, puis extension progressive du périmètre avec des critères de qualité explicites à chaque palier.

Contribution à la répétabilité multi-pathologies & à l'industrialisation

Le WP3 est, parmi les lots de données, celui dont la portabilité multi-pathologies est la plus intrinsèque : les relations entre polymorphismes génétiques et réponse thérapeutique (pharmacogénomique) sont, par nature, indépendantes de la pathologie d'ancrage. Seules les mutations et autres anomalies génétiques en oncologie sont souvent associées à certaines

tumeurs avec une spécificité variable. Les architectures de graphes relationnels {Droque ⇒ Cible ⇒ Variants ⇒ Impacts fonctionnels et toxicologiques documentés} sont identiques quelle que soit l'aire thérapeutique. La calibration pathologie-spécifique porte uniquement sur la sélection des biomarqueurs prédictifs pertinents (mutations driver, variants pharmacogénomiques actionnables, marqueurs de résistance) et des cohortes de validation associées, soit un effort estimé à moins de 10 % du travail total de déploiement. Ce lot constitue ainsi le socle de la stratégie de médecine personnalisée prédictive de BR-PREDICT, directement extensible à la neurologie (via l'ICM), à la cardiologie, et à l'immunologie dans les phases ultérieures de commercialisation.

Partenaires : Cedars Sinai, Mayo Clinic, Institut du Cerveau (ICM), Gradient Health

Période : Q2 2026 - Q4 2027 | **Jalon principal** : EC2 (mi-2027)

WP4 : Extraction, structuration et modélisation prédictive des données de vie réelle (RWE) pour la validation et le renforcement des relations structure-cible-bénéfice-risque.

L'objectif est double. Premièrement, construire un pipeline reproductible d'extraction et de normalisation des données de pharmacovigilance et des données de réponse thérapeutique en conditions réelles, incluant les trajectoires de traitement, les mesures d'efficacité (survie, réponse RECIST) et les événements indésirables, documentés dans les systèmes de soins réelles issues de FAERS (FDA Adverse Event Reporting System), d'entrepôts de données de santé hospitaliers (EDS), dont au minimum un exemple opérationnel avec données d'oncologie pulmonaire annotées a été vérifié en amont avec chaque partenaire (Cedars-Sinai, Mayo Clinic, ICM) pour confirmer la disponibilité et la richesse des variables d'intérêt (indication, posologie, réponse tumorale, événements indésirables codés MedDRA). Deuxièmement, développer des modèles prédictifs qui exploitent ces données pour valider, compléter et, le cas échéant, corriger les profils bénéfice-risque (B-R) générés par les WP1-3 à partir de données moléculaires, précliniques et génomiques. La valeur ajoutée de WP4 réside dans l'intégration de facteurs parfois absents des essais cliniques contrôlés (comorbidités, polymédication) mais surtout d'étudier des cohortes de patients ayant une variabilité socio-démographique et ethnique importante et des conditions d'utilisation en pratique beaucoup plus variables et hétérogènes que dans les essais contrôlés.

Cadre scientifique & périmètre

H1 : Les signaux de sécurité et d'efficacité détectables dans les bases RWE permettent de discriminer, le profil B-R d'une drogue en conditions réelles.

H2 : L'hétérogénéité des populations non sélectionnées (comorbidités, âge, polymédication) constitue une source d'information exploitable - et non uniquement un bruit - lorsqu'elle est correctement modélisée.

H3 : Un modèle généraliste intégrant données RWE et données moléculaires/précliniques (WP1-3) est transférable entre pathologies moyennant une calibration limitée (~10 % des paramètres).

Le périmètre initial cible la pathologie d'ancrage (cancer du poumon) puis sera étendu à au moins deux aires thérapeutiques supplémentaires avant EC3

Méthodologie technique détaillée

- **Qualification des sources (T4.1).** Chaque source RWE est évaluée selon une grille multicritère (couverture, granularité, complétude MedDRA/CIM-10/ATC, biais) et intégrée via un protocole d'harmonisation rigoureux. Ce processus assure l'alignement des historiques CIM-9 vers la CIM-10, le mapping des codes médicaments locaux vers la nomenclature ATC, ainsi que la standardisation des unités de dosage. Une caractérisation fine de la population est également réalisée pour permettre les ajustements statistiques et corriger les biais de sélection identifiés. Un score de qualité composite est attribué ; seules les sources dépassant le seuil prédéfini alimentent les modèles. Pour cette tâche, une estimation du nombre de données disponibles n'est pas faisable à ce stade. Il dépendra de l'accès aux données propriétaires de centres cliniques ou de systèmes de santé ainsi que de la qualité et richesse d'annotation des bases. Il s'agit donc d'un WP plus risqué mais dont la faisabilité ne remet pas en cause l'ensemble du projet (pas de dépendance stricte, les WP1-3 et 5 sont suffisants à délivrer un modèle original et ambitieux)
- **Accès aux données et cadre réglementaire :** l'accès aux sources RWE est conditionné par des accords de partage de données formalisés avec chaque partenaire institutionnel (Cedars-Sinai, Mayo Clinic, ICM), d'ores et déjà accordés par Cedars-Sinai et l'ICM. Pour FAERS, les données sont publiques et immédiatement accessibles. Pour les EDS hospitaliers, les protocoles de pseudonymisation et de gouvernance des données sont définis en conformité avec le RGPD et le HIPAA, et constituent un livrable explicite de T4.1. Ce cadre rigoureux d'accès aux données est un gage de reproductibilité et de conformité réglementaire de l'ensemble du WP4.
- **Extraction et structuration (T4.2).** Les Contextualizing SLMs d'ArcaScience - modèles de langage de petite taille entraînés par des cliniciens - extraient les entités pertinentes des narratifs FAERS (champs libre-texte du formulaire MedWatch) et des comptes rendus d'hospitalisation des EDS partenaires (Cedars Sinai, Mayo Clinic, ICM). L'extraction est suivie d'une normalisation terminologique vers MedDRA 27.x, Ontologie ArcaScience optimisée et ChEBI, puis d'un alignement temporel (date index = date de première prescription). Le pipeline intègre un module de dédoublement probabiliste (record linkage) pour les cas FAERS multiples et un module de pseudonymisation conforme RGPD/HIPAA.

- **Modèles prédictifs - Bénéfices (T4.3) et Risques (T4.4).** Pour chaque molécule, les variables RWE structurées sont fusionnées avec les descripteurs moléculaires et précliniques issus de WP1-3. L'architecture retenue est un modèle gradient-boosted (XGBoost/LightGBM) pour la prédiction tabulaire, complété par une architecture inspirée des réseaux à attention temporelle (type Temporal Fusion Transformer), spécifiquement adaptée au caractère asynchrone des trajectoires patients. Cette approche permet de pondérer les événements cliniques passés via des mécanismes d'attention, tout en intégrant des embeddings d'intervalles de temps pour traiter l'irrégularité des suivis longitudinaux. Les finalités à prédire sont : (i) survenue d'EIG codés MedDRA PT dans les 6/12/24 mois ; (ii) réponse thérapeutique (survie sans progression, réponse RECIST pour l'oncologie). Les modèles sont entraînés avec validation croisée stratifiée par source pour garantir la robustesse inter-bases.
- **Validation et calibration (T4.5).** La validation est conduite en deux temps : (i) validation spécifique cancer du poumon sur cohortes rétrospectives indépendantes (Mayo Clinic, ICM), avec évaluation sur le panel de molécules de référence défini transversalement aux WPs (osimertinib, alectinib, buparlisib, etc.) ; (ii) calibration externe multi-sources avec mesure du gain incrémental par rapport aux prédictions WP1-3 seules. Analyse de sous-groupes (âge, comorbidités, ethnie déclarée) pour identifier les populations où le gain RWE est maximal.

Tâches & articulation avec les autres WPs

Tâche		Entrée		Sortie		Lien WP	
T4.1	Qualification sources	Catalogues EDS, EHDS	FAERS,	Grille qualité, sources qualifiées	-		
T4.2	Extraction & structuration	Données brutes sources qualifiées		Tables normalisées patient-level	WP5 (terminologies)		
T4.3	Modèles prédictifs Bénéfices	Catalogues + Tables T4.2 + descripteurs WP1-3		Scores prédictifs efficacité	WP1, WP2, WP3		
T4.4	Modèles prédictifs Risques	Catalogues + Tables T4.2 + descripteurs WP1-3		Scores prédictifs EIG/ADR	WP1, WP2, WP3		
T4.5	Validation & calibration	Prédictions cohortes externes T4.3/T4.4,		Rapport performance, calibration	de WP6 (intégration)		

Gradient Health fournit un accès structuré à des jeux de données d'imagerie annotés corrélés aux données cliniques, utilisés comme variables complémentaires dans T4.3/T4.4. Cedars Sinai et Mayo Clinic sont à la fois fournisseurs de données (EDS) et sites de validation externe (T4.5).

Livrables & Jalons

- **L4.1** (EC1, fin 2026) : Pipeline d'extraction/structuration opérationnel ; grille de qualification appliquée à FAERS et à 2 EDS partenaires, avec résultats documentés sur la couverture, la complétude et les biais de chaque source, constituant le socle de sélection des données pour les modèles prédictifs T4.3/T4.4.
- **L4.2** (EC2, mi-2027) : Modèles prédictifs RWE B-R pour le cancer du poumon, rapport de calibration externe.
- **L4.3** (EC2+3 mois) : Modèle généralisable intégrant données RWE + moléculaires + précliniques (WP1-3 + WP4), applicable à 2+ pathologies.
- **L4.4** (EC3, fin 2028) : Documentation complète du pipeline, code reproductible, rapport de validation multi-pathologies.

KPI & protocole d'évaluation

- **KPI-1** : AUC-ROC du modèle WP4 (RWE intégré) supérieure à celle des modèles WP1-3 seuls sur la cohorte de test cancer du poumon (objectif cible : delta AUC $\geq 0,05$).
- **KPI-2** : Calibration slope entre 0,8 et 1,2 sur cohorte externe.
- **KPI-3** : Couverture ≥ 80 % des EIG connus (MedDRA PT) pour les molécules du jeu de validation.
- Protocole : validation croisée par exclusion de molécules (leave-drug-out) pour prévenir les fuites de données entre sources, complétée par une validation externe sur une cohorte temporellement disjointe (hold-out 2022-2025).

Risques, verrous, et plans de mitigation

Risque	Impact	Probabilité	Mitigation
Qualité/complétude des données RWD (sous-reporting FAERS, données manquantes EDS)	Élevé	Élevée	Grille de qualification stricte (T4.1) ; imputation multiple avec analyse de sensibilité ; pondération inverse de la probabilité de notification
Hétérogénéité entre sources RWD (codages, granularité, populations)	Moyen	Élevée	Normalisation terminologique centralisée (T4.2 + WP5) ; modèles avec variable indicatrice de source ; méta-analyse à effets aléatoires
Variabilité inter-pathologies difficile à modéliser	Élevé	Moyenne	Architecture modulaire : couche partagée (90 %) + couche spécifique calibrée par pathologie (~10 %) ; validation incrémentale pathologie par pathologie

Accès aux données EHDS Moyen Moyenne
non finalisé dans le calendrier

Sources FAERS + EDS
partenaires suffisantes pour la
validation cancer du poumon ;
EHDS traité comme source
complémentaire, non bloquante

Contribution à la répétabilité multi-pathologies & à l'industrialisation

L'architecture de WP4 est conçue pour être 90 % générique. Le pipeline d'extraction (T4.2) repose sur les Contextualizing SLMs d'ArcaScience dont les capacités NER/RE sont indépendantes de la pathologie, et sur des terminologies standardisées (MedDRA, Ontologie ArcaScience optimisée). Les modèles prédictifs (T4.3/T4.4) séparent une couche de représentation partagée (descripteurs moléculaires, profil patient, signaux RWE) d'une couche de calibration pathologie-spécifique paramétrable en *fine-tuning* sur un volume limité de données annotées. Ce découplage architectural est le fondement de la stratégie d'industrialisation de BR-PREDICT : chaque nouvelle aire thérapeutique bénéficie immédiatement de la couche générique (pipeline d'extraction, modèles tabulaires, module temporel) et ne nécessite qu'une calibration ciblée sur les endpoints et populations spécifiques ; effort estimé à ~10 % du travail de déploiement initial. Cette architecture à deux vitesses (générique et spécifique) est précisément ce qui rend BR-PREDICT scalable comme plateforme industrielle de prédiction B-R.

Période : Q3 2027 - Q2 2028 | **Jalons** : EC2 (mi-2027, schéma ontologique), EC3 (fin 2028, KG complet + API)

WP5 : Conception et déploiement d'un graphe de connaissances interopérable intégrant les données moléculaires, précliniques, génomiques et de vie réelle dans une couche sémantique unifiée au service du world model BR-PREDICT.

Les WP1 à WP4 produisent des prédictions à partir de types de données hétérogènes (structures moléculaires, profils précliniques, variants génomiques, signaux RWE) encodés dans des terminologies et des espaces de représentation distincts. Sans unification sémantique, ces prédictions ne peuvent être ni comparées, ni combinées, ni auditées de façon cohérente. WP5 résout ce verrou en construisant un Knowledge Graph (KG) dont les nœuds représentent les entités biologiques, chimiques, cliniques et les arêtes les relations quantifiées et sourcées entre elles. Ce KG sert de couche d'interopérabilité fondatrice pour le *world model* de WP6 et constitue la base de l'explicabilité de la plateforme BR-PREDICT.

Cadre scientifique & périmètre

H1 : Un schéma ontologique s'appuyant sur les standards internationaux (MedDRA, Ontologie ArcaScience optimisée, ChEBI, Disease Ontology, Gene Ontology) peut couvrir ≥ 90 % des entités générées par WP1-4 sans extension *ad hoc* majeure.

H2 : Les relations extraites par les Contextualizing SLMs à partir de la Profiling Base (100 milliards de points de données/relations) peuvent être projetées dans ce schéma avec un score de confiance traçable.

H3 : Un KG peuplé et indexé permet des requêtes multi-sources complexes avec un temps de réponse < 2 secondes, compatible avec l'usage interactif en WP6.

Le périmètre couvre l'ensemble des entités et relations pertinentes pour le cancer du poumon (pathologie d'ancrage), extensible à d'autres aires thérapeutiques par ajout de sous-graphes calibrés.

Méthodologie technique détaillée

- **Conception ontologique (T5.1).** Le schéma est construit par composition modulaire : un noyau partagé (*upper ontology*) définit les classes de premier niveau (*Molecule*, *Target*, *Pathway*, *Phenotype*, *AdverseEvent*, *Patient*, *ClinicalOutcome*) et les types de relations (*binds_to*, *inhibits*, *causes*, *associated_with*, *treats*, *metabolized_by*). Ce noyau est aligné sur les ontologies de référence : MedDRA 27.x pour les événements indésirables, Ontologie ArcaScience optimisée pour les concepts cliniques, ChEBI pour les entités chimiques, Gene Ontology et Reactome pour les voies biologiques, Disease Ontology pour les pathologies. Les extensions pathologie-spécifiques (ex. staging TNM, mutations driver EGFR/ALK/ROS1 pour le cancer du poumon) sont modélisées en sous-ontologies enfichables, validées par les experts du comité scientifique (Pr. Alexis Brice, Dr. Philippe Peyre).
- **Harmonisation et mapping d'entités (T5.2).** Chaque sortie de WP1-4 est projetée sur le schéma ontologique via un pipeline de résolution d'entités (*entity linking*) combinant : (i) correspondance exacte sur identifiants normalisés (CAS, DrugBank ID, UniProt ID, MedDRA PT code) ; (ii) correspondance approximative par un pipeline en deux étapes : recherche par plus proches voisins approchés (ANN) avec seuil de similarité cosinus $> 0,70$ pour maximiser le rappel, suivie d'un réordonnement par *cross-encoder* pour optimiser la précision ; approche cohérente avec l'état de l'art en *entity linking* biomédical (SapBERT, Liu et al., NAACL 2021); (iii) arbitrage humain pour les entités ambiguës (< 5 % attendu). Les tables de correspondance sont versionnées et auditables.
- **Construction du KG (T5.3).** Le graphe est implémenté sur une base de données graphe (Neo4j ou équivalent) avec un stockage RDF parallèle pour l'interopérabilité SPARQL. Les nœuds portent des attributs typés (identifiants, scores de confiance, provenance WP, *timestamps*). Les arêtes sont pondérées par un score de confiance composite intégrant : la fréquence d'observation dans la Profiling Base, le niveau de preuve (essai clinique $>$ cohorte RWE $>$ cas rapporté $>$ prédiction *in silico*), et la

concordance inter-WP. L'objectif cible est un KG de > 100 000 entités et > 1 million de relations au stade EC3, dont > 95 % des arêtes annotées avec un score de confiance, une provenance traçable (WP d'origine, source de données) et un niveau de preuve (essai clinique randomisé, cohorte, cas rapporté, *in silico*). Cette exigence de qualité différencie fondamentalement le KG BR-PREDICT des graphes publics de référence (DRKG : 5,9M arêtes non pondérées ; PrimeKG : 4M relations sans statut causal) et répond directement aux exigences d'auditabilité réglementaire (ICH E2C(R2), CIOMS XII).

- **Extraction NLP et validation des relations (T5.4).** Les 24 Contextualizing SLMs d'ArcaScience extraient en continu des relations à partir de la littérature, des rapports réglementaires et des données brutes alimentant la Profiling Base. Chaque relation extraite est scorée (précision estimée, rappel par échantillonnage) et soumise à un processus de validation croisée : concordance entre SLMs indépendants, cohérence avec les relations existantes du KG (détection de contradictions), validation par échantillonnage expert (*gold standard* sur 5 % des nouvelles relations par trimestre).
- **Interface de requête et API (T5.5).** Une API RESTful et GraphQL expose le KG avec un langage de requête multi-niveaux : requêtes simples (entité -> voisins directs), requêtes de chemin (*plus court chemin* entre deux entités, chemins causaux), requêtes agrégées (profil B-R complet d'une molécule = sous-graphe de toutes les relations bénéfice et risque avec scores). Un système de cache hiérarchique (*in-memory* pour les requêtes fréquentes, disque pour les requêtes complexes) garantit le respect du KPI de latence < 2 s. L'API est conçue pour être consommée par le *world model* de WP6 et par l'interface de visualisation (*Mental Map*, T6.5).

Tâches & articulation avec les autres WPs

Tâche	Entrée principale	Sortie	Lien WP
T5.1 Ontology design	Standards (MedDRA, Ontologie ArcaScience optimisée, ChEBI, GO, DO)	Schéma ontologique validé	WP1-4 (couverture des entités)
T5.2 Harmonisation & mapping	Sorties WP1-4, Profiling Base	Tables de correspondance versionnées	de WP1, WP2, WP3, WP4
T5.3 Construction KG	Entités mappées, relations scorées	KG peuplé (Neo4j + RDF)	WP1-4 (données), WP6 (consommation)
T5.4 Extraction NLP & validation	Profiling Base, littérature, rapports	Relations validées avec scores de confiance	Contextualizing SLMs (transversal)

T5.5	API & KG peuplé	API RESTful/GraphQL, WP6 (intégration), documentation	T6.5 (Mental Map)
	interface de requête		

WP5 est structurellement le pivot entre les WP de production de connaissances (WP1-4) et le WP d'intégration/simulation (WP6). Toute relation alimentant le *world model* de WP6 transite par le KG et porte une provenance traçable.

Chaque arête est annotée selon trois catégories explicites : (i) causale validée (issue d'études interventionnelles), (ii) directionnelle inférée (soutenue par un mécanisme biologique connu), (iii) associative (co-occurrence, sans direction causale établie). Le SCM du WP6 n'opère que sur les arêtes de types (i) et (ii), garantissant que le raisonnement causal repose exclusivement sur des relations à évidence mécanistique ou interventionnelle. Ce typage constitue une innovation structurelle majeure par rapport aux KGs publics existants.

Livrables & Jalons

- **L5.1** (EC2, mi-2027) : Schéma ontologique finalisé, validé par le comité scientifique ; tables de correspondance WP1-3 livrées ; couverture ≥ 80 % des entités WP1-3.
- **L5.2** (EC2+6 mois) : KG peuplé avec intégration complète des données RWE (WP4) ; $> 100\,000$ entités, > 1 million de relations.
- **L5.3** (EC3, fin 2028) : API opérationnelle testée selon les exigences WP6, documentation technique et guide d'utilisation, rapport qualité données (couverture, scores de confiance, taux de contradictions résolues).

KPI & protocole d'évaluation

- **KPI-1** : ≥ 90 % des entités produites par WP1-4 intégrées dans le KG avec relations sémantiques validées.
- **KPI-2** : Temps de réponse < 2 secondes pour les requêtes multi-sources complexes (95e percentile), mesuré sur un benchmark de 500 requêtes types co-définies avec les partenaires WP6, en distinguant les performances en cache chaud (requête répétée, cible < 500 ms) et cache froid (première exécution, cible < 2 s). Ce benchmark sera publié comme livrable de T5.5 pour garantir la reproductibilité des mesures de performance.
- **KPI-3** : Taux de contradictions non résolues < 5 % des relations du KG.
- Protocole : audit trimestriel par échantillonnage (200 relations tirées aléatoirement, vérification manuelle par expert domaine, calcul de précision/rappel).

Risques, verrous, et plans de mitigation

Risque	Impact	Probabilité	Mitigation
--------	--------	-------------	------------

Couverture ontologique insuffisante pour cibles émergentes ou maladies rares	Moyen	Moyenne	Architecture modulaire (sous-ontologies enfichables) ; processus d'extension trimestriel piloté par les lacunes identifiées en WP6
Exhaustivité du KG dépendante de la qualité des données WP1-4	Élevé	Moyenne	Scores de confiance par relation ; propagation explicite de l'incertitude vers WP6 ; seuils de qualité minimaux pour l'intégration
Maintien de la cohérence lors de l'ajout continu de nouvelles données	Moyen	Élevée	Pipeline de détection de contradictions (T5.4) ; versionnage du KG avec <i>snapshots</i> immuables par jalon ; processus de curation continue (1 ETP dédié)
Performance de requête dégradée avec la croissance du KG	Faible	Moyenne	Indexation incrémentale, partitionnement par domaine thérapeutique, cache hiérarchique ; tests de charge trimestriels

Contribution à la répétabilité multi-pathologies & à l'industrialisation

Le KG est structurellement conçu pour la généralisation. Le noyau ontologique est pathologie-agnostique : les classes *Molecule*, *Target*, *Pathway*, *Adverse Event* ne sont pas spécifiques au cancer du poumon. L'ajout d'une nouvelle pathologie se traduit par l'instanciation de sous-ontologies spécifiques (*staging*, biomarqueurs, *endpoints*) et le peuplement du sous-graphe correspondant à partir des données WP1-4 calibrées. L'API unifiée permet à WP6 d'interroger le KG de manière identique quelle que soit la pathologie, garantissant que le *world model* consomme une couche d'abstraction stable. Enfin, le caractère traçable de chaque relation (provenance, score de confiance, niveau de preuve) répond aux exigences d'auditabilité réglementaire (ICH E2C(R2), CIOMS XII) et prépare la plateforme à un usage en contexte de soumission réglementaire.

Partenaires validation : Sanofi, Cedars Sinai, Mayo Clinic, Institut du Cerveau (ICM), AMI Labs (en cours de cadrage) | **Partenaire données** : Gradient Health

Période : Q1 2027 - Q4 2028 | **Jalons** : EC2 (mi-2027, architecture intégrée), EC3 (fin 2028, *world model* opérationnel validé)

WP6 : Conception, intégration et validation d'un *world model* capable de simuler des profils bénéfice-risque complets pour toute molécule en développement, de la phase préclinique à la phase II, par fusion multimodale des modèles prédictifs WP1-4 et du graphe de connaissances WP5.

Le world model BR-PREDICT constitue la finalité scientifique et industrielle du projet. Il ne s'agit pas d'une agrégation de prédictions, mais d'un système intégré qui apprend à pondérer, réconcilier et enrichir les prédictions issues de sources de données hétérogènes (structure moléculaire, profils précliniques, variants génomiques, données de vie réelle) en exploitant les relations causales et directionnelles encodées dans le Knowledge Graph (WP5), soit les arêtes de types (i) causales validées et (ii) directionnelles inférées, dont la fraction et la distribution par domaine thérapeutique seront caractérisées et rapportées dans le livrable L5.1.1. L'objectif est de fournir, pour une molécule entrant en phase I ou II, un profil B-R simulé comprenant : prédiction d'efficacité, profil de sécurité avec hiérarchisation des risques, comparaison aux thérapies existantes, estimation de l'incertitude, et visualisation interactive sous forme de Mental Map.

Cadre scientifique & périmètre

H1 : L'intégration pondérée de modèles prédictifs entraînés sur des données de nature différente (WP1-4) produit des estimations B-R plus robustes que tout modèle individuel, à condition de modéliser explicitement les contradictions inter-sources et de propager l'incertitude.

H2 : Les relations causales et directionnelles entre propriétés moléculaires, mécanismes biologiques et caractéristiques patient, telles que définies et typées dans le KG (WP5, T5.3) à partir d'études interventionnelles et de mécanismes biologiques documentés, lorsqu'elles sont exploitées par un module de raisonnement causal structuré (SCM), permettent de simuler des scénarios contrefactuels (ex. "quel serait le profil de sécurité de cette molécule chez un patient porteur d'un variant CYP2D6 poor metabolizer ?").

H3 : La Profiling Base existante (100 milliards de points de données/rerelations) et la pile d'extraction des 24 Contextualizing SLMs constituent un actif suffisant pour pré-entraîner les représentations latentes du world model et réduire significativement le besoin de données annotées spécifiques au projet.

Périmètre : cancer du poumon (validation spécifique complète), puis extension à 2+ aires thérapeutiques pour la validation générique.

Méthodologie technique détaillée

Architecture du world model (T6.1). Le world model repose sur une représentation en espace latent multimodal où chaque WP constitue une vue partielle et complémentaire du profil B-R d'une drogue. Ces vues sont de nature fondamentalement différente (structure moléculaire, transposabilité préclinique, variants génomiques, signaux RWE) et ne sont pas supposées partager un espace latent commun a priori. L'architecture est donc conçue pour traiter l'absence de modalités comme le cas par défaut : chaque module fonctionne de façon dégradée mais robuste lorsque certaines sources de données sont indisponibles, ce qui est la situation la plus fréquente pour les molécules en développement précoce. Chaque drogue est encodée comme un vecteur latent z_{drug} (représentation de la drogue dans l'espace latent moléculaire) issu d'un encodeur pré-entraîné sur la Profiling Base. Le nombre de molécules disposant simultanément de données dans les quatre WPs est estimé à 200-800 (molécules approuvées avec données structurales, précliniques, pharmacogénomiques et post-AMM documentées), volume suffisant pour calibrer le module d'intégration de second niveau, mais insuffisant pour entraîner un espace latent partagé profond. L'architecture retenue traite donc explicitement les modalités manquantes via des embeddings de remplacement et des masques d'attention, garantissant des prédictions robustes y compris pour les molécules en développement précoce disposant uniquement de données structurales (fingerprints moléculaires, descripteurs ADMET, profils d'activité cible). Chaque patient est représenté par un vecteur z_{pat} intégrant données démographiques, comorbidités, co-médications et variants pharmacogénomiques. Le contexte pathologique est encodé via un vecteur z_{path} extrait du sous-graphe WP5 correspondant (topologie locale du KG autour de la pathologie d'intérêt). La fusion de ces représentations s'opère par un module d'attention multimodale (cross-modal attention) : chaque source de prédiction (WP1-4) est traitée comme un token d'évidence portant un embedding, un score de confiance et une provenance. Le mécanisme d'attention apprend à pondérer ces tokens en fonction du contexte (pathologie, type de molécule, données disponibles). Le module temporel ne sera développé que si les données longitudinales du WP4 fournissent un suivi ≥ 12 mois par molécule. À défaut, la dynamique temporelle sera traitée via des features agrégées (durée d'exposition, dose cumulée). Le WP6 revendique un pré-entraînement sur 100 milliards de relations. Le WP5 cible ~ 1 million de relations en fin de projet. Ces chiffres sont incohérents d'un facteur $\sim 100\ 000$. Le document doit clarifier ce qui est réellement utilisé pour le pré-entraînement. Les Contextualizing SLMs, entraînés par des cliniciens sur des corpus réglementaires et de pharmacovigilance, fournissent les embeddings textuels des événements indésirables, des mécanismes d'action et des endpoints cliniques, garantissant que l'espace latent du world model est ancré dans un vocabulaire clinique validé. Cette fondation en données propriétaires massives est ce qui rend crédible un world model opérationnel dans le calendrier du projet : le pré-entraînement est largement réalisé, le projet i-Demo finance la couche d'intégration et de raisonnement causal.

Intégration d'ensemble WP1-4 (T6.2). Les prédictions de WP1 (structure-activité), WP2 (préclinique), WP3 (génomique) et WP4 (RWE) ne sont pas moyennées. Le module d'intégration implémente une méta-apprenante (stacking) où les prédictions individuelles et leurs intervalles de confiance sont les features d'un modèle de second niveau. Ce modèle apprend les schémas de concordance et de contradiction entre WPs. Lorsque deux WPs divergent significativement (ex. WP1 prédit faible risque hépatotoxique, WP4 détecte un signal FAERS), un module de résolution de conflit est activé : il interroge le KG (WP5) pour

identifier si une variable confondante (ex. co-médication hépatotoxique fréquente en RWE) explique la divergence, et propage l'incertitude résiduelle vers la sortie finale. Cette approche est fondamentalement supérieure à un vote majoritaire ou à une moyenne pondérée fixe.

Modélisation causale et prédiction d'interactions (T6.3). Le world model intègre un graphe causal structurel (Structural Causal Model, SCM) dont la topologie est initialisée à partir des arêtes de types (i) causales validées et (ii) directionnelles inférées du KG (WP5, T5.3). Ce sous-graphe causal, explicitement délimité lors de la construction du KG, constitue le squelette du SCM ; ses paramètres sont ensuite estimés par les données WP1-4. Cette approche garantit que le raisonnement causal du world model repose sur des relations à évidence interventionnelle ou mécanistique, et non sur de simples co-occurrences. Les paramètres sont estimés par les données WP1-4. Ce SCM permet : (i) la simulation d'interactions médicamenteuses (drug-drug interactions, DDI) en combinant données moléculaires (inhibition enzymatique CYP, compétition au site de liaison) et signaux RWE (co-prescription observée + événements associés) ; (ii) la prédiction d'interactions gène-médicament (pharmacogénomique) en intégrant les variants identifiés en WP3 avec les voies métaboliques du KG ; (iii) la simulation dose-réponse et temps-vers-événement (time-to-event) via des modèles de survie paramétriques conditionnés par les variables latentes du world model. Le raisonnement contrefactuel est opéré par intervention sur les noeuds du SCM (ex. `do(CYP2D6 = poor metabolizer)`) et propagation des effets dans le graphe, permettant de répondre à des questions du type "quel profil de sécurité pour cette molécule si le patient était un métaboliseur lent ?".

Quantification de l'incertitude (T6.4). L'incertitude est modélisée à deux niveaux. Le coût computationnel de cette approche est maîtrisé par une stratégie d'inférence optimisée : les ensembles de modèles (10 répliques) sont évalués en parallèle sur GPU, et l'approximation variationnelle bayésienne est limitée aux couches critiques du modèle, réduisant le surcoût de calcul à moins de 30 % par rapport à une inférence déterministe standard. Au niveau épistémique (incertitude liée aux données insuffisantes) : ensembles de modèles (deep ensembles, 10 répliques avec initialisation différente) et approximation variationnelle bayésienne sur les couches critiques. Au niveau aléatoire (variabilité intrinsèque) : modélisation hétéroscédastique des résidus. La sortie du world model est donc un profil B-R probabiliste : pour chaque événement prédit, un intervalle de confiance et une décomposition des sources d'incertitude (données moléculaires limitées vs. signal RWE contradictoire vs. faible couverture KG). Cette décomposition est essentielle pour l'interprétabilité et pour guider le pharmacien/clinicien vers les zones nécessitant une investigation complémentaire.

Interface de visualisation - Mental Map (T6.5). La Mental Map est une interface frontend interactive, développée comme composant applicatif autonome consommant l'API WP5 (T5.5) et les profils B-R probabilistes produits par T6.2-6.4. Elle projette le profil B-R d'une molécule sous forme de réseau navigable, avec une architecture frontend découplée du moteur de prédiction pour garantir l'indépendance des cycles de développement et la maintenabilité à long terme. Elle sera représentée avec la molécule au centre connectée à ses cibles thérapeutiques, elles-mêmes liées aux voies métaboliques perturbées, débouchant sur les résultats cliniques (efficacité et effets indésirables). Chaque nœud et chaque arête portent leur score de confiance, leur provenance (WP d'origine, source de

données), et leur niveau de preuve. L'utilisateur peut filtrer par type de données, par seuil de confiance, par sous-population patient, ou simuler un scénario contrefactuel (ajout d'une co-médication, changement de variant génomique). La Mental Map est conçue pour être utilisable par un évaluateur réglementaire, un pharmacovigilant ou un clinicien investigateur sans formation spécifique en data science.

Validation et calibration (T6.6). La validation est conduite en deux phases. Phase rétrospective : le world model est évalué sur un jeu de ≥ 200 molécules commercialisées ou retirées du marché, dont les profils B-R réels sont connus. Ce seuil de 200 molécules est cohérent avec les standards de validation des plateformes de prédiction B-R publiées dans la littérature, et sera appliqué de façon homogène à chaque WP pour permettre une comparaison directe des performances entre niveaux de résolution prédictive. Les métriques sont : AUC-ROC pour la prédiction d'EIG sévères (objectif cible $> 0,8$ en validation externe), taux de faux négatifs $< 10\%$ pour les DDI connues, et évaluation qualitative par un panel d'experts (objectif cible : $> 70\%$ des prédictions jugées "cliniquement plausibles"). Phase prospective : monitoring en conditions réelles sur des molécules en développement chez les partenaires (Sanofi, institutions partenaires), avec comparaison longitudinale entre prédictions et observations de pharmacovigilance. AMI Labs (cadrage en cours) interviendra sur la validation des méthodologies d'évaluation.

Tâches & articulation avec les autres WPs

Tâche	Entrée	Sortie	Lien WP
T6.1 Architecture world model	Profiling Base, embeddings SLM	Encodeurs pré-entraînés, architecture fusion	Transversal (SLMs, Profiling Base)
T6.2 Intégration d'ensemble WP1-4	Prédictions + IC WP1-4	Prédictions intégrées, carte de concordance	WP1, WP2, WP3, WP4
T6.3 Modélisation causale & interactions	KG (WP5), données WP1-4	SCM paramétré, prédictions DDI/gène-drug	WP5 (topologie causale)
T6.4 Quantification incertitude	Ensemble de modèles T6.1-6.3	Profils B-R probabilistes, décomposition incertitude	--
T6.5 Mental Map	Profils B-R (T6.2-6.4), KG (WP5)	Interface interactive, visualisation réseau	WP5 (API)

T6.6 Validation & calibration	Jeu rétrospectif + prospectif	Rapport de validation, métriques	Sanofi, Cedars Sinai, Mayo, ICM, AMI Labs
-------------------------------	-------------------------------	----------------------------------	---

Livrables & Jalons

- **L6.1** (EC2, mi-2027) : Architecture du world model validée, encodeurs pré-entraînés opérationnels, prototype d'intégration d'ensemble sur cancer du poumon.
- **L6.2** (EC3-6 mois) : Module d'interactions (DDI, gène-drug), module d'incertitude, prototype Mental Map fonctionnel.
- **L6.3** (EC3, fin 2028) : World model opérationnel intégrant WP1-5, rapport de validation rétrospective (≥ 200 molécules), rapport de validation prospective (monitoring partenaires), tests d'acceptation utilisateur avec ≥ 5 partenaires pharmaceutiques.
- **L6.4** (EC3) : Documentation utilisateur, matériaux de formation, système déployable avec quantification d'incertitude.

Jalon pathologie spécifique (cancer du poumon) : démonstration du workflow complet -- entrée : molécule en Phase I/II ; sortie : profil B-R complet incluant efficacité prédite (ensemble WP1-4), profil de sécurité hiérarchisé, comparaison aux thérapies existantes (immunothérapies, TKI), estimation d'incertitude, visualisation Mental Map. Validation par panel d'experts cliniques.

Jalon générique : world model opérationnel sur 2+ domaines thérapeutiques ; AUC > 0,8 pour la prédiction d'EIG sévères en validation externe ; taux de faux négatifs < 10 % pour les DDI connues ; tests d'acceptation avec ≥ 5 partenaires industriels.

KPI & protocole d'évaluation

- **KPI-1** : Sensibilité/spécificité élevées pour la prédiction d'EIG sévères sur molécules de test (objectif cible : AUC > 0,8 en validation externe d'ensemble).
- **KPI-2** : Capacité à générer des profils B-R cohérents intégrant ≥ 3 sources de données indépendantes (moléculaire, préclinique/génomique, RWE).
- **KPI-3** : > 70 % des évaluateurs experts jugent le KPI « cliniquement plausible » nécessite un protocole d'évaluation : nombre d'évaluateurs, grille de notation standardisée, mesure de l'accord inter-évaluateurs (kappa de Fleiss), et évaluation en aveugle
- **KPI-4** : Taux de faux négatifs < 10 % pour les DDI connues (base de référence : DrugBank + FAERS validated signals).
- **Protocole** : validation rétrospective sur cohorte hold-out temporellement disjointe ; validation prospective par monitoring continu chez les partenaires ; évaluation qualitative par panel d'experts indépendants (≥ 10 évaluateurs, ≥ 3 institutions).

Risques, verrous, et plans de mitigation

Risque	Impact	Probabilité	Mitigation
Données insuffisantes pour les scaffolds moléculaires nouveaux ou les maladies rares (zone d'extrapolation)	Élevé	Moyenne	Détection automatique des zones hors-distribution (OOD detection) avec avertissement explicite dans le profil B-R ; limitation volontaire de la prédiction au périmètre de confiance ; enrichissement continu de la Profiling Base
Interactions émergentes absentes des données d'entraînement	Élevé	Faible-Moyenne	Le SCM causal permet une forme de généralisation par composition (combinaison de mécanismes connus), mais les interactions véritablement inédites restent une limitation déclarée ; monitoring prospectif (T6.6) comme filet de sécurité
Complexité d'intégration multi-WP (dépendances calendaires, formats)	Moyen	Élevée	Spécification précoce des interfaces (formats de sortie WP1-4, API WP5) dès EC1 ; intégration incrémentale (WP1-3 d'abord, WP4 ensuite, WP5 en parallèle) ; sprints d'intégration trimestriels
Acceptation utilisateur insuffisante (interface trop complexe, confiance limitée)	Moyen	Moyenne	Co-conception de la Mental Map avec les partenaires cliniques dès T6.5 ; tests utilisateurs itératifs (3 cycles) ; formation dédiée ; scoring d'incertitude comme levier de confiance (l'utilisateur voit où le modèle doute)
Risque réglementaire : qualification du world model comme dispositif médical ou outil d'aide à la décision soumis à MDR/IVDR	Moyen	Faible	Positionnement initial comme outil de recherche et d'aide à la décision non-clinique (usage pharma R&D, non diagnostic) ; veille réglementaire continue ; architecture compatible avec les exigences futures de traçabilité/reproductibilité

Contribution à la répétabilité multi-pathologies & à l'industrialisation

Le world model est conçu selon le principe 90/10 : 90 % de l'architecture est pathologie-agnostique (encodeurs moléculaires, module d'attention multimodale, SCM, module d'incertitude, Mental Map, pipeline de validation), et ~10 % nécessitent une calibration spécifique (sous-graphe KG pathologie, pondération des endpoints cliniques, seuils de décision). L'ajout d'une nouvelle pathologie se traduit par : (i) peuplement du

sous-graphe WP5 correspondant ; (ii) fine-tuning de la couche de calibration sur un jeu de données annoté limité (objectif : < 500 cas annotés suffisants grâce au transfert) ; (iii) validation rétrospective sur les molécules connues de cette pathologie. Ce processus est documenté et reproductible. La Profiling Base (100 milliards de relations) et les 24 Contextualizing SLMs fournissent la couche de pré-entraînement qui rend ce transfert réaliste : les représentations moléculaires et cliniques apprises sont fondamentalement transversales. L'industrialisation passe par la conteneurisation du pipeline complet, l'exposition via API sécurisée (authentification, rate limiting, audit trail), et la production de matériaux de formation permettant un déploiement autonome chez les partenaires pharmaceutiques. Le plan de recrutement du projet (47 postes, dont 27 R&D) soutient cette montée en capacité sur la durée du financement i-Demo.