

BR-PREDICT

La première plateforme d'évaluation
prédictive du bénéfice-risque



SOMMAIRE

- 1) **Présentation du porteur**
- 2) Contexte et innovation
- 3) Description du projet
- 4) Exploitation industrielle et commerciale des résultats du projet
- 5) Retombées économiques, sociales et environnementales
- 6) Besoins en financements et justification de l'aide demandée


ARCASCIENCE révolutionne l'évaluation du bénéfice-risque des actifs thérapeutiques grâce à l'IA

ARCASCIENCE ambitionne de devenir le premier allié des entreprises pharmaceutiques dans la valorisation de leur actifs

ARCASCIENCE délivre des évaluations bénéfiques / risques complètes en quelques minutes pour informer les décisions tout au long du développement et du cycle de vie des molécules.

Une prouesse rendue possible par l'alliance d'une **intelligence artificielle de pointe** et de l'utilisation des **bases de données cliniques et des ontologies les plus complètes au monde** ainsi que des données patients, avec plus de 100 milliards de datapoints analysés pour chaque décision.

ARCASCIENCE compte déjà 9 clients, dont **Sanofi, AstraZeneca, Biocodex, ICON et Mapi Research Trust**.



Une équipe expérimentée et pluridisciplinaire

Fondateurs




Romain CLEMENT
CEO & Co-Fondateur

Expert en données cliniques et en stratégie d'innovation



Patrick Pierre
Co-Fondateur et superviseur technique infrastructure


Ingénieur expérimenté en infrastructures numériques



Laurent Romary
Co-Fondateur, scientific advisor

Directeur de recherche INRIA, Co-inventeur LLM moderne

Equipe dirigeante



Vassili Soumelis
Chief Medical O.

Immuno-oncologue, hématologue, ancien CMO Owkin, expert AI



Julien Dufour
Chief Business O.

Spécialiste du développement commercial et des stratégies marché dans la santé




Jean-François Arbona
CTO

Expert en architecture cloud et en développement de produits digitaux

Equipe opérationnelle

Equipe active



+ 1 administratif
+ 1 prestataire de recrutement
+ 3 stagiaires

Recrutements prévus pendant le projet

	2026	2027	2028	2029	Total
R&D	6	4	13	4	27
Industriels	2	0	0	4	6
Commercial	2	1	7	4	14
Total	10	5	20	12	47

Un écosystème de partenaires étendu représentant un soutien de taille

Partenaires de recherche et académiques



ArcaScience collabore avec l'ICM et l'Inria sur des projets de recherche avancés, notamment pour identifier de nouveaux candidats thérapeutiques et contribuer à un projet européen IHI sur le cancer du cerveau pédiatrique.

Ecosystème et structure de soutien



Sa présence au sein de **Future4Care** lui donne accès à un écosystème riche réunissant startups, groupes pharmaceutiques, institutions et investisseurs, renforcé par l'accompagnement de Business France depuis 2025 et son intégration dans la communauté international Plug and Play et Cedars Sinai.

Partenaires commerciaux



ArcaScience travaille avec les principaux acteurs engagés dans la recherche et le développement de nouveaux médicaments. Ses solutions s'adressent aux grandes entreprises pharmaceutiques, aux sociétés de biotechnologie de toutes tailles ainsi qu'aux CRO qui conduisent une part majeure des essais cliniques pour le secteur.

À la fin juin 2025, ArcaScience compte 9 contrats signés avec 7 clients, parmi lesquels des leaders internationaux tels que Sanofi, AstraZeneca, Vidal et Biocodex. L'entreprise collabore également avec ICON, y compris sa filiale MAPI, l'une des plus grandes CRO mondiales, ainsi qu'avec des acteurs spécialisés comme Dilon Technologies.

Un conseil scientifique, technique et stratégique de premier plan



Laurent Romary, PhD : Directeur de recherche émérite INRIA, président de DARIAH (infrastructure de recherche numérique pour les arts et les sciences humaines) ;



Philippe Peyre, PhD : Senior VP et secrétaire général chez Sanofi



Kerry Coffee : Fondatrice de Schiller Discovery Healthtech Venture



Geneviève Laurans : Administratrice et CFO de Quotium Technologies



Professeur Clemens M. Schirmer, MD, PhD : Neurochirurgien et professeur à la Geisinger School of Medicine



Hal Lavender : AI, Data and Business Transformation Leader VP chez IBM



Béatrice du Sordet : Fondatrice d'Aplusa (étude de marché de santé)



Professeur Alexis Brice, MD, PU-PH : Président fondateur de l'Institut du Cerveau (ICM), membre de l'Académie des Sciences



Serge Bauin, PhD : Ancien directeur général délégué à la science au CNRS et expert Data Science ministériel



Jean Lopategui, MD, PhD : Directeur du département Pathology de Cedar-Sinai, Los Angeles, Immunohématologue



Fabien Lanteri : Directeur stratégie santé et innovation au sein d'EIT Health (programme d'apprentissage en santé) et expert au Génopole



Emmanuel Capitaine, MD : Coordinateur médical international chez Vivalto Santé (groupe de cliniques privées), ex-responsable innovation chez AstraZeneca



Jordan Lazaro-Gustave : Fondateur d'AAVE, protocole de finance décentralisée qui permet aux utilisateurs de prêter et d'emprunter des cryptomonnaies).



Stéphane Rouault, PhD : Clinical Innovation Lead chez Argenx (société belgo-néerlandaise spécialisée dans l'immunologie) et Roche

SOMMAIRE

- 1) Présentation du porteur
- 2) Contexte et innovation
- 3) Description du projet
- 4) Exploitation industrielle et commercial des résultats du projet
- 5) Retombées économiques, sociales et environnementales
- 6) Besoins en financements et justification de l'aide demandée

Développement clinique d'un médicament : des investissements massifs pour un taux de réussite trop faible

Les essais cliniques depuis le début du XXIème siècle :

- Un investissement moyen estimé entre **1 et 2 Milliards de dollars** pour chaque nouvelle molécule commercialisée.
- Implication de nombreuses expertises
- Inclusion de **milliers de patients malades** et de **sujets sains**

Malgré ces investissements considérables :


- Plus de **92% d'échecs** pour un développement jusqu'à l'AMM
- En moyenne **2 à 3 amendements par protocole** de phase 3
- Près de **85% de retards** pour des coûts supplémentaires évitables estimés à **535K\$** en moyenne par dossier
- **10 ans** d'essais cliniques en moyenne par molécule

Causes des échecs

40 à 54 % des échecs sont attribués à un manque d'efficacité

17 à 30 % sont dus à un problème de toxicité

Causes des amendements



- Nouvelle information de sécurité
- Demande de modification du protocole
- Changement de stratégie
- Mauvaise conception du protocole
- Difficulté de recrutement
- Autre

Les causes de ces échecs et des retards liés aux amendements pourraient être évitées si nous étions capables de les prédire avant la réalisation des essais cliniques.

Les causes de ces échecs et de ces retards sont évitables : protocole mal ciblé, population inadéquate, risques mal évalués, stratégie instable.

Les équipes de recherche tentent d'optimiser les essais via :

- de meilleurs designs (adaptatifs, bayésiens, enrichis),
- une meilleure sélection des patients,
- des processus opérationnels plus rigoureux,
- une surveillance renforcée de la sécurité.

Et pourtant les statistiques de succès des essais n'ont pas changé depuis le début du siècle.

Et si on pouvait anticiper les résultats ?

Une analyse prédictive structurée du bénéfice/risque apporterait cette capacité à anticiper et prévenir en combinant :

- évaluation de l'efficacité attendue,
- identification des risques mécanistiques de toxicité,
- meilleure compréhension du mécanisme d'action,
- ciblage des populations les plus à même de répondre,
- anticipation du positionnement dans le schéma de prise en charge.

Cela permettrait d'éliminer tôt les candidats les moins prometteurs, de concevoir des protocoles plus robustes et de réduire fortement amendements et abandons tardifs.

Une analyse bénéfices/risques prédictive réduirait ainsi les essais inutiles, les amendements, les alertes de sécurité et permettrait un meilleur ciblage des patients et une optimisation de design clinique plus fiable et moins coûteuse tout en réduisant le nombre de sujets sains et de patient à inclure.

Très fort besoin exprimé par les Pharma dans l'évaluation prédictive du Bénéfice/Risque de leurs actifs thérapeutiques

Pratique actuelle pour l'évaluation du bénéfice-risque d'un médicament

L'évaluation du bénéfice/risque est un processus clé qui vise à mesurer l'équilibre entre les effets positifs d'un médicament et les risques liés à son utilisation, afin de déterminer sa valeur thérapeutique réelle et son admissibilité à la mise sur le marché.

Elle constitue une étape décisive du processus réglementaire, conduite par des autorités telles que l'EMA et la FDA pour garantir la sécurité et l'efficacité des traitements proposés aux patients.

Etat actuel du processus

- L'analyse bénéfice-risque consiste à comparer les données relatives au traitement de référence avec celles des essais cliniques du candidat médicament, afin d'identifier les écarts d'efficacité, de tolérance et de profil patient ciblé, tout en garantissant la conformité aux cadres réglementaires en vigueur.
- Le processus d'évaluation structurée du rapport bénéfice-risque (sBR) reste aujourd'hui largement manuel, réalisé par les équipes internes des laboratoires pharmaceutiques ou délégué à des CRO spécialisées.
- Ces évaluations reposent principalement sur des analyses documentaires et des extractions manuelles de données cliniques et réglementaires.
- Les autorités (EMA, FDA) exigent des analyses sBR détaillées dans le cadre des demandes d'autorisation de mise sur le marché.

Aujourd'hui, l'analyse bénéfice-risque est une obligation réglementaire qui n'impacte pas les décisions stratégiques des entreprises pharmaceutiques dans le développement de leurs traitements car elles sont produites trop tard. Elles sont, par contre, l'un des piliers du dossier d'évaluation de l'essai pour le régulateur, tout au long de l'étude jusqu'à la demande finale d'autorisation de mise sur le marché, et ensuite pour la demande de remboursement.

Les limites actuelles des solutions d'analyse bénéfice/risque pour orienter le développement d'actifs thérapeutiques

Les analyses bénéfice/risque peuvent être déterminantes dans l'orientation et le développement d'un actif. Pourtant, même si les laboratoires pharmaceutiques en reconnaissent l'importance, les limites technologiques actuelles en restreignent encore l'optimisation et l'exploitation.

Limites des approches actuelles



Près d'un an de travail est nécessaire pour aboutir à une évaluation complète



Elles exigent une expertise clinique et réglementaire approfondie



Les analyses reposent sur des données non structurées



Elles exploitent les données disponibles de façon partielle et insuffisante



L'énorme quantité de données hétérogènes à traiter qui rend le travail encore plus complexe



Coût estimé de l'analyse : environ 1,2M €



Capacité prédictive réduite, voire inexistante



Le processus global n'est pas étudié pour orienter ni informer les choix de développement

Aujourd'hui, ce type d'évaluation reste insuffisamment spécifique et peu prédictive, intervenant à un stade de développement avancé, lorsque des dizaines de millions d'euros ont déjà été investis.

Des besoins forts dans l'optimisation et l'automatisation de l'évaluation du bénéfice-risque

Renforcer la précision des analyses

Pouvoir mieux orienter les décisions sur les actifs à développer et à positionner dans le schéma de prise en charge

Harmoniser l'exploitation des données hétérogènes massives

Pouvoir traiter, annoter et croiser différents jeux de données massifs et hétérogènes

Limiter l'impact social

Réduire le nombre de patients et de sujets sains à inclure dans des essais non optimisés à forte probabilité d'échec

Réduire la durée et les coûts

Processus BRA standardisés et flux optimisés pour réduire coûts et durée d'analyse.

Agir en amont

Être capables d'évaluer le bénéfice-risque en se basant sur les données précliniques en amont des phases cliniques coûteuses afin d'en réduire les coûts

ArcaScience : la première plateforme permettant de construire l'analyse bénéfice-risque automatiquement


La plateforme d'ArcaScience extrait et collecte un volume massif de données scientifiques, cliniques et centrées patient, puis utilise des modèles d'IA avancés propriétaires pour analyser automatiquement le profil bénéfice-risque d'un candidat médicament. Elle compare ces résultats au traitement de référence pour identifier ses avantages et ses risques et son positionnement optimal par rapport aux options thérapeutiques existantes.

Une architecture data conçue pour offrir la vision B/R la plus exhaustive :

La plateforme repose sur une architecture data unifiée qui combine ingestion multi-source, structuration automatisée et normalisation clinique. Cette infrastructure permet de construire une vue complète, cohérente et exploitable de l'analyse bénéfice-risque d'un actif en comparaison d'un traitement de référence en quelques minutes.

Un workflow entièrement automatisé

L'ensemble du processus : extraction, standardisation, classification, hiérarchisation des signaux, est automatisé grâce à une combinaison de SLMs (Small Language Models) et de modules d'orchestration.



Des jeux de données massifs, annotés et optimisés pour l'analyse B/R

ArcaScience centralise toutes les données clés du bénéfice-risque, effets indésirables, endpoints, mécanismes d'action, profils patients et résultats d'essais, à partir de sources de référence comme PubMed, NIH et MedLine. La plateforme les annote, les harmonise et les structure à grande échelle, créant un référentiel homogène, à jour et exploitable en continu.

Un **workflow** garantissant une mise à jour en continu et l'exploitation optimale de l'ensemble des ressources disponibles.



Bénéfices promis par la solution **ARCASCIENCE**



Construire le profil bénéfice-risque d'un médicament grâce à une approche automatisée et enrichie par 24 modèles d'IA

Maîtriser l'impact de ces médicaments pour chaque patient grâce à une surveillance accélérée.

Un gain de temps et de coûts massif

Réalise l'équivalent de 18 mois de travail en **très peu de temps pour une fraction du coût habituel** (125 k€ versus ≈ 1,2 M€ via CRO sur 18 mois).

Une évaluation continue et permanente plutôt que des évaluations ponctuelles.

Une puissance analytique renforcée par une IA (ou Ensemble AI) explicable

Utilisation de 24 *Small Language Models* pour la standardisation, l'harmonisation et le traitement des données, sans boîte-noire, pour une précision accrue dans l'identification des signaux dés. La solution justifie ses résultats selon le mécanisme d'action du candidat qu'elle analyse et source.

Analyses enrichies

Accès à des jeux de données beaucoup plus vastes: en moyenne 10 à 100 fois plus de datapoints intégrés.

Sources exclusivement fiables et exhaustives (PubMed, NIH, MedLine, bases réglementaires).

Un outil transversal en support de l'ensemble des parties prenantes

La plateforme ArcaScience, opérée de manière centralisée par les équipes Pharmacovigilance, apporte un soutien direct au développement clinique, à l'accès au marché, à la gestion du pipeline de candidats et aux affaires réglementaires

ARCASCIENCE rend cela possible grâce à sa nouvelle plateforme d'évaluation bénéfice-risque, qui s'appuie sur 7 années de R&D en IA pour générer des analyses rapides, fiables et conformes aux exigences réglementaires.

Historique des développements

2016

Naissance d'ArcaScience

Le projet naît d'une expérience patient vécue en 2014, lorsque le CEO d'ArcaScience est diagnostiqué d'une tumeur cérébrale. 2 ans plus tard, le comité scientifique était créé avec parmi les figures les plus pionnières en IA en France

2018

Création d'ArcaScience

2019

Premiers modèles d'IA de classification dédiés aux sujets de bénéfices et de risques

2021

Optimisation des modèles existants

Développement des modèles NLP pour la détection des modalités de traitement et des patients

Sortie de la plateforme "Therapeutic Horizon" pour l'optimisation de l'exploitation des données scientifiques

2023

Développement des modèles pour l'extraction des endpoints, le clustering, et les types de publications, avec d'autres modèles pour les types d'endpoints, les embeddings, la temporalité des risques, le grading et la sévérité des risques.

Création de nouveaux algorithmes de génération automatique de rapports

2024

Optimisation des modèles de bénéfices et de risques par couplage avec des modèles d'extraction de relations

Modèles d'extraction de relations pour l'identification des liens entre biomarqueurs et maladies spécifiques

Lancement de AS Dermato, première plateforme à réponse instantanée pour les études dans le domaine de la dermatologie

2025

Projet BRA réalisé avec Sanofi, consolidation de la technologie

Projet BRA réalisé avec Icon, Dilon et Biocodex

Ajout de nouveaux modèles et de modèles statistiques

Sortie de la première plateforme dédiée au BRA

Résultat : 24 SLM validés, avec des performances F1 comprises entre 75 et 95, et lancement de la première plateforme dédiée au BRA

Cas d'usage : sbr pour un produit en phase 2

Projet Client Sanofi

Test de l'Ensemble AI ArcaScience sur un médicament biologique en phase 2 pour une maladie dermatologique inflammatoire.

La technologie a été appliquée à la fois sur un médicament déjà commercialisé (avec des données cliniques et RWD disponibles) et sur le médicament d'intérêt. L'analyse portait sur les résultats des tests toxicologiques précliniques, les données de polymorphismes génétiques, ainsi que sur les données contextuelles liées à la pathologie. Objectif : Produire une sBR

Données utilisées : publications scientifiques uniquement pour ce POC
Période de recherche : 20 ans
Volume de données analysées : plus de 25 000 publications

Données Exhaustives

ArcaScience met en évidence toutes les options thérapeutiques, les mécanismes liés à la pathologie, ainsi que les données de bénéfices et de risques disponibles.



Conformité BRAT et FDA

Les étapes respectent les exigences des frameworks BRAT et FDA pour la conception du BRA.



Optimisé par l'IA

Des SLM ont été utilisés pour extraire, qualifier et standardiser les données selon les bonnes pratiques en IA et pharmacovigilance.



Resultats

- "18 mois de travail réalisés en 2 semaines" – Head of translational, Sanofi.
- Ajustement du protocole de phase 3 & identification de nouveaux risques qualifiés

Cas d'usage (produit en phase 2) : Limitations

Résultats prédictifs (pour le médicament en phase 2) :

Precision par rapport aux résultats safety de la phase 1
Comparaison avec la méthode actuelle de Sanofi

Extraction des Risques

Nombre de risques à considérer identifiés
jamais documentés 5

Validation externe (Sanofi) : taux de couverture des données 72.1%

Extraction des bénéfices

Validation externe (Sanofi) : taux de couverture des données 40%

Résultats non-prédictifs :

- Precision par rapport aux données RCP
- Comparaison avec la méthode actuelle de Sanofi
- Validation interne et externe avec experts de données génomique

Extraction de biomarqueurs

Validation avec un Golden standard : F1 90.05%

Validation externe (Disgenet) : taux de couverture des données biomarqueurs 92 % pour top 30

Extraction des Risques

Validation avec un Golden standard: F1 88.1%

Validation externe (Sanofi) : taux de couverture des données 96%

Extraction des bénéfices

Validation avec un Golden standard: F1 92%

Validation externe (Sanofi) : taux de couverture des données 97%

Indicateurs de succès :

- Temps de traitement / gains d'efficacité
- Conformité aux réglementations IA

Durée consacrée

Sanofi: 18 mois AS: 2 semaines

Conformité IA

Non applicable Conforme aux considérations [FDA](#)

Effet financier

Cout potentiels d'amendements ou rejet du dossier AS: Risk mitigation plan updated – Budget optimisé: \$100m+

Limitations identifiées :

Besoin d'améliorer nos capacités prédictives, non seulement sur les risques, mais surtout sur les bénéfices, en s'appuyant sur des modèles propriétaires.

Résumé des capacités de la plateforme **ARCASCIENCE** à date

Récupération des données des différentes bases de données incluses essais cliniques	☒	Fonctionnalités intégrées à la plateforme
Harmonisation des données cliniques des traitements à comparer	☒	
Aide à la compréhension du contexte clinique	☒	
Aide à la construction du protocole clinique	☒	
Réalisation d'une analyse bénéfice-risque sourcée	☒	
Analyse de l'impact des interactions médicamenteuse	☒	
Intégration des données de structures moléculaires	☐	Fonctionnalités à développer grâce au programme I-demo
Intégration des données toxicologiques et pharmacodynamique des modèles précliniques	☐	
Intégration des données sur le polymorphisme génétique	☐	
Exploitation de données RWE pour enrichir les analyses	☐	
Exploitation de ces données dans un modèle prédictif	☐	

SOMMAIRE

- 1) Présentation du porteur
- 2) Contexte et innovation
- 3) **Description du projet**
- 4) Exploitation industrielle et commerciale des résultats du projet
- 5) Retombées économiques, sociales et environnementales
- 6) Besoins en financements et justification de l'aide demandée

Un développement ambitieux créateur de forte valeur pour ARCASCIENCE



Le projet a pour ambition de développer la 1^{ère} plateforme d'analyse B/R prédictive automatisée multimodale permettant d'orienter la stratégie de développement dès les étapes de sélection de candidats médicaments.

Impacts projet

- ArcaScience porte sa technologie pionnière vers une nouvelle génération d'analyse bénéfice-risque, plus robuste, prédictive et exploitable dès les premières étapes de développement.
- Le projet transforme la décision pharmaceutique en rendant l'analyse bénéfice/risque réellement opérationnelle pour sélectionner les candidats à plus fort potentiel.
- Sa maturation positionne ArcaScience comme le partenaire incontournable du SBR. La société multiplie son nombre de contrats et assoit durablement la confiance de ses partenaires

Travaux du projet

- Concevoir un Large World Model permettant à la plateforme d'intégrer des données moléculaires, des données précliniques chez l'animal, des informations sur le mécanisme d'action, la voie cible, ainsi que des données de réponse thérapeutique en vie réelle.
- Démontrer une capacité de prédiction d'analyse bénéfice- risque d'un actif avant la clinique.
- Démontrer une amélioration significative des performances de prédiction et leur utilité dans le cas d'usage du cancer du poumon, sans recourir à un entraînement spécifique à cette pathologie.

A date

- Un outil structurant dédié à l'analyse comparative des bénéfices/risques des candidats médicaments dans le cadre de la validation réglementaire.
- Plateforme déjà opérationnelle pour extraire, structurer, standardiser et synthétiser les données (scientifiques, cliniques, réglementaires).

ArcaScience entend devenir la référence mondiale de l'analyse B/R, en accompagnant l'industrie pharmaceutique vers des décisions R&D plus rapides, plus sûres et plus stratégiques.

L'évolution de la solution technologique ARCASCIENCE pendant le programme I-Demo

ArcaScience avant I-Demo

Analyse bénéfice/risque
adaptée aux obligations
réglementaires

Développement
Clinique

Accès marché

Pharmacovigilance

Gestion de pipeline
de candidat

Affaires
réglementaires

Cas d'usage

Maturité cible

Phase2

Phase3

AMM

Suivi

Arcascience après I-Demo (Valeur ajoutée)

Analyse bénéfice- risque
adaptée à l'orientation
du développement d'un
candidat

Recherche et
développement
préclinique

Recherche
translationnelle

Business
développement

Préclinique

Phase1

Phase2

Phase3

AMM

Suivi

La plateforme a vocation à rester largement générique en termes de pathologies ciblées.

Pour affiner les prédictions lorsque cela est nécessaire, ArcaScience prévoit d'intégrer, en fin de développement, certains éléments spécifiques aux produits ou aux indications.

L'outil conservera ainsi environ 90 % de composantes génériques, garantissant à la fois adaptabilité et performance.

Les bénéfices du programme
I-Demo seront démontrés sur le
cancer du poumon.



Un choix pertinent pour plusieurs
raisons :

1- Abondance et disponibilité des données : facilite la validation et calibration sur des données fiables et diversifiées.

2- Enjeux contrastés : équilibre entre bénéfice de survie et toxicités variables illustrant la nécessité de ces modèles.

3- Hétérogénéité des profils et thérapies : permet de tester la robustesse du modèle sur des critères multiples (polymorphisme, biomarqueurs, ...)

4- Evolution des stratégies thérapeutiques : constante innovation du développement clinique idéal pour tester l'adaptabilité du modèle prédictif (stratégie émergentes vs standards) à l'intérêt du marché immédiat.

Plan prévisionnel du projet

Milestones

- ★ MS1 : Prédiction basée sur la structure chimique : AUC > 0,6 (générique).
- ★ MS2: Prédiction intégrant les données précliniques et le MOA : AUC > 0,75 (générique).
- ★ MS3: Architecture complète intégrant le *knowledge graph* et les données en vie réelles
- ★ MS4: Modèles finalisés : AUC > 0,8 (générique) et AUC > 0,9 (spécifique poumon).

Principaux livrables par Work Packages

WP1: Rapport de validation du modèle chimique (prédiction B/R depuis la structure).


WP2: Rapport de validation du pipeline in vivo (prédiction B/R depuis les résultats des modèles précliniques).

WP3: Rapport de validation du modèle génomique (prédiction B/R à partir du polymorphisme génétique de la cible et de son impact sur des biomarqueurs contextuels).

WP4: Rapport de validation du pipeline RWE (prédictions cliniques en vie réelle).

WP5: Modèle ontologique validé + rapport de conformité du *knowledge graph*.

WP6: Rapport de validation du modèle unifié + démonstrateur interactif.



Programme de travail

WorkPackage 1

L'objectif du WP1 est d'être capable de prédire les bénéfices et les risques potentiels liés à une molécule en se basant uniquement sur sa structure. Cette approche est validée par le taux de précision de cette prédiction en utilisant des molécules déjà sur le marché.

WorkPackage 2

Le WP2 vise à prédire les bénéfices et risques d'une intervention à partir des données in vivo et des études toxicologiques, tout en intégrant un score de fiabilité par pathologie. Le KPI porte sur la précision des prédictions de bénéfice/risque supérieure à celle du WP1.

WorkPackage 3

Le WP3 vise à prédire les bénéfices et risques d'une molécule à partir de ses effets sur les biomarqueurs de la pathologie, de sa cible moléculaire et des polymorphismes génétiques associés. La prédiction est évaluée par sa précision sur des molécules commercialisées.

WorkPackage 4

L'extraction des données patients ainsi que des données de sécurité et d'efficacité à partir de bases de données de vie réelle comme FAERS, SNDS, EHDS permet d'identifier et de confirmer les relations existantes entre certaines structures moléculaires, pathologies et cibles thérapeutiques avec des bénéfices et des risques spécifiques.

WorkPackage 5

Développer et structurer le paysage des connaissances en intégrant les données multi-sources (RWE, génomiques, cliniques) dans un cadre conceptuel cohérent permettant l'interopérabilité et l'exploitation par les modèles prédictifs.


WorkPackage 6

Une approche innovante basée sur un Large World Model pour l'analyse multimodale du couple bénéfice-risque. Elle combine prédictions (WP1-4) et knowledge landscape (WP5) pour générer bénéfices et risques avec niveaux d'incertitudes quantifiés, explorables via une interface interactive type mindmap qui synthétise les données hétérogènes.

WorkPackage 7

Assurer la coordination scientifique, administrative et financière du projet en pilotant les interactions entre WPs (WP1-6), le suivi des livrables et jalons, la gestion des risques et du budget. Organiser la gouvernance projet (comités de pilotage, reporting), faciliter la communication inter-partenaires et garantir l'atteinte des objectifs dans les délais impartis.

Budget



Le budget total du programme de travail s'élève à 5 360K€ en 36 mois

Partenaires & ecosysteme du projet



Future4Care

L'Ecosystème Future4Care s'associe avec ArcaScience pour apporter leurs ressources permettant la réussite du projet : cela nous sera accordé dans le cadre de notre implantation au cœur même de l'écosystème depuis 2022, et ne nécessitera pas de financement supplémentaire.



GRADIENT HEALTH

Gradient health

Gradient Health est un *data provider* privilégié de plusieurs startups françaises en santé : ils assureront l'apport de données supplémentaires en vie réelle et hospitalières pour assurer l'équilibrage des *datasets* d'entraînement et l'atteinte des 95%+ de précision lors de leur utilisation.

sanofi



Sanofi & Generali – Fondateurs Future4Care

En tant que fondateurs de Future4Care, Sanofi et Generali sont des partenaires de longue date d'ArcaScience, Sanofi ayant notamment participé à la validation de l'ensemble de nos modèles d'IA ces 6 dernières années. Elle est notamment représenté au comité scientifique d'ArcaScience en la personne de Philippe Peyre, Secrétaire Général et Vice Président de Sanofi.

SOMMAIRE

- 1) Présentation du porteur
- 2) Contexte et innovation
- 3) Description du projet
- 4) **Exploitation industrielle et commerciale des résultats du projet**
- 5) Retombées économiques, sociales et environnementales
- 6) Besoins en financements et justification de l'aide demandée

Présentation du marché des analyses bénéfice-risque

Le marché de l'analyse bénéfice risque est estimé à près de 13,2 milliards de dollars par an principalement focalisé sur l'évaluation d'actifs mis sur marché

Phase de développement du médicament	Taille du marché par phase	Nbr de molécules par phase	Moyenne par molécule
Préclinique	\$1.15Mds	11 351	\$100K
Phase 1	\$1.47Mds	2 947	\$250K
Phase 2	\$1.39Mds	1 385	\$1M
Phase 3	\$0.39Md	388	\$1,2M
Approbation	\$0.32Md	213	\$500k
Post-Marketing	\$8.4Mds	196	\$4,3M



La demande de l'industrie pharmaceutique en analyse B/R évolue de plus en plus vers les stades de développement clinique

1:1

L'intégration d'une analyse B/R permet d'orienter la stratégie clinique de développement des actifs avant d'engager des essais pivots coûteux.



Le goulot d'étranglement reste principalement l'entrée en clinique nécessitant l'évolution des analyses B/R dès les stades précliniques



Le domaine évolue avec l'essor des méthodes quantitatives (MCDA), l'intégration des préférences patients et le développement d'outils de visualisation.

Le marché reste dominé par l'évaluation réglementaire continue de la toxicité des actifs mis sur marché. Le prix unitaire reste donc élevé et les analyses longues et statiques. La pratique actuelle n'intégrant que peu ce type d'analyses pour mieux orienter et concevoir le développement clinique des candidats malgré une très forte dynamique de développement clinique.

Les technologies actuelles restent limitées par leur coût, leur durée et leur spécificité ce qui empêche toute application de screening de candidats médicaments.

Il est donc essentiel de développer de nouvelles technologies rapides à un prix par molécule plus faible afin d'intégrer l'analyse B/R dans la stratégie de développement de médicaments. ArcaScience s'inscrit pleinement dans cette dynamique en apportant une réponse adaptée à cette évolution du secteur.

Analyse de la concurrence

Le développement de solutions d'analyse de bénéfices/risques automatiques est encore très peu répandu et la quasi-totalité sont encore réalisées manuellement.



ArisGlobal est la solution marché la plus proche de la plateforme ArcaScience. Elle utilise différents modèles IA pour optimiser le processus de l'analyse B/R

ArisGlobal 

ArcaScience 

Spécialisé en pharmacovigilance.

Pharmacovigilance - BRA
Analyses prédictives.

Optimisation du workflow interne.

Totalement automatisé.

Réduction de 40% du temps passé par rapport aux analyses manuelles (~8mois).

Production des analyses en quelques minutes.

Utilisation d'une base de données propriétaire.

Exploitation de bases de données biomédicales, biologiques et cliniques.

Modèle SaaS.

Modèle SaaS.

Aucun acteur existant ne combine à la fois la profondeur technologique et une évaluation B/R complètement automatisée et scalable basée sur les données mécanistiques et des réponses précliniques et cliniques comme le propose ArcaScience.

Solution de B/R manuelle

Ces acteurs proposent des analyses bénéfice/risque structurées, fondées sur l'expertise humaine, les cadres méthodologiques des agences (EMA, FDA) et des approches qualitatives ou quantitatives. Leur valeur repose sur la maîtrise réglementaire et l'accompagnement personnalisé, mais leurs processus restent largement manuels.

Bien qu'ils soient fortement orientés sur l'évaluation B/R, ils ne disposent ni d'une infrastructure technologique dédiée, ni d'une capacité d'industrialisation permettant de produire des évaluations rapides, répétables et à grande échelle.

YolaRX

BioBOSTON CONSULTING

MMS
The difference is in the data

freyr

DeltaPV

arriello

Solution automatisée non focalisée sur les B/R

Ces solutions s'appuient sur des bases de données très étendues et sur des moteurs d'IA puissants. Leur objectif principal est d'orienter le développement de candidats médicaments, en fournissant des analyses mécanistiques, documentaires ou RWE, auxquelles peuvent s'ajouter certaines fonctionnalités liées à la sécurité.


Cependant, aucun de ces acteurs n'est conçu pour réaliser des évaluations bénéfice/risque ciblées pour un candidat médicament de manière industrialisée.

 **causal**

nference

 **IQVIA**

Roadmap de developpement



Le plan de développement d'ArcaScience repose sur deux axes complémentaires :

- **L'intégration de nouveaux modules**, afin d'étendre les cas d'usage couverts par la plateforme pour se rapprocher d'un accompagnement de plus en plus complet
- **L'intégration de nouvelles sources de données**, permettant de développer de nouveaux modèles ou d'élargir les aires thérapeutiques prises en charge par la solution.

Une **stratégie Go-To-Market** permettant de s'étendre rapidement en capitalisant sur les forces existantes de la société

Stratégie déploiement sur la base de clients existante

- Promotion de l'add-on BR-Predict auprès des clients existants pour élargir son déploiement à l'ensemble de leurs portefeuilles.
- PoC initiale sur un asset, réalisé avec le module générique pour valider rapidement la pertinence scientifique avant d'élargir à d'autres molécules.
- PoC spécifique à la pathologie, plus approfondie et à un tarif supérieur, incluant analyses MoA et caractérisation détaillée pour démontrer la valeur sur les assets prioritaires.
- Contrats-cadres, facilitant l'utilisation de BR-Predict molécule par molécule et permettant d'industrialiser la collaboration.

Nouvelle typologie de client

ArcaScience cible aujourd'hui les grosses CRO et entreprises Pharma. Avec l'arrivée du module «BR-Predict», ArcaScience peut désormais cibler l'ensemble des entreprises disposant de portefeuilles d'actifs étendus dans les aires thérapeutiques couvertes par la solution : Big Pharma, Mid Pharma et grandes biotechs.

Elargissement de l'offre via l'augmentation des aires thérapeutiques couvertes par BR-Predict

Exploitation de la plateforme générique pour développer rapidement des modèles spécifiques aux aires thérapeutiques à forte dynamique, comme l'oncologie et l'immuno-inflammatoire.

Utilisation des résultats obtenus pour produire des démonstrateurs à forte valeur ajoutée.

Extension mondiale

Pour étendre son champ d'action, la solution sera déployée à l'international, avec un effort prioritaire aux États-Unis afin d'y établir des contrats-cadres.



Le module BRA permettra à ArcaScience de débiter son développement commercial en parallèle du programme I-demo. ArcaScience dispose déjà d'atouts solides pour réussir ce développement : une présence active dans les congrès clés, l'appui de KOL reconnus, la valorisation de démonstrateurs comme le cancer du poumon et une diffusion régulière de contenus à forte valeur ajoutée. L'entreprise s'appuie sur l'expertise de son CBO et de son CMO et prévoit plusieurs recrutements dédiés afin de structurer une véritable équipe commerciale capable de mener à bien ce projet

Modèle économique et pricing de la solution


Le modèle économique de la plateforme s'appuie sur une offre de services chez le client en modèle SaaS

- **Offre modulaire** dépendante des fonctionnalités développées et par l'usage client répondant aux attentes des services réglementaire, pharmacovigilance et *drug development* au sein des pharmas
- Un **modèle à effet de levier basé sur un tarif à l'utilisation par molécule analysée** (e.g. candidat médicament ou médicament approuvé) via la plateforme
- Une **offre complète** incluant la mise en place de la solution jusqu'à livraison du compte rendu final de l'analyse
- Facilité d'utilisation garantie par l'**automatisation complète** de la solution
- **Tarif compétitif à l'unité** permettant d'inclure l'offre dans le screening de candidats multiples en amont de la clinique

Conception de l'offre:

- **Service PoC**: frais de service liés à la prise en main et utilisation de la plateforme à partir d'une nature d'actifs du client démontrant les capacités des modules Trial Balancer et / ou BR-Predict. L'offre service PoC sera proposée à un même client en fonction des natures d'actifs et aires thérapeutiques différentes. Pour l'offre BR-Predict, le prix du service PoC est plus élevé car devant justifier de la capacité de la plateforme à opérer sur un portefeuille d'actifs et non sur une molécule.
- **Module Trial Balancer**: effectue une analyse du B/R sur une molécule à partir des données cliniques du client. L'offre Trial Balancer est principalement positionnée pour les actifs déjà sur le marché ou en développement clinique tardif (à partir de la phase 2).
- **Module BR-Predict**: prédit le B/R de chaque candidat à partir des données de structure de l'actif, de mécanisme d'action, des données précliniques et des données en vie réelle pour orienter la stratégie de développement clinique. L'offre Predict est orientée sur le screening de candidats médicaments, et à ce titre, présente un fort effet de levier par client en raison du grand volume de molécules analysées.

Pricing de la solution



Willingness to pay

Besoins

Les laboratoires pharmaceutiques doivent constamment prioriser les actifs à faire entrer en clinique, et décider où concentrer leurs ressources (budgets, équipes, temps) pour maximiser leurs chances de succès. Cela implique des décisions complexes sur le positionnement clinique, souvent basées sur des analyses longues, coûteuses et incertaines.

Une solution technologique en accord avec les besoins de la pharma

La solution ArcaScience répond directement à ce besoin en fournissant une évaluation bénéfice/risque rapide, structurée et stratégique, permettant de :

- Accélérer la prise de décision sur les molécules à développer ;
- Définir la stratégie de repositionnement des actifs ;
- Augmenter les taux de succès des développements de candidats ;


La plateforme ne remplace pas les outils déjà en place dans l'écosystème pharmaceutique. Elle apporte des résultats complémentaires, s'intégrant naturellement aux solutions déjà utilisées par les laboratoires.

Un modèle de vente en accord avec les besoins de la pharma

Le modèle de vente d'ArcaScience correspond parfaitement aux attentes des pharmas. Il s'appuie sur une approche flexible, modulaire et proposée à un prix très compétitif, tout en offrant la possibilité de tester la solution en deux étapes avant toute décision. Cette progressivité met les clients en confiance et leur permet d'évaluer concrètement la valeur de la plateforme avant de s'engager.

En permettant un développement plus ciblé, plus rapide et moins coûteux, la plateforme génère une valeur directe et mesurable pour les industriels, générant une forte traction commerciale

Stratégie de commercialisation et prévisions économiques



Justification des prévisions :

Le module Trail Balancer cible des molécules plus matures, qui sont par nature moins nombreuses dans les portefeuilles R&D. Pour soutenir la croissance, la stratégie repose donc sur un élargissement progressif du portefeuille client, en adressant les grandes biotechs, les mid pharmas et les big pharmas. Le nombre de molécules analysées passe ainsi de 3 en 2025 à 20 en 2028, puis atteint 135 en 2032,

Le module BR-Predict voit une croissance exponentielle auprès des entreprises pharmas déjà clientes. L'offre prévoyant 2 analyses PoC en 2028, 46 molécules analysés auprès des clients Trial Balancer en 2030, puis atteint 199 en 2032. Cette croissance reflète l'intégration progressive du module sur l'ensemble des portefeuilles précliniques, rendue possible grâce à la stratégie de commercialisation menée en parallèle du programme i-Demo et de la très forte polyvalence de la plateforme.

Une solution qui, par nature, limite fortement les risques liés au vol de **propriété intellectuelle**.

Secret d'affaires & Savoir-faire propriétaire

Protection industrielle centrée sur le savoir-faire interne, les protocoles et les logiques technologiques non brevetables.

Confidentialité de :

- l'architecture du pipeline clinique holistique,
- les mécanismes d'intégration, de normalisation et de cohérence des données,
- les 24 modèles d'IA propriétaires (structure, paramètres, workflows d'inférence).

La structure interne de la base de données (schéma, granularité, liens logiques) constitue un actif propriétaire non reproductible sans les méthodes internes.

Le protocole d'utilisation de données publiques, collecte, annotation, contrôle qualité, alignement clinique, représente un avantage compétitif clé

Le code et les modèles sont réinstallés et protégés chez un *private escrow* chaque année.

Stratégie de protection

ArcaScience a construit une stratégie PI robuste pour protéger son cœur technologique et consolider sa position dans l'analyse bénéfice-risque prédictive.

Dépôt de brevets (USA & Europe) et Construction d'un portefeuille IP évolutif, intégrant à terme

- le processus inventif du pipeline clinique holistique (modèle IA, protocole d'annotation, mécanisme de prédiction, outils d'aide à l'évaluation bénéfices-risques)
- Les modèles IA construits sur une architecture unique au carrefour des technologies *Encoder et Transformer*

ArcaScience va ensuite déposer un brevet sur notre premier *Large World Model* ainsi que sur les *Latent World Models* développés par la suite, les algorithmes étant plus originaux et *deep tech* que des modèles d'IA classiques entraînés en Deep Learning, ils se prêtent parfaitement à une protection par brevets.

Apport du projet

Au minimum un brevet protégeant tous le nouveau processus d'intégration et d'utilisation des nouvelles données sera déposés au cours du programme

Un second brevet est envisagé pour protéger le *Large World Model* et les *Latent World Models* suivants.

Le projet i-Demo nous permettra de produire et de maintenir dans notre stack l'une des technologies de ruptures les plus complètes et frontalières de notre temps. Non seulement elle sera compatible avec les exigences du développement clinique – ce que les LLMs ne sont pas à cause de leurs hallucinations et de leur manque d'exhaustivité et de sourcing –, mais elle matérialise un niveau d'expertise et d'aboutissement en IA uniques au monde. Ce programme fera de nous l'un des seuls acteurs au monde à détenir et à opérer un Large World Model en santé

SOMMAIRE

- 1) Présentation du porteur
- 2) Contexte et innovation
- 3) Description du projet
- 4) Exploitation industrielle et commerciale des résultats du projet
- 5) **Retombées économiques, sociales et environnementales**
- 6) Besoins en financements et justification de l'aide demandée

Impacts sociétaux

Impact de l'accélération du développement de médicament

En identifiant plus tôt les candidats les plus prometteurs, la solution accélère l'arrivée de thérapies réellement innovantes pour des populations médicalement délaissées, améliorant concrètement leur accès aux soins et leur qualité de vie.



Réduction du nombre d'individu impliqué dans des essais clinique

Un essai clinique précoce (phase I ou II) mobilise généralement :

- Environ 10 à 50 volontaires sains (en phase I)
- Puis 50 à 300 patients (en phase II), parfois plus selon l'indication

En moyenne, chaque essai annulé ou évité grâce à une meilleure sélection en amont permettrait d'épargner 10 à 300 personnes (volontaires et patients confondus).



Impact de création d'emplois sur le territoire :

Le projet permettra la création de 27 emplois directs, incluant des ingénieurs IA, bioinformaticiens, chefs de projet R&D et profils en affaires réglementaires.

Il prévoit également l'intégration de 4 doctorants et la formation de 8 personnes par an (stagiaires, alternants, jeunes diplômés).

Des emplois indirects seront aussi générés chez les sous-traitants technologiques et scientifiques, renforçant l'écosystème local.

Impact fillière

En replaçant l'analyse bénéfice/risque au cœur de la décision, ArcaScience transforme ce qui était perçu comme une contrainte réglementaire en un levier stratégique majeur, offrant aux entreprises pharmaceutiques une nouvelle perspective pour prioriser les candidats les plus prometteurs.

Le projet porte un impact sociétal fort, en contribuant à un développement pharmaceutique plus éthique, plus efficace et plus durable, au bénéfice des patients, des soignants et de l'ensemble du système de santé.

Impacts environnementaux

Réduction des ressources utilisés

La réduction des projets non viables limite la consommation de matières premières, d'eau et de réactifs, permettant une utilisation plus responsable des ressources nécessaires au développement pharmaceutique.



Empreinte carbone

En concentrant les efforts de R&D sur les candidats réellement prometteurs, la technologie diminue les émissions liées au transport, aux synthèses répétées et aux activités cliniques dispersées.



Réduction des déchets

La contraction du nombre d'expérimentations et d'essais évités réduit significativement les déchets chimiques, plastiques et biomédicaux générés dans les laboratoires et les sites cliniques.



Réduction de l'impact environnemental dans le développement de candidats

En limitant le gaspillage scientifique et les projets à forte empreinte écologique, la solution contribue à un modèle de développement pharmaceutique plus durable, plus efficient et plus aligné avec les exigences environnementales actuelles.



Bien que le projet n'ait pas pour objectif principal de générer des impacts environnementaux majeurs, la réduction du nombre d'essais cliniques inutiles, et des ressources qu'ils mobilisent, constitue un levier écologique significatif dans le domaine du développement pharmaceutique.

SOMMAIRE

- 1) Présentation du porteur
- 2) Contexte et innovation
- 3) Description du projet
- 4) Exploitation industrielle et commerciale des résultats du projet
- 5) Retombées économiques, sociales et environnementales
- 6) **Besoins en financements et justification de l'aide demandée**

Justificatif de l'aide

La technologie ARCASCIENCE est aujourd'hui principalement utilisée pour des analyses de pharmacovigilance, sur des molécules à forte maturité clinique et commerciale. Bien que la société propose une analyse bénéfice/risque rapide, précise et compétitive, déjà plus performante que les solutions existantes (prix, réactivité, qualité des résultats). Cette offre n'est pas suffisante pour répondre à un besoin plus large pour orienter les stratégies de développement clinique des candidats médicaments.

Le projet i-Demo : un levier stratégique d'innovation

Grâce au soutien du programme i-Demo, ARCASCIENCE pourra développer une nouvelle offre centrée sur l'analyse bénéfice/risque précoce, dès les phases précliniques et de phase I. Cette offre est parfaitement alignée avec :

- Les besoins actuels des laboratoires pharmaceutiques en matière de priorisation stratégique des actifs ;
- Les lacunes des plateformes d'IA existantes, en offrant un apport complémentaire et différenciant ;
- Le potentiel commercial atteignable ;
- LE développement stratégique de la plateforme ARCASCIENCE qui a pour objectif de s'étendre au sein des différents départements de ses partenaires pharmaceutiques

Le projet i-Demo permettra ainsi de positionner ARCASCIENCE comme le premier acteur mondial de l'analyse bénéfice/risque dédiée à la recherche translationnelle et à la stratégie de développement de molécules candidates.

Une ambition industrielle forte, un marché vaste

Contrairement aux solutions actuelles, la plateforme ARCASCIENCE cible :

- Un marché large, transverse à de nombreuses aires thérapeutiques ;
- Tous les niveaux de maturité des molécules, de la recherche exploratoire à la commercialisation ;
- Un fort potentiel de revenus très dynamique dès 2028 poussés par le levier sur les différentes molécules des portefeuilles clients.

A ce jour, aucun acteur ne couvre ce spectre avec un tel niveau de précision et de flexibilité.

Pourquoi i-Demo est essentiel ?

Parce que ce programme représente le catalyseur stratégique permettant à ARCASCIENCE de concrétiser sa vision, d'industrialiser son offre innovante et de se positionner comme leader technologique de la pharmatech française. Cette aide permettra de positionner un acteur Français comme leader de l'utilisation de technologies IA dans l'analyse B/R et l'emploi de plusieurs dizaines de profils ultra-qualifiés sur la durée du projet.

Plan de financement

	2025	2026	2027	2028	2029
	Développement du programme i demo				
Besoins en financements	1 254 k€	3 380 k€	4 323 k€	5 462 k€	6 548 k€
Chiffre d'affaires	525 k€	1 050 k€	2 450 k€	4 400 k€	8 300 k€
Levées de fond	4 500 k€		20 000 k€		
Aide I-Demo		965 k€	724 k€	724 k€	

- La levée de fonds récente de 4,5M€ assure la disponibilité des fonds propres nécessaires pour cofinancer l'ensemble du présent projet ;
- Une prochaine levée prévue Q2-2027, pour un montant de 20 M€, viendra soutenir le déploiement commercial de la solution BR-Predict développée dans le cadre du présent programme i-Demo. De plus la levée de fonds assurera le développement technologique de la plateforme vers le déploiement de nouveaux modules et de l'offre d'essais cliniques virtuels ;
- Le soutien i-Demo a pour objectif d'accélérer le développement de la solution BR-Predict fortement créatrice de valeur pour la société. Cette aide capitalise sur les fonds sécurisés lors de la levée de fonds de 2025 et s'appuie sur le premier niveau de traction commerciale de la plateforme pour assurer un retour sur investissement fort et consolider ArcaScience comme leader de l'analyse B/R



Romain CLEMENT
CEO & Co-Founder

✉ romain@arcascience.ai

☎ +336.38.56.15.21

💻 www.arcascience.ai

Future 4 Care, Biopark, 75013, PARIS

Merci !

They trust us



sanofi



Objectif : Le WP1 a pour objectif de prédire les bénéfices et les risques potentiels associés à une molécule en se basant uniquement sur sa structure chimique. La validité de cette approche sera évaluée par le taux de précision obtenu sur des molécules déjà commercialisées.

Tâches :

T1.1. Qualification des sources de données

Identifier, évaluer et qualifier les bases de données pertinentes (NCGC qHTS cytotoxicity, ChEMBL, ToxCast™, etc.)

T1.2. Construction et curation de la base de données

Constituer un dataset consolidé de molécules commercialisées, adjuvants et protéines avec profils bénéfice-risque documentés.

T1.3. Représentation moléculaire & calcul des descripteurs

Transformer les structures chimiques en représentations numériques descriptives et exploitables pour la modélisation

T1.4. Développement de modèles QSAR

Construire des modèles prédictifs d'efficacité thérapeutique à partir de la structure (approches ML plutôt que QSAR classiques).

T1.5. Développement de modèles QSTR

Construire des modèles prédictifs de toxicité et de risques de sécurité (également basés ML).

T1.6. Intégration & validation

Contrôle qualité des données, validation des résultats et évaluation des performances des modèles.

KPI

Seuil de validation : AUC > 0.65

Limitations rencontrées :

Une revue de 2025 montre qu'aucun modèle QSAR unique ne peut prédire efficacement l'ensemble de l'espace chimique ; les meilleurs modèles restent performants uniquement au sein de domaines chimiques spécifiques [1].

Les modèles de pointe (DNN, Random Forest, GNN...) offrent d'excellentes performances pour les molécules proches du jeu d'entraînement, mais voient leur précision diminuer sur des structures chimiquement dissemblables [2].

Exemples de performances issues de l'état de l'art :

QSAR pour activité FGFR-1: $R^2 = 0,7869$ (train), $0,7413$ (test) [3]

Livrables :

Modèles de prédiction QSAR et QSTR validés.

Jalon associé :

Être en mesure, à partir d'une structure chimique donnée, de prédire les bénéfices et risques potentiels avec un niveau d'incertitude maîtrisé

Annexe : Présentation du Work Package 2

Objectif : Le WP2 vise à prédire les bénéfices et les risques potentiels d'une intervention à partir des données in vivo disponibles et des études toxicologiques de la littérature, tout en intégrant un score de fiabilité par pathologie pour chaque modèle préclinique.

Tâches :

T2.1. Préparation de l'infrastructure

Étape commune aux WP2, WP3 et WP4, visant à tester les architectures de modèles et l'infrastructure optimale pour la réalisation de ces workpackages.

T2.2. Qualification des sources de données in vivo

Identification et sélection des études d'efficacité et de toxicité + littérature générale.

T2.3. Extraction et structuration des données (NLP)

Extraction automatique des informations relatives aux modèles in vivo et structuration des données.

T2.4. Création d'une base de données curée et standardisée

Consolidation des données extraites en une base fiable et exploitable.

T2.5. Modèles ML pour la prédiction de l'efficacité

Prédiction du succès clinique à partir des résultats in vivo au niveau de la pathologie / aspect spécifique de la pathologie,

incluant un score de fiabilité des modèles précliniques.

T2.6. Modèles ML pour la prédiction du risque

Prédiction des risques toxiques humains à partir de données animaux.

T2.7. Validation et intégration

Évaluation des performances, cohérence des données, intégration dans les pipelines internes.

KPI

KPI principal : précision des prédictions pour des molécules déjà commercialisées, supérieure à celle obtenue dans le WP1

Limitations rencontrées :

Données propriétaires inaccessibles, contenus sous paywall. - Biais de publication et de reporting sélectif → augmentation potentielle du risque d'erreur. Limites spécifiques aux biologics (modèles substitutifs, immunogénicité, faible transposabilité).

Livrables :

Modèle NLP fonctionnel pour extraction d'informations in vivo.

Score de fiabilité par modèle préclinique et par pathologie/aspect.

Modèles ML prédictifs des bénéfices et risques basés sur données in vivo.

Capacité finale : prédire les bénéfices et risques potentiels pour une structure donnée.

Milestone associé :

Définition d'objectifs de précision selon le périmètre (spécifique / non spécifique).

Exemple (état de l'art) : des modèles hybrides ML + mécanistiques pour la prédiction PK in vivo ont atteint 64 % (clearance) et 62 % (volume de distribution) de prédictions dans une marge d'erreur ×2.

Objectif : Le WP3 vise à prédire les bénéfices et risques d'une molécule à partir de ses effets sur les biomarqueurs de la pathologie, de sa cible moléculaire et des polymorphismes génétiques associés. La prédiction est évaluée par sa précision sur des molécules commercialisées.

Tâches :

- T3.1. Qualification des sources
 - Biomarqueurs/pathologie
 - Variants génétiques des cibles
- T3.2. Extraction et structuration des données (NLP)
 - Extraction automatique des polymorphismes génétiques
 - Structuration des effets fonctionnels
- T3.3. Construction d'une base de données intégrée
 - Molécule → Biomarqueurs/génomique → Pathologie
 - Molécule → Cible → variants génétiques → impacts fonctionnels
- T3.4. Modèle ML – Bénéfice
 - Input : biomarqueurs/génomique de la pathologie + Cible
 - Output : prédiction de bénéfice
- T3.5. Modèle ML – Risque
 - Input : génotype de la target + mécanisme d'action du traitement
 - Output : prédiction de risque
- T3.6. Validation & Intégration
 - Évaluation des performances
 - Harmonisation et intégration dans les pipelines internes

KPI :

Cette prédiction est évaluée par sa précision sur des molécules déjà commercialisées.

Raison d'être du WP :

- Approche basée sur la médecine personnalisée.
- Applicable à tout type de traitement et toute pathologie.
- Extension avancée du QSIR.
- De nombreuses études démontrent l'impact du profil génétique sur l'efficacité thérapeutique, notamment en oncologie.
- Cette approche n'a pas encore été testée à grande échelle, ce qui en fait un axe d'innovation fort.

Livrables :

- Modèle NLP fonctionnel pour extraction des informations génétiques
- Base de données : cibles ↔ biomarqueurs ↔ pathologie ↔ variants génétiques
- Modèles ML prédictifs : bénéfices & risques basés sur la génétique
- Capacité finale : prédire bénéfices et risques pour une structure donnée via génomique + ciblet

Milestone associé :

Définition des objectifs de précision pour un modèle généraliste, pour prédiction par cible (cible générale non pathologie spécifique)

Exemples de performances de l'état de l'art :

- UGenome (2025) : modèles pharmacogénomiques IA jusqu'à 99 % de précision pour prédire les réponses thérapeutiques via données multi-omiques, validés par comparaison aux essais cliniques et recommandations de régulateurs (ex. FDA) [1].
- Park et al. (2023) : modèles ML/DL prédictifs de réponse (InIC50) basés sur profils d'expression et mutations dans divers cancers ; résultats robustes mais spécifiques à chaque traitement et contexte cellulaire [2].
- Miranda et al. (2021) : modèles intégrant polymorphismes + variables cliniques pour prédire réponse et EIs au tamoxifène ; performances encourageantes mais contexte très spécifique [3].

Objectif : L'extraction des données patients ainsi que des données de sécurité et d'efficacité issues de bases de vie réelle (FAERS, EDS, EHDS...) permet de valider et renforcer les relations identifiées entre structure moléculaire, modèles précliniques, cible thérapeutique, bénéfices et risques.

Le WP4 vise à développer des modèles prédictifs de bénéfices et de risques basés sur les données de vie réelle, intégrant :

- les conditions d'utilisation en pratique,
- les populations non sélectionnées,
- les comorbidités, la polymédication,
- les facteurs socio-démographiques.

Tâches :

T4.1. Qualification des sources RWE

Identifier, évaluer et qualifier les bases FAERS, EDS, EHDS et autres sources utilisables.

T4.2. Extraction & structuration des données RWE

Extraction, harmonisation et standardisation des données de sécurité et d'efficacité.

T4.3. Modèles prédictifs RWE - Bénéfices

Entraînement de modèles ML prédictifs du bénéfice clinique en conditions réelles.

T4.4. Modèles prédictifs RWE - Risques

Entraînement de modèles ML prédictifs des risques / ADRs en vie réelle.

T4.5. Validation & calibration

Calibration externe, évaluation robuste (AUC, accuracy, calibration plots), comparaison aux modèles WP1-3.

KPI :

précision des modèles RWE supérieure à celle obtenue via WP1/2/3.

Livrables :

- Modèles ML prédictifs basés sur données RWE (bénéfices et risques).
- Pipeline complet d'extraction, standardisation et analyse des données RWE.
- Modèle généralisable intégrant facteurs cliniques réels + données moléculaires + données de pathologie (WP1-3 + WP4).

Milestone associé :

un milestone réaliste pour un modèle généralisé, tenant compte de la variabilité inter-pathologies, des biais RWE et de l'hétérogénéité des populations.

Un milestone plus élevés pour le cancer de poumon

Objectifs : Le WP5 vise à créer un cadre de connaissances structuré et interopérable qui intègre de multiples sources de données hétérogènes (structures moléculaires, résultats précliniques, données génomiques, données de vie réelle) dans une couche sémantique unifiée. Ce « paysage de connaissances » sert d'ontologie fondamentale et d'architecture de données permettant de contextualiser, comparer et combiner les prédictions des WP1-4.

Tâches :

T5.1. Conception et Sélection de l'Ontologie

Identifier et adopter des ontologies standard (MedDRA, SNOMED CT, ChEBI, Disease Ontology) et définir les relations entre entités moléculaires, biologiques et cliniques

T5.2. Harmonisation des Données et Cartographie des Entités

Associer les résultats des WP1-4 à des terminologies standardisées et créer des références croisées entre sources de données et résultats

T5.3. Construction du Graphe de Connaissances

Construire la structure de la base de données graphe (nœuds = entités, arêtes = relations) et la peupler avec les données intégrées des WP1-4

T5.4. Extraction et Validation des Relations

Utiliser le traitement automatique du langage naturel pour extraire des relations supplémentaires de la littérature, valider les relations par rapport aux associations connues médicament-maladie-résultat, et attribuer des scores de confiance aux relations

T5.5. Développement de l'Interface de Requête et de l'API

Créer un langage de requête pour les questions complexes multi-niveaux, développer une API permettant au WP6 d'accéder au graphe de connaissances, et implémenter la mise en cache pour les requêtes fréquentes

Raison d'être du WP :

Les WP1-4 génèrent des prédictions isolément en utilisant différents types de données et terminologies (descripteurs chimiques, critères d'évaluation précliniques, variants génétiques, résultats de données de vie réelle)

Sans standardisation, ces prédictions ne peuvent pas être comparées ou intégrées de manière significative

Un graphe de connaissances permet :

- Interopérabilité sémantique : Associer « hépatotoxicité » dans les études précliniques à « élévation des ALAT » dans les données de vie réelle et « lésion hépatique » dans les notices cliniques
- Découverte de relations : Relier cibles moléculaires → voies métaboliques → maladies → résultats
- Propagation de l'incertitude : Tracer la provenance des données et le niveau de confiance entre les sources
- Explicabilité : Permettre la traçabilité de la prédiction jusqu'aux données probantes sources

KPI :

Intégration réussie de ≥90% des entités de données des WP1-4 dans un graphe de connaissances standardisé avec des relations sémantiques validées. Temps de réponse aux requêtes <2 secondes pour les requêtes complexes multi-sources.

Limitations rencontrées :

- La couverture ontologique peut être incomplète pour les nouvelles cibles ou les maladies rares
- L'exhaustivité du graphe de connaissances dépend de la qualité des données des WP1-4
- Maintenir la cohérence lors de l'arrivée de nouvelles données nécessite une curation continue

Livrables :

- Graphe de connaissances peuplé avec >100K entités et >1M relations
- Tables de correspondance validées entre différentes terminologies
- API de requête avec documentation
- Rapport de qualité des données montrant la couverture et les scores de confiance

Milestone associé :

- Schéma ontologique finalisé et validé avec les experts du domaine
- Graphe de connaissances peuplé avec les données des WP1-3 (couverture à 80%)
- Intégration complète des données de vie réelle du WP4 et validation des relations terminée
- API de requête opérationnelle et testée selon les exigences du WP6

Objectifs : Le WP6 intègre tous les modèles prédictifs (WP1-4) avec le paysage de connaissances (WP5) pour créer un « modèle du monde » capable de simuler des profils bénéfice-risque pour n'importe quelle molécule. Ce modèle prédit les résultats au niveau individuel, les interactions médicamenteuses et les risques spécifiques au contexte en apprenant les relations causales entre les propriétés moléculaires, les mécanismes biologiques et les caractéristiques des patients.

Tâches :

T6.1. Conception de l'Architecture du Modèle

Concevoir une architecture de réseau neuronal pour intégrer les prédictions des WP1-4, implémenter des mécanismes d'attention pour pondérer les preuves de différentes sources, et construire un module de dynamique temporelle pour les prédictions dépendantes du temps

T6.2. Intégration en Ensemble des WP1-4

Combiner les prédictions en utilisant des pondérations apprises (pas une simple moyenne), gérer les contradictions (par ex., WP2 prédit une toxicité, WP4 données de vie réelle montrent une sécurité), et implémenter la résolution de conflits avec propagation de l'incertitude

T6.3. Modélisation Causale et Prédiction des Interactions

Entraîner des modèles pour prédire les interactions médicament-médicament en utilisant les données moléculaires + données de vie réelle, modéliser les interactions gène-médicament pour les prédictions pharmacogénomiques, et simuler les relations dose-réponse et temps jusqu'à l'événement

T6.4. Quantification de l'incertitude

Implémenter des approches bayésiennes ou d'ensemble pour les intervalles de confiance, signaler les prédictions avec faible confiance en raison de données éparpillées, et fournir des explications interprétables des sources d'incertitude

T6.5. Interface de Visualisation (Carte Mentale)

Visualisation interactive du réseau bénéfice-risque (molécule → cibles → voies métaboliques → résultats), permettre l'exploration approfondie du résumé de haut niveau aux preuves sources, et afficher les scores de confiance et la provenance des données

T6.6. Validation et Calibration

Validation rétrospective sur les médicaments retirés du marché (le modèle peut-il prédire les échecs ?), suivi prospectif des prédictions pour les molécules en développement, et graphiques de calibration pour s'assurer que les probabilités prédites correspondent aux fréquences observées

Raison d'être du WP

L'évaluation traditionnelle du rapport bénéfice-risque est :

- Statique (instantané à un moment donné)
- Au niveau populationnel (non personnalisé)
- Manuelle (nécessite une synthèse humaine de données disparates)

Un modèle du monde permet :

- Simulation dynamique : Prédire comment le rapport bénéfice-risque évolue, avec des modifications de dose, ou dans différents sous-groupes de patients
- Tests de scénarios : Simuler « et si nous dosions différemment ? » ou « et si le patient avait ce génotype ? » sans essais cliniques réels
- Quantification de l'incertitude : Intervalles de confiance explicites sur les prédictions, identifiant les lacunes de données
- Raisonnement causal : Aller au-delà de la corrélation pour comprendre les relations mécanistiques (par ex., « Inhibition de la cible → perturbation de la voie métabolique → événement indésirable »)

Cela représente un passage d'un rapport bénéfice-risque descriptif (qu'est-ce qui s'est passé ?) à prédictif (que va-t-il se passer ?) à prescriptif (que devons-nous faire ?).

KPI

- Sensibilité et spécificité élevées pour la prédiction d'événements indésirables graves sur des molécules de test
- Capacité à générer des profils bénéfice-risque cohérents incluant ≥ 3 sources de données indépendantes
- Validation utilisateur : ≥ 70% des experts évaluateurs jugent les prédictions comme « cliniquement plausibles »

Limitations rencontrées :

- Rareté des données : Les nouvelles squelettes moléculaires ou les maladies rares peuvent avoir des données d'entraînement insuffisantes
- Interactions émergentes : Impossibilité de prédire des mécanismes complètement nouveaux absents des données d'entraînement

Livrables :

- Modèle du monde intégré combinant les résultats des WP1-5
- Module de prédiction des interactions
- Interface de visualisation interactive sous forme de carte mentale
- Rapport de validation sur 200+ molécules commercialisées et retirées du marché
- Documentation utilisateur et supports de formation
- Système prêt au déploiement avec quantification de l'incertitude

Milestone associé :

- Démonstration spécifique à une maladie : Sélectionner un domaine thérapeutique (cancer du poumon) et démontrer le flux de travail complet :
- Entrée : Nouvelle molécule en Phase 1-2
- Sortie : Profil bénéfice-risque complet avec :
 - Efficacité prédite (ensemble WP1-4)
 - Profil de sécurité prédit (toxicités organiques, événements indésirables)
 - Comparaison aux thérapies existantes
 - Estimations d'incertitude
 - Visualisation au format carte mentale
- Validation : Examen par un panel d'experts pour la plausibilité clinique
- Système généralisé : Modèle du monde opérationnel applicable à plusieurs domaines thérapeutiques, avec :
 - AUC > 0,8 pour la prédiction d'événements indésirables graves (ensemble de validation externe)
 - Taux de faux négatifs < 10% pour les interactions médicament-médicament connues
 - Tests d'acceptation utilisateur avec ≥ 5 partenaires pharmaceutiques
- Documentation conforme à la réglementation démontrant la conformité aux lignes directrices sur l'IA